Villa Mercedes (SL), 2 de diciembre de 2024

VISTO:

El **CUDAP: EXP-UVM: 1351/2024**, mediante el cual el Dr. Gabriel NOVILLO RANGONE, profesor de la carrera de Ingeniería en Sistemas de Información eleva informe del Plan de Trabajo para el Proyecto Final de los estudiantes Nahir Melanie ISRAY y Elio Nicolás BAIGORRIA, y;

CONSIDERANDO:

Que mediante Resolución del Consejo de Escuela de Ingeniería y Ciencias Ambientales Nº 12/2023 se aprobó la Reglamentación de Trabajo Final para la carrera de Ingeniería en Sistemas de Información.

Que mediante Resolución del Consejo de Escuela de Ingeniería y Ciencias Ambientales Nº 11/2024 la propuesta del Proyecto Final de los alumnos Elio Nicolás BAIGORRIA y Nahir Melanie ISRAY, fue aprobada por el Consejo de Escuela de Ingeniería y Ciencias Ambientales.

Que la Dirección de la Escuela de Ingeniería y Ciencias Ambientales, remitió el expediente a la comisión de Carrera de Ingeniería en Sistemas de Información para su conocimiento y aval.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Que la Comisión de Carrera de Ingeniería en Sistemas de Información, aprueba la propuesta presentada por estar en conformidad con la Resolución del Consejo de Escuela de Ingeniería y Ciencias Ambientales Nº 12/2023, presta el aval correspondiente al informe elevado por el Dr. Gabriel NOVILLO RANGONE, y eleva la designación del Ing. Alejandro ROSA, Ing. Alberto LEDESMA y Lic. Walter MOLINA, como tribunal evaluador.

Que la Dirección de la Escuela de Ingeniería y Ciencias Ambientales realiza el pase a la Comisión de Asuntos Académicos del Consejo de Escuela de Ingeniería y Ciencias Ambientales para su conocimiento y aval.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Que la Comisión de Asuntos Académicos en su dictamen aconseja aprobar el informe final del Proyecto Final de la carrera de Ingeniería en Sistema de Información de los alumnos Elio Nicolás BAIGORRIA, DNI: 30.312.122, y Nahir Melanie ISRAY, DNI: 43.954.038, "Implementación de una herramienta de minería de datos educativa para predecir la deserción estudiantil en carreras de informática en Universidades Nacionales" Aprobar la designación como evaluadores a: Ing. Alberto LEDESMA, Ing. Alejandro ROSA y Lic. Walter MOLINA. Aprobar la presentación de dicho informe ante el tribunal examinador en la mesa de examen correspondiente al mes de diciembre de 2024.

RESOL. C. ESC. ING. Y CS. AMB. Nº 28/2024

Que el Consejo de Escuela en su sesión extraordinaria el 25 de noviembre de 2024, resolvió hacer suyo el dictamen de la Comisión de Asuntos Académicos

Que Dirección de Escuela de Ingeniería y Ciencias Ambientales, con el aval del Consejo de Escuela, remite a Secretaría Académica para su conocimiento.

Que Secretaría Académica toma conocimiento, presta aval y remite a la Dirección de Despacho para emisión de acto administrativo.

Que Dirección de Despacho realiza el acto administrativo, incorporando las modificaciones pertinentes, conforme al anteproyecto adjunto al presente.

Por ello, y en uso de sus atribuciones;

EL CONSEJO DE ESCUELA DE INGENIERÍA Y CIENCIAS AMBIENTALES DE LA UNIVERSIDAD NACIONAL DE VILLA MERCEDES

RESUELVE:

ARTÍCULO 1º: PROTOCOLIZAR el Informe del Plan de Trabajo Final "Implementación de una herramienta de minería de datos educativa para predecir la deserción estudiantil en carreras de informática en Universidades Nacionales" de los alumnos Elio Nicolás BAIGORRIA, DNI: 30.312.122 y Nahir Melanie ISRAY, DNI: 43.954.038 de la carrera de Ingeniería en Sistema de Información.

ARTÍCULO 2º: RECONOCER la designación como tribunal evaluador a los profesores:

PRESIDENTE: Lic. Walter MOLINA DNI: 34.127.118

VOCAL 1º: Ing. Alberto LEDESMA, DNI: 29.181.312

VOCAL 2º: Ing. Alejandro ROSA, DNI: 24.719.010

ARTÍCULO 3º: Notifíquese, publíquese, insértese en el Libro de Resoluciones del Consejo de Escuela de Ingeniería y Ciencias Ambientales y archívese.

RESOLUCIÓN C. ESC. ING. Y CS. AMB. Nº 28/2024

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

ANEXO ÚNICO

UNIVERSIDAD NACIONAL DE VILLA MERCEDES

ESCUELA DE INGENIERÍA Y CIENCIAS AMBIENTALES

IMPLEMENTACIÓN DE UNA HERRAMIENTA DE MINERÍA DE DATOS EDUCATIVA PARA PREDECIR LA DESERCIÓN ESTUDIANTIL EN CARRERAS DE INFORMÁTICA EN UNIVERSIDADES NACIONALES.

AUTORES

NAHIR MELANIE ISRAY
ELIO NICOLAS BAIGORRIA

PROFESOR GUÍA: DR. GABRIEL NOVILLO RANGONE

PROFESOR ASESOR: DR. FRANCISCO BAVERA

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

INGENIERÍA EN SISTEMAS DE INFORMACIÓN -VILLA MERCEDES - SAN LUIS- ARGENTINA -2024-

RESUMEN

El presente informe final, que deriva en una tarea de investigación, plantea la implementación de una herramienta basada en técnicas de Minería de Datos Educativa y Aprendizaje Automático para predecir el abandono en estudiantes de informática. Este informe aborda el fenómeno de la deserción estudiantil, un problema crítico en las universidades, especialmente en Argentina, y su impacto tanto en la gestión educativa como en la vida profesional de los estudiantes.
El trabajo se estructura en cuatro fases, definición del problema educativo, obtención y preprocesamiento de datos, ejecución del proceso de minería de datos educativa y elaboración de conclusiones. En donde, se propone un modelo de clasificación basado en árboles de decisión, utilizando un conjunto de datos históricos de universidades argentinas, con técnicas avanzadas para el análisis exploratorio de datos, limpieza de datos y selección y generación de características. Se presentará una implementación de una herramienta que permita validar la hipótesis planteada y facilitar la interpretación de los resultados.
El informe subraya la importancia de la interpretabilidad y explica el uso de métricas para medir el desempeño del modelo.
La investigación se fundamenta en un marco teórico sólido que abarca el estado del arte en minería de datos educativa, así como diversas metodologías para la recopilación y análisis de datos. Se emplearán tecnologías como el lenguaje de programación Python y varias bibliotecas especializadas, para llevar a cabo un análisis de los datos históricos y el

desarrollo de la interpretabilidad de los resultados. Los resultados esperados incluyen la identificación de los factores más influyentes en la deserción estudiantil de los alumnos de las carreras de Informática. Además, se espera que el modelo alcance las métricas de exactitud, precisión, recall, F1-score superiores al 70% como mínimo. Esta información puede permitir mejorar las tasas de retención y graduación en las universidades, beneficiando tanto a los estudiantes como a las instituciones educativas y a la sociedad en general.

DEDICATORIA DE TESISTA: Nahir Melanie ISRAY
Dedico este informe con todo mi corazón a Dios,
a los pilares de mi superación,
mis amados padres, Mirta y Daniel,
y a mi hermano, Kevin.
Ustedes han sido el motor que me ha impulsado a perseguir mis metas y a alcanzar nuevos logros.
Su amor, apoyo y ejemplo constante han sido fundamentales en este trayecto.

DEDICATORIA DE TESISTA: Elio Nicolás BAIGORRIA

Este trabajo está dedicado a todas las personas que, con su esfuerzo, enseñanza y compañía, contribuyeron a mi crecimiento académico y personal. A mi familia, especialmente a Benjamín, Josefina y Benicio, por su constante apoyo y motivación a lo largo de este recorrido.
También extiendo mi gratitud a los docentes, quienes compartieron su conocimiento y pasión por la enseñanza, así como a todas las personas que, de una manera u otra, han sido parte de este proceso.
Este logro es el reflejo del esfuerzo conjunto y de los valores que me han transmitido. Gracias.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

AGRADECIMIENTO TESISTA: Nahir Melanie ISRAY

En primer lugar, le agradezco profundamente a mi familia, especialmente a mis padres y hermano, por brindarme su apoyo incondicional a lo largo de todo mi trayecto. Su cariño y aliento constante han sido fundamentales para que yo pueda cumplir mis objetivos personales y académicos.
También quiero expresar mi más sincero agradecimiento a mi tutor y asesor, los profesores Novillo y Bavera. Su dedicación, paciencia y valiosas correcciones han sido cruciales para que yo pueda alcanzar esta meta tan anhelada. Gracias por su guía incansable y por compartir conmigo sus invaluables consejos, los cuales llevarán conmigo hacia mi futuro profesional.
Asimismo, extiendo mi gratitud a todos los docentes que han sido parte de mi trayectoria universitaria. Cada uno de ustedes me ha transmitido los conocimientos necesarios para poder estar aquí.
Por último, quiero expresar mi agradecimiento a la universidad que me ha exigido tanto, pero que también me ha brindado las herramientas y oportunidades para obtener mi ansiado título. Agradezco a cada directivo

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

por su arduo trabajo y dedicada gestión, sin los cuales no estarían las bases ni las condiciones propicias para el aprendizaje.
De igual manera, quisiera agradecer a mis amistades cercanas, quienes han sido un pilar fundamental en mi vida y me han acompañado a lo largo de este trayecto. Gracias por su apoyo incondicional, por celebrar conmigo mis logros y brindarme su hombro en los momentos difíciles.

AGRADECIMIENTO TESISTA: Elio Nicolas BAIGORRIA

A mis hijos Benjamín, Josefina y Benicio:
Quiero expresar mi sincero agradecimiento a mis hijos, quienes han sido una fuente de apoyo y fortaleza a lo largo de este camino académico. Su comprensión y aliento constante fueron fundamentales para mantenerme motivado y enfocado durante la elaboración de esta tesis.
A mis Padres
Quiero expresar mi más profundo agradecimiento a mis padres, cuyo amor incondicional, sacrificio y apoyo constante han sido la piedra angular de mi vida y de este logro. Su ejemplo de dedicación y perseverancia ha sido mi inspiración a lo largo de este camino académico, y nunca podré agradecerles lo suficiente por todo lo que han hecho por mí.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

ÍNDICE

1.INTRODUCCIÓN 9
2.HIPÓTESIS Y OBJETIVOS 11
2.1 Hipótesis 11
2.2 Objetivo General 12
2.3 Objetivos Específicos 12
3.MARCO DE REFERENCIA 12
3.1 Estado del arte 12
3.2 Marco teórico 14
3.3 Marco tecnológico 20
3.3.1 Plataformas tecnológicas 20
4.METODOLOGÍA 21
4.1 Breve descripción detallada. 22
5.APLICACIÓN DE LA METODOLÓGICA 23
5.1 Definición del problema educativo. 23

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

5.1.1 Identificación del problema 23
5.1.2 Definición de objetivos 25
5.1.3 Justificación de la investigación 25
5.2 Obtención y pre-procesamiento de los datos 26
5.2.1 Recopilación de datos 27
5.2.2 Integración de datos 34
5.2.3 Análisis exploratorio de datos 35
5.2.4 Limpieza de datos 46
5.2.5 Transformación o generación de variables adicionales 51
5.3 Ejecución del proceso EDM 56
5.3.1 División de dataframe 57
5.3.2 Selección de modelo 57
5.3.3 Configuración de hiperparámetros y entrenamiento de modelo 58
5.3.4 Validación de modelo 58
5.3.5 Resultados 59
5.4 Elaboración de conclusiones 61
5.4.1 Análisis de resultados 61
5.4.2 Evaluación y extracción de conocimiento 61
6.CONCLUSIONES 63

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Cpde. RESOL. C. ESC. ING. Y CS. AMB. Nº 28/2024

ÍNDICE DE FIGURAS

Figura 1-Proceso tradicional de EDM 21

Figura 2-Carga del DataSet 34

Figura 3- Etapas del EDA 36

Figura 4-Primeras cinco filas del dataframe 37

Figura 5-Resumen estadístico de las características numéricas 38

Figura 6-Resumen estadístico de la característica "Relación actual con la carrera (4 categorías)" 38

Figura 7-Histograma de la característica "Relación actual con la carrera" 39

Figura 8-Gráfico de barra de la característica Año de ingreso 39

Figura 9-Gráfico de barra de la característica Descripción de la Universidad 40

Figura 10-Gráfico curva de barra de la característica Identidad de genero 40

Figura 11-Gráfico de la característica "Actividades en Proyectos o equipos de investigación" 41

Figura 12-Resumen completo del dataframe 42

Figura 13-Informe inicial del dataframe con Sweetviz 42

Figura 14-Detección de datos ausentes con Pandas 43

Figura 15-Detección de datos ausentes con Sweetviz 43

Figura 16-Detección de datos ausentes con RapidMiner 43

Figura 17-Gráfico BoxPlot de la característica "Identidad de género" 45

Figura 18-Parte del gráfico de matriz de Correlación Lineal ver gráfico total en apéndice B.1 46

Figura 19- Descripción de valores faltantes por cada característica 48

Figura 20- Porcentaje de valores faltantes de la característica "Cursaste otra carrera previamente" 48

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Figura 21-Proceso limpieza de datos, eliminación de la característica "id" 49

Figura 22- Eliminación de característica "Relación actual con la carrera (4 categorías)" 49

Figura 23- Eliminación de característica "Relación actual con la carrera (5 categorías)" 50

Figura 24- Eliminación de característica "Te gustaría participar de estas entrevistas" 50

Figura 25-Parte de grafico Feature Importance de Árbol de decisión ver gráfico completo en apéndice B.2 53

Figura 26- Parte de grafico Permutation Importance de Árbol de decisión ver gráfico completo en apéndice B.2 53

Figura 27-Parte de gráfico de Feature Importance Random Forest ver gráfico completo en apéndice B.2 54

Figura 28-Parte de gráfico de Permutation Importance Random Forest ver gráfico completo en apéndice B.2 54

Figura 29-Parte de gráfico de Feature Importance CatBoost ver gráfico completo en apéndice B.2 55

Figura 30-Parte de gráfico de Feature Importance XGBoost ver gráfico completo en apéndice B.2 55

Figura 31-Grafico Árbol de decisión 59

Figura 32-Grafico Curva de validación del Árbol de decisión 60

Figura 33-Métricas del Árbol de decisión 60

Figura 34-Grafico Feature Importance Árbol de decisión 60

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

ÍNDICE DE TABLAS

Tabla 1-Descripción de Características del Dataset (Parte 1) 28

Tabla 2-Descripción de Características del Dataset (Parte 2) 29

Tabla 3-Descripción de Características del Dataset (Parte 3) 30

Tabla 4-Descripción de Características del Dataset (Parte 4) 31

Tabla 5-Descripción de Características del Dataset (Parte 5) 32

Tabla 6-Descripción de Características del Dataset (Parte 6) 33

Tabla 7-Características seleccionadas (Parte 1) 56

Tabla 8-Características seleccionadas (Parte 2) 56

Tabla 9-Características más significativas 62

INTRODUCCIÓN

La Minería de Datos (DM, por sus siglas en inglés Data Mining), como indican Cesarotto et al. [1], es una técnica que ha dado resultados en diferentes campos del conocimiento, contribuyendo a que las organizaciones tomen decisiones y que tengan un soporte más confiable y asertivo en la administración de estas.

Esta ciencia es considerada como una subdisciplina de las ciencias de computación que presta apoyo a otras ciencias, radica en la búsqueda de patrones de datos válidos y relevantes para la toma de decisiones.

Un campo específico de DM es la Minería de Datos Educativa (EDM, por sus siglas en inglés Educational Data Mining) que hace referencia a las técnicas, herramientas, e investigación, diseñados para extraer el significado de grandes volúmenes de datos generados por o relacionados con las actividades de aprendizaje en los centros educativos.

La ciencia de la computación y la Inteligencia Artificial (IA, por sus siglas en inglés Artificial Intelligence) han sido fundamentales para el desarrollo y la aplicación de DM en el contexto educativo. Los avances en potencia computacional, algoritmos de IA y técnicas de Big Data han permitido analizar y procesar grandes cantidades de datos educativos, lo que ha posibilitado mejorar diversos aspectos del ámbito educativo.

En los últimos años, se ha producido un creciente interés en el uso de técnicas de EDM para mejorar diversos aspectos del ámbito educativo. Estos estudios han demostrado la efectividad de estas herramientas para optimizar el rendimiento académico, los sistemas de enseñanza adaptativa, la calidad general de la educación, las tasas de deserción estudiantil, la procrastinación y la gestión institucional en todos los niveles educativos, desde la educación inicial hasta la universitaria, y en diferentes modalidades de enseñanza (presencial, en línea, híbrida).

El Aprendizaje Automático (ML, por sus siglas en inglés de Machine Learning) es una subdisciplina de la IA que permite a las máquinas aprender de los datos sin ser programadas explícitamente para cada tarea. Su objetivo es desarrollar algoritmos que puedan identificar patrones complejos en grandes volúmenes de datos y realizar predicciones o tomar decisiones basadas en estos patrones. En el contexto de la EDM, el ML juega un rol esencial, ya que ofrece métodos tanto supervisados como no supervisados para analizar el comportamiento estudiantil, predecir el rendimiento académico y detectar posibles riesgos de deserción, entre otras aplicaciones.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

El ML puede dividirse en varias categorías principales. En el aprendizaje supervisado, se entrena al modelo con un conjunto de datos etiquetados, permitiéndole aprender la relación entre las entradas y salidas para luego predecir resultados en nuevos datos no etiquetados. Las técnicas supervisadas, como la clasificación y la regresión, son particularmente útiles en EDM para identificar si un estudiante está en riesgo de abandonar. Por otro lado, el aprendizaje no supervisado permite que el modelo identifique patrones o agrupamientos en los datos sin utilizar etiquetas, lo cual es útil en la segmentación de perfiles estudiantiles o en la identificación de factores comunes entre estudiantes que enfrentan problemas similares. Baker et al. [2] realizaron una revisión exhaustiva del estado de la EDM, identificando varios objetivos clave de la misma. Entre ellos se incluyen la predicción de los comportamientos de aprendizaje futuros de los alumnos, la cual se logra mediante la creación de modelos que incorporan características detalladas de los estudiantes, como sus conocimientos, comportamientos y motivación para aprender.

Además, otras de las referencias más importantes en este campo son la "Conferencia Internacional de Minería de Datos Educativos", que se celebra desde 2008, y la "Revista de Minería de Datos Educativos", publicada desde 2009, Merceron et al. [3]. Estos eventos y publicaciones han sido posibles gracias al avance de componentes clave como la potencia computacional, el Big Data, la IA y el apoyo de investigadores y organizaciones internacionales que promueven el uso de estas herramientas para mejorar la calidad de la educación.

Uno de los principales problemas que enfrenta el sistema de educación superior en distintos países concierne a los altos niveles de deserción académica. El número de alumnos que logra culminar sus estudios superiores no es alto, evidenciando que una gran parte de éstos abandona sus estudios, principalmente en los primeros semestres, como señalan Paura et al. [4].

La deserción estudiantil es un fenómeno que afecta significativamente a las instituciones de educación superior. Investigaciones recientes han demostrado que muchos de los problemas educativos, incluyendo la deserción, pueden ser abordados efectivamente a través de técnicas de Aprendizaje Automático Supervisado, tales como la clasificación y la regresión. Morales Carrillo et al. [5] encontraron que el 76% de los problemas educativos estudiados se pueden resolver utilizando estas técnicas, mientras que Panizzi et al. [6] sostiene que cuestiones como el rendimiento académico, la detección de perfiles, la calidad educativa y la deserción escolar pueden ser resueltas en un 70% o más mediante enfoques supervisados.

Por lo tanto, como nos referimos anteriormente una problemática importante que destacaremos dentro de las instituciones de educación superior es la deserción estudiantil, que es un fenómeno que afecta la población estudiantil de las instituciones de nivel superior y se da cuando los estudiantes abandonan su proceso académico por diversas razones, Las Universidades Nacionales (UUNN) no son ajenas a este fenómeno, como lo expresan Marino et al. [7] en su trabajo titulado "¿Por qué estudiamos informática?".

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

La deserción estudiantil se presenta a una escala global, se tienen referentes internacionales en Latinoamérica como el caso de Bolivia, donde Proveda Velasco et al. [8] menciona que de las 11 universidades públicas de Bolivia se registra una deserción estudiantil promedio del 10,66%. Otro referente es Salazar et al. [9] que afirma que la deserción estudiantil universitaria en argentina es del 43%, México 40% y en Chile con un promedio del 54%.

Según las estadísticas del Ministerio de Educación Nacional de Colombia mencionadas en Guzmán Ruíz et al. [10], el alto nivel de deserción estudiantil es uno de los problemas principales que enfrentan las instituciones de educación superior, de cada cien estudiantes que ingresan, cerca de la mitad no logra culminar su ciclo académico y obtener la graduación.

Como podemos ver, este fenómeno, afecta de forma negativa a indicadores claves que utilizan las universidades para medir y evaluar la efectividad de su gestión académica, por lo cual representa una necesidad de predecir dicha deserción, reconocer cuales podrían llegar a ser las causas y opcionalmente determinar las formas de reducirla con el fin de mejorar el desempeño institucional.

Para abordar esta problemática, mediante los avances tecnológicos en el campo de la IA y , a través de DM que permite el análisis de grandes volúmenes de información, lo cual se lo denomina Big Data (Dumon, 2014) es posible extraer datos, analizarlos aplicando técnicas de analítica de datos, y además también es posible investigar todas las etapas de un modelo de DM para predecir la deserción de alumnos que estudian carreras relacionadas con la informática y explicar los resultados obtenidos como la interpretabilidad de los modelos utilizados. Dicha predicción se basará en datos históricos provistos tanto por las UUNN como también por la Fundación Sadosky.

El alcance de este informe final, que deriva en una tarea de investigación, implicando no solo investigar todas las etapas de un modelo de DM como se mencionó anteriormente, sino también la implementación de una herramienta de predicción, abarcando desde la recolección de los datos hasta la presentación de dicha implementación que permita validar la hipótesis. Para ello, se utilizarán tecnologías como Google Colab, Python, Pandas, Numpy, Feature Importance, Scikit Learn, RapidMiner, Sweetviz, Matplotlib, Seaborn, MySQL, Excel, NLTK.

Los resultados esperados de este informe de investigación son identificar los factores posibles o más probables que influyen en la deserción estudiantil de los alumnos de las carreras de informática.

Estos resultados podrían ser utilizados para intentar mejorar las tasas de retención y graduación en las universidades, beneficiando a los estudiantes, a las instituciones educativas y a la sociedad en general.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

1. HIPÓTESIS Y OBJETIVOS

2.1 Hipótesis

Es posible que instituciones educativas puedan aprovechar los cuantiosos beneficios que otorga la Minería de Datos Educativa con Aprendizaje Automático para predecir la Deserción Estudiantil en Carreras de

Informática en Universidades Nacionales utilizando como fuente de información el conjunto de datos provisto por la Fundación Sadosky.

2.2 Objetivo General

El objetivo general de este informe final es ampliar la utilización del ML en la EDM para que instituciones educativas puedan realizar conclusiones sobre problemas complejos. Como medio para alcanzar este objetivo se propone la utilización de un Modelo para EDM que recopila lo mejor de las metodologías de DM, pero aplicado en este caso al ámbito educativo en especial.

2.3 Objetivos Específicos

En los siguientes apartados se desarrollan de manera concisa los objetivos específicos de este informe final, desagregados a partir del objetivo general.

- Definir el Problema Educativo a abordar
- Definir el proceso de Data Munging (limpiar, validar y preparar datos), a partir de conocimientos en SQL, y proponer herramientas simples que construyan script ETL`s para su tratamiento.
- Definir los métodos de preprocesamiento de datos y características, y los algoritmos clasificadores que formarán parte de ML.
- Definir los modelos de IML que permitirán la explicabilidad de los resultados y modelos, definir tanto los tipos de modelos que se interpretarán (intrínsecamente interpretables y agnósticos del modelo), como su alcance (métodos locales y globales).
- Utilizar un modelo basado que permitan a las instituciones de manera realizar tareas de limpieza de datos, preprocesamiento de datos y características, elección de los algoritmos de ML, optimización de hiperparámetros, interpretación y explicación de resultados y modelos.
- Validar el modelo en el dominio de la Educación Superior, con la construcción de una herramienta que permita sacar conclusiones a partir del conjunto de datos provisto por la Fundación Sadosky.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

3. MARCO DE REFERENCIA

En este capítulo, se exponen las teorías, antecedentes, y demás referentes que son clave para el desarrollo de este informe final.

3.1 Estado del arte

El interés por pronosticar la deserción estudiantil a pesar de que es un tema actual ya ha sido abordado por varios autores en trabajos de investigaciones desde hace algunos años, los cuales se tomarán como referentes para esta investigación.

Se realizó una revisión de los trabajos y la literatura relacionada con la EDM, la educación, la deserción estudiantil y el ML. Estos trabajos previos fueron fundamentales para la selección de los modelos y metodologías que se utilizaron.

Por ejemplo, Eckert et al. [11] realizó un análisis de deserción-permanencia de estudiantes universitarios utilizando técnicas de clasificación en DM. En este estudio, se identificaron los factores que influyen sobre la deserción de los estudiantes de la carrera de Ingeniería en Informática de la Universidad Gastón Dachary en Argentina.

Por otra parte, se tiene el estudio publicado en el 2016 por Hernandez Gonzalez et al. [12]. En este estudio se comparan los algoritmos de regresión logística, algoritmos de clústeres, árboles de decisión y la red neuronal de Microsoft. El estudio muestra que "sí es posible predecir los alumnos que tienen altas posibilidades de desertar de sus estudios a nivel superior. En este caso, fue un análisis sobre los alumnos del programa educativo de Ingeniería en Tecnologías de la Información y Comunicaciones".

Así mismo, en el trabajo presentado por Coussement et al. [13] se detalló el trabajo llevado a cabo para predecir la deserción de los estudiantes en entornos de aprendizaje en línea basados en suscripciones. Este enfoque, muestra la comparación de un algoritmo de modelo de regresión logística (modelo Logit) utilizando un conjunto de datos de la vida real, donde se especifican los impactos de la demografía de los estudiantes, características del aula, y características de participación académica, cognitiva y conductual sobre la deserción de los estudiantes.

Entre otros trabajos referentes están, el modelo predictivo de deserción estudiantil basado en árboles de decisión que muestra la construcción de un modelo para pronosticar la probabilidad que un estudiante abandone su programa académico, mediante técnicas de clasificación, basadas en árboles de decisión. La metodología utilizada, se basó en Knowledge Discovery in Database, con cinco etapas, selección, procesamiento, transformación, minería de datos y evaluación como indican Cuji et al. [14].

También, se encuentra la perspectiva de Barramuño et al. [15] que buscó la implementación de un método para predecir la deserción de los estudiantes en los años superiores de un programa de fisioterapia. Aquí se accedió a una base de datos de 336 estudiantes universitarios en sus cursos superiores, en donde se eligieron cinco variables cuantitativas y 11 cualitativas, asociadas a la deserción de estudiantes universitarios. Con esta base de datos, se probaron 23 clasificadores basados en aprendizaje automático supervisado.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Por otra parte, otros estudios pertinentes como en Moreira et al. [16], que analizaron el rendimiento de cuatro algoritmos de ML con diferentes perspectivas para definir archivos de datos, en la predicción de la deserción de estudiantes universitarios. Estos algoritmos fueron bosque aleatorio, redes neuronales, máquinas de vectores de soporte y regresión logística.

Además, en el estudio realizado por Ramirez et al. [17], que presentó una clasificación basada en árboles de decisión (CBAD) con parámetros optimizados para predecir la deserción de los estudiantes universitarios. El estudio analizó 5288 casos de estudiantes pertenecientes a una universidad pública chilena. Para la técnica CBAD se optimizaron los parámetros para mejorar la predicción usando el software RapidMiner.

Finalmente, el estudio realizado por Romero et al. [18] en 2013 detalló aún más el modelo para la aplicación de la EDM, utilizando 15 tareas básicas divididas en 4 etapas generales, lo cual ha sido adoptado y aplicado por diversos investigadores.

Estos trabajos previos sentaron las bases para diseñar el modelo propuesto de ML, analizar las características estudiadas para la deserción, conocer los distintos algoritmos de aprendizaje utilizados y las métricas más usadas.

Particularmente, el modelo detallado de aplicación propuesto por Romero et al. [18] sirvió como referencia importante para el desarrollo de la presente investigación.

3.2 Marco teórico

En esta sección se presentan los fundamentos teóricos que sustentan esta investigación. Los conceptos y enfoques expuestos han sido recopilados a partir de la revisión de la literatura y de las fuentes bibliográficas consultadas durante el desarrollo del informe, y sirven como base para el análisis y comprensión del problema investigado.

La DM aplicada al ámbito educativo EDM ha demostrado ser una herramienta poderosa para abordar problemas como la deserción estudiantil. Las instituciones educativas recopilan grandes cantidades de datos sobre sus estudiantes, que incluyen información personal, socioeconómica y académica. Estos datos son fundamentales para identificar patrones que pueden influir en la decisión de un estudiante de desertar.

En Páramo et al. [19] se define la deserción estudiantil como el abandono voluntario de la formación académica, ya sea de un programa, institución o del sistema educativo en general, por diversas razones, tanto internas como externas al estudiante.

El uso de técnicas avanzadas de DM permite construir modelos predictivos que ayudan a las instituciones a entender mejor los factores detrás de la deserción y, lo más importante, a poder tomar medidas preventivas antes de que ocurra. Las técnicas de DM desempeñan un papel crucial en la exploración y análisis de grandes volúmenes de datos, permitiendo el descubrimiento de patrones o modelos subyacentes como indican Mikut et al. [20].

Las investigaciones realizadas alrededor del mundo muestran distintas técnicas de DM de la cual el árbol de decisión resulta la alternativa más adecuada ante la predicción ya que abarca numerosas y distintas características como, edad actual, ciudad de procedencia, sexo, ocupación, estado civil, nivel de estudios del padre y de la madre, características económicas como jornada, materias cursadas, materias perdidas, entre otras, abriendo la posibilidad de que las instituciones educativas superiores tengan una solución analítica que indique los motivos de la deserción estudiantil como se detalla en Heredia et al. [21].

La IA desempeña un papel fundamental al proporcionar la capacidad de crear modelos predictivos que permiten anticipar la deserción estudiantil. Mediante la utilización de técnicas de ML y DM, se aplican algoritmos de IA para identificar patrones complejos en el conjunto de datos proporcionado por las universidades. La IA facilita la automatización del análisis de datos a gran escala y la optimización de los modelos predictivos, mejorando la precisión y el desempeño de las predicciones.

Uno de los primeros pasos en la implementación de un modelo predictivo de deserción es la identificación del problema educativo. Este proceso comienza con la observación y análisis de las características del entorno educativo. En este sentido, se identifican los desafíos a lo que nos enfrentamos, como altas tasas de abandono o bajos niveles de retención, y definir claramente sus objetivos estratégicos para abordar estos

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

problemas. Para lograr esto, es necesario recolectar datos relevantes históricos, que permitan analizar las características que afectan el desempeño y la continuidad de los estudiantes.

Un aspecto crucial en la implementación de un modelo predictivo de deserción es el Análisis Exploratorio de Datos (EDA por sus siglas en inglés Exploratory Data Analysis), este proceso es fundamental para entender y evaluar la calidad de los datos con los que se está trabajando antes de llevar a cabo cualquier análisis profundo. Según lo establecido en [22], uno de los principales retos a los nos enfrentamos es comprender las características, así como detectar posibles irregularidades o errores que podrían comprometer la fiabilidad de los resultados. El EDA tiene como objetivo explorar, describir y resumir la naturaleza de los datos, permitiendo una mejor comprensión de las relaciones entre las características de interés. Esta etapa es clave para identificar errores comunes, como valores atípicos (outliers), la ausencia de datos o una codificación incorrecta de las características. Detectar y corregir estos problemas en las etapas iniciales asegura que los resultados obtenidos de los análisis posteriores sean consistentes y objetivos.

Una exploración adecuada de los datos no solo permite identificar posibles errores, sino también revelar correlaciones entre características, su redundancia y, en algunos casos, hasta posibles patrones ocultos. El EDA incluye técnicas estadísticas y gráficas, como histogramas, diagramas de dispersión y boxplots, que ayudan a visualizar estos patrones de manera clara.

Por lo tanto, antes de proceder con la implementación de un modelo predictivo de deserción, es imprescindible realizar un EDA que permita detectar posibles problemas y optimizar la calidad de los datos disponibles. Por otro lado, la limpieza de datos también es una etapa fundamental antes de la implementación del modelo y después del EDA, ya que la calidad de la información influye directamente en la precisión del modelo. Los datos incompletos o incorrectos que se detectan durante el EDA pueden distorsionar los resultados, por lo que es esencial limpiar las características adecuadamente antes de ser utilizadas. La limpieza de datos permite reconocer datos incompletos, inexactos o irrelevantes y, posteriormente, sustituir, modificar o eliminar estos "datos sucios" (o "dirty data"), que también se conocen como valores perdidos o atípicos.

Los valores perdidos, o celdas vacías, son un problema común en muchos conjuntos de datos. Suelen surgir por errores en la transcripción de información o por dificultades en la recolección de datos, como la incapacidad de obtener ciertas mediciones u observaciones.

Por otro lado, un valor atípico, o outlier, es una observación que se desvía significativamente del resto de los datos en una característica y puede considerarse anómalo. Estos valores atípicos pueden afectar los análisis posteriores, alterando los resultados y distorsionando la interpretación de los datos. Por lo tanto, es crucial detectarlos y tratarlos para minimizar su impacto en el análisis.

Una vez que los datos están limpios, la transformación y generación de nuevas características, que incluye la selección de características es un paso importante para que a la hora de implementar el modelo mejore su

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

rendimiento. Para la etapa de selección de características se puede aplicar Análisis de Componentes Principales (PCA, por sus siglas en inglés Principal Component Analysis), para reducir la dimensionalidad del conjunto de datos y así poder obtener un subconjunto de características representativas, también, se utiliza técnicas como la importancia de características (feature importance), y la permutación de características (feature permutation), que definiremos a continuación.

Cuando el conjunto de datos contiene un gran número de características, es esencial considerar la reducción de dimensionalidad, ya que el exceso de características puede afectar negativamente el modelo. Según Guerrero et al. [23] el problema de la dimensionalidad surge cuando el número de características aumenta desproporcionadamente en relación con las observaciones, lo que puede causar sobreajuste (overfitting). En este escenario, el modelo se ajusta demasiado bien a los datos de entrenamiento, logrando una excelente precisión, pero perdiendo capacidad de generalización frente a nuevos datos. A medida que aumentan las características, también crecen los grados de libertad del sistema, lo que incrementa las posibilidades de sobreajuste. En el contexto de la predicción de la deserción estudiantil, es crucial reducir la dimensionalidad para obtener un subconjunto más pequeño y representativo de características que permita un modelo más eficiente y generalizable.

Para mitigar este problema, se emplean técnicas de reducción de dimensionalidad como el PCA, que transforma las características originales en un conjunto de nuevas características no correlacionadas, llamadas componentes principales, que explican la mayor parte de la variabilidad en los datos.

La interpretabilidad en los modelos de ML es un concepto clave para garantizar que los humanos puedan entender y confiar en las decisiones tomadas por un modelo. Según Molnar et al. [24], citado por Miller, la interpretabilidad se define como "el grado en el que un ser humano puede entender la causa de una decisión" o "el grado en el que un ser humano puede predecir consistentemente el resultado del modelo". Cuanto mayor sea la interpretabilidad, más fácil será para una persona entender por qué se tomaron ciertas decisiones o predicciones, lo que hace que un modelo sea más accesible y comprensible.

La importancia de la interpretabilidad va más allá de la precisión predictiva del modelo. Aunque un modelo pueda ofrecer excelentes resultados en términos de métricas como la precisión, estas no siempre proporcionan información completa sobre el funcionamiento real del modelo en el mundo. Comprender el "por qué" detrás de una predicción es fundamental para evaluar la validez del modelo, detectar posibles fallos o sesgos presentes en los datos de entrenamiento, y corregir posibles discriminaciones. Además, la interpretabilidad es esencial para auditar y depurar modelos, lo que permite identificar errores y mejorar el sistema.

Un ejemplo claro de modelo interpretable es el árbol de decisión, conocido por su claridad en la visualización de decisiones. En este tipo de modelo, se parte de un nodo raíz y se avanza por los diferentes nodos y ramas hasta llegar a los resultados previstos en los nodos hoja. Esto facilita la

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

interpretación, ya que el proceso se puede seguir paso a paso y entender fácilmente.

Existen diferentes metodologías de interpretabilidad que se utilizan para entender cómo los modelos toman decisiones. Estas se dividen principalmente en métodos globales y métodos locales, y algunos de ellos son independientes del tipo de modelo utilizado. Haremos énfasis en los métodos globales independientes, que proporcionan una visión general de cómo el modelo utiliza todas las características para tomar decisiones. Entre ellos, se destacan, por un lado, feature importance que estima la relevancia de cada característica para el modelo en su conjunto, asignando una puntuación basada en su contribución a la predicción. Por otro lado, permutation importance que evalúa la importancia de las características midiendo el aumento del error cuando los valores de una característica son permutados aleatoriamente.

La matriz de correlación es una herramienta estadística que organiza los coeficientes de correlación entre múltiples características en un conjunto de datos, presentándose de forma tabular. Cada celda de la matriz representa el valor del coeficiente de correlación entre un par de características específicas. Estos coeficientes cuantifican tanto el grado como la dirección de la relación entre las características, que puede ser positiva, cuando ambas características aumentan o disminuyen juntas, negativa, cuando una característica aumenta mientras la otra disminuye, o nula, cuando no hay relación aparente. Esta herramienta también permite detectar patrones de asociación que pueden ser lineales o no lineales, facilitando así la identificación de dependencias entre características que influyen en el comportamiento general del conjunto de datos.

La matriz de correlación es fundamental en la fase de EDA y en la sección de interpretabilidad del modelo. No obstante, su uso es más común durante el EDA, ya que ayuda a identificar relaciones de dependencia entre las características antes de construir el modelo predictivo. Durante esta etapa, la matriz se utiliza para detectar correlaciones entre las características del conjunto de datos, lo que ayuda a identificar aquellas que podrían ser redundantes o colineales, aspectos que pueden afectar negativamente el rendimiento del modelo.

La correlación se mide a través del coeficiente de correlación (r) que varía entre -1 y 1. Un valor de +1 indica una correlación positiva perfecta, donde las características cambian en la misma dirección. Un valor de -1 representa una correlación negativa perfecta, donde las características cambian en direcciones opuestas. Un valor de 0 sugiere que no existe relación lineal entre las características, indicando que son independientes. El uso de la matriz de correlación facilita la identificación de características altamente correlacionadas que podrían ser eliminadas o transformadas para evitar problemas como la multicolinealidad en los modelos predictivos, mejorando así su precisión y estabilidad.

Luego, una vez seleccionadas y generadas las características se procede a la fase de división del dataframe y selección del modelo. En el contexto de la predicción de la deserción estudiantil, los árboles de decisión han demostrado ser una técnica altamente efectiva.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Los árboles de decisión son un tipo de algoritmo de aprendizaje supervisado utilizado para problemas de clasificación. Como se mencionó anteriormente una de las principales ventajas de los árboles de decisión es su interpretabilidad, ya que permiten visualizar el proceso de toma de decisiones y entender fácilmente cómo el modelo llega a sus conclusiones. Consiste en crear un modelo en forma de árbol, donde cada nodo interno representa una decisión basada en el valor de una característica o atributo, y cada rama corresponde al resultado de esa decisión. Las hojas del árbol representan las etiquetas o valores finales de la predicción.

El funcionamiento de un árbol de decisión se basa en dividir recursivamente el espacio de características en subconjuntos más pequeños, hasta alcanzar condiciones de parada, como una profundidad máxima del árbol o un número mínimo de instancias en cada hoja. Durante cada división, el algoritmo selecciona la característica que proporciona la mayor ganancia de información o la menor impureza, utilizando criterios como la entropía o el índice Gini.

Luego para la implementación del modelo en primer lugar se procede la división del dataframe y la selección del modelo, luego se continua con la configuración de hiperparámetros y el entrenamiento del modelo. La configuración de hiperparámetros es una fase crucial en el proceso de construcción de modelos predictivos, ya que estos parámetros no son aprendidos directamente del proceso de entrenamiento, sino que deben ser ajustados manualmente. Los hiperparámetros controlan el comportamiento del algoritmo de aprendizaje y su ajuste adecuado puede tener un impacto significativo en el rendimiento del modelo.

En el caso de los árboles de decisión, algunos de los hiperparámetros más relevantes incluyen la profundidad máxima del árbol, el número mínimo de muestras por hoja y el criterio de división. La profundidad máxima controla el número máximo de divisiones en cualquier rama del árbol, lo que permite regular la complejidad del modelo y evitar el sobreajuste. El número mínimo de muestras por hoja define el número mínimo de observaciones que debe contener una hoja final, lo que también ayuda a controlar el tamaño del árbol y mejorar la capacidad de generalización del modelo. El criterio de división determina la métrica utilizada para seleccionar la característica en cada nodo del árbol.

Luego, se procede al entrenamiento del modelo, donde este aprende a partir de los patrones observados en los datos de entrenamiento. Durante esta fase, el algoritmo ajusta sus parámetros internos con el objetivo de minimizar el error y mejorar su capacidad predictiva en nuevos datos. Un aspecto importante en esta etapa es el uso de las curvas de validación, las cuales permiten visualizar cómo varía el rendimiento del modelo en función de diferentes parámetros, como la complejidad del modelo o la cantidad de datos utilizados para el entrenamiento. Estas curvas suelen mostrar dos métricas claves, el rendimiento en el conjunto de entrenamiento y el rendimiento en el conjunto de validación (o prueba), lo que ayuda a evaluar si el modelo está sufriendo de sobreajuste o subajuste.

Además de las curvas de validación, una técnica esencial para mejorar la confiabilidad de los resultados es la validación cruzada. La validación cruzada consiste en dividir el conjunto de datos en múltiples subconjuntos

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

(o folds) para garantizar que el modelo se entrene y valide en diferentes porciones de los datos. El procedimiento más común es la validación cruzada k-fold, donde el conjunto de datos se divide en k partes de tamaño similar. En cada iteración, uno de los k subconjuntos se utiliza como conjunto de validación, mientras que los k-1 subconjuntos restantes se usan para entrenar el modelo. Este proceso se repite k veces, asegurando que cada subconjunto actúe como conjunto de validación en al menos una ocasión.

Para la validación del modelo predictivo, se puede utilizar métricas tales como exactitud (accuracy), que es una medida que permite evaluar el desempeño del modelo, arroja el porcentaje de predicciones correctas dentro del conjunto de datos. Por otro lado, el accuracy que es igual al porcentaje de registros clasificados correctamente. También, recall, que es la proporción de verdaderos positivos entre todos los casos que realmente pertenecen a la clase positiva, es útil para evaluar el desempeño del modelo en contextos donde es importante detectar todos los casos positivos, como en la predicción de deserción estudiantil, donde se busca identificar con precisión a todos los estudiantes en riesgo. Por último, precisión, es la proporción de verdaderos positivos entre todos los casos que el modelo clasificó como positivos, en otras palabras, mide qué tan exactas son las predicciones positivas del modelo, una alta precisión indica que el modelo comete pocos errores cuando predice la clase positiva.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Es posible obtener la precisión del modelo a partir de la matriz de confusión dividiendo los casos clasificados como positivos entre el total de registros. La matriz de confusión describe completamente el desempeño del modelo. Dicha matriz permite poder visualizar cuántos casos positivos fueron clasificados correctamente y cuántos casos negativos fueron clasificados correctamente. Se trata de una tabla en la cual se muestran los casos positivos que son verdaderamente positivos, casos positivos que en realidad son negativos, casos clasificados como negativos que en realidad son negativos y por último casos clasificados como negativos que en realidad son positivos como establece Perez et al. [26].

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Por lo tanto, dentro de los elementos que conforman la matriz de confusión encontramos los siguientes, True Positive (TP) son los registros que fueron predichos positivamente y que de verdad eran positivos, True negative (TN) son las instancias que el modelo clasificó como negativas que en verdad lo eran, False Positive (FP) son las instancias que se clasificaron como positivas pero que en verdad eran negativas, es decir, que se clasificaron de manera incorrecta, False negative (FN) son las instancias clasificadas como negativas que en realidad eran positivas.

La precisión es el porcentaje de predicciones positivas del modelo que son correctas y se calcula de la siguiente manera, Precisión = TP/(TP+FT). Define que tan preciso es el modelo en cuanto a predicciones positivas.

La sensibilidad (recall) se define como el porcentaje de casos positivos que el modelo predijo de manera correcta, estos datos también es posible obtenerlos a partir de la matriz de confusión, y se calcula de la siguiente manera, Recall = TP/(TP+FN).

La puntuación F1 (F1 Score), es la media armónica entre la precisión y el recall. Es una medida útil cuando se quiere equilibrar entre precisión y

recall, especialmente cuando se trabaja con clases desbalanceadas y se calcula de la siguiente manera, F1 = 2 x (Precisión x Recall) / (Precisión + Recall).

3.3 Marco tecnológico

En este informe donde se aplica minería se requiere de una plataforma de hardware y de software para la ejecución de los algoritmos y de los modelos. Para esta fase no se necesitan recursos de hardware demasiado robustos.

Los algoritmos de ML, se pueden ejecutar tanto en sistemas operativos Windows, macOS, como también en sistemas operativos de software libre como Linux.

En este orden de ideas, los modelos de predicción como técnica de DM son generados a partir de algoritmos de IA, estos algoritmos procesan los datos históricos de algún fenómeno que se pretenda predecir. A partir de estos datos históricos las computadoras aprenden a predecir el fenómeno en estudio. Estos aprendizajes constituyen los modelos, los cuales pueden ser alimentados con datos actuales y obtener las predicciones más probables sobre el fenómeno en estudio.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

3.3.1 Plataformas tecnológicas

Existen diversas plataformas sobre las cuales se ejecutan los algoritmos de DM y ML. En estas plataformas conviven tanto los datos como los algoritmos de aprendizaje, que operan en lo que Witten et al. [25] denomina "entornos de desarrollo para la ciencia de datos".

En este informe, se ha decidido utilizar Python para el análisis y manejo de datos, debido a su flexibilidad y potencia. Python es un lenguaje de programación de alto nivel, ampliamente utilizado en ciencia de datos, ML y DM. Mediante el uso de Python, se cargará el conjunto de datos proporcionado por las universidades, convirtiéndolo en un dataframe con la biblioteca Pandas. Esta es una biblioteca de código abierto que proporciona estructuras de datos y funciones de análisis de alto rendimiento y fáciles de usar. Entre las características clave de Pandas se incluyen funcionalidades para leer y escribir datos en diferentes formatos (como CSV, Excel y SQL), además de funciones de limpieza, transformación y análisis de datos.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Además de Pandas, utilizamos otras bibliotecas de Python como NumPy, Matplotlib, Seaborn, Sweetviz y Scikit-learn, cuyas funcionalidades se detallarán a continuación.

Para el proceso de EDA, se utilizarán diversas herramientas y bibliotecas, además de RapidMiner y Sweetviz para generar informes visuales y estadísticos, se utilizarán las funcionalidades de Pandas, como describe(), info(), y isnull(), corr(), drop(), entre otras, que permiten obtener estadísticas descriptivas, explorar la estructura de los datos y detectar valores nulos. Estas funciones nos proporcionarán una comprensión detallada de la distribución de los datos y nos servirán para guiar los siguientes pasos en la limpieza y transformación de los mismos.

En la etapa de reducción de dimensionalidad mediante PCA, emplearemos la biblioteca Scikit-learn, que ofrece diversas herramientas para tareas de clasificación, regresión, reducción de dimensionalidad y evaluación de modelos. Utilizaremos específicamente los módulos de Preprocessing y Decomposition.

Para la evaluación del desempeño de los modelos de clasificación, como los árboles de decisión, también recurriremos a Scikit-learn. Utilizaremos su función Train-Test Split del módulo Model Selection para dividir los datos en conjuntos de entrenamiento y prueba. Además, se emplearán métricas como Accuracy Score, Recall Score, Precision Score y F1 Score para evaluar el rendimiento del modelo.

En cuanto al análisis de correlaciones entre características, fundamental para comprender las dependencias entre ellas, utilizaremos las funciones de SciPy Stats, como Pearson y Spearman, que permiten analizar correlaciones tanto lineales como no lineales.

Para la interpretación de los modelos de ML, también utilizaremos herramientas de Scikit-learn, como Permutation Importance y Feature Importances, que nos ayudarán a evaluar la relevancia de las características dentro de los modelos predictivos y proporcionar interpretaciones más claras.

4. METODOLOGÍA

En este capítulo se describe el enfoque utilizado y las etapas para el diseño de la investigación.

Como se mencionó en la introducción, la EDM es una disciplina relacionada con el desarrollo de métodos que permiten extraer conocimiento a partir de datos académicos, socioeconómicos, y de las analíticas de aprendizaje. La información obtenida se utiliza en la toma de decisiones para mejorar los índices de rendimiento académico, calidad educativa, deserción y procrastinación estudiantil entre otros.

En la Fig. 1, se puede observar un proceso tradicional de EDM, en donde a partir de definir un problema para su análisis comienza una serie de quince tareas básicas divididas en cuatro etapas generales En el año 2013 y subsiguientes, Romero y su grupo de investigación de la Universidad de Córdoba, España, detallaron este proceso tradicional de EDM.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

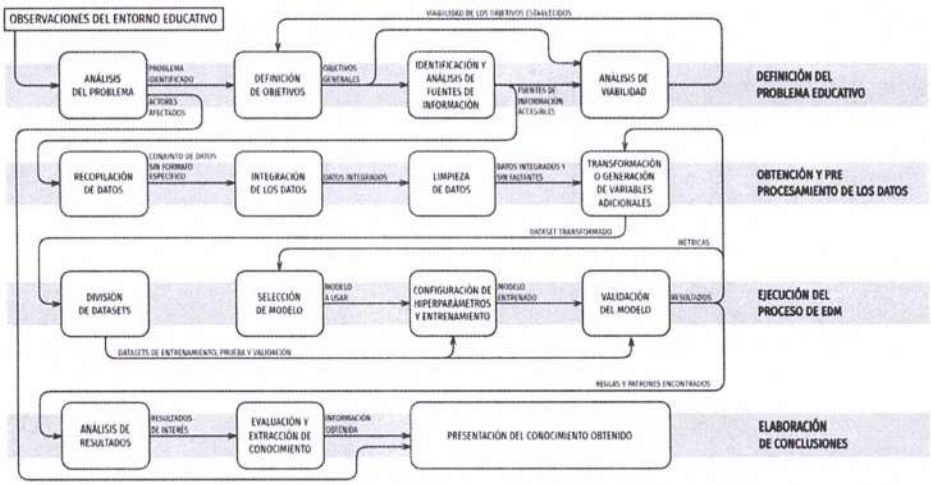


Figura 1-Proceso tradicional de EDM

4.1 Breve descripción detallada.

En la etapa de definición del problema educativo, se comienza con la evaluación del entorno educativo y se divide en 4 etapas particulares, entre ellas las siguientes:

1. Definición del problema a investigar que puede ser abandono, procrastinación, ruptura o rendimiento de los alumnos, entre otros.
2. Definición de los objetivos a cumplir, por ejemplo, en el caso de la deserción estudiantil, el objetivo puede ser conocer la causa o causas que más influyeron (distancia de la Universidad, edad, horarios, calificaciones, etc.).
3. Definición de los datos necesarios y accesibles para la institución.
4. Análisis de la viabilidad técnica, operativa y económica para conseguir los datos necesarios.

En la etapa de obtención y preprocesamiento de los datos se divide en 4 etapas particulares entre ellas las siguientes:

5. Adquisición de datos de las diferentes fuentes que la comunidad educativa, se alimenta a través de aplicaciones, software de las propias instituciones y software de uso general, como encuestas, becas, Sistema de Información Universitaria (SIU), etc.
6. Integración de los datos de las diversas fuentes en un único archivo, esta tarea generalmente queda en manos de un administrador de base de datos.
7. La limpieza de datos significa dar tratamiento a los datos faltantes, a los outliers, eliminar duplicados, inconsistencias, normalizar nomenclaturas, y eliminar instancias o características de las mismas.
8. En la transformación o generación de variables adicionales se realizan actividades como formatear algún tipo de dato, reescalar datos, generar características sintéticas, y agrupar características entre otras. Una vez completadas estas tareas, se crea un conjunto de datos (conjunto de datos separado, completo, coherente y actualizado que sirve de base para el entrenamiento de un algoritmo de ML) para cada problema educativo y se almacena en una base de datos.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

En la etapa de ejecución del proceso de EDM se divide en 4 etapas particulares, entre ellas las siguientes:

9. A partir del conjunto de datos creado (dataset), se realiza una división del mismo que puede ser en 2 o 3 partes, ya sea en conjunto de entrenamiento (70%) y prueba (30%), o en conjuntos de entrenamiento (60%) validación (10%), y prueba (30%). Esto permite poder evaluar a los modelos con datos que nunca ha entrenado
10. Con la definición de los objetivos a conseguir y el dataset preparado, se debe encontrar el algoritmo que mejor se adapte a la problemática, esta es una tarea más que ardua dado el conjunto amplio de algoritmos disponibles (arboles de decisión, support vector machine, naive bayes, perceptrón multicapa, k-vecinos, regresión lineal o polinómica, etc.).
11. La configuración de hiperparámetros es una tarea muy específica y requiere de experticia para no tener que probar cientos, miles de posibles configuraciones. Si bien existen técnicas como grid search o random search o técnicas de optimización bayesiana o procesos gaussianos para reducir

la dimensión de posibilidades a explorar, finalmente la eficiencia del modelo dependerá bastante de la correcta elección de hiperparámetros. Además, en esta tarea hay que realizar el entrenamiento al cual se le pueden agregar técnicas de ensambles (bagging, boosting o stacking) y técnicas de cross validation para disminuir el sesgo en la selección de muestras.

12. En la validación del modelo se utilizan métricas para evaluar el rendimiento del mismo, dependiendo del tipo de problema a resolver. En el caso de regresión podrá ser el error absoluto medio o el error cuadrático medio, en casos de clasificación podrán ser la precisión, exactitud, recuperación, tasa de falsos positivos, F1, etc.

En la etapa de elaboración de conclusiones se divide en 3 etapas particulares, entre ellas las siguientes.

13. Una vez obtenidos los patrones existentes en los datos comienza el proceso de análisis mediante el cual deben extraerse conclusiones de los mismos. Esta etapa nuevamente requiere de recursos humanos con experiencia ya que se puede obtener un modelo con alta precisión, pero con alta varianza o con alta tasa de recuperación, por ejemplo.

14. Las tareas de evaluación y extracción de conocimiento reflejan en cuanto el modelo propuesto se asemeja a los objetivos propuestos y permite entender cabalmente qué es la información, como por ejemplo permite conocer cuáles son las causas que llevaron a la deserción de un alumno.

15. La presentación del conocimiento debe ser de una manera simple e intuitiva para el profesional que tiene que decidir. Los informes deben estar munidos de gráficos y tablas que permitan entender rápidamente si el objetivo se ha cumplido o hay que seguir investigando. Para ello existen librerías por ejemplo en lenguaje Python como matplotlib, seaborn, o pyplot que permiten realizar informes muy descriptivos.

El modelo que se implementara en este trabajo sigue el proceso tradicional de EDM detallado anteriormente, dividido en cuatro etapas generales. En los siguientes capítulos, se comienza a detallar cada etapa del proceso.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

5. APLICACIÓN DE LA METODOLÓGICA

En este capítulo se aplicará la metodología detallada en el capítulo anterior, dicha metodología es propuesta por Romero et al. [18] de la Universidad de Córdoba, España.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

5.1 Definición del problema educativo.

5.1.1 Identificación del problema

En Argentina, por ley, el ingreso a las universidades públicas argentinas debe ser gratuito y no discriminatorio, lo cual ha generado un aumento considerable en la demanda en educación superior, sin embargo, dicho crecimiento en la cantidad de ingresantes no se ha visto reflejado en el incremento proporcional de graduados.

Esto refleja la existencia de dos fenómenos claros. Por un lado, el grupo de graduados es reducido en relación con la cantidad de ingresantes. Por el otro, es evidente que gran parte del grupo que inicia sus estudios abandona la carrera. Según estimaciones de García de Fanelli, basada en los datos brindados por la Secretaría de Políticas Universitarias (SPU, 2011), la tasa de deserción en el ámbito universitario estatal es de aproximadamente un

80 %; mientras que la tasa de deserción universitaria en el ámbito privado es aproximadamente del 60 %. Y si bien en las dos últimas décadas se incorporaron programas de becas y de tutorías como políticas de retención, aún no existen estudios que brinden información exacta acerca del verdadero impacto de esas políticas sobre la problemática aquí abordada. Así, pues, sostiene la autora, que la tasa de deserción sigue siendo alta, especialmente en el caso de jóvenes estudiantes provenientes de los sectores de menor nivel socioeconómico.

Más allá de la discusión sobre si la deserción es positiva o negativa, es importante determinar qué factores influyen en la toma de decisión de desertar, y en qué momentos de la trayectoria académica se dan estos eventos. Conocer estos patrones es fundamental tanto para las universidades como para el Estado, que financia la educación superior.

En este contexto, se propone utilizar técnicas de DM estudiantil y analítica de datos para abordar esta problemática. El objetivo es identificar los principales factores que inciden en la deserción estudiantil en carreras de informática, implementando un modelo predictivo que permita anticipar el riesgo de abandono.

El análisis de los datos históricos de ingreso, permanencia y graduación, combinado con información socioeconómica de los estudiantes, permitirá detectar patrones y tendencias que expliquen el fenómeno. Esto posibilitará a las instituciones diseñar políticas y programas de retención más efectivos, logrando una gestión más eficiente de los recursos públicos destinados a la educación superior.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

5.1.1.1 Formulación del problema

Ante este contexto recorrido y del planteamiento anterior surge la siguiente pregunta de investigación:

¿En qué medida la implementación de un modelo de predicción de deserción estudiantil, apoyado en técnicas de DM, contribuirá a identificar y comprender los factores que afectan la deserción estudiantil en carreras de informática?

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

5.1.1.2 Alcance

El presente informe final, pretende implementar un modelo de predicción de la deserción estudiantil a partir datos históricos de carreras de informática proporcionados por las UUNN.

A partir de estos datos mediante la aplicación de técnicas de DM se pretende implementar un modelo que permita hallar correlaciones entre diferentes características y a partir de allí poder hacer la predicción de la deserción.

Este informe proporcionará, una implementación de una herramienta que ayude a detectar de forma temprana aquellos factores que puedan incidir en la posible deserción y su consecuente permanencia.

Con esta implementación se pretende contribuir a aliviar este fenómeno de deserción que tanto afecta negativamente las instituciones educativas.

5.1.1.3 Limites del informe

Se plantea que el informe estará limitado inicialmente al análisis de datos de los alumnos de carreras informáticas pertenecientes de dichas universidades, para lo cual se tomarán los datos disponibles, correspondientes desde el año 1970 al año 2022, para poder contrastarlos

con la situación actual de los estudiantes en cuanto a permanencia o abandono del proceso de formación en la institución.

5.1.2 Definición de objetivos

5.1.2.1 Objetivo general

El objetivo general es implementar una herramienta de predicción, que puede permitir a las universidades predecir abandono por parte de los estudiantes utilizando ML, y opcionalmente determinar las formas de reducirla con el fin de mejorar el desempeño institucional.

La importancia y pertinencia de este tema radica en el impacto social y económico que tiene la deserción estudiantil. Los estudiantes que abandonan sus estudios universitarios se enfrentan a limitaciones en sus oportunidades de empleo y desarrollo profesional, lo que afecta su calidad de vida y contribuye a la desigualdad social. Además, las instituciones educativas invierten recursos significativos en la formación de los estudiantes, por lo que es fundamental buscar soluciones para maximizar el aprovechamiento de estos recursos y garantizar la culminación exitosa de los estudios.

5.1.2.2 Objetivos específicos

Se plantean una serie de objetivos específicos. En primer lugar, se buscará recolectar, analizar y preparar un conjunto de datos históricos mediante los datos proporcionados por las UUNN.

A continuación, se aplicarán técnicas de preprocesamiento de datos, y limpieza de los datos, asegurando su calidad y consistencia. Asimismo, se utilizarán técnicas de selección de características para identificar el subconjunto más relevante y representativo de características que influyen en el rendimiento académico de los estudiantes.

Una vez seleccionadas las características, se procederá a seleccionar un algoritmo de clasificación dentro del Aprendizaje Supervisado, entrenarlo, optimizar sus hiperparámetros y evaluar el rendimiento del modelo y mostrar los resultados de una manera amigable al usuario de que el modelo supero los umbrales para las métricas establecidas tales como precisión, recall y F1-score, entre otros.

Además, se aplicarán técnicas de validación cruzada y pruebas independientes para evitar sesgo muestral y obtener una evaluación robusta del modelo.

Posteriormente, se realizará un análisis e interpretación de los resultados obtenidos con el objetivo de identificar los factores más influyentes en el rendimiento académico de los estudiantes

5.1.3 Justificación de la investigación

En la Argentina, el problema de fracaso y deserción universitaria se plantea desde los inicios de la Universidad Pública. En 1968, se enfatiza sobre la importancia de investigar "la composición social de los estudiantes y graduados y el problema de la deserción hoy día tan agudo" (Araoz, 1968). Sin embargo, nuevamente se evidencian muy pocos estudios realizados en esta área.

Pese a que el fenómeno de la deserción universitaria en Argentina ha sido una preocupación recurrente desde hace más de 50 años, tal como señala

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Araoz (1968), los estudios y soluciones implementadas hasta el momento han sido insuficientes para abordar de manera efectiva este problema.

En la actualidad, las tasas de abandono y fracaso estudiantil en el nivel universitario argentino siguen siendo alarmantemente elevadas, con un impacto negativo tanto a nivel individual como socioeconómico. Según los últimos datos oficiales del Ministerio de Educación (2022), aproximadamente el 40% de los estudiantes que ingresan a la universidad no logran culminar sus estudios.

Este panorama preocupante se ha visto agravado por la pandemia de COVID-19, que ha tenido un fuerte impacto en la educación superior argentina. Según un artículo publicado en el diario La Nación (Vázquez, 2024), la tasa de deserción universitaria se incrementó en un 15% durante los últimos dos años, debido a factores como la dificultad de acceso a la tecnología, la falta de acompañamiento emocional y el deterioro de la situación socioeconómica de muchos estudiantes.

Por lo tanto, el presente informe final, busca abordar este desafío persistente, utilizando técnicas de ML y EDM para implementar un modelo predictivo que podrían ayudar a identificar a los estudiantes en riesgo de abandonar sus estudios de manera temprana. De esta manera, opcionalmente podrían diseñar e implementar intervenciones oportunas y adaptadas a las necesidades particulares de cada estudiante, con el fin de mejorar los índices de retención y graduación universitaria en Argentina.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

5.2 Obtención y pre-procesamiento de los datos

Las siguientes dos subetapas dentro de la etapa de obtención y preprocesamiento de datos del proceso tradicional EDM propuesto por Romero, la recopilación de datos y la integración de datos, ya han sido completadas previamente, dado que los datos se encuentran consolidados en un solo archivo de Excel. A continuación, se define el flujo de trabajo que seguirá el análisis de los datos antes de la ejecución de los modelos.

En primer lugar, antes de proceder con la etapa de limpieza de datos, se llevará a cabo un EDA. Esta etapa preliminar y exploratoria, es crucial para obtener una visión representativa del conjunto de datos y comprender las relaciones iniciales entre las características.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Es importante destacar que, para realizar ciertos análisis dentro del EDA, como la correlación entre características, puede ser necesario transformar las características categóricas a numéricas. Sin embargo, esto no siempre es obligatorio, ya que existen otros métodos, como el análisis de asociación, que permiten trabajar con características categóricas sin necesidad de transformarlas. La elección del método dependerá del tipo de análisis que se quiera realizar y de las características de los datos.

En caso de que sea necesario realizar la transformación anticipada de características categóricas a numéricas, esto refleja la naturaleza iterativa del proceso de preprocesamiento de datos. Este enfoque permite que ciertas acciones, como la transformación de características, que normalmente ocurre después de la limpieza de datos en el proceso de EDM, se lleven a cabo en diferentes etapas del análisis según las necesidades específicas. Aunque tradicionalmente la limpieza de datos precede a la transformación y al análisis, en este informe se justifica un orden ligeramente diferente para optimizar el flujo de trabajo.

Por lo tanto, antes de la limpieza de datos, se realizará un EDA para identificar patrones, relaciones entre características y posibles problemas en los datos. Dado que algunos análisis requieren que las características estén en un formato numérico, es en esta etapa que se realizará una primera transformación de características categóricas.
Posteriormente, se procederá con la limpieza de datos, donde se manejan datos ausentes, se corregirán inconsistencias y se tratarán los valores atípicos identificados en la etapa del EDA.
Luego, en la etapa de transformación o generación de características adicionales, se aplicarán técnicas de interpretabilidad para la selección de características, se harán transformaciones adicionales y se generarán nuevas características, para optimizar su uso en los modelos y mejorar la capacidad predictiva del mismo.

5.2.1 Recopilación de datos

La recopilación de datos es una etapa fundamental en la EDM, cuyo objetivo es reunir información relevante para analizar y comprender fenómenos educativos como la deserción estudiantil, el rendimiento académico, o la satisfacción de los estudiantes, entre otros. En el contexto educativo, las fuentes de datos pueden ser muy diversas, incluyendo bases de datos institucionales, encuestas realizadas a estudiantes y docentes, registros académicos y plataformas de aprendizaje en línea.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

En este informe, los datos utilizados provienen de encuestas previamente realizadas por la Fundación Sadosky, como parte de su investigación titulada ¿Por qué estudiamos informática? [7]. Estas encuestas, detalladas en el Anexo 3.3 de dicha investigación, incluyen preguntas específicas sobre las trayectorias educativas de estudiantes universitarios en carreras de informática, abarcando temas como los factores que influyen en la elección de la carrera, la experiencia académica, y las razones que podrían llevar al abandono de los estudios. Además, en el Capítulo 1 del mismo trabajo se presenta una lista completa de las universidades y carreras que participaron en el estudio.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Aunque la recopilación de datos es crucial para el análisis en EDM, es importante aclarar que en este informe no fue realizada directamente por nosotros, sino que los datos ya estaban disponibles gracias al trabajo de la Fundación Sadosky. La inclusión de esta sección teórica tiene como objetivo contextualizar la importancia de esta etapa en el proceso de EDM, a pesar de que los datos utilizados en nuestro estudio ya habían sido previamente recolectados.

5.2.1.1 Identificación de la fuente de datos

La identificación de la fuente de datos es un paso clave en el desarrollo de este informe. Se ha determinado que la información académica disponible corresponde a estudiantes de carreras informáticas de las UUNN. A partir de esta identificación, se ha evaluado la calidad de los datos, lo cual es esencial para garantizar la fiabilidad del estudio.
Con base en esta información, se procedió a preparar los datos, asegurando que estén en condiciones óptimas para su uso en la implementación del modelo de predicción. Para ello, se identificó un archivo en formato Excel que contiene datos relevantes, que servirán como base para la implementación del modelo predictivo.

5.2.1.2 Descripción del dataset

Se partió de los datos de estudiantes de carreras informáticas obtenidos provenientes de la fuente mencionada en el apartado anterior, que son las UUNN. En la revisión de estos datos se identificaron las siguientes características, los cuales se pueden ver en las siguientes tablas.

Fuente	Características
Universidades Nacionales	id
	Región de la universidad
	Antiguedad de la universidad
	Tamaño de la universidad
	Descripción de la universidad
	Carrera
	Año de ingreso
	En cuál de las siguientes situaciones te encontrás?
	Relación actual con la carrera (3 categorías)
	Relación actual con la carrera (4 categorías)
	Relación actual con la carrera (5 categorías)
	Cantidad de materias/tesis que debe (sólo estudiantes que terminaron la cursada)
	Contacto con la carrera a través de Redes / sitio web de la universidad
	Contacto con la carrera a través de Jornadas universitarias o Ferias de carreras
	Contacto con la carrera a través de Diario / revistas / cartelería / folletos / Tv / Radio

Tabla 1-Descripción de Características del Dataset (Parte 1)

RESOL. C. ESC. ING. Y CS. AMB. Nº 28/2024

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Fuente	Características
Universidades Nacionales	Contacto con la carrera a través de Amigos / conocidos / familiares
	Contacto con la carrera a través de Visita a mi escuela secundaria
	Contacto con la carrera a través de otros medios
	Contacto con la carrera a través de otros medios. Cual?
	Motivo carrera. A partir de un curso de orientación vocacional
	Motivo carrera. Por la orientación del título
	Motivo carrera. Porque se corresponde con mis aptitudes
	Motivo carrera. Porque era la que más me gustaba
	Motivo carrera. Por la sugerencia de familiares o personas de confianza
	Motivo carrera. Por el prestigio de la carrera
	Motivo carrera. Porque no había otra carrera (descarte otras)
	Motivo carrera. Porque conozco profesionales en el área y me gustaría trabajar como ellas/os
	Motivo carrera. Porque tiene múltiples salidas profesionales
	Motivo carrera. Porque era una carrera corta y adecuada a mis posibilidades
	Motivo carrera. Porque permite acceder a trabajos bien pagados
	Motivo carrera. Por mi experiencia profesional previa o por estar
	Motivo carrera. Porque creía que era más fácil comparada con otras carreras
	Motivo carrera. Otros motivos
	Motivo carrera. Otros motivos. Cuales?
	Motivo universidad. Porque tengo parientes cercanos que son graduados de esta universidad
	Motivo universidad. Por las características del programa académico (tipo de materias que debe cursar, organización, etc.)
	Motivo universidad. Por la calidad del plantel docente
	Motivo universidad. Por la flexibilidad de horarios
	Motivo universidad. Por es una universidad estatal
	Motivo universidad. Porque es gratuita
	Motivo universidad. Porque garantiza una buena inserción laboral/profesional a sus estudiantes o egresados/as
	Motivo universidad. Por la sugerencia de familiares o personas de confianza
	Motivo universidad. Por su prestigio y calidad académica
	Motivo universidad. Porque queda cerca de mi casa
	Motivo universidad. Porque favorece la posibilidad de realizar posgrados en el exterior (convenios, pasantías e intercambios)
	Motivo universidad. Porque no exige examen de ingreso
	Motivo universidad. Ofrece título intermedio
	Motivo universidad. Otros
	Motivo universidad. Otros. Cuales?

Tabla 2-Descripción de Características del Dataset (Parte

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

2)

Fuente	Características
Universidades Nacionales	Al momento de la insripción sentías que tenías información sobre la organización de los horarios y modalidades de cursada
	Al momento de la insripción sentías que tenías información sobre el plan de estudios (materias y contenidos)
	Al momento de la insripción sentías que tenías información sobre la exigencia
	Pensando en tu situación actual, a nivel general ¿cuánto considerás que se cumplieron las expectativas que tenías sobre la carrera
	Pensando en tu situación actual, a nivel general ¿cuánto considerás que se cumplieron las expectativas que tenías sobre la carrera. Por qué (abierta)?
	Año de las materias que estas/estuviste cursando. 1er año
	Año de las materias que estas/estuviste cursando. 2do año
	Año de las materias que estas/estuviste cursando. 3er año
	Año de las materias que estas/estuviste cursando. 4to año
	Año de las materias que estas/estuviste cursando. 5to año
	Año de las materias que estas/estuviste cursando. Trabajo final / tesis
	Obtención Título intermedio
	Porqué no tramitó el título intermedio
	Obtención título intermedio. Otro (abierta)
	Actividades en proyectos o equipos de investigación
	Actividades en Docencia - Ayudante alumno/a
	Actividades en tutorias (en el rol de tutor)
	Actividades en tutorias (en el rol de tutorado)
	Actividades en pasantías rentadas
	Actividades en prácticas profesionalizantes
	Actividades de extensión
	Servicio de comedor
	Servicio de residencia estudiantil
	Servicio de jardín maternal
	Servicio de lactario
	Recibió beca
	Qué beca recibió
	Cuanto considera que la beca ayudó para sostener la trayectoria académica
	Evaluación Relación con docentes
	Evaluación Relación con estudiantes
	Evaluación Relación con nodocentes
	Evaluación Disponibilidad de equipamiento
	Evaluación Laboratorio de informática
	Evaluación Campus virtual

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Tabla 3-Descripción de Características del Dataset (Parte 3)

Universidades Nacionales	Evaluación Carga horaria semanal
	Evaluación Oferta de turnos y horarios
	Evaluación Extensión del plan de estudios
	Evaluación Sistema de correlatividades
	Evaluación Modalidad presencial
	Evaluación Modalidad virtual
	Evaluación Trámites/gestiones administrativas
	Evaluación docente. Conocimiento sobre los temas tratados
	Evaluación docente. Cantidad de docentes por materia
	Evaluación docente. La forma de explicar los temas tratados
	Evaluación docente. Capacidad para escuchar mis consultas y dudas
	Evaluación docente. Capacidad para generar interés en el tema de las y los docentes
	Evaluación docente. Diseño de las evaluaciones
	Evaluación docente. Brindar bibliografía adecuada
	Evaluación docente. Devolución de los trabajos, etc.
	Estudiar esta carrera es una decisión orientada por mi vocación
	Siento que la facultad me brinda herramientas que facilitan la cursada
	Siento que la facultad me brinda herramientas que facilitan la cursada (dicotómico)
	Obtener el título no me brinda ninguna ventaja laboralmente
	El título me posiciona en una situación diferencial en el mercado de trabajo
	Percepción de materias filtro
	Año/s de las materias filtro (abierta)
	Por qué percibis esas materias filtro
	Hubo un cuatrimestre en el que no te anostaste
	Año de la carrera en el que no te anotaste a un cuatrimestre
	Realizaste en algún momento el trámite de reinscripción para volver a ser estudiante regular
	Te anotaste o rendiste una materia en los último 12 meses
	La carrera te llevó o está llevando más tiempo de lo previsto en el plan de estudios
	Demora en la carrera Por cuestiones laborales
	Demora en la carrera Por correlatividades
	Demora en la carrera Por una situación personal
	Demora en la carrera Por una situación de salud
	Demora en la carrera Por el nacimiento de un hije
	Demora en la carrera Porque no aprobaba las materias

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingenieria y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Tabla 4-Descripción de Características del Dataset (Parte 4)

Fuente	Características
Universidades Nacionales	Demora en la carrera Por tener que recursar
	Demora en la carrera Porque debía finales
	Demora en la carrera Por la tesis/tp final
	Demora en la carrera Por la escada oferta
	Demora en la carrera Porque me anoté sin estar muy segura/o de la carrera
	Demora en la carrera Porque tuve diferencias con algún docente
	Demora en la carrera Por compatibilidad de horarios
	Demora en la carrera. Otros motivos
	Demora en la carrera. Otros motivos (abierta)
	Situación laboral
	Situación laboral (dicotómica)
	Cuantos empleados tiene la empresa (abierta)
	Antigüedad en el trabajo
	Área en donde realiza el trabajo
	Trabaja en el área de sistemas
	Trabajo anterior en el área de sistemas
	Situación laboral (tricotómica)
	Área en donde realiza el trabajo. Otra (abierta)
	Cantidad horas semanales
	Posibilidad de teletrabajo
	Posibilidad de días de estudio
	En el trabajo te piden título para efectivizarte
	En el trabajo te piden título para obtener un adicional
	En el trabajo te piden título para acceder a puestos jerárquicos
	En el trabajo te piden titulo para acceder a otros beneficios
	En el trabajo te piden titulo para acceder a otros beneficios. Cuales (abierta)
	En el trabajo no me piden título / puedo acceder a todos los beneficios sin necesidad de tener título
	En el trabajo te piden título. Prefiero no responder
	Utilidad laboral de lo aprendido en la carrera
	Sentis que tu rendimiento decayó a partir de tu ingreso al mercado laboral
	Sentis que tu rendimiento decayó a partir de tu ingreso al mercado laboral. Porqué (abierta)
	Relación entre tu situación laboral y las expectativas que tenías cuando comenzaste los estudios
	Realizaste una capacitación específica para complementar conocimientos académicos
	Dónde realizaste la capacitación (por tu cuenta)
	Dónde realizaste la capacitación (en una organización)
	En qué año te recibiste
	Tramitaste el título intermedio
	Impacto del título de grado en tu desarrollo personal (abierta)
	Abandono Por cuestiones laborales
	Abandono Porque no me interesaba
	Abandono Por una situación personal
	Abandono Por una situación de salud
	Abandono Por el nacimiento de un hije
	Abandono Porque no aprobaba las materias
	Abandono Porque necesitaba una pausa en la vida
	Abandono Porque cambié de carrera
	Abandono Porque debía finales
	Abandono Por la tesis/tp final
	Abandono Por la escasa oferta
	Abandono Porque me anote sin estar muy segura/o de la carrera
	Abandono Porque tuve diferencias con algún docente
	Abandono Por compatibilidad de horarios
	Otros motivos de abandono
	Otros motivos de abandono (abierta)

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Tabla 5-Descripción de Características del Dataset (Parte 5)

Universidades Nacionales	Qué necesitarías para volver a retomar la carrera (abierta)
	Comentarios discriminatorios en razón de tu género u orientación sexual o chistes sexualmente sugestivos que te hicieron sentir incómoda/o
	Quién realizó comentarios discriminatorios en razón de tu género u orientación sexual o chistes sexualmente sugestivos que te hicieron sentir incómoda/o
	Quién realizó comentarios discriminatorios en razón de tu género u orientación sexual o chistes sexualmente sugestivos que te hicieron sentir incómoda/o (abierta)
	Comentarios que subestimen, menosprecien o pongan en cuestión tu capacidad de realizar alguna tarea en razón de tu sexo/género y/u orientación sexual
	Quién realizó Comentarios que subestimen, menosprecien o pongan en cuestión tu capacidad de realizar alguna tarea en razón de tu sexo/género y/u orientación sexual
	Quién realizó Comentarios que subestimen, menosprecien o pongan en cuestión tu capacidad de realizar alguna tarea en razón de tu sexo/género y/u orientación sexual (abierta)
	Contacto físico no deseado (tocamientos, abrazos, y/o besos no consentidos)
	Quién realizó Contacto físico no deseado (tocamientos, abrazos, y/o besos no consentidos)
	Quién Contacto físico no deseado (tocamientos, abrazos, y/o besos no consentidos) (abierta)
	Área específica donde puedas recurrir en caso de algún problema o conflicto vinculado a tu sexo-género y/u orientación sexual
	En mi carrera existe desigualdad de género
	Los varones disponen de ventajas para acceder, permanecer y egresar en una carrera como la mía
	La facultad debería desarrollar políticas tendientes a la igualdad de género en sus carreras
	Las personas en mi carrera tienen iguales oportunidades de cursar y formarse (sin importar su identidad de género)
	En mi carrera las personas se sienten seguras de circular por los diferentes espacios (sin importar su identidad de género y/u orientación sexual)
	Cursaste otra carrera previamente
	Cuál fue la carrera anterior (abierta)
	Donde hicista esa carrera anterior
	Donde hiciste esa carrera anterior (abierta)
	Edad
	Identidad de género
	Identidad de género (3 categorías)
	Otro género
	Qué tipo de orientación tenía tu secundario
	Qué tipo de otra orientación tenía tu secundario (abierta)
	Año de egreso del secundario
	Tenés hijos o hijas menores de 18 años
	Te tuviste que mudar de ciudad/localidad para poder asistir a la Universidad
	Mayor nivel educativo madre
	Mayor nivel educativo padre
	Clima educativo del hogar
	Clima educativo (2 categorías)
	Te gustaría participar de estas entrevistas

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Tabla 6-Descripción de Características del Dataset (Parte 6)

El conjunto de datos utilizado en este análisis cuenta con 205 características y 1211 filas, cada una de ellas representando a un

estudiante que respondió una encuesta. Esta encuesta se llevó a cabo en más de 30 UUNN y recopila información en varias categorías, tales como datos académicos, motivación para elegir la carrera, medios de contacto con la carrera, situación laboral, razones de abandono, servicios institucionales, y experiencias relacionadas con discriminación y acoso.
Cada característica corresponde a una pregunta específica realizada a los estudiantes, abarcando factores diversos que pueden influir en su relación con la carrera. La característica objetivo en este análisis es "Relación actual con la carrera (3 categorías)", la cual tiene tres posibles valores, estudiante, abandonante y egresade. Este diseño permite observar y modelar los factores asociados con la deserción estudiantil, facilitando el análisis de aquellas características que se relacionan con la probabilidad de abandono.

5.2.1.3 Importación de los datos

Para la importación de los datos se utilizó Google Colab, que implementa Jupyter Notebook como backend, permitiendo ejecutar Python y sus diversas librerías para análisis de datos. El proceso comenzó en la sección "Archivos" de Colab, donde se realizó el preprocesamiento inicial. A través de la opción de cargar archivos en el almacenamiento de la sesión, se seleccionó el archivo en formato XLSX y se procedió a la carga del conjunto de datos, tal como se muestra en la Fig. 2. Google Colab facilita la manipulación de datos al proporcionar un entorno accesible y compatible con Python, lo cual permite aprovechar bibliotecas especializadas para el análisis, limpieza y visualización de la información.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes



Figura 2-Carga del DataSet

5.2.2 Integración de datos

La integración de datos es una etapa clave en la Minería de Datos Educativa (EDM) que consiste en consolidar diferentes conjuntos de datos en un único formato unificado y estructurado. El propósito principal es asegurar que los datos provengan de diversas fuentes, pero que sean consistentes y coherentes para facilitar su análisis y modelado en fases posteriores. Esta etapa implica consolidar los datos en un solo conjunto, asegurando que la estructura y el formato sean uniformes, como un paso previo al análisis más profundo.
Durante la integración, el objetivo es combinar los diferentes conjuntos de datos disponibles de manera que se preserven todas las características necesarias para el análisis posterior. Sin embargo, no se incluye en esta fase la resolución de inconsistencias o la estandarización de formatos y tipos de datos (como fechas, categorías o valores numéricos), ya que esas tareas se realizan posteriormente, en la etapa de limpieza de datos. Es en

esa fase donde se identifican y corrigen valores nulos, outliers, y otras anomalías que puedan haber sido detectadas durante el análisis exploratorio de datos (EDA).
En este informe, la integración de los datos no fue realizada directamente por nosotros, ya que los datos utilizados estaban previamente consolidados y organizados en un único archivo de Excel proporcionado por la Fundación Sadosky. Aunque no fue necesario llevar a cabo este paso, esta descripción teórica resalta la importancia de la integración de datos dentro del proceso de EDM.

5.2.3 Análisis exploratorio de datos

Dado que los modelos de EDM se basan en los datos, es fundamental comprender el contenido de esos datos para lograr una adecuada explicabilidad e interpretabilidad de los resultados obtenidos.
El EDA como se detalla en el marco teórico, es una forma de analizar conjuntos de datos para resumir sus características principales, a menudo con métodos visuales. El objetivo del EDA es explorar, describir y resumir las características del conjunto de datos, identificando posibles errores, datos atípicos y relaciones entre características donde estos problemas se abordarán durante la etapa de limpieza de datos. El EDA suele llevar un tiempo considerable.
A continuación, se detallan algunos de los desafíos de interpretabilidad que plantea el EDA en este informe final.
Dimensionalidad, el conjunto de datos cuenta con un gran número de atributos o características, lo que se conoce como alta dimensionalidad. Este reto conlleva un mayor costo computacional para analizar y visualizar los datos proporcionalmente. A medida que aumenta la dimensionalidad, las técnicas de visualización que se basan en proyectar los datos en dimensiones inferiores se vuelven más complejas debido a la pérdida de información.
Tipos mixtos o heterogeneidad, el conjunto de datos incluye características de diferentes tipos, como categóricas, numéricas y de texto. Esta heterogeneidad plantea desafíos significativos al realizar análisis estadísticos, particularmente en el análisis de correlación. En el caso de las características categóricas, la correlación no se puede medir de manera directa como en las características numéricas, lo que requiere la aplicación de técnicas especiales como la codificación de características para convertir las categorías en una representación numérica. Sin embargo, este proceso puede introducir complejidad adicional y afectar la interpretabilidad de los resultados. Además, la combinación de tipos de datos distintos puede complicar la identificación de patrones y relaciones entre las características, lo que podría llevar a interpretaciones erróneas o a la necesidad de aplicar técnicas avanzadas para manejar estas diferencias de manera efectiva.
Valores perdidos y valores atípicos, el conjunto de datos presenta incompletitud con muchos valores faltantes. Otro problema común es la presencia de valores atípicos o valores causados por errores. Manejar los valores perdidos y los valores atípicos es un tema importante y tiene un gran impacto en los resultados del modelo.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

El análisis se llevará a cabo siguiendo la metodología propuesta en la Guía práctica de introducción al Análisis Exploratorio de Datos [22].
El proceso de EDA propuesto por la guía consta de cinco etapas. En primer lugar, comienza con el análisis descriptivo de las características, en el que se obtendrá una visión representativa del conjunto de datos. En segundo lugar, se continúa con el reajuste de los tipos de las características, donde se garantizará la consistencia de las mismas para operaciones posteriores. En tercer lugar, se realiza la detección de datos ausentes, donde se detectarán los datos faltantes para luego ser tratados en la etapa posterior que es la limpieza de datos. En cuarto lugar, se lleva a cabo la identificación de datos atípicos, en el cual se identificarán valores atípicos que podrían distorsionar futuros análisis y posteriormente también tratarlos en la etapa de limpieza de datos. Por último, se realiza un examen numérico y gráfico de las relaciones entre características, donde se evaluará la correlación entre ellas para predecir comportamientos.
Este enfoque garantiza que el análisis posterior se realice sobre un conjunto de datos depurado y comprensible, mejorando la calidad y la fiabilidad de los resultados obtenidos.
En la Fig. 3 se representa de forma esquemática el conjunto de etapas del EDA.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes



Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Figura 3- Etapas del EDA

Para el proceso de EDA, se utilizaron herramientas, bibliotecas y funciones especializadas que permiten una exploración, descripción y resumen exhaustivos, visualmente atractivos, interactivos y fáciles de comprender, facilitando el análisis de las relaciones en los datos, las mismas fueron previamente detalladas en el marco tecnológico, donde, en conjunto, no solo optimizan el proceso de EDA, sino que también aseguran que cualquier decisión tomada en las etapas posteriores se base en una comprensión sólida y detallada de los datos.
A continuación, detallaremos el proceso de EDA propuesto con sus cinco etapas acompañado del código en el apéndice A.1.

5.2.3.1 Proceso de análisis exploratorio de datos

1. Análisis descriptivo:

Como se menciona en la guía práctica, una vez que los datos han sido cargados en nuestro entorno de desarrollo, dicha actividad detallada en nuestro informe final en el punto 4.2.1.3 "Importación de los datos",

procedemos a obtener una vista descriptiva del contenido de las tablas de datos con las que se va a trabajar.

El análisis descriptivo permite abordar los desafíos del EDA mencionados anteriormente como tipos mixtos o heterogeneidad, valores perdidos y valores atípicos, proporcionando una base sólida para la limpieza de datos y para manejar la complejidad de la dimensionalidad en etapas posteriores.

El análisis descriptivo proporciona una visión general y estadísticas de cada atributo o característica del conjunto de datos, permitiendo identificar cuáles características pueden ser irrelevantes o redundantes. Esto es crucial para manejar la alta dimensionalidad, ya que permite una preselección de características que podrían ser eliminadas o combinadas para simplificar el análisis posterior.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

El análisis descriptivo es esencial para entender las diferentes características de los datos, especialmente cuando se trata de características categóricas, numéricas y de texto. Este análisis permite identificar la distribución de las características, lo que a su vez informa sobre cómo se deben tratar y combinar estos tipos de datos para el análisis de correlación y otras etapas del procesamiento.

Para esta etapa, aplicaremos funciones de estadística descriptiva de Pandas que nos permitirán explorar la estructura del conjunto de datos y examinar las características que presenta.

Asimismo, será útil utilizar representaciones gráficas proporcionadas por herramientas que veremos a continuación, en la cual, nos ayudaran a obtener visualizaciones de las distribuciones de los datos, facilitando así la comprensión de su forma y comportamiento.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Para comenzar, utilizaremos la función head() de la librería Pandas, como podemos ver en la Fig. 4. Dicha función muestra las primeras cinco filas del dataframe. Esto nos permite tener una idea general del contenido del conjunto de datos, ayudándonos a identificar rápidamente las características presentes y su formato.

	id	Región de la universidad	Antigüedad de la universidad	Tamaño de la universidad	Descripción de la universidad	Carrera	Año de ingreso	En cuál de las siguientes situaciones te encontrás?	Relación actual con la carrera (3 categorías)	Relación actual con la carrera (4 categorías)
0	75	Centro	Intermedia	Chica	Universidad del Centro, Intermedia y con matrí...	Ingeniería en Sistemas de Información	2018	Soy estudiante, estoy cursando actualmente	Estudiante	Estudiante regular
1	76	Centro	Intermedia	Chica	Universidad del Centro, Intermedia y con matrí...	Ingeniería en Sistemas de Información	2008	Soy estudiante, pero ya terminé toda la cursad...	Estudiante	Estudiante final
2	77	Centro	Intermedia	Chica	Universidad del Centro, Intermedia y con matrí...	Ingeniería en Sistemas de Información	2016	Soy estudiante, estoy cursando actualmente	Estudiante	Estudiante regular
3	78	Centro	Intermedia	Chica	Universidad del Centro, Intermedia y con matrí...	NaN	2020	Soy estudiante, estoy cursando actualmente	Estudiante	Estudiante regular
4	81	Cuyo	Intermedia	Mediana	Universidad de Cuyo, Intermedia y con	Licenciatura en Ciencias de la	1989	Abandoné los estudios relacionados	Abandonante	Abandonante

Figura 4-Primeras cinco filas del dataframe

Siguiendo con las funciones proporcionadas por la librería, emplearemos la función describe(), como podemos ver en la Fig. 5, que generó un resumen estadístico de las características numéricas. Por ejemplo, al analizar la

característica "año de egreso del secundario", obtuvimos estadísticas clave como la media, la desviación estándar, los valores mínimo y máximo, así como los percentiles. Esto fue fundamental para comprender la distribución y dispersión de los datos numéricos.

	Año de egreso del secundario
count	1138.000000
unique	NaN
top	NaN
freq	NaN
mean	2002.260105
std	349.572085
min	0.000000
25%	2006.000000
50%	2014.000000
75%	2018.000000
max	11970.000000

Figura 5-Resumen estadístico de las características numéricas

Para obtener un resumen estadístico de las características categóricas, utilizaremos la misma función que empleamos para las características numéricas, pero especificando la inclusión de características categóricas mediante la cláusula include.

Como podemos observar en la Fig. 6, la función genera como resultado un resumen estadístico adaptado a este tipo de datos para la característica "Relación actual con la carrera (4 categorías)". Este resumen incluye información como el recuento de valores únicos, el valor más frecuente y su frecuencia, permitiéndonos comprender mejor la composición de las características categóricas.

	Relación actual con la carrera (4 categorías)
count	1208
unique	4
top	Estudiante regular
freq	589

Figura 6-Resumen estadístico de la característica "Relación actual con la carrera (4 categorías)"

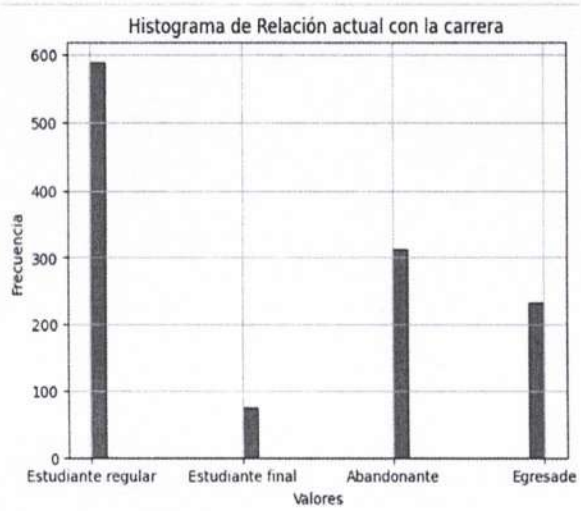
Como mencionamos al principio de esta etapa, es fundamental complementar esta tarea con la representación gráfica de los datos en el que podemos observar y analizar el comportamiento de las distribuciones de los datos de manera más intuitiva.

Como detallamos en el marco tecnológico, en Python, podemos emplear bibliotecas como Matplotlib junto con Pandas para crear gráficos como el de histogramas, que facilitara la visualización de los datos, como podemos ver en la Fig. 7. Este gráfico es útil para el EDA y el análisis descriptivo, ya que, permite visualizar la distribución de una característica categórica como en este caso la característica "Relación actual con la carrera (4

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

categorías)". También, podemos extraer información descriptiva sobre los datos, como la frecuencia de cada categoría, las categorías más y menos comunes, etc. Esto aporta valiosas insights sobre el conjunto de datos. Así mismo, permite detectar características relevantes de los datos que pueden guiar análisis posteriores más profundos.



Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Figura 7-Histograma de la característica "Relación actual con la carrera"

Empleando la misma biblioteca de Python podemos generar otros gráficos, como el de barra, como podemos ver en la Fig. 8, este gráfico es una excelente herramienta para visualizar y analizar la distribución de características, en este caso podemos observar la característica "Año de ingreso" de manera clara y concisa, permitiendo ver fácilmente la frecuencia o cantidad de cada categoría de año de ingreso en el cual facilita la identificación de los años con mayores y menores ingresos. Además, al presentar los datos en forma de barras, es sencillo comparar la magnitud de los ingresos entre los diferentes años, lo que puede revelar patrones y tendencias en el tiempo. El gráfico de barras también ayuda a entender la distribución general de los ingresos por año, identificando picos y outliers, lo cual es fundamental para el EDA.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes



Figura 8-Gráfico de barra de la característica Año de ingreso

Con la herramienta RapidMiner una vez que cargamos nuestros datos, con la sección "Visualizations" podemos generar hasta 36 gráficos diferentes y observar resúmenes estadísticos de manera eficiente, como podemos ver en las Fig. 9 y 10, observamos algunos de los gráficos generados, el gráfico de barras de las características "Descripción de la universidad" y "Identidad de género". Este tipo de representación visual nos permite analizar y comparar fácilmente la distribución de los valores.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

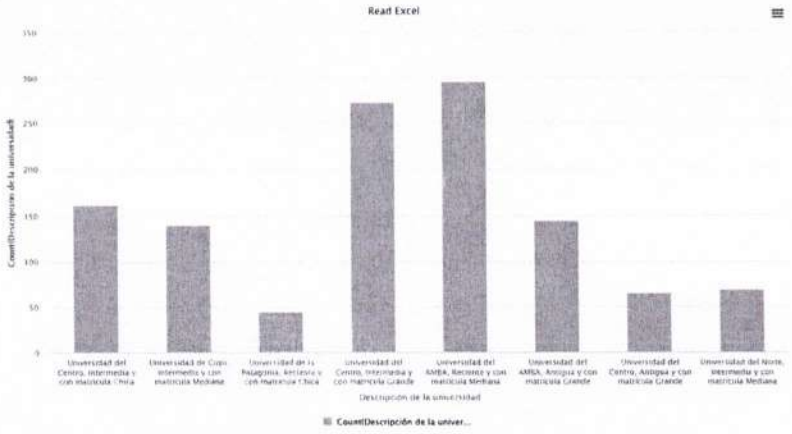


Figura 9-Gráfico de barra de la característica Descripción de la Universidad

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

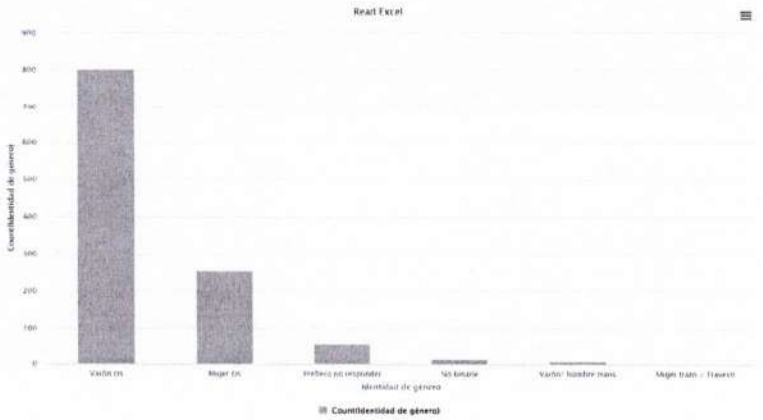


Figura 10-Gráfico curva de barra de la característica Identidad de genero

Por último, usaremos Sweetviz, herramienta que facilita el EDA al generar informes detallados y visuales. Utilizando la función Analyze(), podemos analizar todo el conjunto de datos de una manera eficiente.

Al ejecutar esta función en Python, Sweetviz proporciona un análisis detallado de cada característica individual dentro del conjunto de datos. En la Fig. 11, podemos ver un ejemplo de este análisis aplicado a una característica específica, "Actividades en proyectos o equipos de investigación". Sweetviz visualiza la distribución de las categorías dentro de la característica, presentando tanto los porcentajes como el número total de observaciones para cada categoría. Esta visualización facilita la

comprensión rápida de la estructura y distribución de los datos, permitiendo identificar patrones, anomalías y posibles áreas de interés para un análisis más profundo.

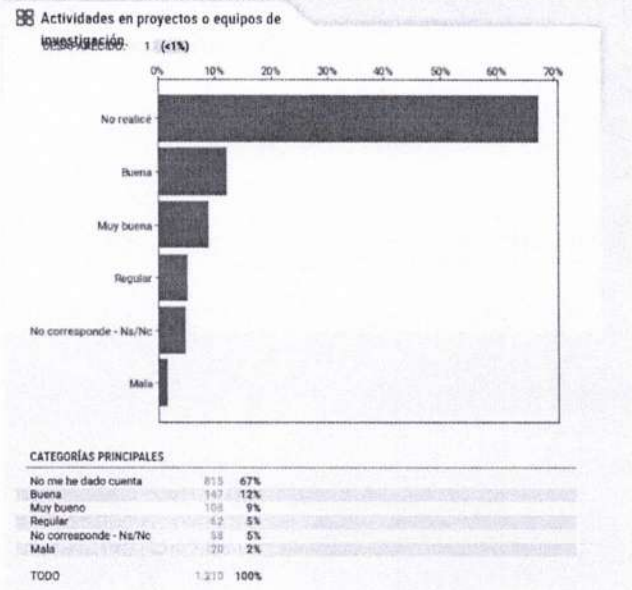


Figura 11-Gráfico de la característica "Actividades en Proyectos o equipos de investigación"

2. Ajuste de los tipos de variables:

Siguiendo la guía, en esta segunda etapa lo que se realiza es una verificación para asegurarse de que cada característica esté correctamente tipificada.

Es crucial comprobar que las características numéricas están representadas como números, y que las características categóricas están definidas como cadenas de caracteres y contienen una cantidad finita de elementos. Este paso es esencial para garantizar que las operaciones y análisis posteriores se realicen de manera correcta y precisa, evitando errores que puedan surgir de una tipificación incorrecta.

El ajuste de los tipos de características permite abordar principalmente el desafío del EDA mencionado, tipos mixtos o heterogeneidad, asegurando que las operaciones y análisis posteriores se realicen correctamente y que las características estén en el formato adecuado para su tratamiento.

En Python, se puede utilizar la función info() de Pandas como podemos ver en la Fig. 12 para verificar el tipo de datos de cada característica en un dataframe. Esta función proporciona un resumen completo del dataframe, que incluye el número total de filas, el tipo de dato asociado a cada columna, y el número de valores no nulos presentes en cada columna.

Este resumen es útil para verificar que las características estén correctamente tipificadas. Y en caso de ser necesario se corrige el problema en la etapa de limpieza de datos, por ejemplo, si el caso en que se espera que una columna específica fuese numérica, pero aparece como object.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1211 entries, 0 to 1210
Columns: 205 entries, id to Te gustaría participar de estas entrevistas
dtypes: float64(3), int64(2), object(200)
memory usage: 1.9+ MB
```

Figura 12-Resumen completo del dataframe

En esta etapa también utilizaremos la herramienta Sweetviz, y ejecutaremos la función Analyze(), en el cual genera un informe inicial que ofrece un resumen del marco de datos, como se muestra en la Fig. 13. Este informe incluye detalles como el número de filas, la cantidad de duplicados, el uso de memoria, la cantidad de características categóricas, numéricas y de texto, entre otros aspectos clave.

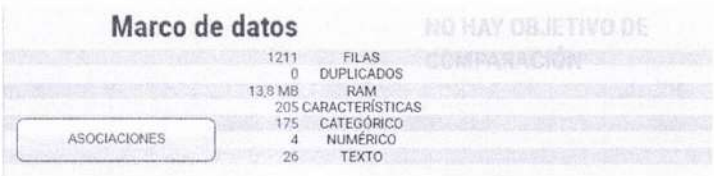


Figura 13-Informe inicial del dataframe con Sweetviz

Además, como se observó anteriormente, Sweetviz genera gráficos de barras que muestran la distribución de las categorías dentro de una característica, presentando tanto los porcentajes como el número total de observaciones por cada categoría. Esta visualización facilita una comprensión rápida de la estructura y distribución de los datos, permitiendo identificar fácilmente valores inconsistentes o errores de codificación. Por ejemplo, nos ayuda a asegurar que las características categóricas cuenten con un número finito de categorías y que no existan codificaciones incorrectas (como "Sí", "No", "no").

Además, para las características de fecha, Sweetviz nos permite verificar que estén correctamente representadas como objetos de tipo fecha y no como cadenas de texto, lo que resulta esencial para realizar análisis como series temporales o cálculos de diferencias de tiempo.

Por último, la herramienta también ayuda a detectar valores atípicos (outliers) que podrían surgir durante el ajuste de los tipos de datos, destacando cualquier valor inusual o fuera de rango que deba ser investigado o tratado.

3. Detección de datos ausentes

A continuación, en esta tercera etapa según la guía, la presencia de datos ausentes, también conocidos como valores perdidos o celdas vacías, en el que detallados en el marco teórico son un problema común en muchos conjuntos de datos.

Trabajar con conjuntos de datos que contienen valores ausentes puede generar dificultades al aplicar análisis estadísticos y al crear representaciones gráficas, afectando la precisión y la integridad de los resultados. Además, los valores ausentes no solo afectan la precisión y la integridad de los análisis estadísticos y las representaciones gráficas, sino que también pueden impactar negativamente la predicción de un modelo

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

de DM, introduciendo sesgos, reduciendo la capacidad predictiva y complicando el proceso de modelado.

Para evitar estos problemas, es fundamental detectar dichos datos ausentes y aplicar un tratamiento adecuado en la etapa de limpieza de datos. Esto asegura que los análisis posteriores se realicen sobre un conjunto de datos lo más completo y preciso posible.

La detección de datos ausentes aborda principalmente el desafío de valores perdidos y valores atípicos planteado, asegurando que los análisis y visualizaciones posteriores se realicen sobre un conjunto de datos íntegro y confiable.

En Python, la detección de datos ausentes se puede realizar como vemos en la Fig. 14 utilizando el método isnull() de Pandas, combinado con sum(). Este método devuelve una matriz booleana que indica la presencia de valores nulos, y al aplicar sum(), se obtiene el número total de valores ausentes en cada columna del dataframe.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

```
Región de la universidad                  18
Antiguedad de la universidad              18
Tamaño de la universidad                  18
Descripción de la universidad             18
Carrera                                   25
                                          ..
Mayor nivel educativo madre               73
Mayor nivel educativo padre               73
Clima educativo del hogar                 73
Clima educativo (2 categorías)            73
Te gustaría participar de estas entrevistas  83
Length: 165, dtype: int64
```

Figura 14-Detección de datos ausentes con Pandas

Además, con las herramientas Sweetviz y la RapidMiner también podemos detectar datos ausentes de manera eficiente, como podemos ver en las Fig. 15 y 16, para la característica "Edad".

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

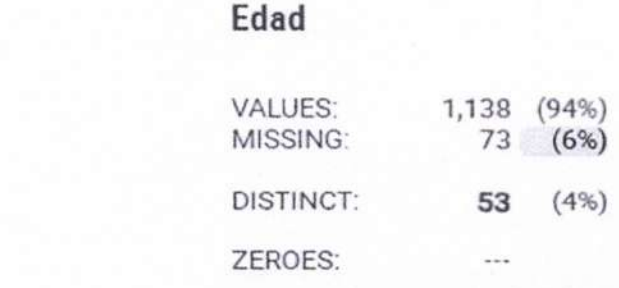


Figura 15-Detección de datos ausentes con Sweetviz

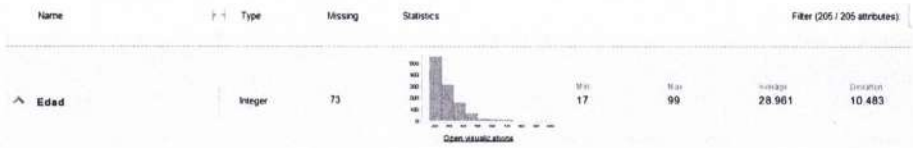


Figura 16-Detección de datos ausentes con RapidMiner

Para la parte del tratamiento de valores faltantes la guía detalla que existen varias maneras de tratarlos, como por ejemplo, rellenar los valores con la media, mediana o el valor más frecuente de la característica, completar los valores que faltan por el valor que esté directamente antes o después en la fila o columna, completar todos los datos faltantes con 0, si se trata de valores numéricos, eliminar las filas que presenten valores ausentes, siempre y cuando el conjunto de datos sea lo suficientemente grande y no se pierde información relevante al eliminar esas filas, y por último, una forma abrupta de tratamiento que depende del contexto de análisis, es eliminar las características que presentan un porcentaje específico de datos ausentes.

En nuestro caso, para llevar a cabo dicho tratamiento en la etapa de limpieza de datos, nos centraremos en la última estrategia, que implica eliminar las características con el 30% de datos ausentes,

4. Detección de valores atípicos (outliers):

La detección de valores atípicos, previamente definidos en el marco teórico, aborda principalmente el desafío de valores perdidos y valores atípicos planteado.

En Python, se puede emplear funciones que nos permita una visualización gráfica para identificar los valores atípicos a través de gráficos como diagramas de caja (boxplots) en lo cual permite visualizar la distribución de los datos y detectar valores atípicos. Nuevamente haremos uso de la biblioteca Matplotlib para crear estos gráficos.

Como se mencionó al principio de este capítulo, ciertos análisis dentro del EDA, como la correlación entre características y, en este caso, la detección de valores atípicos, requieren que las características categóricas se transformen en numéricas. Para ello, se empleó la función LabelEncoder() de Pandas, la cual asigna un valor numérico a cada categoría dentro de una característica, permitiendo que las características categóricas sean tratadas como numéricas en el análisis. Esta transformación anticipada es un ejemplo de la naturaleza iterativa del proceso de pre-procesamiento de datos, porque estamos avanzando a la etapa "Transformación o generación de las características adicionales", etapa posterior a la de limpieza de datos.

En la Fig. 17 podemos ver el gráfico boxplot, ilustra la dispersión de los datos dentro de la característica "Identidad de género" y permite visualizar posibles valores atípicos en relación con las demás observaciones. En el gráfico, cada punto que se encuentra fuera de los bigotes del boxplot representa un outlier potencial, lo que sugiere que esos datos se desvían significativamente del resto de las observaciones.}

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Cpde. RESOL. C. ESC. ING. Y CS. AMB. Nº 28/2024

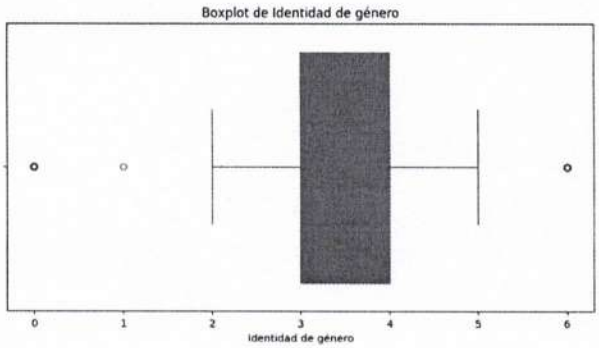


Figura 17-Gráfico BoxPlot de la característica "Identidad de género"

Este tipo de visualización es fundamental para comprender cómo se distribuyen los datos dentro de una categoría particular y detectar cualquier irregularidad que pueda influir en los análisis posteriores. Identificar y tratar estos valores atípicos es esencial, ya que pueden distorsionar la interpretación de los resultados y afectar la precisión de los modelos predictivos.

La detección temprana de outliers, especialmente en características categóricas como "Identidad de género", permite tomar decisiones informadas sobre si estos valores deben ser tratados, transformados o eliminados antes de proceder con análisis más complejos. Además, la visualización gráfica facilita una interpretación intuitiva y rápida de la calidad y consistencia de los datos.

El tratamiento de los valores atípicos, detectados se llevará a cabo en la etapa de limpieza de datos, de igual manera que los valores faltantes.

5. Análisis de correlación entre variables

El análisis de correlación, previamente definido en el marco teórico, está diseñado para abordar los desafíos de dimensionalidad y heterogeneidad al ayudar a identificar y gestionar la redundancia en los datos, lo que puede simplificar los análisis y mejorar la interpretabilidad y eficiencia del modelo. Si se encuentra una correlación significativa entre dos características, podría ser posible simplificar el conjunto de datos eliminando una de ellas, lo cual puede reducir la complejidad en el procesamiento y análisis futuros. Esta práctica es común en el EDA y está estrechamente relacionada con el PCA.

Como se mencionó anteriormente, este análisis está directamente relacionado con el reto de tipos mixtos o heterogeneidad. Por lo tanto, para realizar el análisis de correlación, utilizamos el dataframe con todas las columnas convertidas a numéricas utilizando LabelEncoder() en la etapa anterior de detección de valores atípicos. Esta conversión permitió que las características categóricas pudieran ser incluidas en el análisis de correlación, asegurando que el coeficiente r fuera calculado de manera precisa y que la relación entre todas las características pudiera ser evaluada.

La correlación que realicemos es la lineal, empleando Python con la función corr(), la cual calcula la matriz de correlación para todas las características numéricas en el dataframe. Esta matriz de correlación es fundamental para identificar relaciones directas o inversas entre las características, y

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

proporciona una base sólida para cualquier análisis predictivo que se realice posteriormente.

La matriz de correlación obtenida fue graficada utilizando la biblioteca Matplotlib, lo que permitió visualizar de manera clara las relaciones entre las diferentes características como vemos en la Fig. 18. Este gráfico facilitó la identificación de características altamente correlacionadas, lo cual es clave para tomar decisiones informadas sobre la inclusión o exclusión de características en modelos predictivos y para comprender mejor la estructura subyacente de los datos. Para una visualización más detallada del gráfico completo se encuentra en el Apéndice B.1.

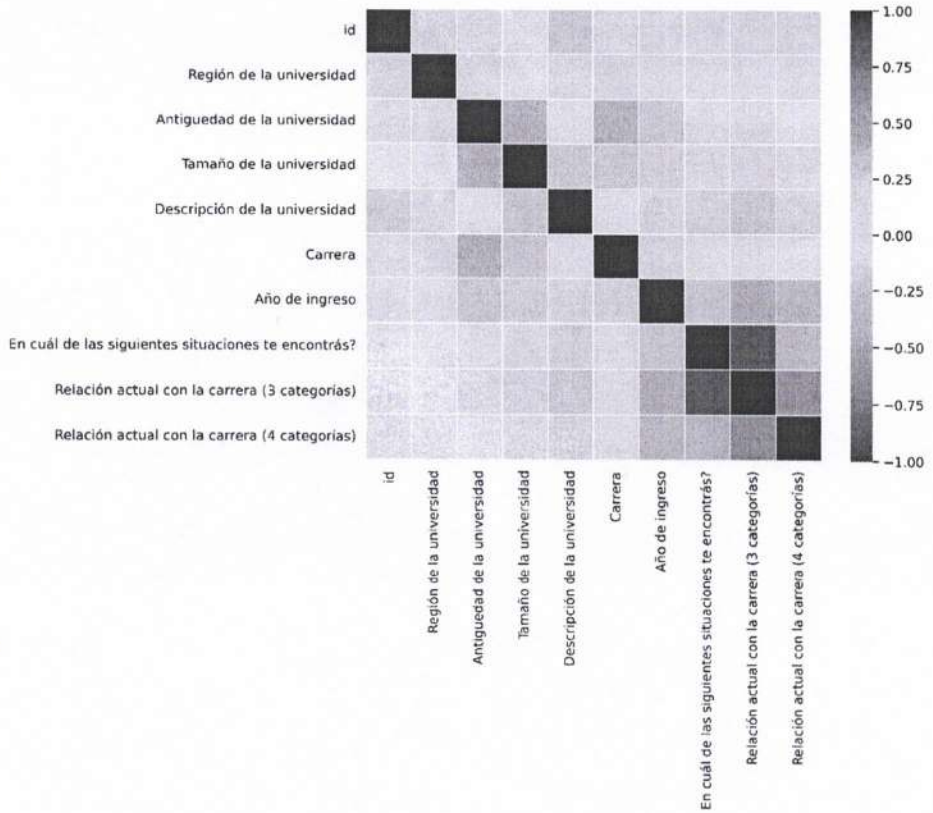


Figura 18-Parte del gráfico de matriz de Correlación Lineal ver gráfico total en apéndice B.1

5.2.4 Limpieza de datos

Después de la etapa del EDA, se procede a limpiar los datos, para su posterior utilización en la ejecución de los algoritmos de ML.

Es muy importante destacar la relevancia que este proceso tiene en el desarrollo del informe ya que, estas actividades impactan directamente en los resultados de la ejecución de los algoritmos de ML. Dicho de otro modo, estas actividades de limpieza de los datos influyen directamente en la calidad y la confiabilidad de los resultados.

Como se detalla en el marco teórico, la etapa de limpieza de datos implica corregir errores, valores faltantes en los datos, estandarizar formatos, unidades y convenciones de los datos, eliminar o filtrar datos irrelevantes o

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

redundantes, y asegurar la calidad y la integridad de los datos para su posterior análisis.

Python y el uso de bibliotecas como Pandas, será sumamente útil para esta etapa, estas bibliotecas ofrecen funcionalidades para llevar a cabo las tareas de limpieza y preparación de los datos de manera eficiente.

La limpieza de datos es un paso crítico en el proceso de EDM, ya que garantiza que el conjunto de datos esté en condiciones óptimas para ser analizado de forma efectiva en las siguientes etapas del proceso.

A continuación, detallaremos el proceso de limpieza acompañado del código en el apéndice A.2.

5.2.4.1 Proceso de limpieza de datos

En el proceso de limpieza de datos, se aplicaron distintos métodos para el análisis, transformación y limpieza de los datos, utilizando el lenguaje de programación Python, implementando diferentes librerías [27].

Estos métodos fueron, método de extracción de datos, por medio de las funciones que nos proporciona la librería Pandas, se realizó la lectura de los registros provenientes de archivos en formato de XLSX (hoja de cálculo de Microsoft Excel), para ser incorporados al informe, dicha actividad detallada en nuestro informe final en el punto 4.2.1.3 "Importación de los datos". Método de limpieza y transformación de los datos, una vez obtenidos los datos se llevó a cabo una limpieza de datos irrelevantes donde se filtraron únicamente las características influyentes. A partir de esto, se generó un nuevo archivo de registros en formato xlsx. Y, por último, método de carga de datos preparados, se realizó la exportación de los registros por medio de funciones que nos proporciona la librería Pandas para que pudiesen ser utilizados en los algoritmos de ML.

En la limpieza de datos se resolverán principalmente los problemas presentados durante la etapa del EDA. La resolución de estos problemas incluirá el tratamiento de los valores faltantes, así como de los valores atípicos.

Para los valores faltantes es fundamental identificar y gestionar las características que presentan una cantidad significativa de valores ausentes o NaN (not a number). Determinar el umbral adecuado para los valores faltantes es crucial para mantener la calidad y la representatividad de los datos.

En este análisis, hemos establecido un umbral del 30% para los valores faltantes por columna. Esto significa que cualquier característica con más del 30% de registros con valores ausentes será eliminada del análisis. Esta decisión se basa en la premisa de que las columnas con un alto porcentaje de valores perdidos probablemente no aporten información relevante ni significativa para el modelo predictivo, y su inclusión podría deteriorar el rendimiento del mismo.

Un ejemplo de esto es la columna "Cantidad de materias/tesis que debe (sólo estudiantes que terminaron la cursada)", que tiene un total de 1,179 valores faltantes Fig. 19 contra los 1211 valores que representa el total de la muestra, representando un porcentaje superior al 30%. Por lo tanto, consideramos que esta característica no es relevante para el modelo. Los valores ausentes pueden representar un problema si son demasiado numerosos, afectando la robustez del análisis.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

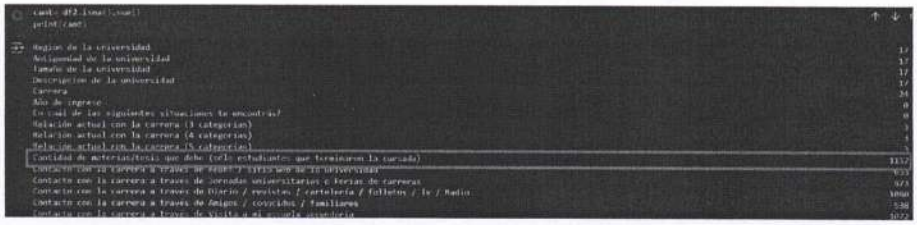


Figura 19- Descripción de valores faltantes por cada característica

Al aplicar este criterio de limpieza, se reduce la cantidad de características a un total de 85 contra las 205 que la muestra presentaba en un principio, lo que a su vez ayuda a enfrentar los desafíos de alta dimensionalidad y la presencia de valores perdidos en el EDA. Este proceso mejora la calidad y la eficiencia del modelado predictivo, asegurando que las características restantes sean las más útiles y representativas para el análisis.

Sweetviz que proporciona un análisis detallado de cada característica individual dentro del conjunto de datos, muestra información relevante, como el porcentaje de valores faltantes para cada característica de manera individual. Como se observa en la Fig. 20, esto es especialmente evidente en la característica "Cursaste otra carrera previamente".

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

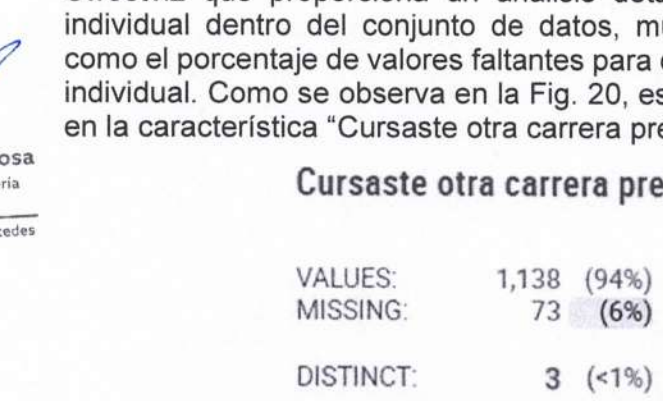


Figura 20- Porcentaje de valores faltantes de la característica "Cursaste otra carrera previamente"

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

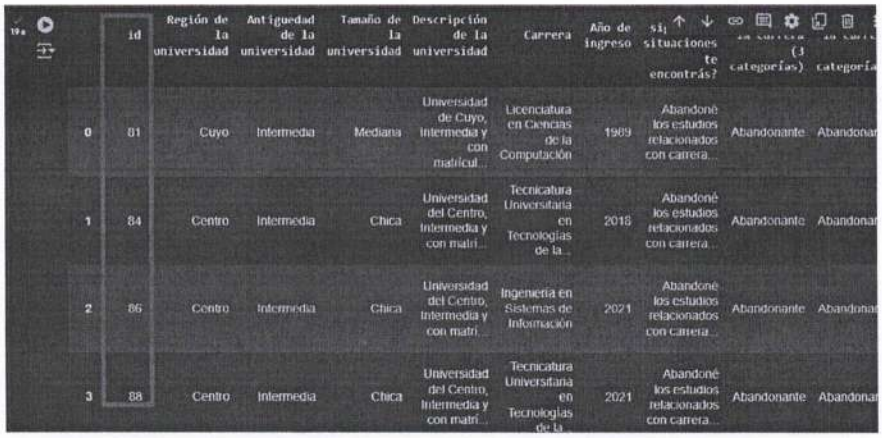
En el tratamiento de outliers, se identificó que los valores desviados eran escasos, por lo que no se consideró necesario eliminarlos, ya que no afectaban de manera significativa al análisis. En lugar de eliminarlos, se optó por reemplazarlos utilizando la media de la columna correspondiente. En la columna "Edad", los valores extremos de 99 fueron sustituidos por la media de los valores válidos de la columna, excluyendo los outliers. Esto se realizó mediante las funcionalidades de Pandas. De forma similar, para la columna "Año de egreso del secundario", se identificaron valores fuera de lo esperado (como 0.0, 4.0, 5.0, 7.0, 17.0, 18.0, 28.0, 93.0, 11970.0) y se procedió a reemplazarlos también por la media calculada, omitiendo dichos valores.

Este enfoque permitió mantener la consistencia de los datos sin introducir sesgos significativos, preservando la información mientras se mitigaban los efectos de los valores atípicos.

Una vez resueltos los desafíos que se presentaron en la etapa de EDA, se procedió con la revisión y eliminación de los atributos.

Cuando se analiza el dataframe en nuestro informe, se hace un recorrido sobre cada atributo y como se observa en la Fig. 21. La columna "id"

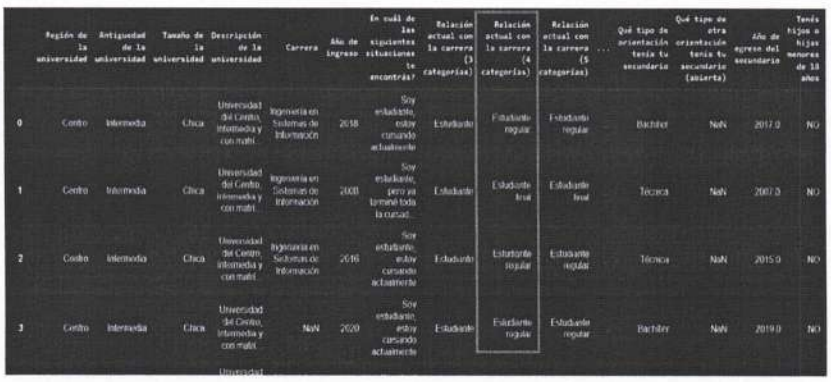
contiene valores únicos para cada registro. Esto significa que cada fila tiene un identificador único que la distingue de las demás.
Sin embargo, en este caso, ese identificador no aporta información relevante para el objetivo del modelo que estás desarrollando. Por lo tanto, se decide eliminar esa columna durante la etapa de limpieza del dataframe, ya que no es necesario para el análisis que vas a realizar.



	id	Región de la universidad	Antigüedad de la universidad	Tamaño de la universidad	Descripción de la universidad	Carrera	Año de ingreso	Si situaciones te encontrás?	(3 categorías)	categoría
0	81	Cuyo	Intermedia	Mediana	Universidad de Cuyo, Intermedia y con matrícul...	Licenciatura en Ciencias de la Computación	1989	Abandoné los estudios relacionados con carrera...	Abandonante	Abandonar
1	84	Centro	Intermedia	Chica	Universidad del Centro, Intermedia y con matri...	Tecnicatura Universitaria en Tecnologías de la...	2018	Abandoné los estudios relacionados con carrera...	Abandonante	Abandonar
2	86	Centro	Intermedia	Chica	Universidad del Centro, Intermedia y con matri...	Ingeniería en Sistemas de Información	2021	Abandoné los estudios relacionados con carrera...	Abandonante	Abandonar
3	88	Centro	Intermedia	Chica	Universidad del Centro, Intermedia y con matri...	Tecnicatura Universitaria en Tecnologías de la...	2021	Abandoné los estudios relacionados con carrera...	Abandonante	Abandonar

Figura 21-Proceso limpieza de datos, eliminación de la característica "id"

Por consiguiente, se procedió a eliminar dos columnas redundantes, podemos observarlas en la Fig. 22 y 23. La primera, que contenía 4 categorías de "Relación con la carrera", ya que se identificó que esta información estaba duplicada en otra característica de 3 categorías.
Adicionalmente, se eliminó otra columna que contenía 5 categorías de "Relación con la carrera", dado que esta característica también resultaba redundante con la información de la característica de 3 categorías. Luego de estos ajustes, se continuó con el análisis y procesamiento de las características restantes para preparar los datos de entrada al modelo predictivo de abandono universitario.



	Región de la universidad	Antigüedad de la universidad	Tamaño de la universidad	Descripción de la universidad	Carrera	Año de ingreso	En cuál de las siguientes situaciones te encontrás?	Relación actual con la carrera (3 categorías)	Relación actual con la carrera (4 categorías)	Relación actual con la carrera ... (5 categorías)	Qué tipo de orientación tenía tu secundario	Qué tipo de otra orientación tenía tu secundario (abierta)	Año de egreso del secundario	Tenés hijos o hijes menores de 18 años
0	Centro	Intermedia	Chica	Universidad del Centro, Intermedia y con matri...	Ingeniería en Sistemas de Información	2018	Soy estudiante, estoy cursando actualmente	Estudiante	Estudiante regular	Estudiante regular	Bachiller	NaN	2017.0	NO
1	Centro	Intermedia	Chica	Universidad del Centro, Intermedia y con matri...	Ingeniería en Sistemas de Información	2008	Soy estudiante, pero ya terminé toda la cursad...	Estudiante	Estudiante final	Estudiante final	Técnico	NaN	2007.0	NO
2	Centro	Intermedia	Chica	Universidad del Centro, Intermedia y con matri...	Ingeniería en Sistemas de Información	2016	Soy estudiante, estoy cursando actualmente	Estudiante	Estudiante regular	Estudiante regular	Técnico	NaN	2015.0	NO
3	Centro	Intermedia	Chica	Universidad del Centro, Intermedia y con matri...	NaN	2020	Soy estudiante, estoy cursando actualmente	Estudiante	Estudiante regular	Estudiante regular	Bachiller	NaN	2019.0	NO

Figura 22- Eliminación de característica "Relación actual con la carrera (4 categorías)"

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Relación actual con la carrera (5 categorías)	..	Qué tipo de orientación tenía tu secundario	Qué tipo de otra orientación tenía tu secundario (abierta)	Año de egreso del secundario	Tenés hijos o hijas menores de 18 años
Estudiante regular	...	Bachiller	NaN	2017.0	NO
Estudiante final	...	Técnica	NaN	2007.0	NO
Estudiante regular	...	Técnica	NaN	2015.0	NO
Estudiante regular	...	Bachiller	NaN	2019.0	NO

Figura 23- Eliminación de característica "Relación actual con la carrera (5 categorías)"

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Por último, siguiendo con la revisión y eliminación de los atributos, procedemos a eliminar la característica "Te gustaría participar de estas entrevistas", dada en la Fig. 24, la razón es que esta característica está relacionada con una preferencia personal o una intención futura, lo que no aporta información útil para predecir la característica objetivo de nuestro modelo. Al eliminar características que no contribuyen significativamente al poder predictivo del modelo, se mejora la eficiencia computacional y se facilita la optimización de los hiperparámetros y el rendimiento general del modelo.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Te tuviste que mudar de ciudad/localidad para poder asistir a la Universidad	Mayor nivel educativo madre	Mayor nivel educativo padre	Clima educativo del hogar	Clima educativo (2 categorías)	Te gustaría participar de estas entrevistas
No	Universitaria completa	Universitaria completa	Universitaria completa	Universitario	NaN
No	Universitaria completa	Universitaria incompleta	Universitaria completa	Universitario	Sí, Dejanos un mail de contacto o te...
Sí (de ciudad / localidad / provincia)	Terciaria completa	Universitaria completa	Universitaria completa	Universitario	No
No	Posgrado completo	Universitaria incompleta	Posgrado completo	Universitario	No
No	Secundaria completa	Secundaria completa	Secundaria completa	No universitario	Prefiero no responder
...	...	...	...	...	...
No	Secundaria completa	Secundaria incompleta	Secundaria completa	No universitario	No

Figura 24- Eliminación de característica "Te gustaría participar de estas entrevistas"

5.2.5 Transformación o generación de variables adicionales

Después de la etapa de limpieza de datos, se realizó la transformación y generación de variables adicionales, un proceso esencial para optimizar el análisis y mejorar el rendimiento de los modelos predictivos. Este proceso no solo implicó la selección cuidadosa de variables mediante técnicas estadísticas, sino también la creación de nuevas variables que aportaron valor significativo a los modelos de predicción de deserción estudiantil.

La selección de variables se basó en la interpretación de varios modelos de aprendizaje automático, como Árboles de Decisión, Random Forest, XGBoost y CatBoost. Se utilizaron enfoques como la importancia de características y el análisis de permutación de características para identificar las variables con mayor impacto en la predicción de la deserción, lo que mejoró considerablemente la precisión del modelo.

Entre las transformaciones más relevantes, se llevó a cabo la codificación binaria (0 y 1) en la característica "Percepción de materias filtro", lo que facilitó su uso en los modelos. De igual manera, la característica objetivo "Relación actual con la carrera" fue codificada en 0 y 1 para distinguir entre estudiantes que abandonaron y aquellos que permanecen en la carrera, ya sea en curso o como egresados. Además, se desglosó la característica "Año/s de las materias filtro (abierta)" en varias columnas correspondientes a cada año (1º, 2º, 3º, 4º, 5º), asignando valores de 0 o 1 según el año mencionado por el estudiante, lo que permitió una mayor granularidad en el análisis de los datos.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Una de las transformaciones más importantes fue la creación de la característica "demora", que representa la diferencia entre el año de ingreso y el año de egreso. Esta nueva característica proporcionó información adicional sobre el tiempo que cada estudiante pasó en la carrera, aportando un contexto valioso para los modelos predictivos.

Por otro lado, se realizó un tratamiento específico para manejar los valores faltantes en algunas características. Los valores "No sé" y "No corresponde" de las características "El título me posiciona en una situación diferencial en el mercado de trabajo", "Evaluación Relación con docentes", "Actividades de extensión" y "Obtener el título no me brinda ninguna ventaja laboralmente" se reemplazaron por la moda, ya que estas eran características categóricas. En cuanto a la característica "Relación actual con la carrera", que presenta tres categorías y es numérica, sus valores nulos fueron reemplazados por la media.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Finalmente, se llevó a cabo un proceso de balanceo del dataset, lo que incluyó la adición de más instancias de abandono, con el fin de equilibrar la distribución de la característica objetivo. Este balanceo fue crucial para mejorar la capacidad del modelo predictivo de identificar patrones relacionados con la deserción estudiantil.

Todas estas transformaciones y selecciones de características fueron fundamentales para simplificar el modelo y mejorar el rendimiento de los algoritmos de clasificación, permitiendo una mejor interpretación de los resultados y un desempeño más robusto del modelo.

5.2.5.1 Reducción de dimensionalidad mediante PCA

La selección de características tiene como objetivo identificar el subconjunto más relevante y representativo que influye en el rendimiento

académico de los estudiantes. Para lograr esto, el primer paso es reducir la dimensionalidad del conjunto de datos, buscando ese subconjunto más pequeño, significativo y depurado. Este proceso se llevó a cabo mediante la limpieza de datos, descrita en las secciones anteriores, lo que permitió eliminar características irrelevantes o redundantes y optimizar el análisis posterior.

En las secciones anteriores, a pesar de haber completado la limpieza de los datos, logramos reducir solo el 60% de las características, pasando de 205 a 81 características. Si bien este es un avance significativo, nuestro objetivo es encontrar un subconjunto de características aún más reducido, pero igualmente relevante y representativo, que influya en el rendimiento académico de los estudiantes.

Es importante destacar que, al momento de hacer predicciones, lo ideal es trabajar con la menor cantidad de información posible, sin sacrificar precisión. Esto se debe a que, si tuviéramos que solicitar las 81 características de cada estudiante cada vez que quisiéramos predecir su rendimiento, el proceso sería considerablemente complejo en términos operativos. Un modelo predictivo eficiente no solo debe ser preciso, sino también práctico y ágil, utilizando la menor cantidad de características necesarias para mantener su efectividad. Por ello, la búsqueda de un conjunto más pequeño de características clave sigue siendo un desafío crucial para mejorar tanto la predicción como la aplicabilidad del modelo en contextos reales.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Para abordar este reto, se decidió implementar una técnica de reducción de dimensionalidad, como PCA, el código de implementación se encuentra en el apéndice A.3. Esta técnica transforma las características originales en un conjunto de componentes principales no correlacionados, que capturan la mayor parte de la variabilidad de los datos con un número reducido de dimensiones. Esta transformación es crucial para identificar y retener solo aquellas características que aportan valor real al modelo, evitando así el sobreajuste y mejorando la eficiencia del proceso.

Para implementar el PCA, primero se estandarizaron los datos utilizando la función StandardScaler de la biblioteca Sklearn, lo cual ajusta las características para que tengan una media de 0 y una desviación estándar de 1. Este paso es fundamental ya que el PCA es sensible a la escala de las características. Posteriormente, se aplicó el PCA, reduciendo las 205 características originales a 70 componentes principales, preservando la mayor parte de la información relevante. La nueva forma del conjunto de datos resultante fue (1137, 70), lo que representa una reducción significativa en la complejidad del modelo.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Sin embargo, esta reducción trae consigo un desafío interpretativo importante. Los nuevos componentes principales generados por el PCA no conservan los valores originales de las características, lo que dificulta una interpretación directa de los resultados en términos del modelo predictivo.

Además, el uso del PCA no cumplió plenamente con nuestras expectativas, ya que, aunque se aplicó para reducir la dimensionalidad, solo se logró disminuir el número de características a 70. Nuestro objetivo era una reducción más significativa.

5.2.5.2 Interpretabilidad de modelos

En las secciones anteriores, se realizaron diversas etapas de limpieza de datos y se aplicó PCA para reducir la dimensionalidad del conjunto de datos. Sin embargo, estas técnicas no lograron simplificar de manera significativa la complejidad del conjunto, lo que dificultó una interpretación directa de las características. Ante esta limitación, se recurrió a técnicas de interpretabilidad del modelo de árbol de decisión, las cuales resultaron fundamentales para identificar las características más influyentes en la predicción de la deserción estudiantil. Este enfoque interpretativo permitió seleccionar y conservar solo las características más relevantes, cumpliendo con el objetivo inicial planteado en este capítulo. Así, no solo se mejoró el rendimiento del modelo, sino que también se facilitó la comprensión de las decisiones tomadas por el algoritmo, un aspecto clave en el contexto de predicción de la deserción.

5.2.5.2.1 Resultados de la interpretabilidad

Los análisis de interpretabilidad realizados mediante técnicas como Feature Importance y Permutation Importance revelaron que las características "Hubo un cuatrimestre en el que no te anotaste", "¿En cuál de las siguientes situaciones te encontrás?" y "Realizaste en algún momento el trámite de reinscripción para volver a ser estudiante regular" tuvieron una alta influencia en la predicción de la deserción estudiantil, como podemos observar en las Fig. 25 y 26. Para una visualización más detallada de los gráficos completos se encuentran en el Apéndice B.2.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

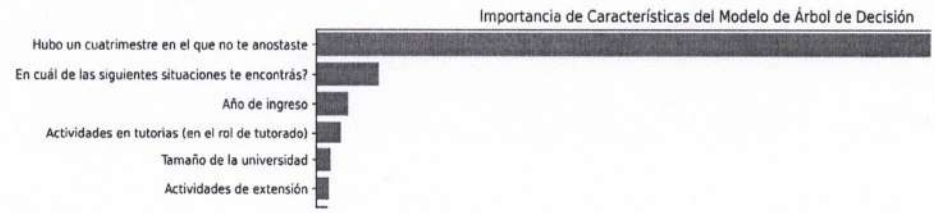


Figura 25-Parte de grafico Feature Importance de Árbol de decisión ver gráfico completo en apéndice B.2

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

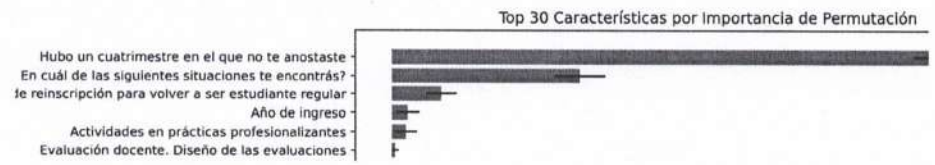


Figura 26- Parte de grafico Permutation Importance de Árbol de decisión ver gráfico completo en apéndice B.2

A partir de un análisis más profundo y teniendo en cuenta que la importancia de la interpretabilidad va más allá de la precisión predictiva del modelo. Aunque un modelo pueda ofrecer excelentes resultados en términos de métricas con estas tres características principales, no siempre proporcionan información completa sobre el funcionamiento real del modelo en el mundo. Comprender el "por qué" detrás de una predicción es fundamental para evaluar la validez del modelo.

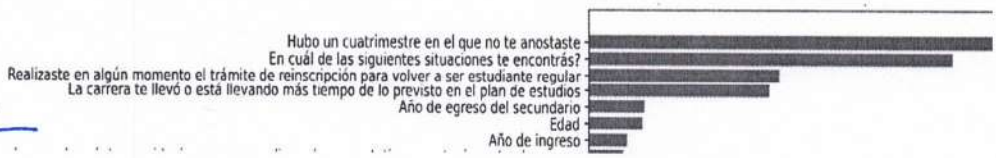
Estas características, aunque predictivas, resultan ser demasiado evidentes, ya que están directamente relacionadas con el acto de

abandonar o con la intención de hacerlo. Por ejemplo, es lógico que un estudiante que no se inscribe en un cuatrimestre esté en riesgo de abandono, y que alguien que se encuentra en la categoría de "abandonante" en la característica de situación actual, o no realizó el trámite de reinscripción, ya haya dejado la carrera o esté cerca de hacerlo. Estas características no nos permiten profundizar en las causas subyacentes de la deserción, que es el verdadero foco de nuestro análisis. Por esta razón, aunque se construyó un modelo de árbol de decisión basado exclusivamente en estas tres características, no fue útil para obtener nuevos conocimientos sobre los factores que llevan a un estudiante a abandonar. El modelo tuvo un excelente desempeño en términos de precisión, aun así, no nos brinda la información que buscamos.

Es por ello que nos centraremos en la identificación de características menos evidentes que puedan estar influyendo en la deserción estudiantil. Este replanteamiento de los resultados va más allá de identificar lo que ya es evidente, y se enfoca en descubrir factores menos perceptibles, pero igualmente determinantes.

A partir de esta evaluación, en lugar de seleccionar únicamente las tres características más significativas en común de los resultados de Feature Importance y Permutation Importance del Árbol de Decisión, se ejecutó análisis de interpretabilidad en otros modelos, como Random Forest, XGBoost y CatBoost como podemos ver en las Fig. 27, 28, 29 y 30. Esto permitió identificar y seleccionar características relevantes. Para una visualización más detallada de los gráficos completos se encuentran en el Apéndice A.6.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes



Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Figura 27-Parte de gráfico de Feature Importance Random Forest ver gráfico completo en apéndice B.2

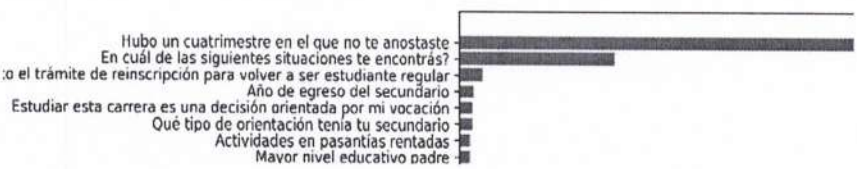


Figura 28-Parte de gráfico de Permutation Importance Random Forest ver gráfico completo en apéndice B.2

Cpde. RESOL. C. ESC. ING. Y CS. AMB. Nº 28/2024

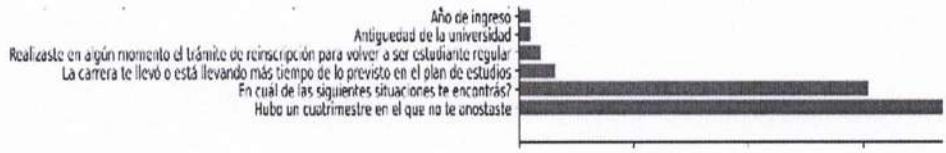


Figura 29-Parte de gráfico de Feature Importance CatBoost ver gráfico completo en apéndice B.2

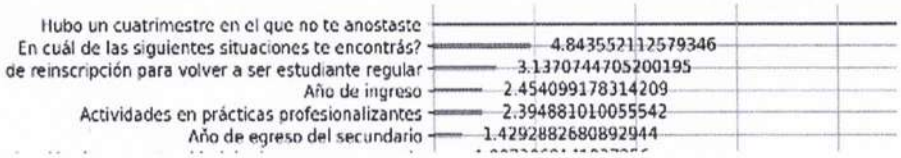


Figura 30-Parte de gráfico de Feature Importance XGBoost ver gráfico completo en apéndice B.2

Varias de las características seleccionadas coincidieron en los diferentes métodos, lo que facilitó la refinación del proceso de selección de características clave. Con esta información, se generó un nuevo archivo en formato xlsx, que contenía solo las características que han sido seleccionadas, como podemos ver en las siguientes tablas.

Región de la universidad
Antiguedad de la universidad
Tamaño de la universidad
Relación actual con la carrera (3 categorías)
Al momento de la insripción sentías que tenías información sobre la organización de los horarios y modalidades de cursada
Al momento de la insripción sentías que tenías información sobre el plan de estudios (materias y contenidos)
Al momento de la insripción sentías que tenías información sobre la exigencia
Pensando en tu situación actual, a nivel general ¿cuánto considerás que se cumplieron las expectativas que tenías sobre la carrera
Actividades en proyectos o equipos de investigación
Actividades en Docencia - Ayudante alumno/a
Actividades en tutorias (en el rol de tutor)
Actividades en tutorias (en el rol de tutorado)
Actividades en pasantías rentadas
Actividades en prácticas profesionalizantes
Actividades de extensión
Servicio de comedor
Servicio de residencia estudiantil
Servicio de jardín maternal
Servicio de lactario
Recibió beca
Evaluación Relación con docentes
Evaluación Relación con estudiantes
Evaluación Campus virtual
Evaluación Carga horaria semanal
Evaluación Oferta de turnos y horarios
Evaluación Extensión del plan de estudios
Evaluación Sistema de correlatividades
Evaluación docente. Cantidad de docentes por materia
Evaluación docente. La forma de explicar los temas tratados

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Tabla 7-Características seleccionadas (Parte 1)

Evaluación docente. Capacidad para escuchar mis consultas y dudas
Evaluación docente. Capacidad para generar interés en el tema de las y los docentes
Evaluación docente. Diseño de las evaluaciones
Evaluación docente. Brindar bibliografía adecuada
Evaluación docente. Devolución de los trabajos, etc.
Estudiar esta carrera es una decisión orientada por mi vocación
Siento que la facultad me brinda herramientas que facilitan la cursada
Siento que la facultad me brinda herramientas que facilitan la cursada (dicotómico)
Obtener el título no me brinda ninguna ventaja laboralmente
El título me posiciona en una situación diferencial en el mercado de trabajo
Percepción de materias filtro
Año/s de las materias filtro (abierta)
1 año
2 año
3 año
4 año
5 año
Por qué percibis esas materias filtro
Situación laboral (dicotómica)
En mi carrera existe desigualdad de género
Los varones disponen de ventajas para acceder, permanecer y egresar en una carrera como la mía
La facultad debería desarrollar políticas tendientes a la igualdad de género en sus carreras
Las personas en mi carrera tienen iguales oportunidades de cursar y formarse (sin importar su identidad de género)
En mi carrera las personas se sienten seguras de circular por los diferentes espacios (sin importar su identidad de género y/u orientación sexual)
Edad
Identidad de género
Qué tipo de orientación tenía tu secundario
Año de egreso del secundario
Tenés hijos o hijas menores de 18 años
Te tuviste que mudar de ciudad/localidad para poder asistir a la Universidad
Mayor nivel educativo madre
Mayor nivel educativo padre
Clima educativo del hogar
Clima educativo (2 categorías)
demora

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Tabla 8-Características seleccionadas (Parte 2)

En el siguiente capítulo, se procederá a ejecutar el modelo utilizando únicamente estas características clave seleccionadas, lo que permitirá analizar los resultados de manera detallada.

5.3 Ejecución del proceso EDM

A partir de la etapa anterior, en la cual se identificaron y generaron las características seleccionadas, pasamos a la fase de ejecución del proceso EDM.

En esta fase, procederemos a utilizar el nuevo archivo generado de registros en formato xlsx y dividir el conjunto de datos en los correspondientes conjuntos de entrenamiento y prueba, seleccionaremos

el modelo que más se adapte a la problemática, configuraremos los hiperparámetros necesarios, y validamos el modelo resultante. El código de la ejecución del proceso se encuentra disponible en el apéndice A.4

5.3.1 División de dataframe

Se dividió el conjunto de datos en dos partes, utilizando una proporción del 70% para el entrenamiento y el 30% para la prueba. El conjunto de entrenamiento se utiliza para enseñar al modelo a hacer predicciones. En esta fase, el modelo analiza los datos de entrada, las características y aprende a relacionarlos con los resultados deseados, la característica objetivo. Al utilizar un 70% del total de los datos para esta etapa, se asegura que el modelo tenga suficiente información para identificar patrones y realizar ajustes en sus parámetros.

Por otro lado, el conjunto de prueba se utiliza para evaluar el rendimiento del modelo después de que ha sido entrenado. Este conjunto representa el 30% restante de los datos y se reserva específicamente para esta etapa de validación. Al evaluar el modelo con datos que no ha visto durante el entrenamiento, podemos medir su capacidad para generalizar y hacer predicciones precisas en datos no conocidos.

La separación de los datos en estos dos conjuntos ayuda a prevenir el sobreajuste, un fenómeno en el cual el modelo aprende demasiado bien los datos de entrenamiento, incluyendo el ruido, lo que puede llevar a un rendimiento deficiente en datos nuevos. Se utiliza la función train_test_split de la biblioteca Scikit-learn en Python, para lograr una división aleatoria y controlada de los datos, asegurando que ambas partes sean representativas del conjunto total.

Además, se estableció un valor de semilla (random_state) de 42, lo que garantiza que la división del conjunto de datos sea reproducible en futuras ejecuciones del código. Esto significa que cada vez que se ejecute el código, la división se realizará de la misma manera, lo que permite comparar los resultados de diferentes ejecuciones y mantener la consistencia en los experimentos.

5.3.2 Selección de modelo

Para la selección del modelo, se optó por el Árbol de Decisión, una técnica previamente definida en el marco teórico como adecuada para la predicción de deserción estudiantil. Este modelo fue elegido principalmente por su capacidad de manejar problemas de clasificación y por ofrecer una estructura interpretativa clara, lo cual lo convierte en una opción ideal para analizar los factores que influyen en el abandono de estudiantes. La principal ventaja del Árbol de Decisión radica en su interpretabilidad. A diferencia de otros algoritmos más complejos, este tipo de árbol es fácil de interpretar, lo que es crucial en el contexto educativo. No solo es importante predecir el abandono, sino también comprender qué características están contribuyendo más a esa predicción.

Otra razón por la cual se prefirió el Árbol de Decisión es su lógica de decisiones, basada en divisiones binarias, resulta intuitiva para quienes no están familiarizados con modelos matemáticos avanzados, facilitando así la comunicación de los resultados a los responsables de la toma de decisiones en las universidades. Además, esta técnica es particularmente

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

eficaz cuando se trabaja con datos mixtos, tanto categóricos como numéricos, lo cual es frecuente en estudios educativos.

5.3.3 Configuración de hiperparámetros y entrenamiento de modelo

Durante la etapa de configuración de hiperparámetros y entrenamiento del modelo, se emplea Python, específicamente utilizando la clase DecisionTreeClassifier de la biblioteca Scikit-learn. El modelo de árbol de decisión se configura con varios hiperparámetros clave. Uno de los más importantes es el criterio de Gini para medir la calidad de las divisiones en cada nodo del árbol, permitiendo que el árbol divida los datos de forma que se minimice la impureza, mejorando la capacidad del modelo para clasificar correctamente.

Además del criterio de Gini, se establece una profundidad máxima (max_depth) de 4. Este valor fue determinado apoyándonos en la curva de validación, que nos ayudó a observar el rendimiento del modelo en función de la profundidad y a tomar una decisión informada para prevenir el sobreajuste. La configuración de esta profundidad ayuda al modelo a capturar patrones generales sin adaptarse demasiado a las particularidades del conjunto de entrenamiento. El gráfico de la curva de validación está disponible en la Fig. 32.

Para garantizar la reproducibilidad, se establece una semilla aleatoria de 42, lo que asegura que, cada vez que se ejecute el código, se obtienen los mismos resultados, lo cual es crucial para asegurar la consistencia en la validación y comparación de los modelos.

El entrenamiento del modelo se realiza con el método fit, utilizando el conjunto de datos de entrenamiento representado por las características predictoras (X_train) y la característica objetivo (y_train).

Adicionalmente, se realiza una curva de validación para evaluar cómo el rendimiento del modelo varía en función de los hiperparámetros. Esto permite identificar los valores óptimos para maximizar el rendimiento en la predicción de la deserción estudiantil. Asimismo, se implementa una validación cruzada con K-Fold, que consiste en dividir el conjunto de datos en K subconjuntos para entrenar y validar el modelo en diferentes particiones de los datos. Esta técnica es esencial para obtener una evaluación más robusta del desempeño del modelo y evitar el sobreajuste.

5.3.4 Validación de modelo

En la etapa de validación del modelo, se emplean diversas métricas para evaluar su rendimiento, entre ellas precisión, exactitud (accuracy), recuperación (recall), tasa de falsos positivos y el puntaje F1. Estas métricas son cruciales para comprender la efectividad del modelo en un contexto de deserción estudiantil. Para el cálculo de estas métricas se utilizan varias funciones de la biblioteca Scikit-learn, entre ellas, la exactitud (accuracy) es una métrica inicial importante, ya que mide la proporción de predicciones correctas sobre el total de predicciones, también se emplea recall (recuperación), esta métrica es especialmente relevante en el análisis de deserción estudiantil, ya que mide qué proporción de los estudiantes que realmente abandonaron fueron correctamente identificados por el modelo. Por otro lado, la precisión, esta métrica mide qué porcentaje de las predicciones de "abandono" realizadas por el modelo fueron correctas, es decir, cuántos de los estudiantes que el modelo predijo como en riesgo de

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

abandonar efectivamente abandonaron. Finalmente, el F1-Score se utiliza como una métrica equilibrada entre precisión y recall, especialmente en casos de clasificación desbalanceada, como suele ocurrir en la deserción estudiantil. El F1-Score es la media armónica entre precisión y recall, y ofrece una única métrica que refleja el compromiso entre estas dos.

5.3.5 Resultados

En esta sección, se presentan los resultados obtenidos tras la aplicación del modelo de árbol de decisión para la predicción de la deserción estudiantil. Los resultados se dividen en cuatro partes principales, la visualización del modelo, la evaluación del rendimiento a través de la curva de validación, las métricas de clasificación obtenidas, y la interpretación del modelo, lo que permite comprender la importancia de las características utilizadas en la predicción.

En la Fig. 31, se muestra la representación gráfica del árbol de decisión generado tras el entrenamiento del modelo con una profundidad máxima de 4.

En la Fig 32, se presenta la curva de validación, la cual visualiza el comportamiento del modelo en función de diferentes valores del hiperparámetro max_depth (profundidad máxima del árbol). Para generar esta curva, se evaluó el rendimiento del modelo para valores de la profundidad máxima que varían de 1 a 20, utilizando un esquema de validación cruzada con 5 particiones (CV=5) y la métrica de exactitud (accuracy).

En la Fig. 33, se presentan las principales métricas obtenidas tras evaluar el modelo con el conjunto de prueba. Estas fueron mencionadas con anterioridad en el apartado "4.3.4 Validación del modelo".

Finalmente, en la Fig. 34, se presenta la interpretación del modelo. A través de herramientas de interpretación como Feature Importance se desglosa el impacto de las principales características en las predicciones del modelo, proporcionando una comprensión más profunda de cómo y por qué el modelo toma sus decisiones.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

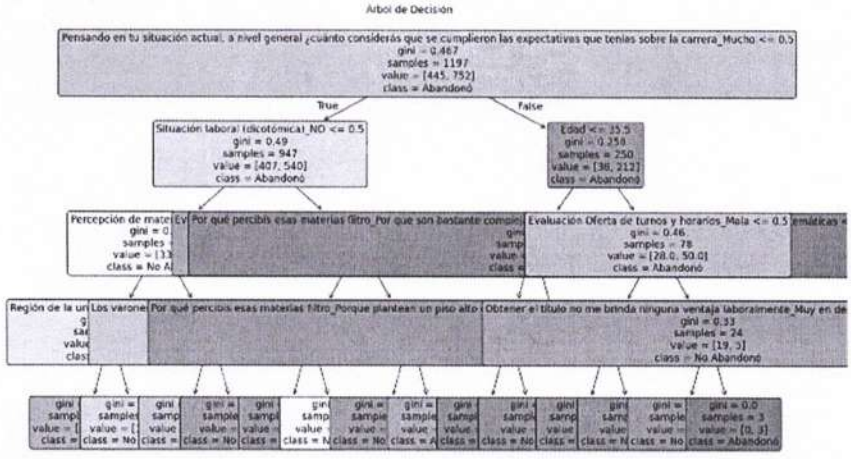


Figura 31-Grafico Árbol de decisión

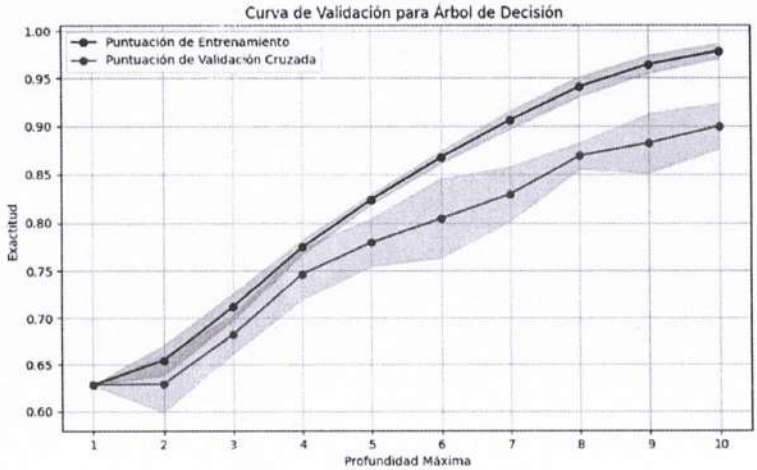


Figura 32-Grafico Curva de validación del Árbol de decisión

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

```
Exactitud (Accuracy): 0.76
Recuperación (Recall): 0.83
Precisión (Precision): 0.80
F1-Score: 0.82
```

Figura 33-Métricas del Árbol de decisión

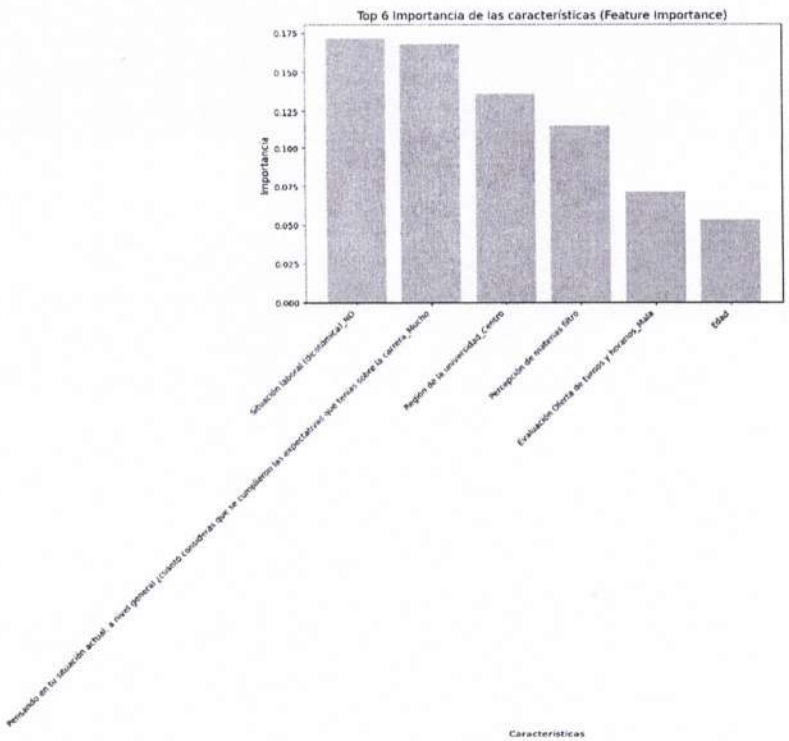


Figura 34-Grafico Feature Importance Árbol de decisión

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

5.4 Elaboración de conclusiones

5.4.1 Análisis de resultados

El árbol de decisión muestra cómo las diferentes características influyen en la predicción de la deserción estudiantil.

La primera división del árbol está relacionada con la pregunta: "¿Considerás que se cumplieron las expectativas que tenías sobre la carrera?". Esta característica es fundamental para dividir a los estudiantes que continúan de aquellos que abandonan. A partir de ahí, características como la "Situación laboral" y la "Edad" también juegan un papel clave en la predicción del abandono.

Cada nodo del árbol presenta el valor del índice de Gini, que mide la impureza de las divisiones. Un valor de Gini más bajo indica una mejor pureza en la clasificación, es decir, que los grupos están mejor diferenciados. A lo largo del árbol, podemos observar cómo se van dividiendo las muestras de acuerdo con las respuestas de los estudiantes, hasta llegar a los nodos terminales que permiten clasificar los casos en las categorías de "Abandonó" y "No Abandonó".

Por otro lado, la curva de validación nos proporciona información esencial sobre el comportamiento del modelo a medida que se ajusta su profundidad. Podemos observar cómo la exactitud del modelo en el conjunto de entrenamiento aumenta continuamente a medida que la profundidad crece. Sin embargo, el rendimiento en la validación cruzada comienza a estabilizarse a partir de una profundidad de 5, lo que indica que un mayor crecimiento de la profundidad no mejora sustancialmente la capacidad de generalización del modelo, y podría inducir al sobreajuste (overfitting). El área sombreada en la curva de validación muestra la desviación estándar, proporcionando una medida de la variabilidad en las puntuaciones.

Respecto a las métricas, las mismas indican que el modelo es capaz de clasificar correctamente el 76% de los casos totales. La precisión del 80% sugiere que de todos los estudiantes clasificados como "Abandono", el 80% efectivamente lo son. Por otro lado, la recuperación del 83% indica que el modelo fue capaz de identificar correctamente el 83% de los estudiantes que realmente abandonaron. Finalmente, el F1-Score de 0.82 muestra un buen equilibrio entre precisión y recuperación, lo que refuerza la solidez general del modelo.

En resumen, el modelo de árbol de decisión, junto con el análisis exhaustivo y las métricas obtenidas, demuestra un buen rendimiento para predecir el abandono estudiantil, cumpliendo con las expectativas iniciales de que el modelo alcance una precisión del 70% o superior en la predicción del abandono.

5.4.2 Evaluación y extracción de conocimiento

En esta sección, se presenta la extracción de conocimiento que refleja cómo el modelo propuesto se alinea con los objetivos establecidos, permitiendo una comprensión profunda de la información relacionada con los factores influyentes en la deserción estudiantil. Dicho modelo fue sometido a un proceso de evaluación utilizando métricas como precisión, recall, F1-score y exactitud. Este proceso no solo confirmó la capacidad

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

predictiva del modelo, sino que también facilitó la extracción de información relevante sobre las características que influyen en la deserción.
A través de la interpretabilidad del modelo implementado, se identificaron diversas características críticas asociadas al abandono. Algunas de las características más significativas incluyen en la siguiente tabla.

Situacion laboral (dicatomica)_NO
Pensando en tu situacion actual, a nivel general ¿cuánto consideras que se cumplieron las expectativas que tenias sobre la carrera_Mucho
Region de la universidad_Centro
Percepcion de materias filtro
Evaluacion Oferta de turnos y horarios_Mala
Edad

Tabla 9-Características más significativas

Estas características, identificadas a través del análisis de interpretabilidad del árbol de decisión, proporcionan una visión profunda de los factores que pueden influir en la deserción estudiantil en carreras de informática. Cada una de estas características destaca aspectos críticos que podría ayudar a las instituciones educativas a prevenir el abandono y mejorar la experiencia académica de los estudiantes.
Un primer aspecto clave es la situación laboral de los estudiantes. Aquellos que no tienen trabajo podrían estar enfrentando dificultades económicas que, en muchos casos, les obligan a priorizar su búsqueda de empleo sobre la continuidad en sus estudios, incrementando así la probabilidad de deserción.
Otro factor determinante es la percepción sobre el cumplimiento de las expectativas que los estudiantes tenían al ingresar a la carrera. Aquellos que consideran que sus expectativas se han cumplido en gran medida ("Mucho") podrían ser menos propensos a abandonar. En cambio, aquellos que se sienten insatisfechos con la formación recibida podría haber perder la motivación para continuar con sus estudios.
La región geográfica de la universidad también podría tener un impacto importante. En este caso, las universidades ubicadas en la región "Centro" parecen tener una mayor retención de estudiantes, posiblemente debido a la mayor disponibilidad de recursos y servicios en comparación con otras regiones.
Un cuarto factor crítico es la percepción sobre las materias filtro. Estas materias suelen ser vistas como obstáculos importantes para el progreso de los estudiantes. Si los estudiantes sienten que estas asignaturas son excesivamente difíciles o no están alineadas con los objetivos del programa, esto podría generar frustración y desmotivación.
La evaluación de la oferta de turnos y horarios es otra característica clave. Aquellos que perciben que los turnos y horarios son insuficientes o inadecuados ("Mala") podrían tener dificultades para compatibilizar sus

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

estudios con otras responsabilidades, lo que aumenta el riesgo de abandono.

Finalmente, la edad también podría jugar un papel importante. Los estudiantes de mayor edad, que suelen tener responsabilidades laborales o familiares, por lo cual podrían estar enfrentándose a mayores desafíos para permanecer en la universidad, lo que incrementa la probabilidad de deserción.

Cada una de estas características podrían proporcionar a las universidades información clave para diseñar estrategias de intervención focalizadas, como mejorar la oferta de turnos y horarios, ofrecer apoyo adicional en las materias filtro, y ayudar a los estudiantes a gestionar sus expectativas sobre la carrera. Este análisis resalta la importancia de interpretar los modelos predictivos en profundidad, lo que podría permitir no solo anticipar qué estudiantes corren mayor riesgo de desertar, sino también identificar los factores subyacentes que pueden ser abordados de manera proactiva.

6. CONCLUSIONES

"Las máquinas pueden hacer cualquier cosa que puedan hacer los humanos,
siempre que se les dé la suficiente información y el tiempo adecuado."
Alan m. Turing

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

En este Informe Final de la Carrera de Ingeniería en Sistemas de Información se estudió la Minería de Datos Educativa (EDM), el Aprendizaje Automático (ML, por sus siglas en inglés), la Interpretabilidad Automática del Aprendizaje Automático (IML, por sus siglas en inglés), como así también un Stack de Herramientas Tecnológicas actualizadas que permitió abordar el problema planteado en la Hipótesis y de esta manera construir una primera versión de una herramienta capaz de identificar causas subyacentes en los datos que permitan inferir futuras deserción de alumnos del sistema universitario a partir del conjunto de datos proporcionado por la Fundación Sadosky.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Se llevó a cabo de manera cuidadosa la selección de características exhaustiva, empleando técnicas que permitieron identificar el subconjunto más relevante y representativo de características que influyen en el rendimiento académico. Este proceso fue clave para reducir la dimensionalidad del conjunto de datos y mejorar la eficiencia del modelo predictivo. Se logró identificar aquellas características que tenían una relación significativa con la deserción, lo cual resultó en un modelo que no solo predice el abandono estudiantil, sino que también ofrece información valiosa sobre los factores subyacentes a este fenómeno.

El informe también logró implementar un algoritmo de clasificación adecuado, en este caso, un modelo de árbol de decisión, que fue entrenado, ajustado y optimizado mediante la selección de hiperparámetros, asegurando así que el modelo capturara los patrones generales sin caer en el sobreajuste. El rendimiento del modelo fue evaluado a través de métricas claves, superando consistentemente los umbrales establecidos, lo que validó su capacidad predictiva y la efectividad de las técnicas empleadas.

Además, se prestó especial atención a la presentación de los resultados de una manera accesible para los usuarios finales, de esta manera las universidades podrían interpretar fácilmente los resultados y tomar decisiones informadas. El modelo no solo ofrece predicciones sobre la deserción, sino que también facilita una comprensión profunda de los factores críticos asociados, proporcionando una herramienta clara y útil para la toma de decisiones.

En cuanto a la fundamentación teórica, el estudio abarcativo realizado del estado del arte fue importante para guiar el proceso, ya que se utilizaron investigaciones previas como referencia para seleccionar los enfoques más adecuados en la construcción del modelo predictivo.

En conclusión, se ha logrado con éxito implementar las tecnologías y técnicas necesarias para abordar el problema de la deserción estudiantil en carreras de informática y para el conjunto de datos provisto por la Fundacion Sadosky. Se ha podido cumplir tanto con el Objetivo General como los Específicos, y se ha validado la herramienta en el dominio de la Educación Superior.

El modelo de ML que implementa la herramienta no solo cumple con los requisitos de predicción planteados, sino que también proporciona una visión clara y detallada de los factores que influyen en el abandono.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Referencias

[1] Cesarotto, Y., & Yuri. (n.d.). El debate académico en curso sobre 'big data' y su incidencia en la comprensión de la comunicación mediática contemporánea. *RECERCAT (Dipòsit de La Recerca de Catalunya)*. Retrieved April 30, 2020, from http://recercat.cat/handle/2072/335833

[2] Baker, R.S.; Yacef, K (2009). "The state of educational data mining in 2009: A review and future visions". JEDM-Journal of Educational Data Mining 1 (1): 2017

[3] Merceron, A. and Berlin University of Applied Sciences, "Journal of Educational Data Mining", JEDM, Available: https://jedm.educationaldatamining.org/index.php/JEDM

[4] L. Paura and I. Arhipova, "Cause analysis of students' dropout rate in higher education study program," Procedia-Social Behav. Sci., vol. 109, pp. 1282–1286

[5] Morales Carrillo, J., Trujillo Utreras, V., Cevallos Molina, S., and Santana Cedeño, M., "Data mining in education: a literary review"

[6] Panizzi, M., "Establecimiento del estado del arte sobre la Minería de Datos
Educacional en el Nivel Superior: Un Estudio de Mapeo Sistemático," Revista de Investigaciones Científicas de la Universidad de Morón, RICUM, vol. 2, no. 4, pp. 51-60, 2019

[7] V. Marino, S. E. Sustas, D. Quartulli, and J. Curcio, "¿Por qué estudiamos informática?," Fundación Sadosky.

[8] Poveda Velasco, J. C., Poveda Velasco, I. M., & España Irala, I. A. (2020). Análisis de la deserción estudiantil en una universidad pública de Bolivia. *Revista Iberoamericana de Educación*, *82*(2), 151–172. https://doi.org/10. 35362/rie8223572

[9] Salazar, A., Gosálbez, j, Bosch, I., Miralles, R., & Vergara, I. (2004). A case study of knowledge discovery on academic achievement, student

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

desertion and student retention *TRE 2004. 2nd International Conference Information Technology: Research and Education. IEEE, 2004.*
[10] C. Guzmán Ruíz, D. Durán Muriel, J. Franco Gallego, E. Castaño Vélez, S. Gallón Gómez, K. Gómez Portilla y J. Vásquez Velásquez, Deserción estudiantil en la educación superior colombiana, Bogota. Colombia: Imprenta Nacional de Colombia, 2009.
[11] K. B. Eckert and R. Suénaga, "Análisis de deserción-permanencia de estudiantes universitarios utilizando técnica de clasificación en minería de datos," Form. Univ., vol. 8, no. 5, pp. 3–12, 2015.
[12] Hernandez Gonzalez, A. G., Melendez Armenta, R. A., Morales Rosales, L. A., Garcia Barrientos, A., Tecpanecatl Xihuitl, J. L., & Algredo, I. (2016). Comparative Study of Algorithms to Predict the Desertion in the Students at the ITSM-Mexico. *IEEE Latin America Transactions*, *14*(11), 4573–4578. https://doi.org/10.1109/TLA.2016.7795831
[13] K. Coussement, M. Phan, A. De Caigny, D. F. Benoit, and A. Raes, "Predicting student dropout in subscription-based online learning environments: The beneficial impact of the logit leaf model," Decis. Support Syst., vol. 135, p. 113325, 2020.
[14] B. Cuji, W. Gavilanes, and R. SANCHEZ, "Modelo predictivo de deserción estudiantil basado en árboles de decisión," Espacios, vol. 38, no. 55, p. 17, 2017.
[15] M. Barramuño, C. Meza-Narváez, and G. Gálvez-Garc\'\ia, "Prediction of student attrition risk using machine learning," J. Appl. Res. High. Educ., 2021.
[16] M. Solis, T. Moreira, R. González, T. Fernández, and M. Hernandez, "Perspectives to predict dropout in university students with machine learning," in 2018 IEEE International Work Conference on Bioinspired Intelligence (IWOBI), 2018, pp. 1–6.
[17] P. E. Ramirez and E. E. Grandón, "Predicción de la Deserción Académica en una Universidad Pública Chilena a través de la Clasificación basada en Árboles de Decisión con Parámetros Optimizados," Form. Univ., vol. 11, no. 3, pp. 3–10, 2018.
[18] Romero, C. andVentura, S., "Educational Data Mining: A Review of the State of The Art", IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews), pp. 601-618, 2010. Available: http://ieeexplore.ieee.org/document/5524021
[19] GJ Páramo, CAC Maya - Revista universidad EAFIT, 1999 - publicaciones.eafit.edu.co, Deserción estudiantil universitaria. Conceptualización
[20] Mikut, R., & Reischl, M. (2011). Data mining tools. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, 431–443. http://tarjomefa.com/wpcontent/uploads/2017/10/7879-English-TarjomeFa.pdf
[21] Heredia, D., Amaya, Y., & Barrientos, E. (2015). Student Dropout Predictive Model Using Data Mining Techniques. *IEEE Latin America Transactions*, *13*(9), 3127–3134. https://doi.org/10.1109/TLA.2015.7350068

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

[22] Guía Práctica de Introducción al Análisis Exploratorio de Datos. (22-09-2021). Datos.gob.es. https://datos.gob.es/es/documentacion/guia-practica-de-introduccion-al-analisis-exploratorio-de-datos
[23] Guerrero, J. A., "El problema de la dimensionalidad." TEMA DE PORTADA, Revista Índice, 22 Julio 2016. Available: http://www.revistaindice.com/numero68/p22.pdf
[24] Molnar, C., Interpretable Machine Learning: A Guide for Making Black Box Models Explainable. Available: https://christophm.github.io/interpretable-ml-book/, 31-Jul-2024.
[25] Witten, I. H., Frank, E., Hall, M. A., & Pal, C. J. (2016). Data Mining: Practical Machine Learning Tools and Techniques. In *Data Mining: Practical Machine Learning Tools and Techniques*. https://doi.org/10.1016/c2009-0-19715-5
[26] Perez, B., Castellanos, C., & Correal, D. (2018, October 5). Applying Data Mining Techniques to Predict Student Dropout: A Case Study. *2018 IEEE 1st Colombian Conference on Applications in Computational Intelligence, ColCACI 2018 - Proceedings*. https://doi.org/10.1109/ColCACI.2018.8484847
[27] NumFOCUS sponsored project., "Pandas," 2021. [Online]. Available: https://pandas.pydata.org/

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

APENDICE

Apéndice A: Código de los notebooks de Google Colab

1. **Apéndice A.1**: Análisis Exploratorio de Datos (EDA)

```
#Importacion de los datos
import pandas as pd
data =
pd.read_excel('Porqueestudiamosinformatica_encuesta_base_publica.xlsx')
df= pd.DataFrame(data)
df.head()  # Muestra las primeras 5 filas
#Resumen estadístico de las variables numéricas
summary = df.describe(include='all')
#Representacion de graficos
import pandas as pd
import matplotlib.pyplot as plt
df['Relación actual con la carrera (4 categorías)'].hist(bins=30,
edgecolor='black')
plt.title('Histograma de Relación actual con la carrera')
plt.xlabel('Valores')
plt.ylabel('Frecuencia')
plt.show()
#Grafico 2
df['Año de egreso del secundario'].plot(kind='line', figsize=(10, 6))
plt.title('Gráfico de Líneas de Año de egreso del secundario')
plt.xlabel('Índice')
plt.ylabel('Valores')
plt.show()
#Grafico 3
```

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

```
df['Año de ingreso'].value_counts().plot(kind='bar', figsize=(10, 6),
color='skyblue')
plt.title('Gráfico de Barras de Año de ingreso')
plt.xlabel('Categorías')
plt.ylabel('Frecuencia')
plt.show()
#Ajuste de los tipos de variables
df.info()  # Muestra un resumen de las columnas, incluyendo los tipos de
datos y valores no nulos
#Uso de sweetviz
# Analyzing the dataset without pairwise analysis
advert_report = sv.analyze(df, pairwise_analysis='off')
# Display the report
advert_report.show_html('Advertising.html')
#Detección de datos ausentes
missing_values = df.isnull().sum()
print(missing_values[missing_values > 0])  # Muestra solo las columnas
con valores nulos
# Calcular el porcentaje de valores ausentes en cada columna
missing_percentage = (df.isnull().sum() / len(df)) * 100
# Mostrar las columnas con valores ausentes y su porcentaje
print(missing_percentage[missing_percentage > 0])
#DETECCION DE OUTLIERS
from sklearn.preprocessing import LabelEncoder
# Definir las columnas categóricas
categorical_columns = ["id","Región de la universidad","Antiguedad de la
universidad","Tamaño de la universidad","Descripción de la
universidad","Carrera","Año de ingreso","En cuál de las siguientes
situaciones te encontrás?","Relación actual con la carrera (3
categorías)","Relación actual con la carrera (4 categorías)","Relación
actual con la carrera (5 categorías)",
"Cantidad de materias/tesis que debe (sólo estudiantes que terminaron la
cursada)",
"Contacto con la carrera a través de Redes / sitio web de la universidad",
"Contacto con la carrera a través de Jornadas universitarias o Ferias de
carreras",
"Contacto con la carrera a través de Diario / revistas / cartelería / folletos /
Tv / Radio",
"Contacto con la carrera a través de Amigos / conocidos / familiares",
"Contacto con la carrera a través de Visita a mi escuela secundaria",
"Contacto con la carrera a través de otros medios",
"Contacto con la carrera a través de otros medios. Cual?",
"Motivo carrera. A partir de un curso de orientación vocacional",
"Motivo carrera. Por la orientación del título",
"Motivo carrera. Porque se corresponde con mis aptitudes",
"Motivo carrera. Porque era la que más me gustaba",
"Motivo carrera. Por la sugerencia de familiares o personas de confianza",
"Motivo carrera. Por el prestigio de la carrera",
"Motivo carrera. Porque no había otra carrera (descarte otras)",
```

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

"Motivo carrera. Porque conozco profesionales en el área y me gustaría trabajar como ellas/os",
"Motivo carrera. Porque tiene múltiples salidas profesionales",
"Motivo carrera. Porque era una carrera corta y adecuada a mis posibilidades",
"Motivo carrera. Porque permite acceder a trabajos bien pagados",
"Motivo carrera. Por mi experiencia profesional previa o por estar trabajando en el área",
"Motivo carrera. Porque creía que era más fácil comparada con otras carreras",
"Motivo carrera. Otros motivos",
"Motivo carrera. Otros motivos. Cuales?",
"Motivo universidad. Porque tengo parientes cercanos que son graduados de esta universidad",
"Motivo universidad. Por las características del programa académico (tipo de materias que debe cursar, organización, etc.)",
"Motivo universidad. Por la calidad del plantel docente",
"Motivo universidad. Por la flexibilidad de horarios",
"Motivo universidad. Por es una universidad estatal",
"Motivo universidad. Porque es gratuita",
"Motivo universidad. Porque garantiza una buena inserción laboral/profesional a sus estudiantes o egresados/as",
"Motivo universidad. Por la sugerencia de familiares o personas de confianza",
"Motivo universidad. Por su prestigio y calidad académica",
"Motivo universidad. Porque queda cerca de mi casa",
"Motivo universidad. Porque favorece la posibilidad de realizar posgrados en el exterior (convenios, pasantías e intercambios)",
"Motivo universidad. Porque no exige examen de ingreso",
"Motivo universidad. Ofrece título intermedio",
"Motivo universidad. Otros",
"Motivo universidad. Otros. Cuales?",
"Al momento de la insripción sentías que tenías información sobre la organización de los horarios y modalidades de cursada",
"Al momento de la insripción sentías que tenías información sobre el plan de estudios (materias y contenidos)",
"Al momento de la insripción sentías que tenías información sobre la exigencia",
"Pensando en tu situación actual, a nivel general ¿cuánto considerás que se cumplieron las expectativas que tenías sobre la carrera",
"Pensando en tu situación actual, a nivel general ¿cuánto considerás que se cumplieron las expectativas que tenías sobre la carrera. Por qué (abierta)?",
"Año de las materias que estas/estuviste cursando. 1er año",
"Año de las materias que estas/estuviste cursando. 2do año",
"Año de las materias que estas/estuviste cursando. 3er año",
"Año de las materias que estas/estuviste cursando. 4to año",
"Año de las materias que estas/estuviste cursando. 5to año",
"Año de las materias que estas/estuviste cursando. Trabajo final / tesis",

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

"Obtención Título intermedio",
"Porqué no tramitó el título intermedio",
"Obtención título intermedio. Otro (abierta)",
"Actividades en proyectos o equipos de investigación",
"Actividades en Docencia - Ayudante alumno/a",
"Actividades en tutorias (en el rol de tutor)",
"Actividades en tutorias (en el rol de tutorado)",
"Actividades en pasantías rentadas",
"Actividades en prácticas profesionalizantes",
"Actividades de extensión",
"Servicio de comedor",
"Servicio de residencia estudiantil",
"Servicio de jardín maternal",
"Servicio de lactario",
"Recibió beca",
"Qué beca recibió",
"Cuanto considera que la beca ayudó para sostener la trayectoria académica",
"Evaluación Relación con docentes",
"Evaluación Relación con estudiantes",
"Evaluación Relación con nodocentes",
"Evaluación Disponibilidad de equipamiento",
"Evaluación Laboratorio de informática",
"Evaluación Campus virtual",
"Evaluación Carga horaria semanal",
"Evaluación Oferta de turnos y horarios",
"Evaluación Extensión del plan de estudios",
"Evaluación Sistema de correlatividades",
"Evaluación Modalidad presencial",
"Evaluación Modalidad virtual",
"Evaluación Trámites/gestiones administrativas",
"Evaluación docente. Conocimiento sobre los temas tratados",
"Evaluación docente. Cantidad de docentes por materia",
"Evaluación docente. La forma de explicar los temas tratados",
"Evaluación docente. Capacidad para escuchar mis consultas y dudas",
"Evaluación docente. Capacidad para generar interés en el tema de las y los docentes",
"Evaluación docente. Diseño de las evaluaciones",
"Evaluación docente. Brindar bibliografía adecuada",
"Evaluación docente. Devolución de los trabajos, etc.",
"Estudiar esta carrera es una decisión orientada por mi vocación",
"Siento que la facultad me brinda herramientas que facilitan la cursada",
"Siento que la facultad me brinda herramientas que facilitan la cursada (dicotómico)",
"Obtener el título no me brinda ninguna ventaja laboralmente",
"El título me posiciona en una situación diferencial en el mercado de trabajo",
"Percepción de materias filtro",
"Año/s de las materias filtro (abierta)",

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

"Por qué percibis esas materias filtro",
"Hubo un cuatrimestre en el que no te anostaste",
"Año de la carrera en el que no te anotaste a un cuatrimestre",
"Realizaste en algún momento el trámite de reinscripción para volver a ser estudiante regular",
"Te anotaste o rendiste una materia en los último 12 meses",
"La carrera te llevó o está llevando más tiempo de lo previsto en el plan de estudios",
"Demora en la carrera Por cuestiones laborales",
"Demora en la carrera Por correlatividades",
"Demora en la carrera Por una situación personal",
"Demora en la carrera Por una situación de salud",
"Demora en la carrera Por el nacimiento de un hije",
"Demora en la carrera Porque no aprobaba las materias",
"Demora en la carrera Por tener que recursar",
"Demora en la carrera Porque debía finales",
"Demora en la carrera Por la tesis/tp final",
"Demora en la carrera Por la escada oferta",
"Demora en la carrera Porque me anoté sin estar muy segura/o de la carrera",
"Demora en la carrera Porque tuve diferencias con algún docente",
"Demora en la carrera Por compatibilidad de horarios",
"Demora en la carrera. Otros motivos",
"Demora en la carrera. Otros motivos (abierta)",
"Situación laboral",
"Situación laboral (dicotómica)",
"Cuantos empleados tiene la empresa (abierta)",
"Antigüedad en el trabajo",
"Área en donde realiza el trabajo",
"Trabaja en el área de sistemas",
"Trabajo anterior en el área de sistemas",
"Situación laboral (tricotómica)",
"Área en donde realiza el trabajo. Otra (abierta)",
"Cantidad horas semanales",
"Posibilidad de teletrabajo",
"Posibilidad de días de estudio",
"En el trabajo te piden título para efectivizarte",
"En el trabajo te piden título para obtener un adicional",
"En el trabajo te piden título para acceder a puestos jerárquicos",
"En el trabajo te piden título para acceder a otros beneficios",
"En el trabajo te piden título para acceder a otros beneficios. Cuales (abierta)",
"En el trabajo no me piden título / puedo acceder a todos los beneficios sin necesidad de tener título",
"En el trabajo te piden título. Prefiero no responder",
"Utilidad laboral de lo aprendido en la carrera",
"Sentis que tu rendimiento decayó a partir de tu ingreso al mercado laboral",

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

"Sentis que tu rendimiento decayó a partir de tu ingreso al mercado laboral. Porqué (abierta)",
"Relación entre tu situación laboral y las expectativas que tenías cuando comenzaste los estudios",
"Realizaste una capacitación específica para complementar conocimientos académicos",
"Dónde realizaste la capacitación (por tu cuenta)",
"Dónde realizaste la capacitación (en una organización)",
"En qué año te recibiste",
"Tramitaste el título intermedio",
"Impacto del título de grado en tu desarrollo personal (abierta)",
"Abandono Por cuestiones laborales",
"Abandono Porque no me interesaba",
"Abandono Por una situación personal",
"Abandono Por una situación de salud",
"Abandono Por el nacimiento de un hije",
"Abandono Porque no aprobaba las materias",
"Abandono Porque necesitaba una pausa en la vida",
"Abandono Porque cambié de carrera",
"Abandono Porque debía finales",
"Abandono Por la tesis/tp final",
"Abandono Por la escasa oferta",
"Abandono Porque me anote sin estar muy segura/o de la carrera",
"Abandono Porque tuve diferencias con algún docente",
"Abandono Por compatibilidad de horarios",
"Otros motivos de abandono",
"Otros motivos de abandono (abierta)",
"Qué necesitarías para volver a retomar la carrera (abierta)",
"Comentarios discriminatorios en razón de tu género u orientación sexual o chistes sexualmente sugestivos que te hicieron sentir incómoda/o",
"Quién realizó comentarios discriminatorios en razón de tu género u orientación sexual o chistes sexualmente sugestivos que te hicieron sentir incómoda/o",
"Quién realizó comentarios discriminatorios en razón de tu género u orientación sexual o chistes sexualmente sugestivos que te hicieron sentir incómoda/o (abierta)",
"Comentarios que subestimen, menosprecien o pongan en cuestión tu capacidad de realizar alguna tarea en razón de tu sexo/género y/u orientación sexual",
"Quién realizó Comentarios que subestimen, menosprecien o pongan en cuestión tu capacidad de realizar alguna tarea en razón de tu sexo/género y/u orientación sexual",
"Quién realizó Comentarios que subestimen, menosprecien o pongan en cuestión tu capacidad de realizar alguna tarea en razón de tu sexo/género y/u orientación sexual (abierta)",
"Contacto físico no deseado (tocamientos, abrazos, y/o besos no consentidos)",
"Quién realizó Contacto físico no deseado (tocamientos, abrazos, y/o besos no consentidos)",

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

```
"Quién Contacto físico no deseado (tocamientos, abrazos, y/o besos no consentidos) (abierta)",
"Área específica donde puedas recurrir en caso de algún problema o conflicto vinculado a tu sexo-género y/u orientación sexual",
"En mi carrera existe desigualdad de género",
"Los varones disponen de ventajas para acceder, permanecer y egresar en una carrera como la mía",
"La facultad debería desarrollar políticas tendientes a la igualdad de género en sus carreras",
"Las personas en mi carrera tienen iguales oportunidades de cursar y formarse (sin importar su identidad de género)",
"En mi carrera las personas se sienten seguras de circular por los diferentes espacios (sin importar su identidad de género y/u orientación sexual)",
"Cursaste otra carrera previamente",
"Cuál fue la carrera anterior (abierta)",
"Donde hicista esa carrera anterior",
"Donde hiciste esa carrera anterior (abierta)",
"Edad",
"Identidad de género",
"Identidad de género (3 categorías)",
"Otro género",
"Qué tipo de orientación tenía tu secundario",
"Qué tipo de otra orientación tenía tu secundario (abierta)",
"Año de egreso del secundario",
"Tenés hijos o hijas menores de 18 años",
"Te tuviste que mudar de ciudad/localidad para poder asistir a la Universidad",
"Mayor nivel educativo madre",
"Mayor nivel educativo padre",
"Clima educativo del hogar",
"Clima educativo (2 categorías)",
"Te gustaría participar de estas entrevistas"]
label_encoder = LabelEncoder()
# Aplicar Label Encoding a cada columna categórica
for col in categorical_columns:
    df[col] = label_encoder.fit_transform(df[col])
# Seleccionar solo las columnas numéricas del DataFrame
numerical_columns = df.select_dtypes(include=['float64', 'int64']).columns
# Crear un boxplot para cada variable numérica
for column in numerical_columns:
    plt.figure(figsize=(10, 5) )
    sns.boxplot(x=df[column])
    plt.title(f'Boxplot de {column}')
    plt.show()
# Calcular la matriz de correlación para todas las variables del dataset
correlation_matrix = df.corr()
# Mostrar la matriz de correlación
print(correlation_matrix)
```

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

```
# Configurar el tamaño de la figura
plt.figure(figsize=(10, 8))
# Crear un heatmap de la matriz de correlación sin los números
sns.heatmap(correlation_matrix, cmap='coolwarm', vmin=-1, vmax=1,
center=0, square=True, linewidths=0.5)
# Guardar el gráfico como un archivo de imagen
plt.savefig('correlacionTODAS.png', dpi=300, bbox_inches='tight')
# Mostrar el gráfico
plt.show()
```

2. **Apéndice A.2**: Limpieza de Datos

```
#Importación De Los Datos
import pandas as pd
data =
pd.read_excel('Porqueestudiamosinformatica_encuesta_base_publica.xls
x')
df= pd.DataFrame(data)
# Calculo del porcentaje de valores nulos por columna
percent_missing = df.isnull().mean() * 100
# Filtro de las columnas con menos del 30% de valores nulos
columns_to_keep = percent_missing[percent_missing < 30].index
# Creacion de un nuevo DataFrame con solo esas columnas
df1 = df[columns_to_keep]
df2=df1.drop('id',axis=1)
df3 = df2.drop('Relación actual con la carrera (4 categorías)', axis=1)
df4 = df3.drop('Relación actual con la carrera (5 categorías)', axis=1)
df5 = df4.drop('Te gustaría participar de estas entrevistas', axis=1)
#Tratamiento de outliers
# Calculamos la media de la columna 'Edad', excluyendo los valores de 99
media_edad = df6[df6['Edad'] != 99]['Edad'].mean()
# Creamos una copia de df6 para trabajar en df7
df6 = df5.copy()
# Reemplazamos los valores 99 por la media calculada en df7
df6['Edad'] = df6['Edad'].replace(99, media_edad)
# Calculamos la media de la columna 'Año de egreso del secundario' en
df7
media_egreso = df6['Año de egreso del secundario'].mean()
# Creamos una copia de df7 y la guardamos en df8
df7 = df6.copy()
# Si es necesario, puedes realizar más operaciones en df8 o verificar que
la media se haya calculado correctamente
print("Media del Año de egreso del secundario en df7:", media_egreso)
# Lista de valores a reemplazar
valores_a_reemplazar = [0.0, 4.0, 5.0, 7.0, 17.0, 18.0, 28.0, 93.0, 11970.0]
# Calculamos la media de la columna excluyendo los valores que se van a
reemplazar
media_egreso = df7[~df7['Año de egreso del
secundario'].isin(valores_a_reemplazar)]['Año de egreso del
secundario'].mean()
# Reemplazamos los valores específicos por la media
```

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

```
df7['Año de egreso del secundario'] = df7['Año de egreso del
secundario'].replace(valores_a_reemplazar, media_egreso)
# Verificamos que los valores se hayan reemplazado correctamente
print(df8['Año de egreso del secundario'].value_counts())
```

3. **Apéndice A.3**: PCA y Reducción de Dimensionalidad

```
#importacion de datos
import pandas as pd
data =
pd.read_excel('Porqueestudiamosinformatica_encuesta_base_publica.xls
x')
df= pd.DataFrame(data)
#Conversion de todas las variables a numericas
from sklearn.preprocessing import LabelEncoder
# Definir las columnas categóricas
categorical_columns = ["Región de la universidad", "Tamaño de la
universidad", "Antiguedad de la universidad", "Descripción de la
universidad", "Carrera", "Año de ingreso",
 "En cuál de las siguientes situaciones te encontrás?", "Relación actual
con la carrera (4 categorías)", "Motivo carrera. Porque era la que más me
gustaba", "Motivo universidad. Por es una universidad estatal",
 "Al momento de la insripción sentías que tenías información sobre la
organización de los horarios y modalidades de cursada", "Al momento de
la insripción sentías que tenías información sobre el plan de estudios
(materias y contenidos)",
 "Al momento de la insripción sentías que tenías información sobre la
exigencia", "Pensando en tu situación actual, a nivel general ¿cuánto
considerás que se cumplieron las expectativas que tenías sobre la
carrera",
 "Actividades en proyectos o equipos de investigación", "Actividades en
Docencia - Ayudante alumno/a", "Actividades en tutorias (en el rol de
tutor)","Actividades en tutorias (en el rol de tutorado)",
 "Actividades en pasantías rentadas", "Actividades en prácticas
profesionalizantes", "Actividades de extensión", "Servicio de
comedor", "Servicio de residencia estudiantil", "Servicio de jardín
maternal", "Servicio de lactario",
 "Recibió beca", "Evaluación Relación con docentes", "Evaluación
Relación con estudiantes", "Evaluación Relación con nodocentes",
"Evaluación Disponibilidad de equipamiento", "Evaluación Laboratorio de
informática",
 "Evaluación Campus virtual", "Evaluación Carga horaria semanal",
"Evaluación Oferta de turnos y horarios", "Evaluación Extensión del plan
de estudios", "Evaluación Sistema de correlatividades", "Evaluación
Modalidad presencial",

 "Evaluación Modalidad virtual", "Evaluación Trámites/gestiones
administrativas" ,"Evaluación docente. Conocimiento sobre los temas
tratados", "Evaluación docente. Cantidad de docentes por materia",
"Evaluación docente. La forma de explicar los temas tratados",
```

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

"Evaluación docente. Capacidad para escuchar mis consultas y dudas", "Evaluación docente. Capacidad para generar interés en el tema de las y los docentes", "Evaluación docente. Diseño de las evaluaciones", "Evaluación docente. Brindar bibliografía adecuada",

"Evaluación docente. Devolución de los trabajos, etc.", "Estudiar esta carrera es una decisión orientada por mi vocación", "Siento que la facultad me brinda herramientas que facilitan la cursada", "Siento que la facultad me brinda herramientas que facilitan la cursada (dicotómico)",

"Obtener el título no me brinda ninguna ventaja laboralmente", "El título me posiciona en una situación diferencial en el mercado de trabajo", "Percepción de materias filtro", "Año/s de las materias filtro (abierta)", "Por qué percibis esas materias filtro",

"Hubo un cuatrimestre en el que no te anostaste", "Realizaste en algún momento el trámite de reinscripción para volver a ser estudiante regular", "La carrera te llevó o está llevando más tiempo de lo previsto en el plan de estudios", "Situación laboral",

"Situación laboral (dicotómica)", "Antigüedad en el trabajo", "Área en donde realiza el trabajo", "Trabaja en el área de sistemas", "Situación laboral (tricotómica)", "Cantidad horas semanales", "Posibilidad de teletrabajo", "Posibilidad de días de estudio",

"En el trabajo te piden título para efectivizarte", "En el trabajo te piden título para obtener un adicional", "En el trabajo te piden título para acceder a puestos jerárquicos", "En el trabajo no me piden título / puedo acceder a todos los beneficios sin necesidad de tener título",

"Utilidad laboral de lo aprendido en la carrera", "Sentis que tu rendimiento decayó a partir de tu ingreso al mercado laboral", "Realizaste una capacitación específica para complementar conocimientos académicos", "Comentarios discriminatorios en razón de tu género u orientación sexual o chistes sexualmente sugestivos que te hicieron sentir incómoda/o",

"Comentarios que subestimen, menosprecien o pongan en cuestión tu capacidad de realizar alguna tarea en razón de tu sexo/género y/u orientación sexual", "Contacto físico no deseado (tocamientos, abrazos, y/o besos no consentidos)", "Área específica donde puedas recurrir en caso de algún problema o conflicto vinculado a tu sexo-género y/u orientación sexual",

"En mi carrera existe desigualdad de género", "Los varones disponen de ventajas para acceder, permanecer y egresar en una carrera como la mía", "La facultad debería desarrollar políticas tendientes a la igualdad de género en sus carreras", "Las personas en mi carrera tienen iguales oportunidades de cursar y formarse (sin importar su identidad de género)",

"En mi carrera las personas se sienten seguras de circular por los diferentes espacios (sin importar su identidad de género y/u orientación sexual)" ,"Cursaste otra carrera previamente", "Edad", "Identidad de género", "Identidad de género (3 categorías)", "Qué tipo de orientación tenía tu secundario", "Año de egreso del secundario", "Tenés hijos o hijas menores de 18 años",

"Te tuviste que mudar de ciudad/localidad para poder asistir a la Universidad", "Mayor nivel educativo madre", "Mayor nivel educativo

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

```
padre", "Clima educativo del hogar", "Clima educativo (2 categorías)",
"Te gustaría participar de estas entrevistas"]
label_encoder = LabelEncoder()
# Aplicar Label Encoding a cada columna categórica
for col in categorical_columns:
   df[col] = label_encoder.fit_transform(df[col])
#PCA
from sklearn.preprocessing import StandardScaler
# Guardar los nombres originales de las características
original_feature_names = df.columns
# Separar las características que se van a utilizar para PCA
X = df.values
# Estandarizar las variables (media = 0, desviación estándar = 1)
X_std = StandardScaler().fit_transform(X)
from sklearn.decomposition import PCA
# Inicializar PCA
pca = PCA(n_components=0.95)
X_pca = pca.fit_transform(X_std)
#Reducir dimensionalidad
# Número de componentes principales que se usan para la reducción
n_components = pca.n_components_
# Inicializar PCA con el número específico de componentes
pca = PCA(n_components=n_components)
X_reduced = pca.fit_transform(X_std)
print("Forma de los datos reducidos:", X_reduced.shape)
```

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

4. **Apéndice A.4**: Ejecución del Modelo de EDM

```
#se carga el dataset con las variables seleccionadas
data = pd.read_excel('datasetsadosky.xlsx')
df= pd.DataFrame(data)
# Calcular la media de la variable objetivo y redondearla
media = df['Relación actual con la carrera (3 categorías)'].mean()
media_redondeada = round(media)
# Rellenar los NaN con la media redondeada
df['Relación actual con la carrera (3 categorías)'].fillna(media_redondeada,
inplace=True)
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
import pandas as pd
# Aplicar One-Hot Encoding a las variables categóricas
X = df.drop('Relación actual con la carrera (3 categorías)', axis=1)  #
Variables predictoras
y = df['Relación actual con la carrera (3 categorías)']  # Variable objetivo
X_encoded = pd.get_dummies(X, drop_first=True)
# Dividir los datos
X_train, X_test, y_train, y_test = train_test_split(X_encoded, y,
test_size=0.3, random_state=42)
# Crear el modelo de Árbol de Decisión con profundidad máxima de 3
decision_tree = DecisionTreeClassifier(max_depth=4, random_state=42)
```

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

```
# Entrenar el modelo
decision_tree.fit(X_train, y_train)
import matplotlib.pyplot as plt
from sklearn.tree import plot_tree
# Configurar el tamaño de la figura
plt.figure(figsize=(15, 10))
# Graficar el árbol de decisión
plot_tree(decision_tree,
          feature_names=X_train.columns,  # Nombres de las características
          class_names=['No Abandonó', 'Abandonó'],  # Nombres de las
clases
          filled=True,  # Colorear los nodos
          rounded=True,  # Bordes redondeados
          fontsize=12)  # Tamaño de la fuente
# Guardar la figura con un nombre específico
plt.title("Árbol de Decisión")
plt.savefig("arbol_decision.png", format='png')
# Mostrar el gráfico
plt.show()
from sklearn.metrics import classification_report
# Realizar predicciones
y_pred = decision_tree.predict(X_test)
# Calcular las métricas solicitadas
accuracy = accuracy_score(y_test, y_pred)
precision = precision_score(y_test, y_pred)
recall = recall_score(y_test, y_pred)
f1 = f1_score(y_test, y_pred)
# Imprimir las métricas con el formato solicitado
print(f'Exactitud (Accuracy): {accuracy:.2f}')
print(f'Recuperación (Recall): {recall:.2f}')
print(f'Precisión (Precision): {precision:.2f}')
print(f'F1-Score: {f1:.2f}')
from sklearn.model_selection import validation_curve
from sklearn.tree import DecisionTreeClassifier
import numpy as np
import matplotlib.pyplot as plt
# Definir el rango de valores para el hiperparámetro a evaluar (en este
caso max_depth)
param_range = np.arange(1, 11)  # Rango ajustado según tu ejemplo
anterior
# Generar las curvas de validación usando max_depth como
hiperparámetro
train_scores, test_scores = validation_curve(
    DecisionTreeClassifier(random_state=42),
    X_train,  # Usar X_train en lugar de X
    y_train,  # Usar y_train en lugar de y
    param_name="max_depth",
    param_range=param_range,
    cv=5,  # Número de folds para la validación cruzada
```

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

```
    scoring="accuracy",  # Métrica de evaluación
    n_jobs=-1  # Usar todos los procesadores disponibles
)
# Calcular la media y la desviación estándar para los puntajes de
entrenamiento y prueba
train_mean = np.mean(train_scores, axis=1)
train_std = np.std(train_scores, axis=1)
test_mean = np.mean(test_scores, axis=1)
test_std = np.std(test_scores, axis=1)
# Graficar las curvas de validación
plt.figure(figsize=(10, 6))
plt.plot(param_range, train_mean, label="Puntuación de Entrenamiento",
color="blue", marker='o')
plt.plot(param_range, test_mean, label="Puntuación de Validación
Cruzada", color="green", marker='o')
# Rellenar las áreas de la desviación estándar
plt.fill_between(param_range, train_mean - train_std, train_mean +
train_std, color="blue", alpha=0.2)
plt.fill_between(param_range, test_mean - test_std, test_mean + test_std,
color="green", alpha=0.2)
# Añadir etiquetas y leyendas
plt.title("Curva de Validación para Árbol de Decisión")
plt.xlabel("Profundidad Máxima")
plt.ylabel("Exactitud")
plt.xticks(param_range)
plt.legend(loc="best")
plt.grid(True)
# Guardar la figura
plt.savefig('curvaSadosky.png', format='png')
plt.show()
import matplotlib.pyplot as plt
import numpy as np
# Obtener la importancia de las características del Árbol de Decisión
feature_importances = decision_tree.feature_importances_
# Crear un gráfico de barras para mostrar las 6 características más
importantes
features = X_encoded.columns  # Nombres de las características después
del One-Hot Encoding
indices = np.argsort(feature_importances)[::-1]  # Ordenar las
características por importancia
# Seleccionar las 6 características más importantes
top_n = 6
top_indices = indices[:top_n]
top_features = features[top_indices]
top_importances = feature_importances[top_indices]
# Plotear las importancias de las 6 principales características
plt.figure(figsize=(10, 6))  # Aumentar el tamaño de la figura
plt.bar(top_features, top_importances, align="center", color='skyblue')  #
Color para mejorar visibilidad
```

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

```
plt.ylabel("Importancia", fontsize=12)  # Tamaño de la fuente
plt.xlabel("Características", fontsize=12)  # Tamaño de la fuente
plt.title("Top 6 Importancia de las características (Feature Importance)",
fontsize=14)  # Tamaño de la fuente
plt.xticks(rotation=45, ha='right', fontsize=10)  # Rotar etiquetas y
alinearlas a la derecha
plt.tight_layout()
# Guardar el gráfico
plt.savefig("interpretabilidadSadosky6.png", format='png')
plt.show()
```

Apéndice B: Gráficos completos del informe

5. **Apéndice B.1**: Gráficos de matriz de correlación

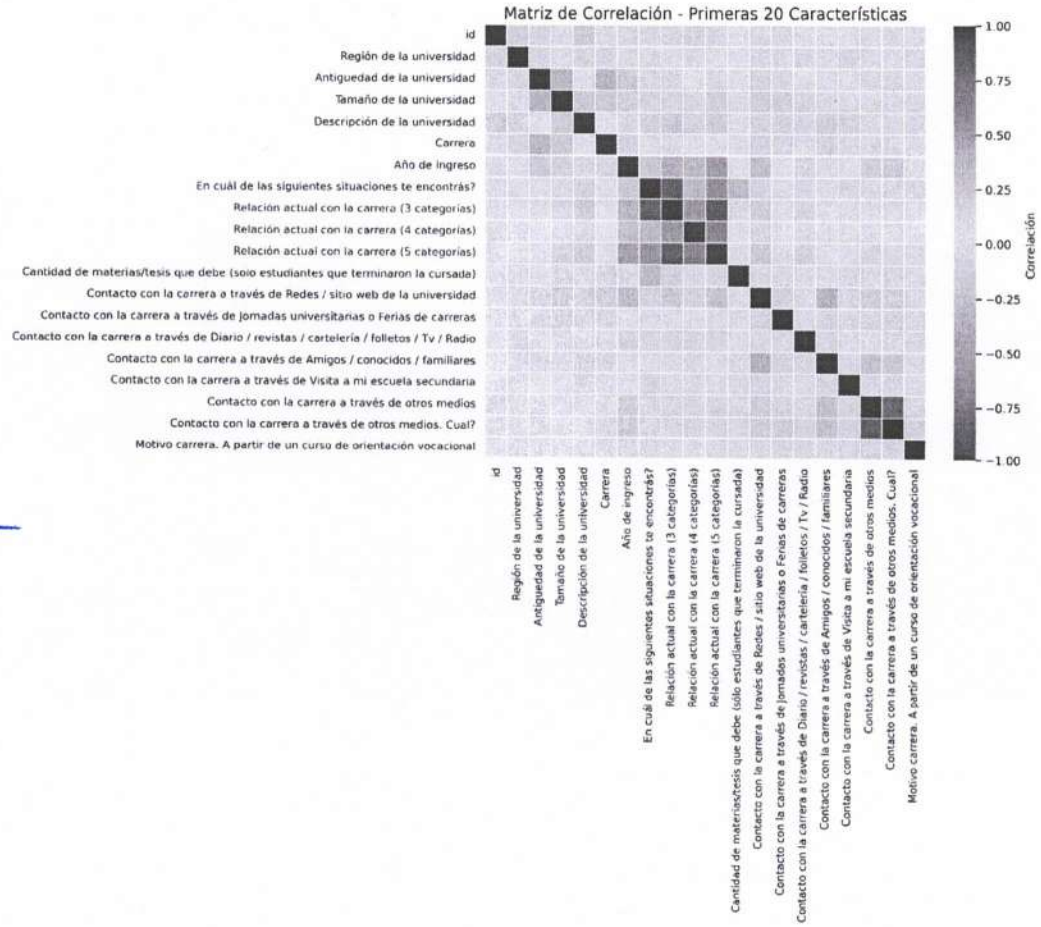
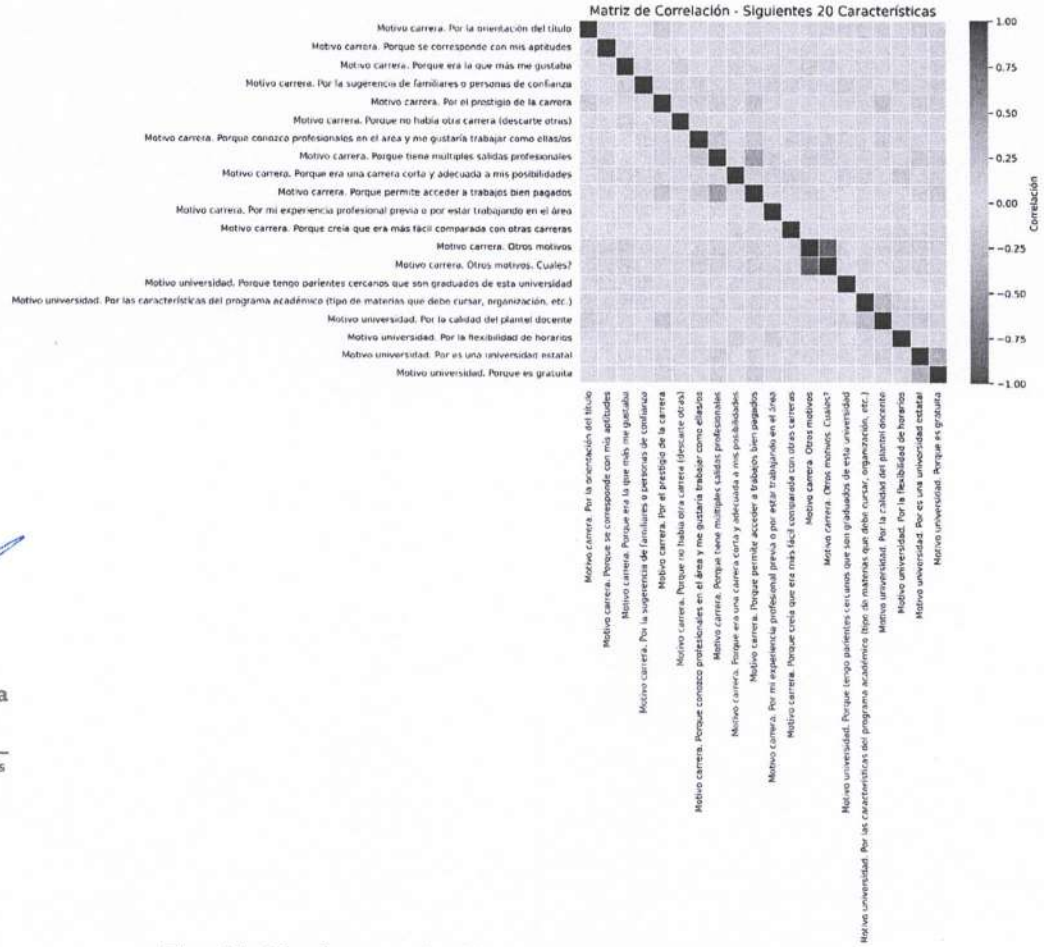


Fig- Matriz de correlación primeras 20 características

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes



Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Fig- Matriz de correlación ultimas 20 características

6. **Apéndice B.2**: Gráficos de interpretabilidad de modelos

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes



Fig- Interpretabilidad árbol de decisión primeras 10 características

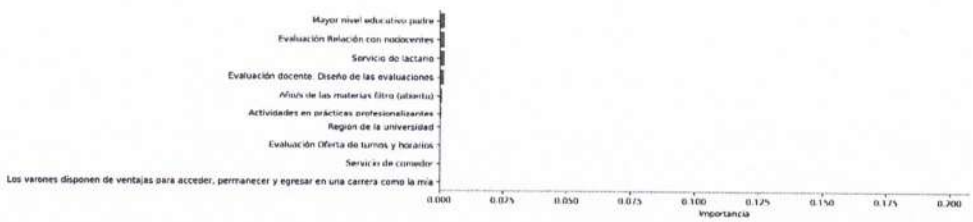


Fig- Interpretabilidad feature importante árbol de decisión ultimas 10 características

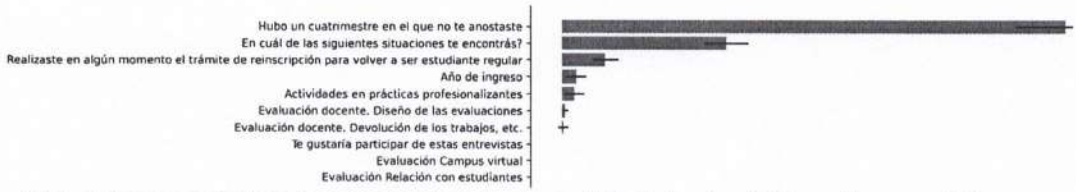


Fig- Interpretabilidad permutation feature árbol de decisión primeras 10 características

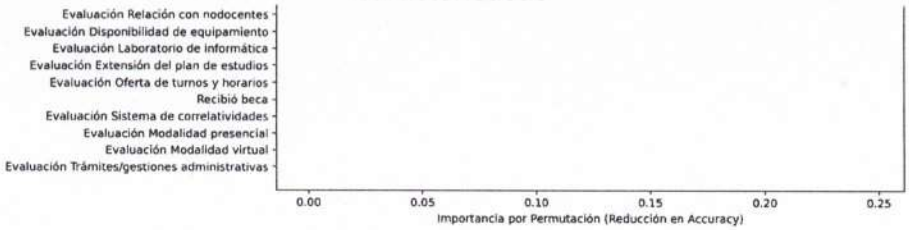


Fig- Interpretabilidad permutation feature árbol de decisión ultimas características

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

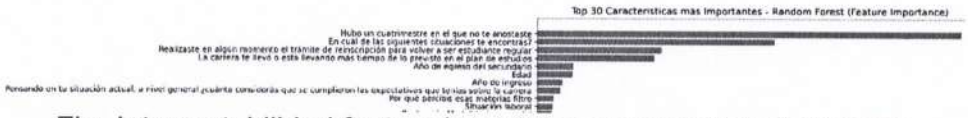
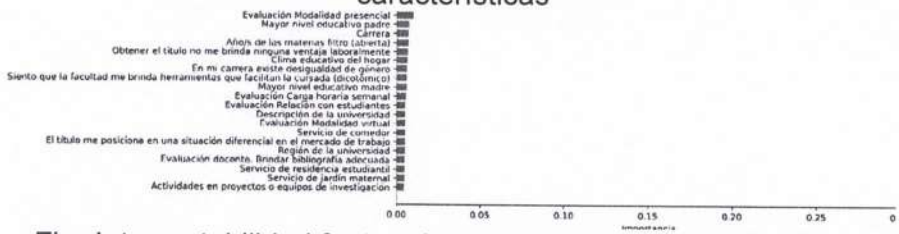


Fig- Interpretabilidad feature importance random forest primeras características



Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Fig- Interpretabilidad feature importance random forest ultimas características



Fig- Interpretabilidad permutation importance random forest primeras características

Cpde. RESOL. C. ESC. ING. Y CS. AMB. Nº 28/2024

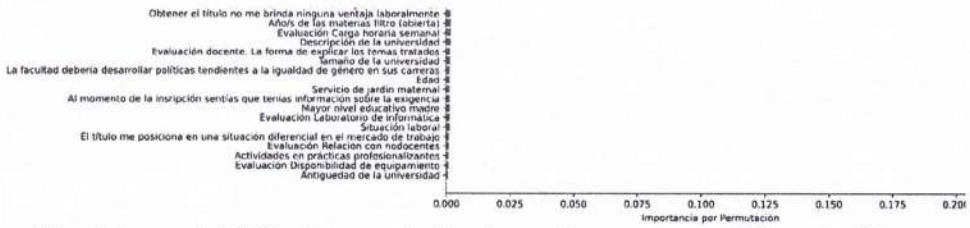


Fig- Interpretabilidad permutation importance random forest ultimas características

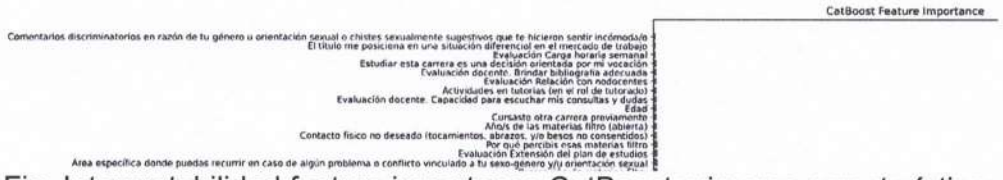


Fig- Interpretabilidad feature importance CatBoost primeras características

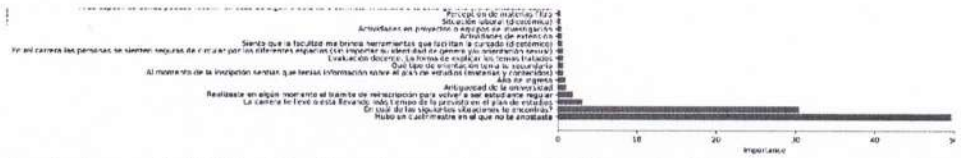


Fig- Interpretabilidad feature importance CatBoost ultimas características

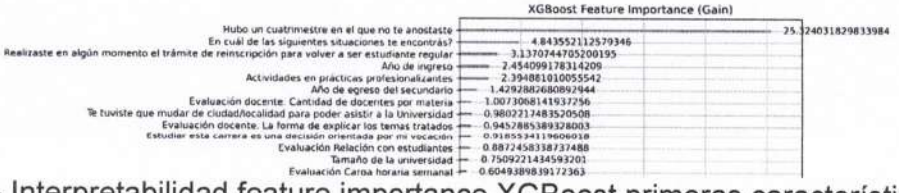


Fig- Interpretabilidad feature importance XGBoost primeras características

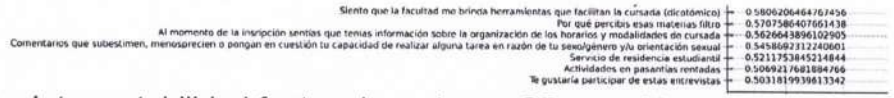


Fig- Interpretabilidad feature importance GBoost ultimas características

RESOLUCIÓN C. ESC. ING. Y CS. AMB. Nº 28/2024

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes