Villa Mercedes (SL), 3 de diciembre de 2024

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

VISTO:

El **CUDAP: EXP-UVM: 1278/2024**, mediante el cual el Dr. Francisco BAVERA, presenta Informe Final de la Práctica Profesional Supervisada del alumno Elio BAIGORRIA de la carrera de Ingeniería en Sistemas de Información, y;

CONSIDERANDO:

Que mediante Resolución del Consejo de Escuela de Ingeniería y Ciencias Ambientales Nº 58/2022 se aprobó la Reglamentación de la Práctica Profesional Supervisada para la carrera de Ingeniería en Sistemas de Información.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Que mediante Resolución del Consejo de Escuela de Ingeniería y Ciencias Ambientales Nº 21/2024, se protocolizo el inicio de la Práctica Profesional Supervisada.

Que la Dirección de la Escuela de Ingeniería y Ciencias Ambientales, remitió el expediente con el informe final a la comisión de Carrera de Ingeniería en Sistemas de Información para su conocimiento y aval.

Que la Comisión de Carrera de Ingeniería en Sistemas de Información, aprueba el informe presentado por el Dr. Francisco BAVERA y, propone como jurado evaluador a la Lic. Vanesa TORRES, al Ing. Marcelo ALTABA, y al Ing. Alejandro ROSA.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Que la Dirección de la Escuela de Ingeniería y Ciencias Ambientales realiza el pase a la Comisión de Asuntos Académicos del Consejo de Escuela de Ingeniería y Ciencias Ambientales para su conocimiento y aval.

Que la Comisión de Asuntos Académicos en su dictamen aconseja Aprobar el informe final de la Práctica Profesional Supervisada de la carrera de Ingeniería en Sistema de Información de del alumno Elio Nicolás Baigorria, DNI: 30.313.122, Titulada "Técnicas de Procesamiento de Lenguaje Natural y Machine Learning", llevadas a cabo en la Secretaría de Ciencia y Técnica y Vinculación Tecnológica, perteneciente a la Universidad Nacional de Villa Mercedes. Aprobar la designación como evaluadores a: Ing. Alejandro ROSAS, Ing. Marcelo ALTABA y Lic. Vanesa TORRES. Aprobar la presentación de dicho informe ante el tribunal examinador en la mesa de examen correspondiente.

Cpde. RESOL. C.ESC. ING. Y CS. AMB. N° 32/2024

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Que el Consejo de Escuela en su sesión ordinaria del día 11 de noviembre de 2024, resolvió hacer suyo el dictamen de la Comisión de Asuntos Académicos

Que la Dirección de Escuela de Ingeniería y Ciencias Ambientales, y con el aval del Consejo de Escuela, remite a Secretaría Académica para su protocolización.

Que la Secretaría Académica toma conocimiento, presta aval y remite a la oficina de Despacho para emisión de acto administrativo.

Que Dirección de Despacho realiza el acto administrativo, incorporando las modificaciones pertinentes, conforme al anteproyecto adjunto al presente

Por ello, y en uso de sus atribuciones;

EL CONSEJO DE ESCUELA DE INGENIERÍA Y CIENCIAS AMBIENTALES DE LA UNIVERSIDAD NACIONAL DE VILLA MERCEDES

RESUELVE:

ARTÍCULO 1º: PROTOCOLIZAR el Informe Final de la Práctica Profesional Supervisada del alumno Elio Nicolás BAIGORRIA, DNI: 30.313.122, Titulada "Técnicas de Procesamiento de Lenguaje Natural y Machine Learning", llevadas a cabo en la Secretaría de Ciencia y Técnica y Vinculación Tecnológica, de la Universidad Nacional de Villa Mercedes", carrera de Ingeniería en Sistemas de Información, según se detallan en el ANEXO ÚNICO de la presente disposición.

ARTÍCULO 2º: RECONOCER al Ing. Alejandro ROSA, DNI: 24.719.010, Ing. Marcelo ALTABA, DNI: 21.638.609 y Lic. Vanesa TORRES, DNI: 30.312.995, como evaluadores de las practicas.

ARTICULO 3º: Notifíquese, publíquese, insértese en el Libro de Resoluciones de la Escuela de Ingeniería y Ciencias Ambientales y archívese.

RESOLUCIÓN C. ESC. ING. Y CS. AMB. Nº 32/2024

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Téc. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

ANEXO UNICO

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

UNIVERSIDAD NACIONAL DE VILLA MERCEDES

ESCUELA DE INGENIERÍA Y CIENCIAS AMBIENTALES

PRACTICA PROFESIONAL SUPERVISADA

Técnicas de Procesamiento de Lenguaje Natural y Machine Learning

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

AUTOR: ELIO NICOLAS BAIGORRIA

PROFESOR TUTOR: FRANCISCO BAVERA

PROFESOR SUPERVISOR: GABRIEL NOVILLO RANGONE

CARRERA: INGENIERÍA EN SISTEMAS DE INFORMACIÓN

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

VILLA MERCEDES SAN LUIS- ARGENTINA

-2024-

Cpde. RESOL. C.ESC. ING. Y CS. AMB. N° 32/2024

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Tabla de Contenidos

1. Introducción

2. Estructura organizacional de la institución

3. Marco teórico

3.1. Procesamiento de Lenguaje Natural (PLN) y su Relevancia

3.2. Machine Learning (ML) Aplicado al PLN

3.3. Análisis Predictivo en la Deserción Estudiantil

3.4. Modelos de Representación de Texto

3.5. Análisis Predictivo en la Deserción Estudiantil

4. Recolección y exploración inicial

4.1. Importancia de la Recolección de Datos en Machine Learning

4.2. Desafíos Específicos en la Recolección de Datos para PLN

4.3. Métodos de Recolección de Datos para Machine Learning y PLN.

4.4. Identificación de la fuente de datos

4.5. Colab para el Tratamiento de Datos en Procesamiento de Lenguaje Natural (PLN)...

5. Limpieza de datos y Procesamiento Léxico

5.1. Técnicas y Herramientas

5.2. Expresiones Regulares con 're'

5.3. Búsqueda Difusa de Strings con thefuzz

5.4. Expresiones Regulares y Normalización

5.5. Identificación de Patrones

5.6. Extracción de información

5.7. Limpieza de datos

5.8. Transformación de texto

5.9. Automatización

5.10. Aplicación en Python con re

5.11. Innovación en la Normalización de Texto

5.12. Informe Limpieza de datos y Procesamiento Léxico

6. Tokenización, Lematización y Stemmig

6.1. Tokenización

6.2. Lematizacion

Ing. Alejandro Pablo Ross
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Soares
Secretario Académico
Universidad Nacional de Villa Mercedes

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

6.3. Stemmig (Stemizacion)
6.4. Comparación y Aplicaciones

7. Palabras frecuentes e infrecuentes

7.1. Eliminación de Stop Words
7.2. Importancia en PLN
7.3. Beneficios de eliminar stop Word
7.4. Consideraciones al eliminar Stop Word
7.5. Filtro de Frecuencia
7.6. Palabras con alta frecuencia
7.7. Palabras con baja frecuencia
7.8. Beneficios del filtro de frecuencia
7.9. Establecimiento de Umbrales de Frecuencia
7.10. Herramientas para la Implementación

8. Representación de Textos

8.1. Bag of Words (BoW)
8.2. TF-IDF (Term Frequency - Inverse Document Frequency)
8.3. Word Embeddings (Word2Vec)
8.3.1. Representación de Palabras
8.3.2. Aprendizaje Automático de Representaciones
8.3.3. Beneficios en Tareas Avanzadas de PLN
8.3.4. Eficiencia y Compactación
8.3.5. Mejora en el Rendimiento de Modelos
8.3.6. Relaciones semánticas: una mirada más cercana
8.3.7. Diferencias entre conceptos aparentemente relacionados
8.3.8. Información y su relación con otras palabras
8.3.9. Limitaciones y utilidad de la reducción dimensional

9. Análisis de eficiencia e implementación de Pipeline

9.1. Combinaciones necesarias según el proceso
9.2. Consideraciones

10. Interpretación del análisis semántico

10.1. Desarrollo de análisis NLP en característica categórica

11. Conclusiones

12. Material Bibliográfico

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

1. Introducción

La deserción estudiantil es un fenómeno que afecta a las instituciones educativas de todo el mundo, representando un desafío tanto para los estudiantes como para las universidades. En particular, las carreras relacionadas con computación y tecnología suelen presentar tasas de deserción considerables, debido a la alta demanda académica y la necesidad de habilidades técnicas específicas. Identificar los factores que contribuyen a este fenómeno es crucial para el desarrollo de estrategias que promuevan la retención estudiantil y mejoren el rendimiento académico.

Con los avances en tecnologías de Inteligencia Artificial (IA), el análisis de grandes volúmenes de datos se ha vuelto más accesible y preciso. Dentro de este campo, el Procesamiento de Lenguaje Natural (PLN) ha ganado relevancia por su capacidad para analizar textos no estructurados, como respuestas a encuestas o comentarios de los estudiantes. Al combinarse con técnicas de aprendizaje automático (Machine Learning, ML), el PLN ofrece una herramienta poderosa para detectar patrones y tendencias en los datos, facilitando la predicción de eventos como la deserción estudiantil.

Este informe tiene como objetivo aplicar técnicas de PLN y ML para el análisis predictivo de la deserción en estudiantes de carreras de computación. A través de la recolección y procesamiento de datos académicos y demográficos, se pretende identificar los factores clave que influyen en el abandono de los estudios. Las técnicas implementadas incluyen la tokenización, lematización, eliminación de palabras irrelevantes (stop words), y el uso de modelos de representación de texto como Bag of Words (BoW) y TF-IDF. Asimismo, se aplicarán algoritmos de aprendizaje supervisado para crear modelos que predigan la probabilidad de deserción de los estudiantes.

En definitiva, este análisis busca proporcionar una visión más clara de los factores que inciden en la deserción estudiantil y contribuir al diseño de estrategias que mejoren la retención y el éxito académico en las carreras de computación.

2. Estructura organizacional de la entidad

La PPS se desarrolló en la Secretaría de Ciencia y Técnica y Vinculación Tecnológica de la Universidad Nacional de Villa Mercedes. Esta Secretaría depende de Rectorado de la Universidad. A nivel de gestión la máxima autoridad es el Secretario de Ciencia y Técnica y Vinculación Tecnológica y lo apoyan la comisión Asesora de Investigación y la Coordinación de Vinculación Tecnológica. Luego cuenta con una jerarquía administrativa que depende de la Dirección General de Ciencia y Técnica y Vinculación Tecnológica que coordina y lleva adelante todos los procesos administrativos y la gestión de los laboratorios.

La Secretaría asesora y asiste al Rector en el desarrollo de la actividad científica y tecnológica, siendo sus funciones intervenir en la elaboración de normas y desarrollo de programas. administrar recursos para el

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

funcionamiento de la investigación, promover y fortalecer la vinculación con organismos nacionales e internacionales. Realizar el planeamiento de investigación, siendo sus funciones elaborar normas, desarrollar programas y administrar recursos para el desarrollo de la investigación y la vinculación tecnológica.
Las actividades realizadas durante la PPS se inserta en la Secretaría con el fin de generar un marco de trabajo para procesar datos generados en el marco de los proyectos de investigación para poder generar información y/o alimentar otras herramientas que contribuyan a generar información que favorezcan la toma de decisiones en la Secretaría pero también el la Universidad. En esta instancia se tomaron datos de interés para el proyecto de investigación del Dr. Gabriel Novillo con el fin de procesarlos, limpiarlos y formatearlos para que puedan ser entrada de modelos de Machine Learnnig. Este trabajo es la primer instancia para generar herramientas que permitan procesar los datos de los distintos proyectos de la UNViMe.

3. Marco Teórico

3.1. Procesamiento de Lenguaje Natural (PLN) y su Relevancia

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

El Procesamiento de Lenguaje Natural (PLN) es una subdisciplina de la Inteligencia Artificial (IA) que se enfoca en la interacción entre las computadoras y el lenguaje humano. Utiliza técnicas que permiten a las máquinas comprender, interpretar y generar texto de manera similar a como lo haría una persona. El PLN abarca una variedad de tareas, como el análisis de sentimientos, la clasificación de texto, la extracción de información y la traducción automática(Practica Profesional Su...).

3.2. Machine Learning (ML) Aplicado al PLN

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

El aprendizaje automático (ML), otra rama fundamental de la IA, permite a las computadoras mejorar su desempeño en tareas específicas mediante el aprendizaje a partir de datos. En el contexto del PLN, el ML se utiliza para entrenar modelos que realizan predicciones o clasificaciones a partir de grandes volúmenes de texto, permitiendo analizar patrones en el lenguaje(Practica Profesional Su...). Técnicas de aprendizaje automático como la regresión logística, los árboles de decisión y las redes neuronales son comúnmente empleadas para mejorar la precisión y efectividad en tareas relacionadas con el lenguaje natural(Practica Profesional Su...).

3.3. Técnicas de Limpieza y Preprocesamiento de Datos

El preprocesamiento de datos es crucial para garantizar la calidad de los datos utilizados en modelos de aprendizaje automático. En PLN, se implementan varias técnicas de limpieza y normalización, como la tokenización, la lematización y la eliminación de palabras irrelevantes (stop words)(Practica Profesional Su...). Estas técnicas aseguran que el texto esté en un formato que los modelos puedan entender, mejorando así su capacidad de generalización.

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

3.4. Modelos de Representación de Texto

Los modelos de representación de texto, como Bag of Words (BoW), TF- IDF y Word Embeddings (Word2Vec), son esenciales para convertir el lenguaje natural en un formato numérico que los modelos de ML puedan procesar. BoW se centra en la frecuencia de palabras sin tener en cuenta su orden, mientras que TF-IDF ajusta la importancia de las palabras según su relevancia en el documento. Word2Vec, por otro lado, captura relaciones semánticas entre palabras mediante la representación de términos en espacios vectoriales(Practica Profesional Su...).

3.5. Análisis Predictivo en la Deserción Estudiantil

El análisis predictivo aplicado a la deserción estudiantil busca identificar patrones que permitan predecir qué estudiantes están en riesgo de abandonar sus estudios. Mediante técnicas de ML y PLN, es posible analizar grandes cantidades de datos textuales y académicos para encontrar relaciones significativas entre variables demográficas, académicas y socioeconómicas(Practica Profesional Su...). La identificación de estas relaciones es clave para implementar políticas y estrategias que mejoren la retención de estudiantes.

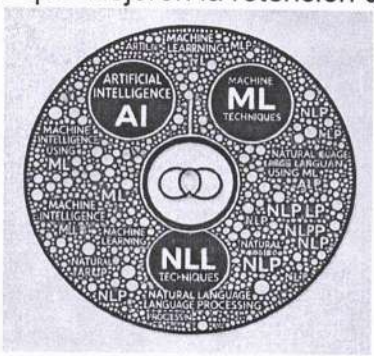


Figura - 1 Ubicación del NLP

4. Recolección y exploración inicial

Ya que hemos definido como esta disciplina abarca algunos aspectos de la IA, y por ello es necesario mostrar y tener en cuenta la recolección de datos.

En la actualidad, el desarrollo de modelos de (ML) ha tomado un rol preponderante en diversas disciplinas, desde la medicina hasta la economía, pasando por la ingeniería y las ciencias sociales. Uno de los pilares fundamentales para el éxito de estos modelos es la recolección de datos de calidad, ya que estos constituyen la base sobre la cual se entrenan y evalúan los algoritmos. En particular, en el campo del (NLP), la importancia de los datos es aún más crítica debido a la complejidad inherente al manejo del lenguaje humano, con sus matices, ambigüedades y variaciones contextuales.

4.1. Importancia de la Recolección de Datos en Machine Learning

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

El proceso de ML comienza con la identificación de una fuente adecuada de datos, los cuales deben ser representativos del problema que se desea resolver. La cantidad, calidad y relevancia de los datos recolectados son factores determinantes para el desempeño de los modelos predictivos. Una recolección inadecuada de datos puede llevar a sesgos en los modelos, sobreajuste, o resultados no generalizables a contextos diferentes del conjunto de datos de entrenamiento.

4.2. Desafíos Específicos en la Recolección de Datos para PLN

El PLN, una subárea del aprendizaje automático enfocada en la interacción entre las computadoras y el lenguaje humano, presenta desafíos únicos en la recolección de datos. El lenguaje es inherentemente complejo, con variaciones en dialectos, jerga, tono y contexto, lo que requiere un enfoque detallado y cuidadoso en la recolección de datos para asegurar que los modelos puedan generalizar efectivamente a una amplia gama de situaciones lingüísticas.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

En el PLN, no solo es crucial recolectar grandes cantidades de datos textuales, sino también asegurar que estos datos estén bien etiquetados y preprocesados. Sin un adecuado tratamiento de los datos, los modelos pueden fallar en captar la semántica o en manejar la ambigüedad, lo que comprometería la calidad de las predicciones.

4.3. Métodos de Recolección de Datos para Machine Learning y PLN

- **Web Scraping**: Una técnica común que implica la extracción de datos de sitios web. Para PLN, esta técnica se utiliza para recolectar textos que pueden ser analizados posteriormente. Herramientas como BeautifulSoup o Scrapy son frecuentemente empleadas para estos fines. No obstante, es importante tener en cuenta las consideraciones éticas y legales asociadas al scraping de datos.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

- **APIs (Application Programming Interfaces)**: Muchas plataformas ofrecen APIs que permiten la recolección de datos de manera estructurada. Por ejemplo, Twitter API proporciona acceso a tweets, lo que es útil para el análisis de opiniones o para detectar tendencias en redes sociales.
- **Crowdsourcing**: Para obtener datos etiquetados, el crowdsourcing ha emergido como una solución efectiva. Plataformas como Amazon Mechanical Turk permiten la recolección de grandes volúmenes de datos etiquetados por humanos, lo cual es esencial para el entrenamiento de modelos supervisados en NLP.
- **Text Mining**: Involucra la extracción de información útil a partir de textos no estructurados. Técnicas de text mining permiten recolectar y estructurar datos a partir de grandes corpus de texto, facilitando la creación de conjuntos de datos relevantes para tareas específicas de NLP.
- **Scraping de PDFs**: Muchas fuentes valiosas de datos están contenidas en documentos PDF. El scraping de PDFs se refiere a la extracción de texto y metadatos de estos documentos.

Herramientas como PyPDF2 y PDFMiner son comúnmente utilizadas para estos propósitos.

- **Redes Sociales**: Las redes sociales son una fuente rica de datos lingüísticos. A través de APIs o técnicas de scraping, es posible recolectar grandes volúmenes de datos textuales, lo que es particularmente útil para análisis de sentimientos, identificación de tendencias, y otras tareas de NLP.

En esta etapa se recolectaron los datos de los estudiantes, para ello se tomaron en cuenta los factores que pueden influir en la deserción estudiantil y a partir de allí considerar las fuentes disponibles para la construcción del set o conjunto de datos, el cual constituye el punto de partida para la construcción de cualquier modelo.

La recopilación de datos es fundamental en el proceso de ML, ya que implica la identificación, obtención y reunión de los conjuntos de datos relevantes para el análisis de todo tipo de entorno.

4.4. Identificación de la fuente de datos

La identificación de la fuente de datos es una tarea fundamental que se aborda en el desarrollo de este proyecto

Se logró identificar que se cuenta con información académica de los estudiantes de las Universidades Nacionales en carreras informáticas y la determinación de la calidad de los datos con los que se cuenta para el estudio.

Y a partir de allí hacer una labor de preparación de los datos, para lograr un nivel óptimo del estado de la información.

Se ha identificado que la información está contenida en un archivo de Excel que se considera relevante como base para el desarrollo del modelo de predicción. Este archivo es tratado mediante el uso de la herramienta Google Colab.

Es una plataforma basada en la nube que permite a los usuarios escribir y ejecutar código Python directamente en su navegador. Está diseñada para facilitar el desarrollo de proyectos de aprendizaje automático y análisis de datos, ofreciendo un entorno preconfigurado que incluye bibliotecas populares como TensorFlow, PyTorch, Keras, y muchas otras, sin necesidad de instalación local.

4.5. Colab para el Tratamiento de Datos en Procesamiento de Lenguaje Natural (PLN)

En el contexto del PLN, Google Colab se convierte en una herramienta poderosa debido a varias características clave:

Facilidad de Uso: proporciona un entorno accesible para la experimentación con diferentes técnicas de PLN. Es ideal tanto para principiantes como para expertos, ya que permite ejecutar código en tiempo real y ver los resultados de inmediato.

Recursos Computacionales: acceso gratuito a GPUs y TPUs, lo cual es particularmente útil para entrenar modelos complejos de PLN que requieren grandes volúmenes de datos y poder de procesamiento. Esto facilita el trabajo con redes neuronales profundas y otros algoritmos intensivos en recursos.

Integración con Google Drive: Los usuarios pueden guardar sus

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes UNViMe Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

proyectos y datos directamente en Google Drive, facilitando el manejo y la persistencia de datos. Esta característica es útil para almacenar corpus de texto, modelos entrenados, y resultados de análisis.

Colaboración en Tiempo Real: Similar a Google Docs, Colab permite que múltiples usuarios trabajen en el mismo cuaderno de notas al mismo tiempo, lo que facilita la colaboración en proyectos de PLN, ya sea en un entorno académico, de investigación o profesional.

Acceso a Librerías de PLN: viene preconfigurado con una serie de bibliotecas esenciales para PLN, como NLTK, SpaCy, Gensim, y Hugging Face Transformers. Esto permite a los usuarios empezar a trabajar en tareas de procesamiento de texto sin preocuparse por las configuraciones iniciales. Algunas de estas librerías las utilizaremos más adelante.

Preprocesamiento y Análisis de Texto: es ideal para realizar tareas de preprocesamiento de texto, como tokenización, lematización, eliminación de stopwords, y otras transformaciones necesarias antes de aplicar modelos de PLN. Los usuarios pueden escribir código para limpiar y preparar los datos, y luego utilizar ese texto procesado como entrada para modelos de clasificación, generación de texto, análisis de sentimientos, entre otros.

Visualización de Datos: soporta bibliotecas de visualización como Matplotlib y Seaborn, que pueden ser utilizadas para explorar y analizar las características del texto de forma gráfica, ayudando a entender mejor los datos antes de aplicar técnicas de PLN.

Como mencionamos anteriormente vamos a utilizar la herramienta colab, también para una visualización y una primera interpretación de los datos nos vamos a apoyar en SweetViz.

Sweetviz es una biblioteca de Python diseñada para facilitar el análisis exploratorio de datos (EDA). Su principal característica es la generación automática de informes visuales detallados y comprensibles que permiten a los usuarios obtener una visión general rápida de sus conjuntos de datos.

```
1 import pandas as pd
2
3 data = pd.read_excel('Porqueestudiamosinformatica_encuesta_base_publica.xlsx')
4 data.head(10)
5
6 df= pd.DataFrame(data)
7 df
```

Figura 2 - Importación de dataset en formato xlsx

```
[ ]  1 import sweetviz as sv
     2
     3 # Analyzing the dataset without pairwise analysis
     4 advert_report = sv.analyze(df, pairwise_analysis='off')
     5 # Display the report
     6 advert_report.show_html('Advertising.html')
```

Figura 3 - Uso de biblioteca Sweetviz

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

```
[ ]  1 from google.colab import files
     2
     3 files.download('Advertising.html')
     4
```

Figura 4 - Generación de archivo formato HTML

Para una mayor interpretabilidad y explicabilidad mostramos los gráficos generados por SweetViz, utilizamos github como plataforma ya que nos permite mostrar a todos las instancias de una manera más organizada, nombre del archivo ***Estadísticas.pdf***.

https://github.com/Elio-Nicolas/Practica-Profesional-Supervisada

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

En esta etapa de recolección y exploración inicial de datos pudimos determinar el tamaño de la muestra a la cual vamos a analizar.
Esta integración de datos está contenida en un archivo .xlxs la cual tiene un tamaño en cantidad de 205 columnas que en nuestro estudio denominaremos características o features y de 1211 filas que en el mismo sentido llamaremos instancias. El tipo de muestra está relacionado a la educación universitaria, estas encuestas abarcan diferentes aspectos de un estudiante como lo es información demográfica entre otras. para el análisis se importó el archivo a la herramienta Google Colab para hacer uso de algunas funciones con el objetivo de poder realizar observaciones, además se logró más detalles de la información y la manera de relacionarse.
Otra herramienta que se utilizo fue SweetViz la cual nos da una visión más clara y detallada de los tipos de datos que componen la información.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Podemos observar un porcentaje elevado de características de tipo categóricas las cuales nos pueden presentar algunas complicaciones a la hora de trabajar con ML:
Trabajar con características categóricas en análisis de datos y modelos de aprendizaje automático puede presentar varias complicaciones debido a la naturaleza no numérica de estos datos. Recordemos que todos los modelos de ML deben ser entrenados con datos numéricos y si las características tienen naturaleza textual estas deben ser convertidas.

a. **Codificación**

- **Conversión a Datos Numéricos**: Los modelos de aprendizaje automático generalmente requieren datos numéricos. Por lo tanto, las características categóricas deben ser codificadas en un formato numérico, lo que introduce complejidades.
  - **One-Hot Encoding**: Transforma cada categoría en una columna binaria (0 o 1), lo que puede aumentar considerablemente la dimensionalidad del conjunto de datos si la característica tiene muchas categorías.
  - **Label Encoding**: Asigna un número entero a cada categoría, pero

puede introducir relaciones ordinales no deseadas entre categorías.

b. **Alta Dimensionalidad**

- **Curse of Dimensionality**: Con técnicas como One-Hot Encoding, un solo atributo categórico con muchas categorías puede aumentar significativamente el número de columnas en tu conjunto de datos, lo que puede llevar a problemas de sobreajuste y hacer que los modelos sean menos eficientes.
- **Esparcidad de Datos**: La creación de muchas columnas puede resultar en un conjunto de datos disperso, donde muchas entradas son cero, lo que complica la tarea de los modelos de aprendizaje y afecta su rendimiento.

c. **Relaciones entre Categorías**

- **Dificultad en Capturar Relaciones**: Algunas categorías pueden tener una relación implícita (por ejemplo, los días de la semana tienen una relación temporal), pero las técnicas de codificación básica como One-Hot Encoding no capturan estas relaciones.
- **Orden Incorrecto**: Usar Label Encoding para variables que no son ordinales puede introducir un orden artificial que no tiene sentido, lo que puede confundir a los modelos.

d. **Manejo de Categorías Nuevas o Desconocidas**

- **Nuevas Categorías en Datos de Prueba**: Si se encuentran categorías nuevas en los datos de prueba que no estaban presentes en los datos de entrenamiento, el modelo podría no saber cómo manejarlas, lo que puede llevar a errores o a la necesidad de técnicas adicionales como "handle unknown" en encoding.

e. **Modelos Específicos**

- **Compatibilidad con Modelos**: No todos los modelos manejan características categóricas de la misma manera. Por ejemplo, los árboles de decisión pueden manejar categorías directamente, pero otros modelos como las redes neuronales requieren codificación previa.
- **Pérdida de Interpretabilidad**: En algunos casos, codificar categorías puede hacer que el modelo sea menos interpretable, especialmente cuando se utilizan técnicas complejas de codificación.

f. **Imbalance o Desbalance**

- **Categorías Desbalanceadas**: Cuando una categoría es mucho más frecuente que las otras, puede llevar a que el modelo se sesgue hacia la categoría dominante, ignorando las otras.

Las características categóricas requieren atención cuidadosa en su manejo para asegurar que se extraigan los patrones adecuados sin introducir errores o aumentar la complejidad innecesaria. Las técnicas de codificación, selección de modelos y manejo de categorías nuevas son aspectos clave a considerar para trabajar eficazmente con estos tipos de datos

Téc. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes UNViMe Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

5. Limpieza de datos y Procesamiento Léxico

Para esta etapa el objetivo es realizar una limpieza de aquellos datos que tienen altas posibilidades de hacer fallar el modelo de ML o que los datos provoquen sesgos al mismo, es por eso por lo que por medio de funciones nativas de Python y otras que son propias de librerías se tratara de lograr este fin.

Valores del dataframe sin ningún tratamiento, podemos observar los campos de cada instancia y sus características.

Antes de continuar con el tratamiento de los datos mediante técnicas puramente NLP vamos a hacer una reducción de dimensionalidad del data frame el cual en una primera instancia observamos que predomina totalmente caracteristicas de tipo categórico lo cual señalamos que es un obstáculo para los modelos de ML, es por eso que debemos tratar estos datos además mejoramos la eficiencia computacional ya que no serán necesarios muchos cálculos debido a caracteristicas que son irrelevantes para el modelo.

Lo primero que vamos a hacer es una eliminación de los valores Null que tengan una cantidad mayor a un 30% del total de valores existentes

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

```
[ ]  1 # Calculo del porcentaje de valores nulos por columna
     2 percent_missing = df.isnull().mean() * 100
     3
     4 # Filtro de las columnas con menos del 30% de valores nulos
     5 columns_to_keep = percent_missing[percent_missing < 30].index
     6
     7 # Creacion de un nuevo DataFrame con solo esas columnas
     8 df = df[columns_to_keep]
     9
    10 df=df.drop('id',axis=1)
    11
```

Figura 5 - eliminación de valores Null e ID

Luego de esa eliminación podemos pensar en características que no tienen importancia para el aprendizaje automático, por ejemplo, el ID que es un identificador numérico el cual no aporta información al modelo. Luego de esta eliminación redujimos el dataframe de 205 caracteristicas a 85.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Luego de esta eliminación de ID nos queda un data frame de 84 características, con estas caracteristicas sin datos que no sean relevantes podemos aplicar técnicas de NLP.

Primero vamos a enumerar algunas de las librerías, técnicas, funciones y herramientas:

```
[6]  1 import re
     2 import pandas as pd
     3
     4 # Función para eliminar caracteres especiales y emojis, preservando acentos
     5 def eliminar_caracteres_especiales(texto):
     6     if isinstance(texto, str):  # Verifica si el valor es una cadena de texto
     7         # Eliminar emojis y otros caracteres no ASCII
     8         texto_sin_emojis = re.sub(r'[^\x00-\x7F\u00C0-\u017F\s]', '', texto)
     9         # Mantener letras y números, incluyendo acentos y caracteres especiales comunes
    10         texto_limpio = re.sub(r'[^a-zA-Z0-9\u00C0-\u017F\s]', '', texto_sin_emojis)
    11         return texto_limpio
    12     else:
    13         return texto  # Si no es una cadena, regresa el valor sin cambios
    14
    15 # Aplicar la función a todas las columnas del DataFrame
    16 df_limpio = df.applymap(eliminar_caracteres_especiales)
    17
    18 # Mostrar un resumen del DataFrame limpio
    19 df_limpio
    20
```

Figura 6 - Uso de la Librería 're' de Python

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

En la imagen se observa la importación de la librería Pandas para la utilización de la estructura de datos "Data frame" y de 're' que es una biblioteca estándar de Python que proporciona herramientas para trabajar con expresiones regulares.
Una vez que se realizó una limpieza de algunos caracteres como lo emojis, caracteres especiales, etc. que no son útiles para el uso y el aprendizaje del modelo, podemos aumentar la limpieza implementando algunas técnicas como es la transformación de mayúsculas a minúsculas, eliminación de espacios adicionales, etc.

```python
import re
import pandas as pd

# Función para eliminar caracteres especiales, emojis, y espacios en blanco adicionales, preservando acentos
def eliminar_caracteres_especiales(texto):
    if isinstance(texto, str):  # Verifica si el valor es una cadena de texto
        # Eliminar emojis y otros caracteres no ASCII
        texto_sin_emojis = re.sub(r'[^\x00-\x7F\u00C0-\u017F\s]', '', texto)
        # Mantener letras y números, incluyendo acentos y caracteres especiales comunes
        texto_limpio = re.sub(r'[^a-zA-ZáéíóúÁÉÍÓÚüÜñÑ\s]', '', texto_sin_emojis)
        # Cambio de mayúsculas a minúsculas
        texto_limpio = texto_limpio.lower()
        # Eliminar espacios en blanco adicionales
        texto_limpio = re.sub(r'\s+', ' ', texto_limpio).strip()
        return texto_limpio
    else:
        return texto  # Si no es una cadena, regresa el valor sin cambios

# Aplicar la función a todas las columnas del DataFrame
df_limpio = df.applymap(eliminar_caracteres_especiales)

# Mostrar un resumen del DataFrame limpio
print(df_limpio.head(10))
```

Ing. Alejandro Pablo Ros
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Figura 7 - Uso de 'lower' y 'sub'

5.1. Técnicas y Herramientas

En el NLP, existen diversas herramientas y técnicas que facilitan el análisis de grandes cantidades de texto de manera eficiente. La selección adecuada de las herramientas depende del objetivo y la naturaleza del análisis. En este contexto, exploraremos algunas de las herramientas más utilizadas, junto con procesos de normalización y modos de representación que permiten optimizar el procesamiento de textos, además de incluir una novedad en cuanto a la búsqueda difusa de strings con thefuzz.

5.2. Expresiones Regulares con re

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Las expresiones regulares son una herramienta poderosa en la limpieza y normalización de datos textuales. La biblioteca re de Python permite identificar patrones complejos en texto, como fechas, direcciones de correo electrónico, URLs, o números telefónicos. Las expresiones regulares también son esenciales para eliminar caracteres no deseados, como puntuación, emojis o etiquetas HTML. Esto ayuda a estructurar y normalizar el texto, preparándolo para su posterior análisis. Su flexibilidad y potencia las convierten en una herramienta indispensable en muchas fases del procesamiento del lenguaje natural.

5.3. Búsqueda Difusa de Strings con thefuzz

Una herramienta novedosa en el campo del NLP es la búsqueda difusa de strings mediante la biblioteca thefuzz, que se basa en el algoritmo de Levenshtein. Este tipo de búsqueda es útil cuando se

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

necesita comparar cadenas de texto que pueden no coincidir exactamente, pero son similares. thefuzz permite realizar comparaciones entre strings y medir la similitud entre ellos, una tarea útil en aplicaciones como la limpieza de datos, la detección de duplicados, o la corrección automática de errores tipográficos. Por ejemplo, la palabra "procesamiento" y "procesamiento" podrían ser reconocidas como similares, con una puntuación de coincidencia que indica su similitud. Esta técnica es particularmente valiosa cuando se trabaja con grandes corpus de datos no estructurados que contienen errores comunes de escritura.

5.4. Expresiones Regulares y Normalización

Las expresiones regulares (RegEx) son una herramienta esencial en diversas disciplinas de la ciencia de la computación, especialmente en el análisis de datos y el NLP. Estas permiten buscar, identificar y manipular patrones en cadenas de texto de manera extremadamente precisa y eficiente. A continuación, se detallan algunas de las aplicaciones más comunes de las expresiones regulares en NLP, así como su relevancia para otras áreas tecnológicas y científicas.

5.5. Identificación de patrones

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

En el campo del NLP, uno de los usos más frecuentes de las expresiones regulares es la identificación de patrones en grandes corpus de texto. Estos patrones pueden ser estructuras como fechas, números de teléfono, direcciones de correo electrónico, URLs, entre otros formatos estándar. Al definir un patrón con expresiones regulares, los analistas pueden identificar fácilmente estos elementos dentro de conjuntos de datos desestructurados, lo que es útil en tareas como la extracción de datos o la clasificación de información.

Por ejemplo, si un sistema necesita identificar todas las direcciones de correo electrónico en un conjunto de correos electrónicos, una expresión regular puede definir el patrón general que deben seguir las direcciones de correo (e.g., texto seguido de "@" y un dominio). Esto permite encontrar estos elementos en textos largos sin necesidad de analizarlos manualmente.

5.6. Extracción de información

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Además de identificar patrones, las expresiones regulares permiten extraer información relevante de un texto de manera rápida y eficiente. En el contexto de un análisis de deserción estudiantil en carreras de computación, las expresiones regulares pueden ser de gran utilidad para extraer datos críticos sobre los estudiantes, como motivos de abandono, problemas académicos, o incluso para detectar tendencias demográficas que puedan influir en la deserción. Por ejemplo, se podrían utilizar para identificar frases específicas que los estudiantes mencionan en encuestas o entrevistas, como "problemas financieros", "dificultades con las materias" o "falta de motivación", ayudando a las instituciones a enfocar sus esfuerzos en los aspectos clave que afectan la permanencia de los estudiantes.

Este tipo de extracción estructurada de información es crucial para automatizar el análisis de grandes volúmenes de datos y evitar la necesidad de una intervención manual en la revisión de textos. En un conjunto de datos con miles de respuestas abiertas de estudiantes

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

que describen sus experiencias académicas, las expresiones regulares pueden identificar rápidamente palabras o frases como "fracaso en exámenes", "sobrecarga académica" o "problemas personales", lo que facilita una clasificación automática de los estudiantes en función de los motivos mencionados.

Por ejemplo, en la minería de datos educativa, las expresiones regulares pueden emplearse para extraer información específica, como el año de ingreso, la cantidad de materias cursadas, o el porcentaje de materias aprobadas. Este tipo de datos es invaluable para identificar estudiantes en riesgo de abandonar la carrera. Además, en tareas de análisis más avanzadas, como la clasificación de estudiantes en riesgo, las expresiones regulares pueden detectar indicadores tempranos de deserción, como referencias a la falta de interés en el campo de estudio o dificultades con temas específicos de programación o matemáticas.

En resumen, las expresiones regulares ofrecen una herramienta poderosa para automatizar el análisis de datos textuales en el contexto de la deserción estudiantil. Permiten extraer rápidamente información valiosa de grandes volúmenes de texto, lo que hace más eficientes las tareas de identificación de patrones, problemas y tendencias. Esto resulta fundamental para desarrollar modelos predictivos precisos que puedan ayudar a las instituciones educativas a tomar medidas proactivas para reducir la deserción y mejorar la retención de los estudiantes en carreras de computación.

5.7. Limpieza de datos

En el NLP, la limpieza de datos es una etapa fundamental para garantizar que el modelo de machine learning funcione correctamente. Los datos textuales suelen contener mucho "ruido", como caracteres especiales, espacios en blanco adicionales, etiquetas HTML o emojis. Las expresiones regulares son una herramienta eficiente para eliminar estos elementos, mejorando la calidad del texto y permitiendo que los algoritmos posteriores se enfoquen en los datos relevantes.

Un ejemplo común de limpieza de datos con expresiones regulares es la eliminación de puntuación o la normalización de espacios en blanco en un corpus de texto. Al aplicar expresiones regulares, es posible reducir el tamaño del conjunto de datos y eliminar elementos irrelevantes que podrían introducir sesgos o errores en el análisis posterior.

5.8. Transformación de texto

Otra funcionalidad de las expresiones regulares es la transformación del texto. Esta técnica es útil cuando se necesita modificar el formato de los datos para adaptarlos a un análisis posterior o para unificar diferentes formatos dentro de un mismo corpus. Un ejemplo de esto es el reformateo de fechas en diversos formatos, o la reestructuración de direcciones, eliminando redundancias o reorganizando la información para que sea consistente a lo largo de todo el conjunto de datos.

Imagina un sistema que recibe fechas en diferentes formatos (por ejemplo, “12/09/2023”, “Sept 12, 2023” o “2023-09-12”). Utilizando

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

expresiones regulares, es posible identificar estos formatos y transformarlos automáticamente en una representación unificada (e.g., "YYYY-MM-DD").

5.9. Automatización

Las expresiones regulares juegan un papel crucial en la automatización de tareas repetitivas dentro del NLP, facilitando una serie de operaciones que de otro modo serían tediosas y propensas a errores. Su capacidad para identificar patrones específicos en el texto no solo ahorra tiempo, sino que también reduce significativamente los errores humanos en la manipulación de datos. Por ejemplo, en una base de datos extensa, la corrección automática de errores tipográficos puede ser lograda mediante el uso de expresiones regulares que buscan y reemplazan palabras mal escritas con sus versiones correctas.

Este tipo de automatización no solo se limita a la corrección de errores, sino que también abarca tareas como la normalización de datos y la extracción de información. En la normalización, las expresiones regulares ayudan a estandarizar datos, asegurando que todas las fechas, números de teléfono, o direcciones de correo electrónico sigan un formato uniforme, lo que facilita su manejo y análisis posterior. En la extracción de información, permiten localizar patrones específicos, como identificadores de documentos o detalles de contacto, en grandes volúmenes de texto.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

La capacidad de las expresiones regulares para limpiar y preparar datos es igualmente valiosa. En el proceso de limpieza de datos, pueden eliminar caracteres no deseados, como signos de puntuación erróneos o caracteres especiales que no aportan valor al análisis, así como reemplazar patrones problemáticos por versiones más adecuadas. Esta función es especialmente útil en el procesamiento de datos de entrada en sistemas donde la calidad y la integridad de la información son fundamentales.

Además, la automatización con expresiones regulares se convierte en una herramienta indispensable en sistemas que gestionan grandes cantidades de texto en tiempo real, como los motores de búsqueda y las plataformas de redes sociales. En estos entornos, la rapidez en la identificación y corrección de errores es crucial para mantener la calidad de los datos y ofrecer una experiencia de usuario sin interrupciones. La habilidad de las expresiones regulares para manejar estas tareas de manera eficiente asegura que los datos sean precisos y útiles, lo que es vital para la operatividad de estos sistemas y para la satisfacción del usuario final.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

En resumen, las expresiones regulares proporcionan una forma poderosa y flexible de automatizar el procesamiento y análisis de texto, permitiendo una gestión más eficiente de grandes volúmenes de información y mejorando la calidad general de los datos en sistemas complejos y de alta demanda.

5.10. Aplicación en Python con re

La biblioteca re de Python proporciona las herramientas necesarias para implementar expresiones regulares en el contexto de NLP. Por ejemplo, una tarea común es remover números, signos de puntuación,

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

emojis, o caracteres no ASCII de un texto. Mediante re, se puede definir un patrón que elimine estos elementos de manera eficiente. Una función en Python para realizar esta tarea podría ser:

```python
import re
import pandas as pd

# Función para eliminar caracteres especiales y emojis, preservando acentos
def eliminar_caracteres_especiales(texto):
    if isinstance(texto, str):  # Verifica si el valor es una cadena de texto
        # Eliminar emojis y otros caracteres no ASCII
        texto_sin_emojis = re.sub(r'[^\x00-\x7F\u00C0-\u017F\s]', '', texto)
        # Mantener letras y números, incluyendo acentos y caracteres especiales comunes
        texto_limpio = re.sub(r'[^a-zA-ZáéíóúÁÉÍÓÚüÜñÑ\s]', '', texto_sin_emojis)
        # Cambio de mayusculas a minusculas
        texto_limpio = texto_limpio.lower()
        return texto_limpio
    else:
        return texto  # Si no es una cadena, regresa el valor sin cambios

# Aplicar la función a todas las columnas del DataFrame
df_limpio = df.applymap(eliminar_caracteres_especiales)

# Mostrar un resumen del DataFrame limpio
print(df_limpio.head(10))

```

Figura 8 – función para eliminar caracteres no ASCII

Esta función elimina todos los caracteres no pertenecientes al conjunto ASCII, convierte el texto a minúsculas y elimina la puntuación. El resultado es un texto más limpio y listo para ser procesado por algoritmos de machine learning o análisis de sentimientos.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

5.11. Innovación en la Normalización de Texto

Como complemento a las técnicas anteriores, es importante mencionar la inclusión de herramientas más avanzadas en la normalización de texto. Por ejemplo, la integración de modelos basados en inteligencia artificial, como el uso de embeddings de palabras (Word2Vec, GloVe) o transformers (BERT), permite mejorar la semántica y el significado de los textos más allá de lo que las expresiones regulares pueden lograr. Si bien las expresiones regulares son potentes para manipular y limpiar texto, estas nuevas técnicas permiten comprender mejor el contexto, lo que resulta en un análisis mucho más profundo y preciso. Continuaremos con estas herramientas en capítulos posteriores

Conclusión

Las expresiones regulares son una herramienta indispensable en el procesamiento de lenguaje natural y en muchas otras áreas de la ciencia de datos. Permiten identificar patrones, extraer información, limpiar texto y automatizar tareas repetitivas, mejorando así la eficiencia de los análisis textuales. En combinación con bibliotecas como re en Python, proporcionan una solución flexible y potente para abordar los desafíos del procesamiento de grandes volúmenes de datos textuales. Además, al combinar estas técnicas tradicionales con modelos más avanzados de inteligencia artificial, el análisis de texto puede alcanzar nuevos niveles de precisión y profundidad, optimizando tareas como la clasificación de textos, la extracción de entidades o el análisis de sentimientos.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

5.12. Informe Limpieza de datos y Procesamiento Léxico

En el proceso de limpieza de datos y procesamiento léxico, el objetivo principal es reducir la dimensionalidad y mejorar la calidad de los

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Ghiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

datos que se emplearán en los modelos de Machine Learning (ML). Al principio, se llevó a cabo una eliminación de aquellas columnas que contenían más del 30% de valores nulos. Esta acción permitió reducir la cantidad de información incompleta o inconsistente que podría generar ruido en el modelo. Asimismo, se identificaron características irrelevantes para el aprendizaje automático, como los identificadores numéricos (ej., IDs), los cuales, al no aportar información predictiva, fueron eliminados. Esta reducción en la cantidad de características no solo mejora la eficiencia computacional, sino que también reduce el riesgo de que el modelo se vea afectado por datos que no son útiles para el proceso de predicción.

Un paso esencial dentro de esta fase fue la limpieza de los textos mediante expresiones regulares. A través de la librería re de Python, se identificaron y eliminaron patrones que no eran relevantes, tales como números, signos de puntuación, emojis y otros caracteres especiales. El texto se normalizó aplicando transformaciones, como la conversión de mayúsculas a minúsculas, lo cual es clave para reducir la variabilidad en el vocabulario y evitar que palabras idénticas en su raíz, pero con distinta capitalización, se consideren diferentes. Además, se eliminaron espacios adicionales y otros caracteres no pertenecientes al conjunto ASCII, excepto aquellos con acentos o caracteres especiales que son comunes en español y pueden ser relevantes para el análisis de texto. Esta normalización permitió mejorar la calidad del corpus textual al eliminar el ruido y mantener únicamente la información relevante.

Las expresiones regulares también jugaron un papel fundamental en la identificación de patrones dentro del texto. Por ejemplo, se emplearon para detectar y extraer información estructurada, como fechas, correos electrónicos o URLs. Esta extracción de información facilita el análisis posterior, ya que se puede trabajar con elementos organizados que son más útiles para ciertas tareas, como la clasificación o el análisis de sentimientos.

En cuanto a la automatización de procesos, las expresiones regulares permitieron agilizar tareas repetitivas dentro del NLP, como la limpieza de grandes volúmenes de texto, lo que optimiza el tiempo de procesamiento y reduce la posibilidad de errores. Por otro lado, la conversión de texto no estructurado a un formato más estándar mediante expresiones regulares permitió unificar diferentes formatos de datos dentro del corpus textual, simplificando el trabajo posterior del modelo.

Un aspecto adicional para destacar es que los datos categóricos, como mencionamos anteriormente, aunque no explícitamente tratados en este punto, deben ser convertidos a un formato numérico para que los modelos de ML puedan interpretarlos. Esto generalmente se logra mediante técnicas como One-Hot Encoding o Label Encoding. Estas transformaciones son cruciales para asegurar que los modelos puedan procesar y aprender de los datos de manera eficiente.

En conclusión, el proceso de limpieza y preprocesamiento de los datos textuales no solo mejoró la calidad de los datos, sino que

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

también permitió que el modelo trabaje de manera más eficiente al deshacerse de información irrelevante o problemática. La reducción de dimensionalidad, junto con la eliminación de caracteres especiales y la normalización de texto, fueron pasos fundamentales para garantizar que el modelo de ML pueda enfocarse únicamente en los datos más relevantes, mejorando tanto el rendimiento como la precisión en el proceso de aprendizaje.

6. Tokenización, Lematización y Stemmig

Una vez terminada la etapa de eliminación de caracteres especiales y de cambio de mayúsculas a minúsculas, seguimos con la normalización del texto, podemos pensar en utilizar algunas técnicas como son:

En el NLP, la tokenización, la lematización y el stemming que son técnicas fundamentales y que se utilizan para preparar y transformar texto antes de aplicar modelos de análisis. Cada técnica cumple un propósito específico, y la elección entre ellas depende del objetivo del análisis y del equilibrio entre la precisión y la eficiencia. A continuación, se desarrolla una investigación detallada sobre estas técnicas, explorando sus características, aplicaciones y comparaciones.

6.1. Tokenización

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

El objetivo principal de la tokenización es dividir un texto en unidades más pequeñas, generalmente palabras o frases, denominadas "tokens". Esta fragmentación facilita el análisis del texto, ya que cada token puede ser procesado de manera individual. En el contexto de un análisis de **deserción educativa**, la tokenización puede ayudar a descomponer los datos textuales de los estudiantes (como respuestas a encuestas o registros académicos) en unidades más manejables, lo que permite analizar características demográficas o académicas clave de forma detallada.

La tokenización puede realizarse a diferentes niveles, como a nivel de palabra, oración o incluso caracteres, dependiendo del tipo de análisis que se desea llevar a cabo. Por ejemplo, en el análisis de factores asociados a la **edad**, el **año de ingreso**, o el **número de materias cursadas** por los estudiantes, cada uno de estos aspectos puede ser transformado en tokens que representen estas variables específicas. Esto permite un análisis más preciso de la relación entre las características individuales de los estudiantes y su probabilidad de deserción.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Sin embargo, es importante tener en cuenta que la tokenización no siempre maneja bien el contexto. En el análisis de deserción, donde factores como el **estado económico** o la **situación laboral** del estudiante pueden estar reflejados en respuestas textuales, la tokenización simple puede dividir frases compuestas o ignorar las sutilezas en las respuestas. Por ejemplo, expresiones como "trabajo a tiempo completo" o "dificultades financieras" pueden ser divididas de manera incorrecta, afectando la comprensión de los factores que contribuyen a la deserción.

Otro aspecto clave de la tokenización es que las reglas pueden variar dependiendo del idioma y del contexto específico del análisis. En el

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

caso de los estudiantes de carreras de computación, donde muchas respuestas o descripciones pueden incluir términos técnicos, es esencial que la tokenización no solo divida correctamente las palabras, sino que también sea capaz de manejar adecuadamente términos compuestos como "ciencia de datos", "ingeniería de software" o "desarrollo web". Si se realiza una tokenización errónea, estos términos importantes podrían perder su significado en el análisis.

Por ejemplo, en una frase como "El estudiante de segundo año enfrenta dificultades con su carga de materias y trabajo a tiempo parcial", una tokenización adecuada identificaría correctamente términos clave como "segundo año", "carga de materias" y "tiempo parcial". De esta manera, el análisis podría enfocarse en la relación entre estas variables y la deserción estudiantil, en lugar de perder información valiosa debido a una segmentación incorrecta de los datos.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Región de la universidad	Antigüedad de la universidad	Tamaño de la universidad
['Cuyo']	['Intermedia']	['Mediana']
['Centro']	['Intermedia']	['Chica']
['Centro']	['Intermedia']	['Chica']
['Centro']	['Intermedia']	['Chica']
['Centro']	['Intermedia']	['Grande']
['Centro']	['Intermedia']	['Grande']
['Centro']	['Intermedia']	['Chica']

Figura – 10 proceso de tokenizado

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

En resumen, la tokenización permite descomponer los datos textuales en elementos procesables, pero es crucial que las reglas de tokenización se adapten al contexto educativo y las características demográficas y académicas de los estudiantes para garantizar un análisis más eficaz de los factores asociados a la deserción.

6.2. Lematización

La lematización es una técnica fundamental en el procesamiento de lenguaje natural que busca reducir las palabras a su forma base o "lema", lo que permite mantener la coherencia semántica en el análisis de texto. En el contexto de la **deserción educativa**, la lematización resulta especialmente útil al analizar respuestas textuales o registros académicos de los estudiantes, ya que ayuda a unificar términos que pueden variar en su forma dependiendo de la conjugación verbal o el uso gramatical, pero que tienen el mismo significado.

Por ejemplo, en un análisis de **datos académicos** de estudiantes en carreras de computación, es común encontrar términos como "aprobó", "aprobando" o "aprobar". Aplicar la lematización permitirá reducir todas estas variaciones a su forma base, "aprobar", facilitando un análisis más coherente de los patrones relacionados con el desempeño académico de los estudiantes. Este proceso es crucial cuando se quieren identificar factores que afectan la deserción, como

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

la **cantidad de materias aprobadas o reprobadas** a lo largo del tiempo, sin que la variación gramatical de las palabras distorsione los resultados.

A diferencia del stemming, que simplemente corta las palabras a su raíz sin tener en cuenta su contexto, la lematización ofrece un enfoque más preciso al considerar el papel gramatical y el significado dentro de la oración. En el caso de la deserción estudiantil, donde el análisis de factores como el **rendimiento académico** o el **estado emocional** del estudiante puede implicar una amplia variedad de conjugaciones verbales y estructuras sintácticas, la lematización es preferible porque preserva el significado exacto de las palabras. Por ejemplo, tanto "abandonó" como "abandonando" se lematizarán a "abandonar", unificando los conceptos de deserción independientemente del tiempo o la conjugación.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Sin embargo, la lematización tiene sus desafíos. Para lograr este proceso de manera efectiva, es necesario disponer de un modelo lingüístico o diccionario que sea capaz de identificar correctamente el lema de cada palabra, lo que implica **una mayor complejidad computacional**. En un análisis de deserción estudiantil, donde los datos pueden incluir una gran cantidad de texto relacionado con la **edad**, el **estado económico** o la **situación académica**, la lematización puede demandar recursos significativos, especialmente si se trata de un corpus extenso de datos.

A pesar de su alto costo computacional, la lematización sigue siendo una herramienta preferida cuando el objetivo es mantener la coherencia semántica. En el contexto educativo, esta técnica puede ser crucial para identificar tendencias de deserción relacionadas con el uso de ciertos términos en **encuestas de opinión** o **registros académicos**, lo que permite a los investigadores realizar análisis más precisos y generar modelos predictivos que consideren todas las formas posibles de una palabra. Por ejemplo, al analizar términos como "finalizar" o "completar", la lematización permitirá unificar variantes como "finalizó", "completó" o "finalizando", lo que facilita la comprensión de los factores que inciden en la decisión de un estudiante de completar o abandonar su carrera.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

En conclusión, la lematización juega un rol importante en los análisis textuales avanzados relacionados con la **deserción educativa**, ya que ayuda a preservar la coherencia semántica y permite un análisis más preciso de los factores clave. Si bien puede ser más costosa en términos computacionales, su capacidad para reducir la distorsión semántica la convierte en una técnica fundamental cuando se busca obtener resultados precisos y coherentes en estudios de deserción en estudiantes de **carreras de computación**.

Región de la universidad	Antiguedad de la universidad	Tamaño de la universidad
['cuyo']	['Intermedia']	['Mediana']
['Centro']	['Intermedia']	['Chica']
['Centro']	['Intermedia']	['Chica']
['Centro']	['Intermedia']	['Chica']

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

['Centro']	['Intermedia']	['grande']
['Centro']	['Intermedia']	['grande']

['Centro'] ['Intermedia'] ['Chica']

Figura – 11 proceso de lematizado

6.3. Stemming (Stemización)

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Por otro lado, el **stemming** o **stemización** es una técnica de procesamiento de texto que se enfoca en reducir las palabras a su raíz o "stem", eliminando prefijos y sufijos, sin tener en cuenta el contexto o las reglas gramaticales del idioma. En el análisis de **deserción estudiantil**, el stemming puede ser útil en ciertas aplicaciones rápidas donde la precisión semántica no es tan crucial, como al agrupar respuestas textuales para identificar temas generales relacionados con la deserción, pero puede generar desafíos en el análisis más detallado de los factores asociados a la deserción educativa.

Por ejemplo, en el caso de analizar las características académicas o demográficas de estudiantes de **carreras de computación**, el stemming puede tomar términos como "aprobando" o "aprobó" y reducirlos a una raíz común como "aprob". Si bien esto simplifica el análisis en ciertos contextos, como en la **clasificación rápida de datos** o la **identificación de patrones generales**, puede no ser lo suficientemente preciso cuando se requiere mantener la integridad del significado de las palabras. Al truncar las palabras de esta manera, se corre el riesgo de perder información importante sobre el **estado académico** o el **rendimiento** de los estudiantes, ya que no se respetan las variaciones gramaticales que pueden ser cruciales para entender el progreso de un estudiante en su carrera.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

El stemming es computacionalmente más eficiente que la lematización, ya que no requiere un modelo lingüístico que determine la forma base de las palabras, sino que simplemente recorta las palabras hasta su raíz. En un escenario donde se analizan grandes volúmenes de datos, como los registros académicos de un número elevado de estudiantes, esta técnica puede ser valiosa para realizar un procesamiento inicial rápido de los textos. Sin embargo, en el contexto de un análisis detallado de los factores de **deserción educativa**, donde es importante distinguir entre términos como "abandonando" y "abandonado", el stemming puede generar problemas, ya que ambos términos serían reducidos a una raíz similar sin diferenciar el tiempo verbal ni la situación específica del estudiante.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

En aplicaciones como la **clasificación automatizada de respuestas de encuestas** o el análisis de grandes volúmenes de textos, como los comentarios de estudiantes en evaluaciones o encuestas sobre su experiencia académica, el stemming puede ser una opción rápida y eficaz. Por ejemplo, al agrupar respuestas sobre las razones por las cuales un estudiante considera abandonar su carrera, el stemming puede simplificar el análisis al reducir palabras relacionadas, como "abandonando" y "abandono", a un mismo stem, lo que puede ayudar a identificar rápidamente tendencias generales. No obstante, para tareas más complejas, como la **predicción de la deserción basada**

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

en datos textuales, el stemming puede distorsionar el significado de las palabras, afectando la precisión del análisis.

Región de la universidad	Antiguedad de la universidad	Tamaño de la universidad
['cuy']	['intermedi']	['median']
['centr']	['intermedi']	['chic']
['centr']	['intermedi']	['chic']
['centr']	['intermedi']	['chic']
['centr']	['intermedi']	['grand']
['centr']	['intermedi']	['grand']
['centr']	['intermedi']	['chic']

Figura - 12 proceso de stemizacion

En resumen, el stemming es una técnica valiosa para aplicaciones rápidas y de menor demanda semántica, donde la precisión contextual no es crítica. Sin embargo, en el contexto de un análisis de **deserción estudiantil** en estudiantes de **carreras de computación**, donde se necesita un análisis profundo de las respuestas textuales relacionadas con características como el **rendimiento académico**, la **edad**, o la **situación económica**, la simplicidad del stemming puede ser una desventaja. Si el objetivo es entender de manera precisa los factores que influyen en la deserción, el stemming podría resultar insuficiente, dado que no preserva el contexto ni la estructura gramatical del lenguaje, lo que puede ser crucial para un análisis más detallado y preciso.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingenieria y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

6.4. Comparación y Aplicaciones

La **comparación entre la lematización y el stemming** revela que ambas técnicas tienen aplicaciones específicas y ventajas particulares dentro del procesamiento de lenguaje natural (PLN), y esta elección se vuelve especialmente relevante en el contexto de análisis de deserción estudiantil en **carreras de computación**. En primer lugar, la **tokenización** es siempre el paso inicial en el procesamiento de texto, ya que permite dividir el texto en unidades más pequeñas (tokens), como palabras, que luego pueden ser procesadas a través de técnicas más avanzadas como la lematización o el stemming.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Lematización, al preservar el contexto y la función gramatical de las palabras, se vuelve crucial cuando se quiere hacer un análisis profundo de los factores asociados con la deserción. Por ejemplo, al analizar respuestas textuales sobre el rendimiento académico de los estudiantes o sus expectativas sobre la carrera, sería preferible utilizar la lematización, ya que asegura que términos como "abandonando" o "abandonado" se unifiquen en su forma base ("abandonar") sin perder el significado específico asociado a la situación educativa del estudiante. Esto es fundamental cuando se desea identificar los **motivos específicos** que llevan a un estudiante de computación a abandonar su carrera, donde mantener la coherencia semántica del texto es clave para entender las relaciones entre las variables como **edad**, **carga académica**, o **situación económica**.

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Por el otro lado, el **stemming** es una técnica más rápida y menos precisa, ya que simplemente corta las palabras hasta su raíz, sin tener en cuenta las reglas gramaticales ni el contexto. Esta técnica puede ser valiosa en tareas más generales, como la **clasificación automática** de grandes volúmenes de texto, donde la velocidad es más importante que la precisión. En el análisisde grandes conjuntos de datos sobre estudiantes, donde la intención es obtener una visión global de patrones generales relacionados con el rendimiento o la deserción, el stemming puede reducir rápidamente el texto a formas más simples, como convertir "abandonando" y "abandonado" a la raíz "abandon". Sin embargo, esta simplificación puede ser problemática si se intenta realizar un análisis más detallado, ya que el stemming no diferencia entre las distintas formas gramaticales, lo que puede llevar a resultados menos precisos.

Por ejemplo, en un **análisis rápido** sobre respuestas textuales de estudiantes en una encuesta de satisfacción, el stemming puede ser suficiente para identificar términos relacionados con el abandono, sin necesidad de hacer un análisis semántico profundo. Sin embargo, si el objetivo es realizar una predicción precisa sobre qué estudiantes tienen más probabilidades de abandonar su carrera, la lematización será más adecuada, ya que permite capturar con mayor detalle la **relación entre las diferentes variables académicas** y demográficas de los estudiantes.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

En resumen, la **decisión entre lematización o stemming** en el análisis de deserción educativa dependerá del tipo de tarea que se esté llevando a cabo. Si el objetivo es mantener la precisión semántica y analizar en profundidad las causas detrás de la deserción en estudiantes de computación, la lematización será la opción más adecuada. Sin embargo, si el análisis es de alto volumen y el tiempo es un factor crítico, el stemming puede ser una opción válida para obtener resultados más rápidos, aunque con menor precisión en la representación del significado de las palabras. La elección de una u otra técnica depende, por tanto, del **equilibrio necesario entre velocidad y precisión** en cada situación.

7. Palabras frecuentes e infrecuentes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

En el campo del NLP, la limpieza y preparación de los datos textuales son fundamentales para garantizar que los modelos trabajen con información relevante y útil. Dos de los métodos más efectivos para lograrlo son la **eliminación de stop words** y la **aplicación de un filtro de frecuencia**. Ambas técnicas mejoran la precisión y eficiencia de los modelos de machine learning al reducir el ruido y el costo computacional.

7.1. Eliminación de Stop Words

Dentro de las tareas relacionadas con el NLP, se utilizó la tokenización para segmentar los textos en palabras individuales, también llamadas tokens. Esto permitirá aplicar técnicas más avanzadas, como la eliminación de stopwords (palabras comunes como "de", "y", "que" que no aportan significado semántico) y el filtrado de términos de baja frecuencia, optimizando aún más el

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

contenido que será procesado por los modelos de ML

Las **stop words** son aquellas palabras comunes en un idioma que, aunque esenciales para la estructura y la fluidez del lenguaje, no aportan un valor semántico significativo en tareas de análisis de texto, especialmente cuando se busca identificar **patrones** o **factores clave** en fenómenos como la **deserción estudiantil** en estudiantes de **carreras de computación**. Estas palabras suelen incluir artículos, preposiciones, conjunciones y pronombres, tales como "el", "de", "la", "en", "y", "a", "que", entre otras. Aunque son importantes para la **construcción gramatical** del texto, en el análisis de datos se eliminan para centrar la atención en las palabras que realmente aportan información relevante.

Por ejemplo, si se analiza un conjunto de respuestas textuales en una encuesta dirigida a identificar los **motivos de abandono** de los estudiantes, eliminar las stop words permite que las palabras más importantes, como **"abandono"**, **"dificultad"**, **"financiero"** o **"estrés"**, sean las que dominen el análisis. Esto facilita la **reducción de la dimensionalidad** del conjunto de datos, lo que permite que los modelos predictivos o de clasificación se centren en las palabras más significativas para el problema que se está abordando, en lugar de perderse en palabras que no añaden valor a la interpretación del fenómeno.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Por otro lado, es fundamental adaptar la lista de stop words al **contexto** de análisis. En el caso de estudiantes de computación, palabras como "proyecto", "materia", o "curso" podrían ser consideradas stop words en un contexto más general, pero en un análisis de deserción, estos términos podrían tener un peso significativo, ya que están directamente relacionados con el **desempeño académico** y las **expectativas** del estudiante. Esto sugiere que las stop words no son universales y deben ajustarse según la naturaleza de los datos y los objetivos del análisis.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

La eliminación de stop words también ayuda a **reducir el ruido** en los datos. En un análisis de deserción, eliminar términos como "de" o "que" permite que los modelos se concentren en términos más predictivos, como **"abandono", "fracaso"**, o **"carga académica"**. Sin este proceso, las palabras comunes y de poca relevancia saturarían el análisis, haciendo que sea más difícil identificar las palabras clave que están vinculadas a los motivos por los cuales un estudiante podría estar considerando dejar su carrera.

Además, en el análisis de textos largos, como respuestas abiertas a encuestas o entrevistas sobre la **experiencia académica**, la eliminación de stop words acelera el procesamiento y mejora la eficiencia del análisis. Esto es crucial cuando se manejan grandes volúmenes de datos textuales, como comentarios de estudiantes sobre sus **dificultades** en la carrera, sus **expectativas laborales**, o su **percepción de la carga académica**. Al eliminar las stop words, se mejora la capacidad de los modelos para identificar patrones y realizar predicciones más precisas sobre los factores que contribuyen a la deserción.

En conclusión, la eliminación de stop words es una técnica clave en

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

el **preprocesamiento de datos textuales**, especialmente en el análisis de fenómenos como la deserción estudiantil. Al reducir el conjunto de palabras analizadas a aquellas que realmente aportan valor informativo, se mejora la eficiencia de los modelos predictivos y se obtiene un enfoque más claro sobre los factores que influyen en la decisión de los estudiantes de computación de **abandonar sus estudios**. Sin embargo, es importante ajustar la lista de stop words al **dominio específico** del análisis para no eliminar palabras que podrían ser clave para el entendimiento del problema en cuestión.

Descripción de la universidad
['Universidad', 'Cuyo', ',', 'Intermedia', 'matrícula', 'Mediana']
['Universidad', 'Centro', ',', 'Intermedia', 'matrícula', 'Chica']
['Universidad', 'Centro', ',', 'Intermedia', 'matrícula', 'Chica']
['Universidad', 'Centro', ',', 'Intermedia', 'matrícula', 'Chica']
['Universidad', 'Centro', ',', 'Intermedia', 'matrícula', 'Grande']
['Universidad', 'Centro', ',', 'Intermedia', 'matrícula', 'Grande']
['Universidad', 'Centro', ',', 'Intermedia', 'matrícula', 'Chica']

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Descripción de la universidad
['Universidad', 'de', 'Cuyo', ',', 'Intermedia', 'y', 'con', 'matrícula', 'Mediana']
['Universidad', 'del', 'Centro', ',', 'Intermedia', 'y', 'con', 'matrícula', 'Chica']
['Universidad', 'del', 'Centro', ',', 'Intermedia', 'y', 'con', 'matrícula', 'Chica']
['Universidad', 'del', 'Centro', ',', 'Intermedia', 'y', 'con', 'matrícula', 'Chica']
['Universidad', 'del', 'Centro', ',', 'Intermedia', 'y', 'con', 'matrícula', 'Grande']
['Universidad', 'del', 'Centro', ',', 'Intermedia', 'y', 'con', 'matrícula', 'Grande']
['Universidad', 'del', 'Centro', ',', 'Intermedia', 'y', 'con', 'matrícula', 'Chica']

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Figura – 13 proceso de tokenizado y eliminación de stop words

7.2. Importancia en PLN

La **importancia de las stop words** en el **NLP** radica en su capacidad para introducir **ruido** en los análisis, afectando la precisión de los modelos que buscan identificar patrones y relaciones entre términos. En el contexto de un análisis de **deserción estudiantil** en **carreras de computación**, las stop words podrían incluir términos como "el", "de", "la", "en", que se repiten frecuentemente en los textos y no aportan información útil para predecir si un estudiante está en riesgo de abandonar su carrera. Al eliminarlas, se mejora la **eficacia del análisis** al permitir que los modelos se concentren en términos más relevantes y específicos que ofrecen una mayor comprensión del fenómeno en cuestión.

En tareas como la **clasificación de estudiantes en riesgo**, la

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

eliminación de stop words ayuda a los modelos a enfocar su atención en las palabras que realmente diferencian a los estudiantes que **persisten en la carrera** de aquellos que tienden a **abandonar**. Si se incluyen en el análisis términos como "el", "de" o "que", estos dominarían el proceso, haciendo que se dificulte la identificación de los factores clave como **"rendimiento académico"**, **"carga de materias"**, **"estrés"**, o **"dificultades económicas"**, que son determinantes en el proceso de deserción.

Por ejemplo, al analizar **opiniones de estudiantes** sobre su experiencia académica o sus dificultades para continuar en la carrera, es fundamental eliminar las stop words para que el análisis pueda concentrarse en palabras como **"complicado"**, **"difícil"**, **"abrumador"** o **"satisfactorio"**, que aportan un valor semántico significativo. Estas palabras brindan una mejor visión de la **percepción académica** del estudiante y pueden ayudar a detectar patrones que sugieren una mayor probabilidad de abandono.

En el caso específico de las **carreras de computación**, los estudiantes podrían mencionar palabras como **"proyectos"**, **"exámenes"**, **"laboratorios"**, o expresiones relacionadas con las **habilidades técnicas** que se requieren. Si bien estas palabras son comunes en el dominio, eliminar otras más generales, como preposiciones o pronombres, permite que los modelos se enfoquen en los términos que son más predictivos del comportamiento académico del estudiante.

En resumen, al eliminar las stop words, se reduce el **ruido semántico** en los análisis de NLP, permitiendo que los modelos se enfoquen en los términos que realmente aportan información sobre el **rendimiento académico**, las **dificultades** y las **expectativas** de los estudiantes de carreras de computación. Esto es esencial para mejorar la precisión y efectividad de los modelos predictivos en el análisis de deserción estudiantil, ayudando a las instituciones educativas a identificar **patrones clave** y tomar medidas preventivas más eficientes.

7.3. Beneficios de eliminar stop words:

1. **Reducción de ruido:** La eliminación de stop words elimina términos que, aunque aparecen frecuentemente en los textos, no aportan información relevante para la tarea en cuestión.
2. **Mejora en la precisión del modelo:** Al eliminar palabras irrelevantes, se permite que el modelo se concentre en las palabras clave que realmente capturan el significado o la intención del texto.
3. **Disminución del costo computacional:** La reducción en el número de palabras que se procesan ayuda a que los algoritmos sean más rápidos y eficientes, lo que es crucial en grandes corpus de texto.
4. **Menor dimensionalidad:** Disminuye el número de características que los modelos de machine learning necesitan manejar, lo que reduce la probabilidad de sobreajuste y mejora la capacidad de generalización.

7.4. Consideraciones al eliminar Stop Words

No todas las tareas de análisis de texto requieren la eliminación de stop words, y su relevancia puede variar dependiendo del contexto específico. En el caso de análisis de texto aplicado a estudiantes de

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

carreras de computación, es esencial evaluar el impacto de las stop words en la estructura de las oraciones y en los resultados del análisis. En situaciones como la extracción de relaciones entre entidades o la construcción de un grafo semántico, las stop words pueden ser necesarias para entender la conexión entre términos clave relacionados con características demográficas o académicas de los estudiantes.

Por ejemplo, en el análisis de datos de **estudiantes universitarios** en carreras de computación, palabras como "año", "carrera", "estudiante", "grado" o "edad" pueden parecer términos comunes que podrían eliminarse en otro contexto. Sin embargo, en un análisis de deserción estudiantil, estos términos pueden ser cruciales para identificar patrones relacionados con el momento en que un estudiante decide abandonar la carrera. Variables como la **edad**, el **año en curso**, o la **situación académica** (si está cursando materias de primer o último año) pueden influir significativamente en las predicciones del modelo, por lo que eliminarlas podría resultar en la pérdida de información clave.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Además, es importante adaptar la lista de stop words al **dominio educativo** en cuestión. Palabras como "matrícula", "inscripción", "semestre" o "universidad", que podrían parecer triviales en otros contextos, pueden ser esenciales para identificar factores importantes en el análisis de deserción en estudiantes de computación. Por ejemplo, un estudiante que ha repetido múltiples veces el **primer semestre** puede tener un mayor riesgo de abandonar la carrera, y eliminar la palabra "semestre" en este contexto podría ocultar esa relación.

Al personalizar la lista de stop words para el análisis de datos sobre **demografía**, **situación académica** y otras características relevantes de los estudiantes, se garantiza que el proceso de preprocesamiento de texto no elimine información crítica. Esto es especialmente importante en estudios predictivos que buscan identificar variables que influyen en la deserción o en el éxito académico, como la edad del estudiante o el año en que se encuentra dentro de la carrera. Mantener estos términos garantiza un análisis más preciso y alineado con los objetivos de investigación, mejorando la interpretación de los resultados en el contexto educativo específico.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

7.5. Filtro de Frecuencia

El filtro de frecuencia es otro paso esencial en el preprocesamiento de textos. Su función principal es eliminar tanto las palabras que aparecen con demasiada frecuencia como las que aparecen muy raramente. Ambas situaciones pueden introducir ruido en los modelos de ML o hacer que estos aprendan patrones irrelevantes. El filtro de frecuencia permite optimizar el análisis conservando las palabras que tienen una frecuencia relevante dentro del corpus.

7.6. Palabras con alta frecuencia

En el análisis de deserción educativa, las palabras que aparecen con mucha frecuencia en casi todos los documentos del corpus suelen ser

términos genéricos que no aportan información significativa para diferenciar entre categorías o factores clave asociados a la deserción. Por ejemplo, en un corpus de datos académicos de estudiantes, términos como "estudiante", "curso", "materia" o "carrera" pueden aparecer repetidamente, pero no contribuyen a identificar las razones específicas de la deserción.

En lugar de proporcionar información relevante para el análisis, estas palabras de alta frecuencia pueden dominar el proceso y ocultar otras variables críticas. En el contexto de la **deserción educativa**, es más útil concentrarse en palabras que reflejan factores diferenciadores como el **estado económico** del estudiante, su **situación académica** (número de materias aprobadas o reprobadas), su **edad**, o su **dedicación académica** (si es estudiante a tiempo completo o parcial). Estas palabras tienen más potencial para revelar patrones que influyan en la decisión de un estudiante de continuar o abandonar la carrera.

El eliminar términos que son demasiado frecuentes, y que no aportan valor específico en el contexto de análisis, ayuda a evitar que distorsionen el enfoque del estudio. Por ejemplo, en un análisis de deserción de **estudiantes de computación**, palabras como "informática", "programa" o "ingeniería" podrían aparecer en todos los registros, pero no ayudan a identificar los factores de riesgo de deserción. En cambio, es más relevante prestar atención a términos que podrían estar relacionados con **situaciones personales o académicas**, como "trabajo", "falta de tiempo", "dificultades económicas", o "reprobación de materias".

Al centrarse en estas variables más específicas y eliminar las palabras que son demasiado comunes, el análisis se vuelve más preciso y eficaz para detectar los patrones de deserción en función de características demográficas, académicas y socioeconómicas de los estudiantes. Esto permite que los resultados del análisis sean más útiles para la **predicción y prevención de la deserción estudiantil** en carreras relacionadas con computación.

7.7. Palabras con baja frecuencia

Por otro lado, las palabras que aparecen en muy pocos documentos no suelen tener suficiente contexto para aportar valor. Estas palabras raras pueden ser errores tipográficos, términos demasiado específicos o simplemente palabras irrelevantes para el análisis general. Eliminar estas palabras ayuda a reducir la dimensionalidad del modelo y mejora su capacidad de generalización al enfocarse en términos que tienen un impacto estadístico más fuerte.

7.8. Beneficios del filtro de frecuencia:

a) **Eliminación de términos irrelevantes:** Al eliminar las palabras con frecuencia muy baja o alta, se evita que el modelo se enfoque en información irrelevante o en ruido.

b) **Mejora en la generalización del modelo:** Mantener solo las palabras que tienen una frecuencia adecuada ayuda a que el modelo aprenda patrones útiles y evite el sobreajuste a características que no generalizarán bien en nuevos datos.

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

c) **Optimización del espacio de características:** Al reducir la cantidad de términos, el modelo se vuelve más eficiente tanto en el tiempo de entrenamiento como en el uso de memoria.

7.9. Establecimiento de Umbrales de Frecuencia

Definir los umbrales de frecuencia adecuados es un desafío que depende del contexto y del tamaño del corpus. Generalmente, se eliminan palabras que aparecen en un número extremadamente bajo o extremadamente alto de documentos. A continuación, se sugieren algunas directrices para establecer estos umbrales:

- **Umbral bajo:** Las palabras que aparecen en menos del 1% de los documentos pueden ser consideradas demasiado raras para ser útiles en el análisis. Estas palabras no tienen suficiente contexto y, por lo tanto, no aportan valor significativo.
- **Umbral alto:** Las palabras que aparecen en más del 90% de los documentos son demasiado comunes y no ayudan a diferenciar entre categorías o temas. Estas palabras suelen ser términos genéricos que no aportan información semántica útil para la tarea de análisis.

En la práctica, estos umbrales pueden variar dependiendo del tamaño y naturaleza del corpus, y es recomendable realizar experimentos para encontrar el equilibrio óptimo. También es importante considerar la distribución de frecuencias de las palabras en el corpus, ya que algunos dominios pueden tener una mayor concentración de términos relevantes.

7.10. Herramientas para la Implementación

Existen diversas herramientas y bibliotecas que facilitan la implementación de la eliminación de stop words y el filtro de frecuencia en proyectos de procesamiento de lenguaje natural. Algunas de las más populares incluyen:

a) **NLTK (Natural Language Toolkit):** Una biblioteca muy utilizada en el NLP que incluye funciones predefinidas para eliminar stop words en múltiples idiomas. Además, ofrece herramientas para realizar el filtrado de frecuencia basado en estadísticas de los corpus.

b) **spaCy:** Otra biblioteca avanzada de NLP que ofrece funcionalidades de lematización, tokenización y eliminación de stop words de manera eficiente. spaCy también permite ajustar la lista de stop words según las necesidades del usuario.

c) **Scikit-learn:** Para el filtrado de frecuencia, scikit-learn incluye el parámetro min_df y max_df en sus implementaciones de vectorización de texto, como CountVectorizer y TfidfVectorizer, que permiten controlar las palabras que se mantienen según su frecuencia.

Lic. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes



Descripción de la universidad
['Cuyo', 'Mediana']
['Centro', 'Chica']
['Centro', 'Chica']
['Centro', 'Chica']
['Centro', 'Grande']
['Centro', 'Grande']
['Centro', 'Chica']

Descripción de la universidad
['Universidad', 'Cuyo', ',', 'Intermedia', 'matrícula', 'Mediana']
['Universidad', 'Centro', ',', 'Intermedia', 'matrícula', 'Chica']
['Universidad', 'Centro', ',', 'Intermedia', 'matrícula', 'Chica']
['Universidad', 'Centro', ',', 'Intermedia', 'matrícula', 'Chica']
['Universidad', 'Centro', ',', 'Intermedia', 'matrícula', 'Grande']
['Universidad', 'Centro', ',', 'Intermedia', 'matrícula', 'Grande']
['Universidad', 'Centro', ',', 'Intermedia', 'matrícula', 'Chica']

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Figura – 14 proceso de filtrado de frecuencias

La eliminación de stop words y la aplicación de un filtro de frecuencia son pasos esenciales en el procesamiento de lenguaje natural. Ambos métodos reducen el ruido, mejoran la precisión del modelo y optimizan el uso de los recursos computacionales. Ajustar correctamente los umbrales de frecuencia y adaptar la lista de stop words al contexto y dominio del análisis garantiza que los modelos se centren en la información relevante, mejorando su capacidad para identificar patrones, clasificar textos y realizar análisis semánticos detallados.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

8. Representación de Textos

8.1. Bag of Words (BoW)

La técnica de Bag of Words (BoW) es una de las más utilizadas en el NLP para convertir texto en un formato numérico que pueda ser utilizado por algoritmos de Machine Learning. En este caso, aplicamos BoW para representar las respuestas textuales de los estudiantes en el contexto del análisis de deserción estudiantil. El enfoque de BoW convierte cada documento (en este caso, las respuestas de los estudiantes) en un vector de tamaño igual al número de palabras únicas en el corpus completo, sin tener en cuenta el orden en el que aparecen las palabras.

Cada componente de este vector contiene el número de veces que aparece una palabra específica en el documento. Por ejemplo,

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

palabras clave como "abandono", "carrera" y "computación" pueden aparecer varias veces en diferentes respuestas de los estudiantes, y BoW simplemente cuenta cuántas veces ocurre cada una en cada documento.

Esta técnica es sencilla porque no requiere un conocimiento profundo sobre el significado de las palabras o su contexto. Se enfoca únicamente en la frecuencia con la que las palabras aparecen, lo que es útil para identificar términos recurrentes que pueden estar relacionados con el fenómeno de deserción. Por ejemplo, si observamos que palabras como "dificultad", "estrés" o "exámenes" aparecen con frecuencia en los documentos de estudiantes que abandonaron sus estudios, podemos deducir que estos son factores importantes en la decisión de abandonar la carrera.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Sin embargo, BoW también tiene sus limitaciones. Una de las principales es que ignora el contexto de las palabras. Esto significa que frases como "no me gusta mi carrera" y "me gusta mi carrera" serían tratadas de manera similar, ya que BoW no puede interpretar que la palabra "no" está negando el significado de "gustar". Además, BoW tiende a generar vectores de dimensiones muy grandes cuando el corpus contiene muchas palabras únicas, lo que puede aumentar la demanda de memoria y reducir la eficiencia computacional, especialmente si se está trabajando con un vocabulario amplio.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

A pesar de estas limitaciones, BoW sigue siendo útil en este tipo de análisis exploratorio de deserción estudiantil, donde buscamos detectar patrones generales en el uso de términos. Su simplicidad lo hace adecuado para tareas como la clasificación de textos o el análisis de sentimientos en las respuestas de los estudiantes, donde lo importante es identificar qué palabras clave se asocian más con la deserción.

	abandonante	abandoné	carreras	centro	chica	ciencias	computación	cuyo
Doc 1	2	1	1	0	0	2	2	2
Doc 2	2	1	1	2	2	1	1	0
Doc 3	2	1	1	2	2	1	1	0
Doc 4	2	1	1	2	2	1	1	0
Doc 5	2	1	1	2	0	2	2	0
Doc 6	2	1	1	2	0	2	2	0
Doc 7	2	1	1	2	2	1	1	0

Figura – 15 proceso de Bag of words

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

8.2. TF-IDF (Term Frequency - Inverse Document Frequency)

A medida que se busca mejorar la representación del texto, surge la técnica de TF-IDF, que introduce una forma más sofisticada de medir la relevancia de las palabras dentro de un documento y en relación con todo el corpus. Mientras que BoW simplemente cuenta la frecuencia de las palabras, TF-IDF pondera esas frecuencias para tener en cuenta tanto la importancia de una palabra en un documento individual como su distribución en el corpus completo. Este enfoque es clave para destacar aquellas palabras que son verdaderamente representativas de un documento y reducir el peso de palabras que, aunque aparecen con frecuencia, no son necesariamente informativas.

El proceso de TF-IDF consta de dos componentes principales:

- TF (Term Frequency): Este componente mide la frecuencia de una palabra dentro de un documento específico. Si una palabra aparece muchas veces en un documento, su frecuencia será alta.
- IDF (Inverse Document Frequency): Este componente ajusta la frecuencia de una palabra según el número de documentos en los que aparece en el corpus. Si una palabra aparece en muchos documentos, su valor IDF será bajo, lo que significa que es común y no aporta mucha información distintiva. Por otro lado, si una palabra aparece en pocos documentos, su valor IDF será alto, lo que refleja que es más única o representativa de esos documentos específicos.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

La combinación de estos dos factores da como resultado una métrica que pondera cada palabra de acuerdo con su relevancia tanto en el documento como en el corpus. Por ejemplo, palabras muy comunes como "y", "el" o "de" recibirán un peso bajo, ya que son poco informativas, mientras que términos más específicos relacionados con el contenido del documento tendrán un peso mayor.

Uno de los principales beneficios de TF-IDF es que permite resaltar las palabras importantes en un documento, eliminando el ruido generado por aquellas que son frecuentes en todo el corpus pero que no aportan valor significativo al análisis. Esto lo hace muy adecuado para tareas como la clasificación de textos, búsqueda de información o resúmenes automáticos, donde es crucial identificar los términos clave.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Sin embargo, al igual que BoW, TF-IDF no captura el contexto de las palabras ni sus relaciones semánticas. Aunque puede identificar qué palabras son importantes en un documento, no puede determinar cómo interactúan o cuál es su significado en función de las palabras que las rodean. A pesar de esta limitación, sigue siendo una técnica ampliamente utilizada debido a su capacidad para mejorar la representación del texto sin requerir un modelo complejo.

	abandonante	abandoné	carreras	centro	chica	cienciias	computación	cuyo
Doc 1	0,249179925	0,12459	0,12459	0	0	0,24918	0,24917992	0,59461
Doc 2	0,322660324	0,16133	0,16133	0,36574	0,47431	0,16133	0,16133016	0

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Doc 3	0,3242774 8	0,1621 39	0,1621 3	0,3675 7	0,4766 8	0,1621 3	0,162138 74	0
Doc 4	0,3226603 24	0,1613 3	0,1613 3	0,3657 4	0,4743 1	0,1613 3	0,161330 16	0
Doc 5	0,3174160 98	0,1587 08	0,1587	0,3598	0	0,3174 1	0,317416 09	0
Doc 6	0,3174160 98	0,1587 08	0,1587	0,3598	0	0,3174 1	0,317416 09	0
Doc 7	0,4101046 58	0,2050 52	0,2050 5	0,4648 6	0,6028 5	0,2050 5	0,205052 32	0

Figura – 16 proceso de TF-IDF

8.3. Word Embeddings (Word2Vec)

En el ámbito del NLP, la representación de texto es fundamental para que los modelos de aprendizaje automático comprendan y analicen el lenguaje. Si bien técnicas como el Bag of Words (BoW) y TF-IDF se centran en contar y ponderar palabras de manera independiente, los Word Embeddings, como Word2Vec, ofrecen un enfoque mucho más avanzado y poderoso para la vectorización de texto, especialmente en el contexto de estudiantes universitarios de computación.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

8.3.1. Representación de Palabras

Los Word Embeddings asignan a cada palabra un vector denso y continuo que no solo captura la presencia de la palabra en el texto, sino también sus relaciones semánticas con otras palabras en el corpus. Este enfoque es crucial en el ámbito académico, donde términos técnicos y jergas pueden estar interrelacionados. Por ejemplo, en un corpus que incluye términos como "algoritmo", "programación" y "estructura de datos", Word2Vec puede capturar cómo estas palabras se relacionan entre sí en diferentes contextos.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

8.3.2. Aprendizaje Automático de Representaciones

Los Word Embeddings son entrenados utilizando modelos como Word2Vec, que emplean redes neuronales para aprender automáticamente las representaciones vectoriales de las palabras en función de su contexto dentro de las oraciones. Un principio fundamental detrás de Word2Vec es que las palabras que aparecen en contextos similares tienden a tener significados relacionados. Por ejemplo, en un entorno académico, términos como "desarrollo" y "programación" aparecerán juntos con frecuencia en discusiones sobre proyectos de software, lo que hace que sus vectores estén más cercanos en el espacio vectorial.

8.3.3. Beneficios en Tareas Avanzadas de PLN

Este enfoque proporciona una representación más rica y útil para tareas avanzadas de NLP, como la generación de texto, la traducción automática y el análisis de sentimientos, que son relevantes para estudiantes de computación. Por ejemplo, un modelo entrenado con Word2Vec puede ser utilizado para analizar comentarios en foros de discusión sobre asignaturas específicas, capturando no solo las palabras individuales, sino también las interacciones entre ellas en diferentes contextos. Esto resulta útil para comprender las opiniones de los estudiantes sobre ciertos temas o

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

asignaturas.

8.3.4. Eficiencia y Compactación

Además, los Word Embeddings suelen ser mucho más compactos que los vectores de BoW o TF-IDF, lo que los hace más eficientes en términos de espacio y procesamiento. Esto es especialmente importante para los estudiantes universitarios que manejan grandes volúmenes de datos textuales, como artículos académicos o discusiones en grupos de estudio. La capacidad de representar las palabras de manera más eficiente permite a los modelos de machine learning trabajar más rápido y de manera más efectiva.

8.3.5. Mejora en el Rendimiento de Modelos

Los Word Embeddings son especialmente útiles cuando se busca capturar matices semánticos y contextuales. En lugar de tratar cada palabra como una entidad independiente, los embeddings permiten que los modelos comprendan las relaciones entre palabras. Esto resulta en mejoras significativas en el rendimiento de los modelos en una variedad de tareas, desde la clasificación de textos hasta la recomendación de recursos académicos.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

	vector_0	vector_1	vector_2	vector_3	vector_4	vector_5	vector_6
Información	-0,00054	0,000236	0,005104	0,00901	-0,0093	-0,00712	0,006459
Computación	-0,00862	0,003666	0,00519	0,005742	0,007467	-0,00617	0,001106
Ciencias	9,46E-05	0,003077	-0,00681	-0,00138	0,007669	0,007346	-0,00367
Licenciatura	-0,00824	0,009299	-0,0002	-0,00197	0,004604	-0,0041	0,002743
MD	-0,00714	0,001241	-0,00718	-0,00224	0,003719	0,005833	0,001198
Tecnologías	-0,00873	0,00213	-0,00087	-0,00932	-0,00943	-0,00141	0,004432
Tecnicatura	0,008132	-0,00446	-0,00107	0,001006	-0,00019	0,001148	0,006114
Sistemas	0,0081	-	0,0089	0,0082	-	0,0003	0,0042

Lic. Enrique R. Chiesa Larsen
Secretario Académico
Universidad Nacional de Villa Mercedes

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

	69	0,00444	87	56	0,00444	02	76
Ingeniería	-0,00958	0,008943	0,004165	0,009235	0,006644	0,002925	0,009804

Figura – 16 proceso de Embeddings

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

A modo de ejemplificar el resultado del análisis realizamos esta representación reducida, estamos limitándonos a 7 dimensiones en lugar de las 100 originales. A pesar de esta reducción, cada palabra o concepto sigue teniendo una representación numérica que captura cierta parte de su significado y cómo se relaciona con otros términos en el corpus de datos.

8.3.6. Relaciones semánticas: una mirada más cercana

Cuando comparamos palabras como ***Computación*** y ***Sistemas***, notamos que, aunque los números específicos no sean exactamente los mismos, hay patrones similares en cómo se distribuyen las magnitudes en los vectores. Esto significa que estas dos palabras, dentro del contexto reducido a 7 dimensiones, siguen manteniendo una relación significativa. No es sorprendente, ya que, en la vida real, estos términos están intrínsecamente relacionados. "Sistemas" y "Computación" suelen aparecer juntos en contextos educativos o tecnológicos, lo cual se refleja en la proximidad de sus vectores.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Esta relación puede interpretarse como una similitud conceptual: las palabras, al ser utilizadas en textos similares, tienen vectores que se orientan de manera parecida. En otras palabras, el modelo, basado en cómo las palabras coexisten, ha aprendido que estos dos términos pertenecen a un campo semántico común.

8.3.7. Diferencias entre conceptos aparentemente relacionados

Por otro lado, cuando comparamos ***Tecnologías*** con ***Tecnicatura***, a pesar de que ambas palabras parecen estar conectadas en un sentido académico o técnico, los vectores nos dicen otra historia. La representación numérica muestra que estas palabras no están tan relacionadas como podríamos pensar. ¿Por qué ocurre esto? Probablemente porque, aunque ambas pertenezcan al ámbito tecnológico, pueden usarse en contextos distintos dentro del corpus analizado. Es decir, ***Tecnologías*** puede abarcar un espectro más amplio, mientras que ***Tecnicatura*** tiene un enfoque más específico. Esto se refleja en las diferencias de los vectores, que capturan esos matices.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

En términos de uso, mientras que ***Tecnologías*** podría ser un concepto más amplio, aplicable a muchos campos y niveles de especialización, ***Tecnicatura*** puede estar más relacionada con un tipo de formación específica, lo cual explica las diferencias en sus representaciones vectoriales.

8.3.8. Información y su relación con otras palabras

Cuando observamos la palabra ***Información***, esta parece ocupar un espacio conceptual que no está tan cerca de términos como ***Licenciatura***, al menos

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes UNViMe Ministerio de Educación

dentro de este conjunto de datos y en las primeras 7 dimensiones. Esto sugiere que, en el contexto del corpus utilizado, ***Información*** no tiene una conexión directa o fuerte con estudios formales o títulos como *Licenciatura*. De hecho, ***Información*** puede ser un concepto más abstracto y general, mientras que ***Licenciatura*** tiene connotaciones más específicas dentro del ámbito educativo. Esta diferencia se refleja en las posiciones de los vectores en el espacio semántico.

8.3.9. Limitaciones y utilidad de la reducción dimensional

Reducir la representación a solo 7 dimensiones tiene sus ventajas y desventajas. Por un lado, nos permite simplificar el análisis y centrarnos en las relaciones más esenciales. Es como observar un paisaje desde lejos: podemos captar las formas generales y cómo los elementos principales están distribuidos. Sin embargo, también perdemos detalles finos. En un espacio de
100 dimensiones, probablemente se captarían matices adicionales que podrían ofrecer más precisión sobre cómo las palabras realmente se relacionan entre sí.

Aun así, este enfoque reducido sigue siendo útil para identificar relaciones claras entre términos que están fuertemente conectados, como vimos con *Computación* y *Sistemas*. Sin embargo, cuando las palabras tienen conexiones más sutiles, como *Información* y *Licenciatura*, esta simplificación puede no ser suficiente para captar completamente esas relaciones.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

9. Análisis de eficiencia e implementación de Pipeline

En esta última etapa vamos a implementar por medio de un PIPELINE un flujo de procesos que por medio de todo lo expuesto se ajusta a nuestro set de datos.

Para garantizar un flujo eficiente en el procesamiento de texto destinado a modelos de ML y NLP, es fundamental seguir una serie de pasos lógicos y secuenciales que optimicen la calidad de los datos y su representación.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

El primer paso es la **limpieza de datos**, cuyo objetivo es eliminar valores nulos y caracteres no deseados, como puntuación, emojis, números o caracteres especiales. Este proceso incluye la normalización del texto, que implica convertir todo a minúsculas y eliminar duplicados si es necesario. Al finalizar, se obtiene un texto limpio y listo para su posterior análisis.

A continuación, se procede a la **tokenización**, que consiste en dividir el texto limpio en una lista de tokens, que pueden ser palabras, frases o caracteres. Esta acción es crucial, ya que los tokens son las unidades básicas sobre las cuales se realizará el análisis posterior.

El siguiente paso es la **eliminación de stop words**. En este proceso, se filtran palabras comunes como artículos y preposiciones que no aportan significado semántico. Se aplica una lista predefinida de stop words para eliminar aquellos tokens que no son relevantes para el análisis, lo que resulta en una lista de tokens más significativos.

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Posteriormente, se elige entre **lematización o stemización**. La lematización busca reducir las palabras a su forma base o lema, respetando la estructura gramatical, mientras que la stemización reduce las palabras a su raíz o "stem", aunque esto puede conllevar una pérdida de precisión. El resultado es una colección de tokens reducidos a su forma base, facilitando la representación y análisis.

El siguiente paso es el **filtro de frecuencia**, que tiene como objetivo eliminar palabras que aparecen con baja o muy alta frecuencia. Se definen umbrales específicos para las palabras que son consideradas ruido o irrelevantes en el contexto del análisis, dejando solo aquellos tokens que cumplen criterios de frecuencia adecuados.

Una vez filtrados los tokens, se pueden representar utilizando el modelo de **Bag of Words (BoW)**. Este método genera una matriz donde cada fila representa un documento y cada columna una palabra, con las frecuencias respectivas de aparición. Alternativamente, se puede optar por el método **TF- IDF**, que pondera la importancia de una palabra en un documento dentro de un corpus, calculando el Term Frequency (TF) y el Inverse Document Frequency (IDF) para generar un puntaje que refleje la relevancia de cada término.

Finalmente, se pueden utilizar **embeddings**, que convierten las palabras en vectores densos de características, capturando relaciones semánticas. Técnicas como Word2Vec, GloVe o BERT permiten calcular representaciones vectoriales para cada token, proporcionando una comprensión más profunda del contexto y significado.

Dependiendo de los objetivos del proyecto, se pueden combinar diferentes procesos. Por ejemplo, se puede optar por un flujo que incluya limpieza de datos, tokenización, eliminación de stop words, y posteriormente aplicar lematización o stemización, seguido de un filtro de frecuencia y la representación mediante BoW o TF-IDF. Alternativamente, se puede prescindir de lematización o stemización y optar directamente por los embeddings. Esta flexibilidad permite adaptar el flujo a las necesidades específicas de cada análisis, asegurando que se utilicen las técnicas más adecuadas para lograr resultados óptimos.

9.1. Combinaciones necesarias según el proceso:

1. **Limpieza de datos → Tokenización → Stop Words → Lematización/Stemización → Filtro de Frecuencia → Bag of Words/TF-IDF**.
2. **Limpieza de datos → Tokenización → Stop Words → Lematización/Stemización → Embeddings**.
3. **Limpieza de datos → Tokenización → Stop Words → Embeddings** (si no necesitas lematización o stemización).
4. **Limpieza de datos → Tokenización → Filtro de Frecuencia → Bag of Words → Embeddings** (si quieres mezclar representación BoW con embeddings).

9.2. Consideraciones:

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

- Si usas **BoW** o **TF-IDF**, los embeddings no son estrictamente necesarios, ya que ambas son representaciones vectoriales del texto.
- Si necesitas una representación semántica profunda (capturando contexto), los **embeddings** son mejores que BoW y TF-IDF.

Nosotros vamos a optar según nuestro objetivo que es la adaptación de un dataset para un modelo de ML que pueda predecir la deserción educativa en alumnos de carreras de grado con técnicas de NLP y ya que no necesitamos una representación semántica profunda vamos a implementar el siguiente PIPELINE:

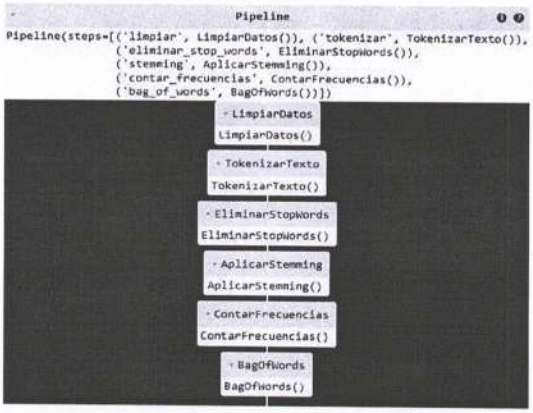


Figura – 17 Pipeline

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

10. Interpretación del análisis semántico

10.1. Desarrollo de análisis NLP en característica categórica

Como expresamos con anterioridad entendemos que este dataset no esta pensado y o diseñado para la utilización de técnicas NLP ya que en la mayoría del corpus pudimos determinar que este carece de texto donde se expresen ideas, pensamientos, sentimientos, etc. Es por eso que vamos a realizar un análisis sobre una sola característica la cual por medio del análisis exploratorio definimos que presenta un carácter semántico el cual si permite un análisis mediante NLP, la caracteristica es ***" porque percibís esa materia filtro".***

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Para este análisis vamos a seguir el siguiente flujo que a diferencia del propuesto anteriormente que se utilizo para el tratamiento del dataset completo este no contiene el paso de Stemming por que se considera que no es relevante para este corpus ya que solo estamos tratando una sola característica.

Limpieza de datos → Tokenización → Stop Words → Filtro de Frecuencia → Bag of Words.

El análisis de las respuestas de los estudiantes en la pregunta ***"porque percibís esa materia filtro"*** revela patrones importantes tras el proceso de NLP. Las 20 palabras más frecuentes en el conjunto de datos reflejan temas recurrentes en las opiniones de los alumnos sobre su experiencia académica.

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Palabra	Frecuencia
materias	287
carrera	173
materia	164
nivel	87
temas	87
si	84
dificultad	82
exigencia	78
cantidad	74
filtro	61
tiempo	60
año	56
contenido	53
ser	50
alumnos	50
carga	48
cursada	46
muchas	45
difíciles	42
mas	39

Figura - 18 20 palabras más relevantes

Palabras clave: *dificultad (82), exigencia (78), difíciles (42), materias (287), contenido (53), temas (87).*

Una de las observaciones más claras es la presencia constante de términos relacionados con la dificultad académica. Palabras como "dificultad", "exigencia", "materias", "contenido" y "temas" aparecen con bastante frecuencia, lo que sugiere que muchos estudiantes encuentran el nivel de exigencia de los cursos como un desafío significativo. Este patrón refleja que la carga académica y la complejidad de los contenidos enseñados son puntos de fricción importantes en la experiencia de los alumnos. Estos términos podrían estar vinculados a la percepción de que el nivel de las materias es elevado o que la cantidad de contenidos a cubrir es excesiva, generando una carga de trabajo que algunos estudiantes podrían considerar abrumadora.

Palabras clave: *carga (48), cursada (46), tiempo (60), cantidad (74).*

La percepción sobre la carga de trabajo se refuerza con la aparición de palabras como "carga", "cursada", "tiempo" y "cantidad". Estas palabras sugieren que los estudiantes están muy conscientes del esfuerzo y tiempo requerido para cumplir con las exigencias del programa. Es probable que muchos de ellos sientan que el tiempo disponible es insuficiente para lidiar con la cantidad de temas y tareas

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

que deben completar. Esta sensación de sobrecarga podría estar vinculada al estrés académico y, en algunos casos, podría contribuir a decisiones de abandono o cambio de carrera. El énfasis en la palabra "cantidad" sugiere que no solo se refieren a la complejidad de los temas, sino también al volumen total de trabajo que se espera que realicen, lo que podría estar afectando su desempeño o bienestar general.

Palabras clave: *carrera (173), materias (287), nivel (87).*

Otra palabra que aparece con bastante frecuencia es "carrera", lo cual indica que muchos estudiantes están haciendo referencia a su experiencia general en la carrera. Las menciones a "carrera" podrían estar relacionadas con la evaluación que hacen los estudiantes sobre la calidad de la formación que están recibiendo. En este sentido, la palabra "nivel" aparece también de manera recurrente, lo que puede sugerir que los estudiantes están valorando si el nivel de las materias está alineado con sus expectativas o si consideran que es demasiado elevado o bajo en relación con sus metas profesionales. Este tipo de información es valiosa para las instituciones académicas, ya que podría indicar la necesidad de ajustar la dificultad o estructura de ciertas materias para hacerlas más accesibles o desafiantes, según el caso.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Palabras clave: *filtro (61), contenido (53), temas (87).*

En relación con el contenido de las materias, la palabra "filtro" es interesante, ya que sugiere una posible percepción de selección o de barrera. Esto podría implicar que ciertos cursos son percibidos como "filtros" que seleccionan a los estudiantes que pueden continuar avanzando en la carrera y aquellos que quedan rezagados. El hecho de que se mencionen tanto el "contenido" como los "temas" en los documentos sugiere que los estudiantes tienen opiniones fuertes sobre lo que se les enseña y cómo se les enseña. Estas palabras parecen reflejar una valoración directa de los contenidos curriculares, y puede ser una señal de que los estudiantes están pidiendo una revisión o actualización de los temas abordados, especialmente si consideran que no son del todo relevantes para el mundo laboral o los avances tecnológicos recientes.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Palabras clave: *si (84), ser (50), muchas (45), mas (39).*

Otra observación interesante es la presencia de palabras genéricas como "si", "ser", "muchas" y "más", que, aunque en principio parecen menos reveladoras, podrían ser parte de construcciones más complejas dentro de las respuestas. Aunque estas palabras por sí mismas no aportan mucha información directa, el hecho de que aparezcan con tanta frecuencia indica que los estudiantes pueden estar utilizando estas palabras como parte de
frases que expresan sentimientos o evaluaciones más completas sobre su experiencia en la carrera.

Palabras clave: *materias (287), materia (164).*

Finalmente, destaca la alta frecuencia de las palabras "materias" y "materia", lo cual sugiere que los estudiantes están enfocando una gran parte de sus respuestas en la evaluación de las asignaturas específicas que conforman el plan de estudios. Esto podría indicar

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

que están diferenciando entre las materias que encuentran más o menos útiles o desafiantes, y también podría reflejar su interés en mejorar o cambiar la estructura de ciertas asignaturas. El hecho de que esta palabra aparezca más que otras puede ser indicativo de que los estudiantes ven las materias como el eje central de su experiencia académica, y sus opiniones sobre ellas son cruciales para entender su satisfacción o insatisfacción con la carrera en general.

En conclusión, el análisis de las palabras más frecuentes en las encuestas de los estudiantes permite identificar temas críticos en su experiencia educativa. La carga de trabajo, la dificultad de las materias y la relevancia del contenido académico son los aspectos más mencionados, lo que sugiere que estos son los principales factores que influyen en la percepción de los alumnos sobre la calidad de la formación que están recibiendo. Estos resultados proporcionan una base sólida para que las instituciones académicas realicen ajustes en el currículo y en las metodologías de enseñanza, con el fin de mejorar la experiencia de los estudiantes y reducir los índices de deserción.

11

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Conclusión

Este informe demuestra cómo el NLP y el ML pueden transformar la forma en que se aborda un problema crítico como la deserción estudiantil. Al aplicar técnicas avanzadas de recolección, limpieza y análisis de datos, hemos construido un pipeline robusto capaz de interpretar patrones complejos ocultos en los datos textuales y categóricos. Este enfoque no solo ofrece una visión más profunda sobre los factores que influyen en la deserción, sino que también abre nuevas oportunidades para predecir y mitigar este fenómeno en el ámbito educativo.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Uno de los puntos más destacados del trabajo es la **automatización** del procesamiento de datos. La implementación de herramientas como Python, junto con librerías especializadas en NLP (re, NLTK, SpaCy), ha permitido realizar un preprocesamiento eficiente, eliminando ruido innecesario y normalizando grandes volúmenes de texto. Esta automatización no solo optimiza el tiempo, sino que reduce significativamente el riesgo de errores humanos, lo que es esencial en estudios de gran escala como el análisis de deserción estudiantil en carreras de computación.

A través del uso de **embeddings** como Word2Vec y técnicas de vectorización como Bag of Word, el informe va más allá de las metodologías tradicionales para la representación de texto. No se trata simplemente de contar palabras, sino de entender su significado en el contexto del corpus general. Esta capacidad de identificar relaciones semánticas entre conceptos clave, como "abandono", "dificultades económicas" o "carga académica", proporciona un análisis mucho más preciso y matizado que puede informar decisiones educativas y estrategias de intervención.

Un aspecto crucial del análisis ha sido la **reducción de la dimensionalidad** y el tratamiento de **características categóricas**. Esto no solo mejoró la eficiencia computacional, sino que también

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

permitió que los modelos se concentraran en las variables más relevantes, eliminando características que podrían introducir sesgos o ruido en los resultados. Este proceso fue crítico para evitar el sobreajuste y garantizar que los modelos predictivos puedan generalizar correctamente en datos futuros.

Los **filtros de frecuencia** y la eliminación de **stop words** contribuyeron de manera significativa a este refinamiento, enfocando el análisis en términos que aportan valor semántico y reduciendo la influencia de palabras irrelevantes o demasiado comunes. Esta decisión, aunque a menudo pasada por alto, fue fundamental para garantizar que los algoritmos futuros aprendan de las señales correctas, lo que aumentara la precisión de los modelos.

Más allá de los desafíos técnicos, este informe también destaca la **importancia de los datos** como el pilar sobre el cual se construyen los modelos de Machine Learning. La recolección de datos de calidad, junto con un riguroso preprocesamiento, ha sido la clave para asegurar que los resultados obtenidos sean no solo precisos, sino también interpretables y accionables para la toma de decisiones educativas.

En última instancia, este trabajo no solo aclara sobre los factores que contribuyen a la deserción estudiantil, sino que también ofrece un marco sólido para el uso de tecnologías avanzadas en la predicción y prevención de este fenómeno. Las instituciones educativas que adopten este tipo de enfoques basados en datos podrán identificar a los estudiantes en riesgo de manera más efectiva y diseñar estrategias personalizadas de intervención. De este modo, el análisis predictivo se convierte en una herramienta poderosa para mejorar la retención estudiantil y garantizar el éxito académico a largo plazo.

12. Material Bibliográfico

1. **Bird, S., Klein, E., & Loper, E. (2009). *Natural Language Processing with Python*. https://doi.org/10.5555/1019199**
2. **Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. https://doi.org/10.5555/1289059**
3. **Provost, F., & Fawcett, T. (2013). *Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking*. https://doi.org/10.5555/1911995**
4. **Rozo, M. A. L. B. S., & otros. (2021). *Predictive Analytics for Student Retention*. https://doi.org/10.1109/ICCS.2021.9448312**
5. **Hussain, A. G. D. V. S. T., & otros. (Año). *Using Natural Language Processing to Analyze Student Feedback*. 10.1097/ACM.0000000000004153.**
6. **Coursera. (2024). *Courses on Natural Language Processing and Machine Learning*. https://www.coursera.org**
7. ***Machine Learning for Education: A Systematic Review*. (2024). https://doi.org/10.5944/ried.27.1.37491**

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes