Villa Mercedes (SL), 19 de mayo de 2025

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

VISTO:

El **CUDAP: EXP-UVM:162/2025**, mediante el cual el Sr. Gabriel NOVILLO RANGONE, profesor de la carrera de Ingeniería en Sistemas de Información, eleva informe del Plan de Trabajo para el Proyecto Final del alumno Micael LATORRE, y;

CONSIDERANDO:

Que mediante Resolución del Consejo de la Escuela de Ingeniería y Ciencias Ambientales Nº 12/2023 se aprobó la Reglamentación de Trabajo Final para la carrera de Ingeniería en Sistemas de Información.

Que mediante Resolución del Consejo de la Escuela de Ingeniería y Ciencias Ambientales Nº 25/2024, la propuesta del Proyecto Final del alumno Micael LATORRE, fue aprobada.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería
y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Que la Dirección de Escuela de Ingeniería y Ciencias Ambientales, remitió el expediente a la comisión de Carrera de Ingeniería en Sistemas de Información para su conocimiento y aval.

Que la Comisión de Carrera de Ingeniería en Sistemas de Información, aprueba la propuesta presentada por estar en conformidad con la Resolución del Consejo de la Escuela de Ingeniería y Ciencias Ambientales Nº 12/2023, presta el aval correspondiente al informe elevado por el Prof. Ing. Gabriel NOVILLO RANGONE, y eleva la designación del Ing. Alejandro Rosa, Esp. Ing. Marcelo Altaba y el Ing. Emmanuel Absh Guillaumin como tribunal evaluador.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Que la Dirección de la Escuela de Ingeniería y Ciencias Ambientales realiza el pase a la Comisión de Asuntos Académicos del Consejo de Escuela de Ingeniería y Ciencias Ambientales para su conocimiento y aval.

La Comisión de Asuntos Académicos aconseja aprobar el informe final del Proyecto Final de la carrera de Ingeniería en Sistemas de Información, correspondiente al alumno Micaél LATORRE, DNI 39.441.457, titulado *Desarrollo y acondicionamiento de un Dataset para el análisis predictivo del rendimiento del cultivo de cannabis medicinal mediante machine learning*; aprobar la designación como evaluadores de los ingenieros Alejandro Marcelo ALTABA, Emmanuel ABSCH GUILLAUMIN y Alejandro Pablo ROSA; y autorizar la presentación del mencionado informe ante el tribunal examinador en la mesa de examen correspondiente al mes de abril de 2025.

Que el Consejo de Escuela en sesión ordinaria el 14 de abril de 2025, resolvió hacer suyo el dictamen de la Comisión de Asuntos Académicos.

Cpde. RESOL. C. ESC. ING. Y CS. AMB. Nº 8/2025

ES COPIA

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Que la Dirección de Escuela de Ingeniería y Ciencias Ambientales, y con el aval del Consejo de Escuela, remite a Secretaría Académica para su conocimiento.

Que Secretaría Académica toma conocimiento, presta aval y remite a la Dirección de Despacho para emisión del acto administrativo.

Que Dirección de Asuntos Jurídicos no tiene objeciones a la protocolización solicitada.

Que Dirección de Despacho realiza el acto administrativo, incorporando las modificaciones pertinentes, conforme al anteproyecto adjunto en el presente.

Por ello, y en uso de sus atribuciones;

EL CONSEJO DE ESCUELA DE INGENIERÍA Y CIENCIAS AMBIENTALES DE LA UNIVERSIDAD NACIONAL DE VILLA MERCEDES

RESUELVE:

ARTÍCULO 1º: PROTOCOLIZAR el Informe del Plan de Trabajo Final tema "Desarrollo y acondicionamiento de una Dataset para el análisis predictivo del rendimiento del cultivo de cannabis medicinal mediante machine learning" del alumno Micaél LATORRE, DNI: 39.441.457, de la carrera de Ingeniería en Sistema de Información, según se detallan en el ANEXO ÚNICO de la presente disposición.

ARTÍCULO 2º: RECONOCER la designación como tribunal evaluador a los profesores:

- **PRESIDENTE:** Ing. Alejandro Marcelo ALTABA, DNI: 21.638.609
- **VOCAL 1º:** Ing. Alejandro Pablo ROSA, DNI: 24.719.010
- **VOCAL 2º:** Ing. Emmanuel ABSH GUILLAUMIN, DNI 33.359.863

ARTÍCULO 3º: Notifíquese, publíquese, insértese, en el Libro de Resoluciones del Consejo de Escuela de Ingeniería y Ciencias Ambientales y archívese.

RESOLUCIÓN C. ESC. ING. Y CS. AMB. Nº 8/2025

Lic. Enrique E. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

ANEXO ÚNICO

UNIVERSIDAD NACIONAL DE VILLA MERCEDES
ESCUELA DE INGENIERÍA Y CIENCIAS AMBIENTALES

DESARROLLO Y ACONDICIONAMIENTO DE UN DATASET PARA EL ANÁLISIS PREDICTIVO DEL RENDIMIENTO DEL CULTIVO DE CANNABIS MEDICINAL MEDIANTE MACHINE LEARNING

AUTOR: Analista Universitario en Sistemas LATORRE Micaél
PROFESOR GUÍA: DR. ING. Gabriel NOVILLO RANGONE
PROFESOR ASESOR: ING. Guillermo Luis ZANON
INGENIERÍA EN SISTEMAS DE INFORMACIÓN VILLA MERCEDES - SAN LUIS - ARGENTINA 2025

Resumen

El presente proyecto tiene como objetivo desarrollar y acondicionar un dataset para el análisis predictivo del rendimiento del cultivo de cannabis medicinal mediante técnicas de machine learning. La metodología aplicada incluye la creación de una plataforma web diseñada para recopilar datos reales de cultivadores, permitiendo obtener información detallada sobre sus prácticas y experiencias de cultivo. Esta plataforma, alimentada con datos históricos obtenidos de diversos bancos de semillas, facilitó la construcción del esquema de relaciones entre cultivadores y sus cultivos, identificando patrones y mediciones clave para el rendimiento del cultivo.

En el análisis predictivo, se identificó una relación significativa entre el cronograma de cultivo, derivando en valores como la cantidad de horas de luz diaria utilizable recibida, el DLI (Daily Light Integral), y el VPD (Vapor Pressure Deficit) y la cosecha obtenida. Los resultados evidencian la viabilidad del dataset para aplicaciones futuras en agricultura de precisión, proporcionando una referencia útil para optimizar prácticas de cultivo.

El proyecto pretende ser una herramienta de valor para los cultivadores, quienes resaltaron la importancia de contar con un modelo predictivo para ayudar a perfeccionar sus métodos y estandarizar sus procesos de cultivo.

Agradecimientos

A lo largo de estos años, tuve la suerte de contar con el apoyo incondicional de muchas personas que fueron clave en mi camino académico y profesional.

A mi familia y amigos, que siempre me bancaron en cada etapa, dándome su apoyo y aliento. A mis profesores, por su enseñanza, inspiración y por impulsarme a ser un mejor profesional.

En especial, quiero agradecer a mis padres, por confiar en mí y darme la oportunidad de formarme en la carrera que elegí, que hoy me permite construir mi futuro. A mi hermano, por ser el ideador de este y muchos más de nuestros proyectos. A mi novia, por su apoyo incondicional de todos los días, ayudándome a enfocarme en terminar la carrera. A mis amigos ingenieros, por ser mi cable a tierra y por aportar su mirada a mis proyectos desde otras ramas de la ingeniería. A mis amigos de jiujitsu, también por ser mi otro cable a tierra y por ayudarme a construir carácter durante estos años de carrera. Y a mis compañeros, por el tiempo compartido y los momentos vividos en este camino.

A todos, gracias de corazón.

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Índice

Índice De Ilustraciones 7
Índice De Tablas 8
Lista De Abreviaturas 9
I- Introducción 1
II- Marco Teórico 3
I- Impacto Económico de la Legalización del Cannabis 3
II- Origen, Domesticación y Evolución del Cannabis Medicinal 4
III- Ciclo de Cultivo y Clasificación Genética del Cannabis 6
IV- Factores Clave en el Entorno de Cultivo 10
Déficit de Presión de Vapor e Integral de Luz Diaria 11
V- Machine Learning y Procesamiento de Datos en Agricultura de Precisión 13
III- Metodología 17
I- Recolección de Datos 18
Datos Históricos 18
Selección de Fuentes 18
Información Recopilada 18
Herramientas y Técnicas de Recolección 19
Pre Procesado de Datos 23
Pre Procesamiento de Características 25
Dataset de Genéticas Obtenido 25
Aplicación Web - Green Star 30
Arquitectura de la Aplicación 31
Experiencia de Usuario 32
Mecanismos de Validación de Datos 37
Promoción de la Aplicación 37
Segmentación y Normalización de Cronogramas de Cultivo 38
II- Armado del Dataset 40
Integración de los Datos Recolectados en un Dataset General 40
Proceso de Automatización Continuo 42
Pipeline para el Procesamiento de Datos Recopilados 43
III- Desarrollo y Entrenamiento del Modelo 45
Estructura del Proyecto 45
Preprocesamiento y Preparación de los Datos 46
Técnicas de Data Augmentation 50
Entrenamiento del Modelo 52
Random Forest 52
Support Vector Machine (SVM) 53
XGBoost 53
IV- Resultados 55
Importancia de Características 55
Análisis de las Matrices de Confusión 57
Evaluación Comparativa de Modelos 59
Limitaciones Actuales 60
V- Conclusiones 62
Potencial Futuro del Proyecto 63
VI- Bibliografía 64
VII- Anexos 67
Anexo 1 67

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Anexo 2 68
Anexo 3 69
Anexo 4 71
Anexo 5 72
Anexo 6 73
Anexo 7 75
Anexo 8 76
Anexo 9 78
Anexo 10 80
Anexo 11 81
Anexo 12 81
Anexo 13 89
Anexo 14 89
Anexo 15 92
Anexo 16 92
Anexo 17 93
Anexo 18 95
Anexo 19 96
Anexo 20 100
Anexo 21 100
Anexo 22 102
Anexo 23 102
Anexo 24 105
Anexo 25 106
Anexo 26 107
Anexo 27 107
Anexo 28 108
Anexo 29 110
Anexo 30 112
Anexo 31 115
Anexo 32 116
Anexo 33 117

Índice De Ilustraciones

Figura 1: Etapas del cultivo de cannabis en fotoperiódicas. 8
Figura 2: Etapas del cultivo de cannabis en autoflorecientes. 8
Figura 3: Distribución del fenotipo dominante en la muestra. 36
Figura 4: Distribución del tipo de fotoperiodo en la muestra. 37
Figura 5: Representación porcentual promedio de los principales cannabinoides.38
Figura 6: Representación porcentual promedio de los principales terpenos. 39
Figura 7: Distribución de frecuencia de ocurrencia para los días de floración. 40
Figura 8: Frecuencia de palabras en las columnas name y slug. 41
Figura 9: Frecuencia de genéticas en la columna parents. 41
Figura 10: Arquitectura de la aplicación Green Star. 43
Figura 11: Modelo entidad relación de la aplicación Green Star. 48
Figura 12: Diagrama de flujo del pipeline del procesamiento de datos. 57

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Figura 13: Importancia de características en el modelo Random Forest. 70
Figura 14: Importancia de características en el modelo SVM. 71
Figura 15: Importancia de características en el modelo XGBoost. 72
Figura 16: Matriz de confusión para el modelo Random Forest. 73
Figura 17: Matriz de confusión para el modelo SVM. 73
Figura 18: Matriz de confusión para el modelo XGBoost. 74
Figura 19: Comparación de desempeño entre modelos. 75

Índice De Tablas

Tabla 1: Composición original del dataset previo al procesamiento de datos. 20
Tabla 2: Representación de valores únicos y constantes para las columnas'flowerImagePng','flowerImageSvg','nucleusImagePng', 'nucleusImageSvg'. 25
Tabla 3: Representación de valores únicos y duplicados para las columnas'growInfo', 'parents'. 67
Tabla 4: Evaluación comparativa de las técnicas de oversampling. 49
Tabla 5: Comparación de métricas de desempeño. 75

Lista De Abreviaturas

nm: Nanómetros. µmol: Micromol. g: Gramos.
h: Horas.
VPD: Déficit de Presión de Vapor.
kPa: Kilopascal.
DLI: Luz Diaria Integral (Daily Light Integral).
PAR: Luz Fotosintéticamente Activa (Photosynthetically Active Radiation).
PPFD: Densidad de Flujo de Fotones Fotosintéticos (Photosynthetic Photon Flux Density).
ML: Aprendizaje de Máquina (Machine Learning).
ANN: Redes Neuronales Artificiales (Artificial Neural Networks).
PCA: Análisis de Componentes Principales (Principal Component Analysis). SMOTE: Técnica de Sobremuestreo de Minorías Sintéticas (Synthetic Minority Oversampling Technique).
ADASYN: Muestreo Sintético Adaptativo (Adaptive Synthetic Sampling).
SVM: Máquina de Vectores de Soporte (Support Vector Machine).
KNN: K Vecinos Más Cercanos (K-Nearest Neighbors).
ORM: Object Relational Mapping.
PWA: Progressive Web App.
CI/CD: Continuous Integration and Continuous Deployment.

I- Introducción

Al igual que en el resto de la industria agrícola, en la industria del cannabis medicinal el rendimiento del cultivo representa el objetivo final de cada ciclo de cultivo y es crucial tanto para autocultivadores como para organizaciones y productores industriales. Sin embargo, a diferencia de otras áreas agrícolas, el cultivo de cannabis medicinal se caracteriza por ciclos relativamente cortos —de aproximadamente 3 meses en plantas autoflorecientes y hasta 6 meses en plantas fotoperiódicas—, lo que plantea desafíos únicos en términos de planificación y optimización. Otro hiper parámetro es que existen tres escalas principales de producción: el autocultivo, el cultivo solidario (como clubes sociales y ONGs), y la

Téc. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

producción industrial, cada una con requerimientos y objetivos específicos. Esto complica la estandarización y optimización de prácticas. Esta industria además enfrenta una falta de estandarización considerable debido a su criminalización histórica, lo cual ha resultado en una diversidad de nomenclaturas, métodos de cultivo y categorizaciones para genéticas similares, lo que complica la comparación y mejora de técnicas de cultivo.

La necesidad de estandarizar y optimizar los procesos de cultivo de cannabis medicinal se hace evidente, especialmente considerando la carencia de datos especializados en esta área. Actualmente, los datasets existentes relacionados con el cannabis se enfocan en aspectos comerciales o índices de criminalidad, sin abordar directamente las condiciones de cultivo y sus efectos en la producción. El presente proyecto busca desarrollar un dataset robusto y estandarizado que reúna datos específicos sobre el rendimiento de distintos fenotipos de cannabis medicinal, categorizando genéticas y condiciones de cultivo, estableciendo una base sólida de datos confiables y organizados para el análisis predictivo.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

El propósito de este proyecto es estandarizar el proceso de cultivo de distintas genéticas de cannabis medicinal, generando una base de conocimiento que permita a los cultivadores orientar sus prácticas hacia una producción óptima. Para el autocultivador, prever el rendimiento del cultivo ayuda a coordinar sus ciclos,
optimizando el uso de recursos y asegurando un suministro constante. En el caso de los cultivadores solidarios, clubes sociales y ONGs, predecir el rendimiento les facilita distribuir eficientemente la producción entre sus socios y gestionar la capacidad de sus salas de cultivo. Finalmente, para los cultivadores industriales, la capacidad de anticipar la producción les permite proyectar sus ventas y cumplir con los volúmenes y fechas de entrega necesarios, especialmente en mercados de exportación que requieren estándares de calidad específicos.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

El presente trabajo se posiciona como pionero en la integración de datos comerciales de las diferentes genéticas utilizadas junto con resultados reales de producción en cultivos de cannabis medicinal. El uso de una plataforma web para recolectar datos directamente de cultivadores reales fue clave para consolidar esta base de conocimiento y establecer un esquema estructurado de factores de cultivo. Este proyecto establece las bases para futuros desarrollos adicionales como la integración de modelos de simulación que orienten ciclos de cultivo en transcurso, la exploración del linaje, el contenido de terpenos y cannabinoides de genéticas específicas, y la implementación de técnicas de cultivo más eficientes.

II- Marco Teórico

I - Impacto Económico de la Legalización del Cannabis

El cultivo de cannabis medicinal ha sido legalizado en diversos países, incluidos Estados Unidos, Canadá, Uruguay y algunos países de Europa como Alemania, Italia y Países Bajos. En EE.UU., estados como California han reportado ingresos fiscales anuales superiores a los 1000 millones de dólares en los primeros años después de la desregulación del cannabis recreacional. El impacto económico ha sido considerable, generando miles de millones de dólares en ingresos provenientes de impuestos, creando nuevos empleos en esta industria e industrias secundarias que se

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

benefician de la producción y distribución del cannabis medicinal. En Canadá, la legalización completa en 2018 no sólo impulsó el PIB al crear nuevas oportunidades de empleo, sino que también permitió el crecimiento de la exportación y el fortalecimiento de industrias complementarias como la investigación, el transporte y la producción de tecnología agrícola【1】【2】.

En términos de empleo, la industria ha abierto diversas oportunidades: desde cultivo y producción hasta distribución y venta, especialmente en dispensarios y servicios de entrega. Además, ha generado nuevas propuestas en áreas de investigación, desarrollo y control de calidad (laboratorios). En Colorado y California, por ejemplo, el número de empleos en la industria del cannabis ha crecido rápidamente, convirtiéndose en uno de los sectores de empleo con el crecimiento más dinámico en esos estados【3】.

Por otro lado, la legalización del cannabis ha mostrado una disminución en el mercado negro en varias regiones, ya que los consumidores pueden acceder al cannabis de forma legal y segura. En Colorado y Washington, por ejemplo, se ha observado una disminución en las operaciones de narcotráfico relacionadas con el cannabis. Además, los consumidores tienden a preferir productos regulados por la garantía de calidad y seguridad, reduciendo así el atractivo del mercado ilícito【2】【3】.

En general, los estudios e informes reflejan que la legalización del cannabis no solo ha permitido beneficios económicos, sino también un control más efectivo sobre su consumo y distribución, afectando positivamente la lucha contra el narcotráfico【2】【3】.

II- Origen, Domesticación y Evolución del Cannabis Medicinal

El cannabis tiene una larga historia de uso medicinal, con sus primeros registros en la antigua China, donde fue documentado por el emperador Shen Nong alrededor del 2737 a.C., considerado el "padre de la medicina china". Describió el cannabis en su obra como un remedio eficaz para enfermedades como el reumatismo, el dolor y hasta trastornos menstruales. En la India antigua, el cannabis era empleado en la medicina Ayurveda como analgésico y sedante. También fue usado por los antiguos egipcios, quienes lo aplicaban para tratar inflamaciones y dolores. En escritos como el Papiro de Ebers (1500 a.C.), se encuentran recetas medicinales que incluyen el uso del cannabis para aliviar el dolor y como tratamiento para infecciones【4】【5】. En la antigua Grecia, Galeno y otros médicos usaban extractos de cannabis para tratar heridas y aliviar dolores. En registros del Imperio Romano, se menciona su uso para reducir dolores articulares y tratar inflamaciones【5】.

Durante los siglos XIX y XX, el cannabis fue reintroducido en la medicina occidental, impulsado por el auge de extractos y tinturas medicinales en Europa y Estados Unidos. Uno de los pioneros en este ámbito fue el médico irlandés William O'Shaughnessy, quien, tras investigar la planta en India, destacó sus propiedades analgésicas y antiespasmódicas, promoviendo su uso en tratamientos médicos. Sin embargo, la historia del cannabis en la medicina también estuvo marcada por importantes hitos legislativos y científicos que influyeron en su aceptación y rechazo

Tgo. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

【4】【5】.

En 1914, el Harrison Act en Estados Unidos estableció que el cannabis solo podía ser prescrito con fines médicos, lo que marcó el inicio de un control más estricto sobre su uso. Posteriormente, en 1937, el Marihuana Tax Act impuso restricciones fiscales y legales severas, desincentivando su uso incluso con fines medicinales. Estas medidas estuvieron fuertemente influenciadas por el gobierno del presidente Franklin D. Roosevelt y se desarrollaron en un contexto social marcado por prejuicios raciales y objetivos políticos específicos. En particular, el cannabis se vinculó de manera estigmatizada con sectores marginados de la sociedad, como mexicanos, afroamericanos e inmigrantes italianos, quienes eran vistos como principales usuarios recreativos de la planta. Esta narrativa fue aprovechada para justificar políticas de criminalización que no sólo perseguían el consumo de cannabis, sino también apuntaban al control social de estas comunidades【5】.

A mediados del siglo XX, la criminalización se intensificó con la clasificación del cannabis como una sustancia de Clase I bajo la Ley de Sustancias Controladas de 1970 durante la administración de Richard Nixon. Esta clasificación, que definía al cannabis como una droga sin valor médico aceptado y con alto potencial de abuso, formó parte de la estrategia conocida como la "Guerra contra las drogas"【5】.

A pesar de estos retrocesos, la investigación científica continuó avanzando. En 1964, en Israel, el químico Raphael Mechoulam aisló y sintetizó el tetrahidrocannabinol (THC), el principal compuesto psicoactivo de la planta, un descubrimiento que proporcionó un entendimiento más profundo de sus efectos en el organismo【6】. Este hallazgo culminaría décadas después en el descubrimiento del sistema endocannabinoide en 1992 por Allyn Howlett y William Devane, lo que renovó el interés médico por el cannabis y sus aplicaciones terapéuticas【7】.

Desde finales del siglo XX, estos avances científicos y una reevaluación de los conocimientos históricos han impulsado su reintroducción en la farmacología moderna. Este movimiento ha fomentado el uso del cannabis bajo estándares científicos rigurosos, reafirmando sus beneficios terapéuticos y abriendo el camino hacia su aceptación en tratamientos médicos especializados, particularmente en países como Estados Unidos e Israel, donde la investigación ha sido fundamental para su legitimación【5】【6】【7】.

Domesticación y Evolución del Cannabis Medicinal

La domesticación ha generado grandes cambios en el cannabis. Tradicionalmente, la planta se ha seleccionado para mejorar características como el contenido de cannabinoides (principalmente THC y CBD), la resistencia a plagas y el rendimiento de las cosechas. Este proceso ha dado lugar a una mayor diferenciación entre cepas psicoactivas y medicinales, con el cannabis medicinal centrado en altos contenidos de CBD y bajo THC. La manipulación genética ha permitido desarrollar cepas con concentraciones específicas de compuestos para usos terapéuticos precisos【8】【9】.

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Mientras que las plantas de cannabis en los años 70 presentaban niveles de THC de alrededor del 2-3%, las cepas actuales, especialmente aquellas destinadas al uso medicinal, alcanzan concentraciones superiores al 30% de THC en algunos casos y hasta un 20% de CBD en genéticas específicas. Este progreso es un testimonio del impacto combinado de la domesticación y la biotecnología moderna, marcando un avance significativo en la farmacología y agricultura de precisión.

En comparación con décadas anteriores, las plantas de cannabis actuales suelen tener una mayor concentración de cannabinoides debido a la selección genética y técnicas modernas de cultivo. Hoy en día, existen cepas con perfiles específicos de cannabinoides y terpenos que responden a necesidades médicas distintas, como la epilepsia o el dolor crónico. La resistencia a factores ambientales también ha mejorado, permitiendo cultivos en condiciones controladas que maximizan el rendimiento y reducen el tiempo de cosecha【9】.

La industria moderna utiliza tecnología avanzada como la clonación, la hidroponía y la iluminación LED para optimizar el cultivo. Además, prácticas como la micropropagación y el uso de laboratorios de cultivo in vitro permiten la creación de cepas altamente uniformes y productivas. Estas prácticas permiten controlar las condiciones de cultivo y obtener plantas con características genéticas estables, adaptadas a los requisitos específicos de pacientes y tratamientos【10】.

El cannabis actual no solo se diferencia significativamente del cultivado históricamente por su perfil químico, sino también por las prácticas agrícolas avanzadas que maximizan el rendimiento y la calidad, ofreciendo a la industria y los pacientes productos altamente especializados y controlados.

III - Ciclo de Cultivo y Clasificación Genética del Cannabis

Cannabis sativa L. es una especie anual de la familia Cannabaceae, clasificada por primera vez en 1753 por Carl Linnaeus. Posteriormente, en 1785, Jean Baptiste Lamarck identificó una segunda especie, Cannabis indica. En la actualidad, el Jardín Botánico de Missouri reconoce hasta trece especies dentro del género Cannabis, incluyendo C. sativa, C. indica, C. ruderalis y otras variedades adaptadas a distintas condiciones ambientales.

Morfológicamente, C. sativa es una planta herbácea de hasta 4 metros de altura, con tallo erecto y hojas palmadas estipuladas. Sus hojas inferiores son opuestas y las superiores alternas, con foliolos angostos y márgenes serrados recubiertos de tricomas glandulares, los cuales secretan resina para proteger la planta de agresiones externas. Sus flores se presentan en inflorescencias masculinas ramificadas y laxas, mientras que las femeninas son densas y con menor número de flores. El fruto es un aquenio ovoide, con una semilla única recubierta por el perianto
【11】.

El ciclo de cultivo del cannabis medicinal comprende una serie de etapas fundamentales que son influenciadas por diversos factores: las técnicas de cultivo utilizadas por el cultivador, las genéticas seleccionadas para el lote de cultivo, y las condiciones ambientales del entorno de cultivo. Estas etapas son ampliamente reconocidas por productores de equipos y

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

suministros agrícolas especializados en la industria del cannabis medicinal, así como por estudios técnicos y científicos del desarrollo morfológico del cannabis 【12】 【13】. En este proyecto, se describen seis etapas principales del ciclo de cultivo: Germinación o Clonación, Plantín, Vegetativo, Prefloración, Floración, y Cosecha. Cada una de ellas responde a condiciones específicas que optimizan el desarrollo de la planta, desde sus primeros días hasta la obtención del producto final.

Para el propósito de este proyecto final, seguiremos con esta segmentación para el ciclo de vida del cultivo, considerando la etapa de cosecha como un evento en lugar de un periodo de tiempo prolongado, ya que el número en gramos cosechados por lote de cultivo es nuestra variable objetivo en el ensamblado de el dataset de este proyecto.

Germinación o Clonación

- **Germinación:** Es el proceso mediante el cual una semilla inicia su desarrollo, formando raíces y brotes iniciales. Este proceso requiere un ambiente con humedad constante (60-70%), temperaturas cálidas (21-26 °C) y baja exposición a la luz. La germinación es fundamental para garantizar un desarrollo saludable y uniforme de las plántulas 【14】.
- **Clonación:** Alternativamente, el cultivo puede iniciar mediante esquejes tomados de una planta madre. Este método asegura características genéticas idénticas, favoreciendo la estandarización de la producción. Los clones requieren altos niveles de humedad (80-100%) y condiciones controladas para enraizar con éxito 【15】.

Plantín

En esta fase, las plántulas o plantines (plantas jóvenes) desarrollan su estructura básica, incluyendo hojas verdaderas y raíces funcionales. Es esencial proporcionar luz moderada, nutrientes suaves, y riego controlado para evitar el estrés y fomentar un crecimiento saludable. Esta etapa prepara a las plantas para un desarrollo más acelerado en la fase vegetativa 【12】 【13】.

Vegetativo

Durante esta etapa, la planta enfoca su energía en la producción de tallos y hojas, acumulando biomasa para la floración. Se requiere un ciclo de luz prolongado
(16-18 horas diarias), niveles elevados de nitrógeno, y humedad relativa controlada (40-70%). Este crecimiento vigoroso establece la base estructural y metabólica para una floración exitosa 【14】.

Prefloración

En esta etapa, las plantas comienzan a diferenciarse sexualmente, formando estructuras reproductivas visibles. Las hembras desarrollan pistilos, mientras que los machos producen estambres con anteras. Para los cultivos de cannabis medicinal se busca la producción de plantas hembras, por lo tanto, las plantas machos deben ser removidas del cultivo de manera temprana para prevenir polinización cruzada.

Dependiendo del fotoperiodo de la genética cultivada es ideal transicionar el cultivo progresivamente durante esta etapa desde el fotoperiodo vegetativo al fotoperiodo de la etapa de floración, junto con modificaciones en la fertilización y circulación de aire en la sala de cultivo 【13】 【14】.

ES COPIA

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Floración

Aquí es donde se forman los cogollos (flores), que contienen los principales compuestos químicos psicoactivos dentro de glándulas conocidas como tricomas, ricos en cannabinoides y terpenos. Durante esta fase, la planta requiere una nutrición específica (concentraciones elevadas de fósforo y potasio) y una intensidad lumínica adecuada. El monitoreo del desarrollo de tricomas es esencial para determinar el momento óptimo de cosecha 【12】 【13】.

Cosecha

Finalmente, los cogollos se recolectan, secan y curan, procesos que preservan los compuestos activos del cannabis y determinan la calidad final del producto. Durante esta etapa, el manejo cuidadoso de las condiciones ambientales asegura la conservación de cannabinoides y terpenos esenciales 【14】.

Para ilustrar la duración del ciclo, se presenta las Figuras 1 y 2 que relaciona las etapas con la duración aproximada en semanas, diferenciando los cultivos fotodependientes y autoflorecientes.

Figura 1: Etapas del cultivo de cannabis en fotoperiódicas.

Figura 2: Etapas del cultivo de cannabis en autoflorecientes.

El ciclo de cultivo del cannabis y su clasificación genética juegan un rol fundamental en el manejo y la optimización de cultivos, especialmente en el contexto de aplicaciones medicinales 【12】 【13】. A continuación, se detallan las principales características y diferencias de las variedades fotoperiódicas y autoflorecientes, así como el impacto de la genética, las condiciones de cultivo, y la categorización fenotípica en su desarrollo 【14】.

Variedades Fotoperiódicas vs. Autoflorecientes

Las variedades fotoperiódicas se caracterizan por su dependencia del cambio de ciclo de luz para inducir la floración, generalmente al pasar de 18 a 12 horas de luz. Este tipo de planta requiere un manejo más prolongado, lo que permite obtener mayores rendimientos en cultivos controlados como los de interior, donde es posible ajustar cuidadosamente el fotoperiodo 【13】 【14】. Por el contrario, las autoflorecientes florecen automáticamente después de un periodo determinado, sin importar el ciclo de luz. Estas variedades tienen un ciclo más corto, lo que las hace ideales para cultivos exteriores o situaciones donde se requiere un cultivo rápido de la genética y las condiciones de cultivo 【14】.

Semillas en el Cultivo Medicinal

El uso de semillas feminizadas ha revolucionado el cultivo de cannabis medicinal. Estas semillas están diseñadas para producir exclusivamente plantas hembra, las cuales desarrollan los cogollos ricos en cannabinoides utilizados con fines terapéuticos 【13】 【14】. Esto reduce el riesgo de polinización accidental y maximiza la producción. Sin embargo, una desventaja de estas semillas es que limitan la variabilidad genética, lo que puede hacer que las plantas sean más susceptibles a enfermedades o plagas bajo ciertas condiciones 【14】.

Categorización Fenotípica

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

La categorización fenotípica del cannabis permite diferenciar las variedades indica, sativa e híbrida en función de sus características observables y comportamientos químicos. Las indicas son compactas, de floración rápida y más adaptadas a climas fríos, mientras que las sativas son altas, de floración más lenta y se desarrollan mejor en climas cálidos 【12】 【14】. Los híbridos, por su parte, combinan características de ambas, ofreciendo un rango de adaptaciones y propiedades terapéuticas. Esta diferenciación es crucial para seleccionar cepas específicas según las necesidades médicas del paciente 【14】.

En la actualidad, la mayoría de las genéticas disponibles en el mercado son híbridas, están feminizadas, y es más común encontrar sus versiones autoflorecientes 【14】.

IV - Factores Clave en el Entorno de Cultivo

Cada etapa del cultivo de cannabis tiene requerimientos específicos que afectan el desarrollo y la calidad del producto final. Dentro de los factores clave más relevante se encuentran:

Temperatura: La temperatura influye directamente en el metabolismo de la planta. Durante la etapa vegetativa, un rango de 25-30 °C es ideal para variedades tropicales, mientras que las variedades templadas prosperan a 25 °C. En la floración, temperaturas más bajas (23 °C) favorecen una mayor acumulación de cannabinoides, como THC y CBD. Exceder estos rangos puede causar estrés térmico, reduciendo la fotosíntesis y la eficiencia del uso del agua. La interacción de la temperatura con la humedad también determina el VPD, un indicador crítico del balance hídrico de la planta.

Humedad: La humedad relativa óptima varía a lo largo del ciclo de cultivo. Durante la germinación y la etapa de plántula, niveles altos de humedad (70-80 %) facilitan la absorción de agua. En la etapa vegetativa, se recomienda una humedad relativa de 60-75 % para maximizar el crecimiento. Sin embargo, en la floración, reducir la humedad al 55-60 % ayuda a prevenir enfermedades fúngicas, como el moho Botrytis cinerea (comúnmente conocido como moho gris) y el moho Erysiphe cichoracearum (comúnmente conocido oídio), que pueden afectar gravemente la calidad de las flores. Mantener estos niveles de humedad ayuda a controlar la proliferación de hongos patógenos, promoviendo una maduración saludable y preservando la integridad de los tricomas y terpenos.

Luz: La luz es esencial para la fotosíntesis y regula el ciclo de vida de la planta. En la etapa vegetativa, el cannabis requiere un fotoperiodo prolongado de 18-24 horas de luz al día, con una intensidad adecuada medida en PPFD. Durante la floración, el fotoperiodo se reduce a 12 horas de luz y 12 de oscuridad, lo que estimula la producción de flores. La cantidad total de luz diaria (DLI) debe ajustarse a las necesidades de cada etapa para evitar el estrés lumínico.

Nutrientes: Los requerimientos de nutrientes también varían según la etapa del ciclo. En el crecimiento vegetativo, se prioriza el nitrógeno para favorecer el desarrollo foliar. En la floración, se incrementa la proporción de fósforo y potasio para soportar la formación y maduración de los cogollos. Un desequilibrio nutricional puede afectar significativamente el rendimiento y la calidad del producto final.

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Sí bien existen más factores en el entorno de cultivo que afectan directa o indirectamente en la cosecha, estos suelen ser los más relevantes y más fáciles de medir y controlar. Estos valores: temperatura, humedad, luz y nutrientes, son los indicadores que la mayoría de los cultivadores utilizan para monitorear sus salas de cultivo 【13】 【15】 .

Déficit de Presión de Vapor e Integral de Luz Diaria

Hoy en día, los cultivadores cuentan con numerosos instrumentos de medición que ayudan a obtener una mejor comprensión de los factores primitivos del entorno de cultivo (temperatura, humedad, luz, nutrientes, etc.) a través de cálculos y comparaciones. El Déficit de Presión de Vapor (VPD), es uno de los valores calculados que mide la diferencia entre la cantidad actual de vapor de agua en el aire y la cantidad máxima que el aire puede contener a una temperatura específica. Este indicador combina la humedad relativa y la temperatura para proporcionar una métrica más precisa que guíe el manejo ambiental en el cultivo de cannabis.

Donde:

- **VPD:** Déficit de Presión de Vapor (Pa).
- **RH:** Humedad Relativa del aire (valor decimal, por ejemplo, 0.6 para 60%).
- **T:** Temperatura del aire en grados Celsius (°C).
- **610.7:** Constante que representa la presión de saturación de vapor de agua a 0 °C (en Pa).

Un VPD óptimo equilibra la apertura de los estomas, promoviendo una transpiración eficiente. Esto es crucial para la absorción de nutrientes y el transporte de agua.

Durante la etapa vegetativa, se recomienda un VPD de 0.8-1.0 kPa, mientras que en la floración un rango de 1.2-1.5 kPa resulta más adecuado para evitar problemas como el estrés hídrico o el desarrollo de moho 【13】 .

Además, el VPD tiene un impacto directo en la fotosíntesis. Condiciones de VPD desbalanceadas, ya sea muy bajas o muy altas, pueden causar estrés en la planta, reduciendo el rendimiento.

Otra medición esencial en las salas de cultivo es la luz diaria integral (DLI, por sus siglas en inglés: Daily Light Integral, medido en µMol/m²/día), es la suma total de de luz fotosintéticamente activa (PAR, por sus siglas en inglés: Photosynthetically Active Radiation) medida como densidad de flujo de fotones fotosintéticos (PPFD, por sus siglas en inglés: Photosynthetic Photon Flux Density, medido en µMol/m²/seg) durante el fotoperiodo correspondiente a la planta. En resumen, el DLI es una medida de luz que recibe una planta por la duración del fotoperiodo (en horas). Este valor permite a los cultivadores optimizar la exposición lumínica de la planta según su etapa de desarrollo.

En la etapa vegetativa, el cannabis requiere una DLI alta, entre 20-40 mol/m²/día, para soportar un crecimiento rápido. Esto se logra mediante un fotoperiodo largo de 18-24 horas de luz al día con intensidades moderadas. Durante la floración, la DLI disminuye a 15-25 mol/m²/día debido a la reducción del fotoperiodo a 12 horas de luz y 12 horas de oscuridad. Este cambio estimula la producción de flores y maximiza la energía disponible para la maduración 【15】 .

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Un control adecuado de la DLI permite evitar el estrés lumínico, que podría causar quemaduras en las hojas o inhibir el desarrollo de la planta. Además, al ajustar la DLI, los cultivadores pueden manejar eficientemente el consumo de energía en cultivos de interior, maximizando el rendimiento 【15】.

Abastecimiento de CO2

El dióxido de carbono (CO2) es un componente esencial de la fotosíntesis, y su concentración puede influir directamente en el crecimiento y el rendimiento del cannabis. A niveles elevados, el CO2 mejora la eficiencia en el uso del agua, aumenta la tasa fotosintética y promueve un desarrollo más vigoroso. Estudios muestran que concentraciones de 750 µmol/mol de CO2 bajo condiciones óptimas de luz (1500 µmol/m²/s PPFD) y temperatura (30 °C) pueden incrementar significativamente la biomasa y la producción de cannabinoides 【13】.

Sin embargo, el CO2 solo es efectivo cuando otros factores, como el fotoperiodo, la luz y el VPD, están equilibrados. Por ejemplo, niveles altos de CO2 son más útiles durante la etapa vegetativa, donde las plantas necesitan un metabolismo rápido para crecer. En la floración, aunque el CO2 sigue siendo importante, su impacto es menor en comparación con la luz y los nutrientes 【13】 【15】.

Además, es crucial mantener una ventilación adecuada en cultivos de interior para evitar acumulaciones tóxicas de CO2 y garantizar que las plantas aprovechen los niveles suplementados de manera eficiente.

V - Machine Learning y Procesamiento de Datos en Agricultura de Precisión

En agricultura de precisión, machine learning (ML) es principalmente utilizado para modelos de relaciones complejas entre variables del entorno, la gestión del cultivo y los rendimientos esperados. Aplicando conceptos fundamentales como:

Regresión y Clasificación: Modelos como regresión lineal predicen métricas como el rendimiento del cultivo o categorizan enfermedades en las plantas 【16】 【17】.

Redes Neuronales Artificiales (ANN): Son ideales para captar patrones no lineales en grandes volúmenes de datos, como por ejemplo la interacción entre clima y calidad del suelo 【19】 【20】.

Sistemas de Aprendizaje No Supervisado: Clustering y reducción de dimensionalidad (como PCA) son usados para agrupar cultivos según características específicas o eliminar redundancia en los datos 【17】 【20】.

Técnicas de Ensamble: Métodos como Random Forests y Gradient Boosting combinan múltiples modelos para mejorar la precisión de las predicciones 【18】 【19】.

Estas herramientas han permitido avances como la identificación temprana de enfermedades, la optimización del uso de fertilizantes y agua, y la mejora de los rendimientos agrícolas en escenarios diversos. Por ejemplo,

Téc. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

estudios han demostrado cómo Random Forest y redes neuronales predicen con precisión el rendimiento de trigo, maíz y café【17】【20】.

Procesamiento de Datos

El éxito de los modelos de ML depende de la calidad y preparación del dataset. En todos estos casos para lograr obtener un modelo aplicable, es indispensable la recolección, el procesamiento y el análisis de datos. Para esto, algunas técnicas aplicadas son:

Limpieza y Normalización

Garantiza la calidad del dataset al eliminar datos incompletos, manejar valores atípicos y normalizar escalas. En la agricultura, la recopilación proviene de diversas fuentes, como sensores, drones y registros manuales. Algunos escenarios que pueden ocurrir son:

- **Eliminación de Datos Incompletos:** Los sensores pueden fallar o registrar valores nulos; eliminar o imputar estos datos asegura que los modelos no se vean afectados por errores.
- **Tratamiento de Outliers:** En un sistema agrícola, valores anómalos, como mediciones de humedad del suelo extremadamente altas o bajas, pueden ser causados por errores de lectura o eventos inusuales. Identificar y manejar estos valores evita que afecten negativamente los resultados predictivos.

Estas acciones no solo evitan sesgos, sino que también mejoran la estabilidad y el rendimiento de los modelos predictivos【16】【17】.

Codificación de Variables Categóricas

En agricultura, las variables categóricas incluyen datos como el tipo de suelo (arenoso, arcilloso) o métodos de riego (goteo, aspersión). Los algoritmos de machine learning requieren que estas variables se traduzcan a formatos numéricos comprensibles:

- **Codificación One-Hot:** Transforma cada categoría en una nueva columna binaria. Por ejemplo, "Tipo de suelo: Arcilloso" se representaría como [0, 1, 0] para un modelo.
- **Codificación Ordinal:** Se aplica cuando existe una jerarquía natural entre categorías, como en las calificaciones de calidad del suelo.

Esta técnica facilita que los modelos entiendan la relación entre categorías y sus efectos en el rendimiento del cultivo【18】【20】.

Selección de Características

El objetivo es identificar las variables más influyentes para el rendimiento del cultivo, reduciendo la dimensionalidad del dataset sin perder información relevante. En agricultura:

- **Métodos Basados en Importancia:** Algoritmos como Random Forest pueden calcular la importancia de cada característica. Por ejemplo, pueden mostrar que el nivel de nitrógeno es más relevante que la temperatura ambiental en ciertos cultivos.
- **Análisis de Correlación:** Identifica relaciones entre variables para evitar redundancia, como entre humedad y VPD.

La selección de características mejora la interpretabilidad del modelo y reduce su complejidad computacional【16】【19】.

Aumento de Datos

ES COPIA

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

En agricultura, los datos recolectados pueden estar desbalanceados, especialmente en casos raros como plagas específicas o climas extremos. El aumento de datos genera ejemplos sintéticos que equilibran las clases:

- **SMOTE (Synthetic Minority Oversampling Technique):** Se aplica al detectar enfermedades poco frecuentes en cultivos, creando instancias sintéticas basadas en las existentes.
- **Transformaciones de Datos Reales:** En imágenes, técnicas como rotación o cambio de iluminación simulan variaciones reales de las plantas. Esto asegura que los modelos tengan suficientes datos para aprender patrones representativos en todos los escenarios posibles 【17】 【20】.

La aplicación de ML en cultivos de precisión resulta cada vez más redituable, numerosos estudios han demostrado el potencial de ML en cultivos agrícolas. Por ejemplo, investigaciones han utilizado redes neuronales y Random Forests para predecir el rendimiento de trigo y maíz, mientras que algoritmos como SVM han identificado plagas en cultivos de arroz y café 【16】 【17】. En cannabis medicinal, aunque menos explorado, los estudios comienzan a usar ML para optimizar condiciones de crecimiento y predecir concentraciones de cannabinoides.

Digital Twins

El concepto de Digital Twin se refiere a la representación virtual de un sistema físico que se actualiza continuamente con datos en tiempo real. Este enfoque combina tecnologías como el Internet de las Cosas (IoT), la inteligencia artificial (IA) y el aprendizaje automático (ML) para modelar, simular y predecir el comportamiento de un activo físico, optimizando su rendimiento. En el ámbito de la agricultura, los gemelos digitales permiten a los agricultores simular condiciones de cultivo, evaluar diferentes estrategias de manejo y predecir escenarios futuros sin necesidad de experimentar directamente con los cultivos, lo que reduce riesgos y costos 【21】 【22】.

En el caso de los cultivos de cannabis medicinal, la implementación de gemelos digitales podría revolucionar la gestión de los recursos y la toma de decisiones. Al integrar datos en tiempo real provenientes de sensores IoT, como niveles de humedad, temperatura, y calidad del suelo, junto con modelos predictivos basados en ML, un gemelo digital puede replicar las condiciones de un cultivo real. Este modelo puede simular cómo respondería el cultivo a cambios en el riego, la fertilización o las condiciones climáticas. Estas simulaciones ayudan a optimizar las prácticas agrícolas y a garantizar la sostenibilidad y eficiencia en el uso de recursos 【21】 【23】.

La aspiración final de este proyecto es utilizar el dataset desarrollado para modelar un gemelo digital dinámico que represente el rendimiento del cultivo bajo diferentes escenarios. Esto permitiría a los productores simular estrategias, evaluar riesgos y mejorar la toma de decisiones basada en datos precisos y en tiempo real. La adopción de gemelos digitales en agricultura es una herramienta poderosa para maximizar el rendimiento del cultivo y avanzar hacia prácticas agrícolas más sostenibles.

III - Metodología

El desarrollo del proyecto se estructura en tres pilares fundamentales: recolección de datos, construcción del dataset y desarrollo y entrenamiento

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Mg. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

del modelo. Cada uno de estos componentes representa una fase crucial para alcanzar los objetivos planteados.

La primera etapa, la recolección de datos, se orientó a la obtención de información de dos fuentes principales: datos históricos de genéticas de cannabis, recopilados a través de bancos de semillas y dispensarios, y datos empíricos proporcionados por cultivadores participantes mediante la aplicación web Green Star. Estos dos conjuntos de datos forman la base del trabajo, integrando características específicas de las genéticas con datos prácticos sobre los ciclos de cultivo.

En la segunda etapa, la construcción del dataset, se ensamblaron y refinaron estos datos para crear un recurso robusto y de alta calidad. El dataset inicial, basado en datos históricos, fue ampliado con la información recopilada de los cultivadores para formar un dataset final consolidado, el cual combina las especificaciones de las características genéticas con datos sobre el rendimiento y las prácticas de cultivo. Este proceso incluyó la limpieza, normalización y selección de variables clave para garantizar la relevancia y consistencia de los datos.

Finalmente, en la tercera etapa, se procedió al desarrollo y entrenamiento del modelo. A partir del dataset final, se implementó un modelo predictivo basado en aprendizaje automático, entrenado para identificar patrones y realizar predicciones sobre el rendimiento de las plantas de cannabis medicinal. Este modelo no solo valida la calidad del dataset construido, sino que también demuestra su potencial para aplicaciones futuras en estudios de agricultura de precisión.

I - Recolección de Datos

Datos Históricos

La recolección de datos comenzó con una búsqueda exhaustiva de bases de datos y conjuntos de datos existentes relacionados con el cultivo de cannabis medicinal. Sin embargo, las búsquedas iniciales revelaron una limitación importante: la mayoría de los datos estructurados disponibles en internet se enfocan en temas relacionados con la comercialización de productos derivados del cannabis y con índices de criminalidad en regiones donde su consumo ha sido legalizado, dejando de lado información detallada sobre prácticas de cultivo o rendimiento agrícola.

Ante este panorama, surgió un desafío fundamental: no existe una base de datos estándar ni datasets ampliamente disponibles específicamente diseñados para el cultivo de cannabis medicinal. A pesar de esta limitación, se identificaron datos estructurados valiosos en los catálogos de productos de dispensarios de cannabis en países como Canadá y Estados Unidos. Estas plataformas suelen incluir amplios listados de genéticas provenientes de bancos de semillas reconocidos internacionalmente, lo que las convirtió en una fuente clave para la recopilación de información.

Selección de Fuentes

El proceso de selección de fuentes se llevó a cabo siguiendo criterios estrictos de relevancia y confiabilidad. Se priorizaron páginas web con catálogos amplios y datos consistentes sobre cada genética. En particular, se valoraron aquellas que ofrecían información adicional relevante para el cultivo, como el tipo de floración, los perfiles de cannabinoides y terpenos, así como el linaje genético. Además, se buscó garantizar que cada genética

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

tuviera datos mínimos consistentes en todas las categorías relevantes, para maximizar la utilidad del dataset resultante.

Información Recopilada

Dado que no se encontró información directamente relacionada con prácticas de cultivo o rendimiento agrícola, el enfoque se centró en recolectar características genéticas detalladas. Estas incluyen variables como el tipo de fenotipo (Indica, Sativa, o Híbrida), los perfiles químicos (contenido promedio de THC, CBD, y CBG), los efectos percibidos y las condiciones médicas asociadas. Esta información es esencial, ya que las condiciones genéticas determinan en gran medida las prácticas de cultivo necesarias para cada planta.

Herramientas y Técnicas de Recolección

Las páginas web seleccionadas no ofrecían opciones para descargar datos directamente ni APIs abiertas al público para obtener información estructurada. En su lugar, las APIs disponibles estaban diseñadas para propósitos comerciales, como la gestión de puntos de venta, y requerían acceso restringido mediante un pago. Por lo tanto, se optó por implementar técnicas de web scraping para extraer los datos necesarios.

Antes de proceder, se revisó el archivo robots.txt del sitio web Leafly, que establece directrices sobre el acceso automatizado. Este archivo restringe el scraping en rutas específicas, como /wp-admin/, /web-strain-explorer/api y /store-locator/. Sin embargo, los datos recolectados provienen de páginas públicas correspondientes a genéticas específicas, las cuales no están incluidas en dichas restricciones. Además, estos datos son de carácter meramente informativo, no están protegidos por autenticación ni asociados a información personal generada por usuarios del sitio.

Se priorizó el respeto a las buenas prácticas del scraping, accediendo únicamente a contenido visible para cualquier usuario sin necesidad de iniciar sesión. La recolección de datos tuvo un propósito estrictamente académico.

El proceso comenzó identificando un archivo JSON accesible a través de las herramientas de desarrollador del navegador, que contenía un índice alfabético de genéticas y sus respectivos identificadores únicos (slugs).

Obtener este archivo no presentó complicaciones relevantes, se denominó al archivo obtenido con el nombre strain_names.json este contenía un total de 8,169 identificadores únicos. Estos slugs permitieron construir un método iterativo para recorrer las páginas individuales de cada genética, ya que el formato de las URLs seguía una estructura fija donde únicamente variaba el slug.

Se descubrió que la información específica de cada genética era cargada dinámicamente a través de una API interna en las páginas de detalle de genética. Aunque esta API no estaba diseñada para ser utilizada directamente por los usuarios, las solicitudes HTTP realizadas por la página devolvían un archivo JSON con datos completos sobre cada genética. Para acceder a esta API, se requería una llave de acceso temporal generada tras verificar la identidad del usuario mediante un sistema de captcha.

Utilizando la biblioteca requests de Python, se automatizó el proceso de extracción de datos. El script iteró sobre los slugs almacenados en el archivo strain_names.json y, utilizando la llave de acceso generada previamente,

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

c. Enrique R. Chiesa Torres
Secretario Académico
iversidad Nacional de Villa Mercedes

recopiló los datos de cada genética en un archivo JSON denominado strains_data.json. Este archivo contenía más de 40 atributos por genética, incluyendo información detallada como:

- **Identificadores únicos:** slug, id y name.
- **Características genéticas:** phenotype, cannabinoids, y terps.
- **Información descriptiva:** description, subtitle, y nugImage.
- **Datos adicionales:** averageRating, reviewCount, y photoCount.

Puede encontrar el script en el siguiente anexo, Anexo 1.

Para una manipulación más práctica de los datos se optó por parsear el archivo strains_data.json para obtener el dataset strains_data.csv, donde los campos de los objetos formaron las columnas del dataset. Contando ahora con un dataset más estructurado de las genéticas, fue posible realizar un análisis y exploración inicial de los datos recolectados para identificar patrones, inconsistencias y posibles problemas.

Puede encontrar el script en el siguiente anexo, Anexo 2.

El análisis inicial del archivo strains_data.csv, que contiene 8166 registros y 43 columnas, permitió identificar varias observaciones significativas en cuanto a la calidad, estructura y contenido de los datos. Una primera aproximación general al dataset muestra la siguiente composición de los datos:

Columna	Tipo de Dato	Valores No Nulos	Valores Nulos
slug	object	8166	0
id	int64	8166	0
averageRating	float64	8166	0
award	object	8166	0
cannabinoids	object	8166	0

Puede encontrar la tabla completa en el siguiente anexo, Anexo 3.

Tabla 1: Composición original del dataset previo al procesamiento de datos.

En cuanto a la estructura del dataset, se identificaron columnas con un alto potencial para el análisis predictivo y descriptivo, tales como slug, id, name, descriptionPlain, phenotype, cannabinoids, terps, parents, children, growInfo y flavors. Estas variables contienen información clave para modelar características importantes de las genéticas de cannabis, como su asignación genética fenotípica, su composición química y sus aplicaciones medicinales.

Realizando un análisis general del contenido de las columnas se logró identificar ciertas situaciones particulares. Como por ejemplo, las columnas category y phenotype contienen valores que representan el tipo de genética: Hybrid, Sativa e Indica. Sin embargo, category también incluye el valor Edible, que no son relevantes para este proyecto, ya que no están relacionados con el proceso de cultivo. Rastreando la ubicación del dato en las pantallas de la página, fue posible identificar que está destinada a clasificar el tipo de producto dentro del catálogo, mientras que phenotype describe específicamente el fenotipo de la planta. Por lo tanto, se decidió conservar phenotype para el dataset que alimentara la aplicación de los cultivadores.

Similar al caso anterior, las columnas description y descriptionPlain contienen descripciones textuales de las genéticas. La columna description incluye texto con metalenguaje de marcado en formato HTML, mientras que descriptionPlain contiene el mismo contenido pero en un formato string más

ES COPIA

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

legible y fácil de procesar. Se optó por conservar descriptionPlain para el dataset de la aplicación.

Aunque columnas como highlightedPhotos, effectReviewCount, celebrationColors, flavorReviewCount, negativeReviewCount, award, averageRating, nugImageAltText, conditionReviewCount, photoCount, rating, reviewCount, stockNugImage, y symptomReviewCount contienen datos potencialmente útiles, su relación con el proceso de cultivo es limitada. Estas columnas podrían ser relevantes en un análisis orientado a preferencias del consumidor o popularidad de las genéticas, pero no contribuyen directamente a los objetivos del proyecto, enfocado en el rendimiento del cultivo. Por este motivo, se conservaron estas variables en el dataset histórico pero para mantener un enfoque claro en las características relacionadas con el proceso de cultivo el dataset que alimentara la aplicación de los cultivadores contendrá únicamente las columnas relevantes al cultivo.

Después de este primer análisis, implementando análisis del contenido de cada columna se descubrió que algunas columnas presentan problemas de calidad, como datos ausentes o insuficientes.

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Por ejemplo, la columna phenotype, que identifica el fenotipo predominante, carece de información en 558 registros, un 6.8%. Además, aproximadamente el 16% de descriptionPlain están incompletas, limitando su utilidad.

Se identificaron redundancias en columnas con variabilidad prácticamente inexistente, como flowerImagePng, flowerImageSvg, nucleusImagePng y nucleusImageSvg, las cuales contienen el mismo valor constante en todos los registros. Dado que estos datos no aportan información relevante para el cultivo, se decidió descartarlas para evitar sobrecargar la aplicación con información irrelevante. Puede encontrar el script en el siguiente anexo, Anexo 4.

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Obteniendo los siguientes resultados:

Columna	Valores Únicos	Valor Constante (si aplica)
'flowerImagePng'	1	https://page.com/strains/flowers/default.png
'flowerImageSvg'	1	https://page.com/strains/flowers/default.svg
'nucleusImagePng'	1	https://page.com/strains/flowers/default.png
'nucleusImageSvg'	1	https://page.com/strains/flowers/default.svg

Tabla 2: Representación de valores únicos y constantes para las columnas 'flowerImagePng', 'flowerImageSvg', 'nucleusImagePng', 'nucleusImageSvg'.

Por otro lado, se detectaron duplicaciones o información redundante en variables de mayor interés para el cultivo, como growInfo y parents, que requieren un tratamiento adicional para evaluar su relevancia. Puede encontrar el script en el siguiente anexo, Anexo 5.

Obteniendo los siguientes resultados:

Columna	Total de Duplicados	Valores Únicos	Total de Registros
'growInfo'	7449	781	8166
'parents'	5227	3559	8166

Tabla 3: Representación de valores únicos y duplicados para las columnas 'growInfo', 'parents'.

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

El análisis también permitió detectar inconsistencias en los datos. Las columnas con valores ausentes representados de diversas formas, como null, {} o [], se unificaron bajo el formato NaN para simplificar el manejo de los datos ausentes.

Pre Procesado de Datos

Tratamiento de Valores Faltantes

La finalidad de este primer dataset es la de alimentar a los cultivadores participantes de este proyecto con la mayor cantidad de genéticas disponibles para representar su cultivo. Es por esto que para asegurar la calidad y consistencia de los datos fue necesario completar los campos faltantes.

El primer paso en el proceso de acondicionamiento de los datos fue identificar los valores faltantes en las columnas que serían relevantes para el cultivo, como phenotype, descriptionPlain y otras relacionadas con las características de las genéticas. La técnica utilizada para tratar estos valores dependió de la columna y del tipo de datos involucrado.

La columna phenotype presentaba registros con valores faltantes en aproximadamente el 6.8% de las entradas. Para completar estos valores, se utilizó una estrategia de imputación basada en la lógica de los padres (lineage), ya que en muchos casos, las características de los padres son representativas del fenotipo de la descendencia. La lógica aplicada fue la siguiente: Si los valores de phenotype faltaban, se comprobó si ambos linajes de los padres (parents) contenían tanto "Indica" cómo "Sativa". Si era así, se asignó el valor "Hybrid", reflejando la naturaleza híbrida del cruce.

Si el linaje sólo contenía un tipo dominante, se asignó el valor correspondiente de acuerdo con el linaje principal (por ejemplo, si sólo se detectaba "Sativa", se asignaba "Sativa").

Adicionalmente, si la imputación basada en los linajes no podía completar los valores faltantes, se utilizó la moda (valor más frecuente) de la categoría de la genética y el sabor (category y flavors) como un criterio adicional para asignar el valor de phenotype. En caso de no encontrar un valor válido, se asignó el valor 'Hybrid' como valor predeterminado para cualquier entrada aún faltante. Puede encontrar el script en el siguiente anexo, Anexo 6.

Para la columna descriptionPlain, que contiene una descripción simple de cada genética, presentaba un 16% de valores faltantes. Dado que esta columna no se consideró esencial para la predicción del rendimiento del cultivo, pero sí aportaba una comprensión general de la genética, se completaron los valores faltantes utilizando una técnica de imputación de texto. Para aquellos registros con valores faltantes, se asignó una cadena de texto genérica, indicando las características concatenando datos presentes para la genética, como phenotype, flavors y effects. Esto permitió crear descripciones simplificadas Que, aunque no tan específicas como las originales, seguían siendo representativas y útiles para el cultivador.

Puede encontrar el script en el siguiente anexo, Anexo 7.

En cuanto a la columna cannabinoids, esta no presentó columnas faltantes, por lo que no fue necesario aplicar ningún tipo de imputación en este caso. Por otro lado, la columna terps sí presentó valores faltantes, los cuales fueron tratados mediante un proceso de agrupación. Se identificaron prefijos y sufijos comunes en los registros existentes ya que estos se

ES COPIA

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

utilizan comúnmente en la nomenclatura de nuevas genéticas para identificar el linaje, utilizando esta información, se determinó la moda (valor más frecuente) en cada grupo para imputar los valores faltantes de manera coherente con las características comunes de los terpenos asociados a cada genética. Esta técnica permitió completar los datos de forma precisa, manteniendo la consistencia con los registros que ya contenían información. Puede encontrar el script en el siguiente anexo, Anexo 8.

Un proceso similar se siguió con la columna growInfo, la cual también contenía valores faltantes. En este caso, se agrupó y analizó el contenido de los campos de growInfo para identificar las características comunes que se asocian a determinadas características genéticas. Se utilizó un enfoque de imputación basado en la lógica de los padres y la categorización de la genética, similar al tratamiento de phenotype. Esto permitió rellenar los campos faltantes con información relevante y consistente para cada entrada. Puede encontrar el script en el siguiente anexo, Anexo 9.

Por otro lado, las columnas parents y children quedaron sin modificaciones, ya que no fue posible deducir su contenido de manera confiable. Estas columnas contienen información muy específica y no se pudo aplicar una técnica de imputación lógica o estadística sin comprometer la validez de los datos. En este caso, se optó por mantener los valores originales, reconociendo que en algunos casos podrían estar incompletos, pero sin modificar la información de manera arbitraria.

Una vez completados los campos faltantes y asegurada la consistencia del dataset, se obtuvo un archivo resultante, strains_data_v5.csv. Este dataset fue el resultado de un proceso de curación que permitió consolidar y enriquecer la información de manera adecuada. A partir de este archivo, se extrajo un conjunto de datos menor, reteniendo únicamente las columnas relevantes para la aplicación de los cultivadores: id , slug, name, descriptionPlain, phenotype,
cannabinoids, terps, parents, children, growInfo. A este conjunto reducido de datos se lo denominó strains_data_app.csv. Este archivo optimizado, elimina información redundante, ya que se almacenaría en un bucket en la nube y sería consultado a través de una API por los cultivadores. El servicio implementado tiene límites de tamaño para los archivos cargados, por lo que fue necesario realizar este ajuste para asegurar que los datos estuvieran disponibles de manera eficiente y accesible para los usuarios finales sin comprometer el rendimiento del sistema.

Pre Procesamiento de Características

Finalmente fue necesario agregar una columna para indicar el fotoperiodo, esta columna con el nombre photoperiod ha sido una parte fundamental en el proceso de acondicionamiento de los datos, ya que influye directamente en diversas variables del cultivo, como la duración del ciclo de crecimiento, la cantidad de ingesta diaria y, en general, las condiciones de manejo del cultivo.

La clasificación se realizó utilizando un enfoque basado en el análisis de palabras clave tanto en el nombre como en la descripción de las genéticas. Se otorgaron pesos diferenciados a las palabras clave relacionadas con las categorías Auto y Photoperiod, con el objetivo de crear una distribución más equilibrada entre ambos tipos de fotoperíodo, sí no era posible clasificar la

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

genética en ninguno de las categorías mencionadas sería clasificada como Hybrid. Puede encontrar el script en el siguiente anexo, Anexo 10.

Cabe mencionar que es posible encontrar las genéticas actuales en formatos variados, una genética tradicionalmente conocida como fotoperiódica puede tener su versión autofloreciente, y viceversa, lo que complica la clasificación precisa y unívoca de la columna. Dado que la clasificación puede no ser completamente precisa en todos los casos, se le otorgará al cultivador la posibilidad de modificar el fotoperíodo asignado a cada genética si lo desea. Esta flexibilidad es crucial para adaptarse a las diferentes prácticas y necesidades de los cultivadores.

Dataset de Genéticas Obtenido

En cuanto a la distribución del fenotipo dominante, el análisis de la columna phenotype reveló una marcada disparidad entre las genéticas recolectadas. Entre las diversas genéticas analizadas se observó que el 80.8% de estas corresponden a variedades híbridas (Hybrid), un dato consistente con la tendencia predominante en el mercado actual de semillas, donde las genéticas híbridas dominan debido a su versatilidad y características balanceadas. En contraste, las variedades Indica y Sativa están menos representadas, con un 11.8% y 7.4%, respectivamente, lo que sugiere una menor prevalencia de estas variedades puras en los datos recolectados.

Figura 3: Distribución del fenotipo dominante entre las características genéticas de la muestra.

En cuanto a la columna photoperiod, se logró una distribución de 85 genotipos clasificados como Auto, 485 como Photoperiod, y la mayoría de estos (7596) fueron clasificados como Hybrid. La alta proporción de genéticas clasificadas como Hybrid podría explicarse por la tendencia actual del mercado hacia híbridos, que combinan características tanto de variedades Autoflowering como de Photoperiod. Sin embargo, es importante señalar que las deducciones hechas para esta columna no son definitivas, sino que se basan en patrones lógicos extraídos de los datos disponibles. Esta variabilidad de formatos entre las genéticas requiere que el cultivador esté atento a las características específicas de cada cepa y decida, en última instancia, cuál fotoperíodo es más adecuado para sus necesidades de cultivo.

Figura 4: Distribución del tipo de fotoperiodo entre las características genéticas de la muestra.

Desde una perspectiva predictiva, algunas columnas destacan por su riqueza informativa. En particular, las variables relacionadas con la química de las plantas, agrupadas en la columna cannabinoids, son especialmente relevantes. Estas contienen información anidada sobre componentes como el contenido promedio de THC, CBD, y CBG, entre otros cannabinoides. Este desglose en componentes individuales permitió realizar un análisis más detallado, evidenciando patrones significativos. Por ejemplo, los niveles promedio de THC (19.42%) y CBD (0.27%) sugieren que las genéticas están orientadas a maximizar el contenido de THC, mientras que otros cannabinoides, como el CBC y el THCV, presentan niveles promedio considerablemente más bajos.

Figura 5: Representación porcentual promedio de los principales cannabinoides.

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Adicionalmente, el análisis de las variables de terpenos (terps) proporcionó insights valiosos. Los valores promedio indican que los terpenos más representados en la muestra obtenida son mirceno (20.5%) y cariofileno (16.6%), compuestos clave asociados con efectos medicinales y aromáticos específicos. La presencia de terpenos como el limoneno (13.6%) y el pineno (10.3%) refuerzan la diversidad química de las genéticas analizadas, siendo estos 2 los terpenos más populares en el mercado actual de cannabis medicinal.

Figura 6: Representación porcentual promedio de los principales terpenos.

En la categoría floweringDays, dentro de la columna growInfo, los datos recopilados permiten observar patrones relevantes sobre el tiempo de floración de los genotipos analizados. El tiempo promedio que duran las genéticas en floración se sitúa en aproximadamente 31 días, con una desviación estándar de 31.5 días, lo que indica una gran variabilidad entre las genéticas. El máximo alcanza los 98 días, típico de genéticas de floración más prolongada, como ciertas variedades sativas. El percentil 50 (mediana) se ubica en 43 días, mientras que el percentil 75 sugiere que el 25% superior de las genéticas tiene tiempos de floración superiores a 60 días.

Estos valores son consistentes con las diferencias observadas entre genéticas híbridas, índicas y sativas. Sin embargo, estos datos aunque descriptivos dependen de cada cultivador.

Figura 7: Distribución de frecuencia de ocurrencia para los días de floración.

Finalmente, el análisis de las palabras más frecuentes en los nombres y slug mostró patrones interesantes relacionados con las nomenclaturas comunes en el mercado de semillas. A través de la sustracción de prefijos y sufijos, fue posible identificar que palabras como OG, Kush, Purple y Cookies se encuentran entre las más frecuentes, destacando la influencia de ciertas genéticas originales en los procesos de crianza.

Figura 8: Frecuencia de palabras en las columnas name y slug.

Confirmando este análisis, se encontró que la genética OG Kush aparece como el mayor representante en la columna parent dominante, con una frecuencia de 212.

Figura 9: Frecuencia de genéticas en la columna parents.

Aplicación Web - Green Star

Para recopilar datos reales de cultivadores sobre sus ciclos de cultivo, se desarrolló una aplicación web llamada Green Star, diseñada específicamente para centralizar y estructurar la información recolectada. Esta plataforma fue concebida como una herramienta eficiente para capturar datos críticos sobre prácticas de cultivo, entornos productivos y resultados obtenidos. La información recolectada fue clave para la construcción del dataset desarrollado en este proyecto, proporcionando una base para el análisis predictivo del rendimiento de cultivos.

La dirección de acceso a la aplicación web puede encontrarse en el siguiente anexo,

Anexo 11.

Se optó por desarrollar una aplicación web en lugar de formularios web simples por diversas razones. En primer lugar, una aplicación permite un

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

mayor control sobre la estructuración y calidad de los datos ingresados. Además, a diferencia de un formulario básico, Green Star ofrece una experiencia interactiva y visual, que no solo facilita el ingreso de datos sino también transmite de manera más efectiva el potencial de aplicar técnicas de aprendizaje automático al cultivo de cannabis medicinal. Esto mejora la comprensión y la motivación de los usuarios, reforzando su participación en el proyecto.

Arquitectura de la Aplicación

Para la arquitectura de la aplicación web, se eligieron tecnologías modernas y escalables. Next.js fue seleccionado para el frontend debido a su capacidad de ofrecer interfaces dinámicas y rápidas, así como su integración nativa con herramientas de servidor. TypeScript se utilizó para el desarrollo, brindando un entorno más robusto gracias a su tipado estático y reducción de errores en tiempo de ejecución.

En cuanto al almacenamiento de datos, se optó por PostgreSQL, alojado en Supabase. Para facilitar las consultas y el manejo de datos, se empleó Prisma como ORM. Finalmente, la aplicación se desplegó en Vercel, un servicio de hosting que proporciona soporte nativo para aplicaciones basadas en Next.js.

Figura 10: Arquitectura de la aplicación Green Star.

El diagrama en la Figura 10 ilustra la arquitectura de la aplicación Green Star, detallando las interacciones entre el frontend, backend, base de datos y servicios del stack tecnológico. La organización sigue un flujo lógico, comenzando con los usuarios y extendiéndose hacia los servicios en la nube.

Los usuarios interactúan con la aplicación a través de una PWA. Estos usuarios envían solicitudes HTTP al servidor para acceder a los recursos de la aplicación, y a su vez, reciben las respuestas necesarias para renderizar la interfaz del usuario.

En el centro del diagrama se encuentra el cluster de Vercel, que alberga la instancia de Next.js, dividida en dos componentes principales. Por un lado, el UI Frontend (ubicado en la carpeta /pages) contiene las vistas y la lógica necesarias para renderizar la interfaz del usuario. Por otro lado, las Funciones de Servidor (dentro de la carpeta /api) gestionan las solicitudes entrantes y se encargan de la lógica del backend. Ambas entidades están conectadas mediante funciones de comunicación interna: el frontend utiliza fetch() para enviar solicitudes a las funciones de servidor, que responden con datos procesados utilizando res().

Desde las Funciones de Servidor, se establecen tres conexiones clave con otros servicios. La primera conexión es con NextAuth.js, el servicio de autenticación utilizado para gestionar las credenciales de los usuarios. Aquí, las funciones del backend envían credenciales al servicio de NextAuth.js, que autentica a los usuarios y devuelve la información de sesión correspondiente. Dentro de este servicio, se incluye un proveedor de autenticación de Google, aunque también puede integrarse con otros proveedores.

La segunda conexión de las Funciones de Servidor se realiza con el cluster cloud de Supabase, que contiene dos componentes fundamentales: una base de datos PostgreSQL, encargada de almacenar los datos estructurados de la aplicación, como información de usuarios y ciclos de

Téc. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

cultivo; y un Bucket de almacenamiento, donde se alojan archivos estáticos en formato CSV. La interacción con la base de datos se realiza a través de Prisma, un ORM que facilita operaciones CRUD (crear, leer, actualizar y eliminar) entre el backend y PostgreSQL. En paralelo, las funciones del servidor también solicitan archivos al bucket de almacenamiento, obteniendo los recursos necesarios en formato optimizado, gracias al uso de caché para mejorar el rendimiento.

Experiencia de Usuario

Se diseñaron y optimizaron dos flujos principales dentro de la aplicación Green Star, cada uno orientado a facilitar la recolección de datos relevantes para el análisis predictivo y a garantizar una interacción intuitiva y fluida para los usuarios. Estos flujos son el Registro de Perfil de Cultivador y el Registro de Ciclos de Cultivo, ambos fundamentales para construir una base sólida de datos de alta calidad.

Onboarding: Registro de Perfil de Cultivador

Los datos recolectados para el cultivador se obtienen en el onboarding de la aplicación donde el usuario debe completar los datos de su perfil. El flujo de registro de perfil está diseñado como el primer paso dentro de la aplicación Green Star, donde se recolecta información general del cultivador para estructurar un perfil básico que será utilizado como referencia. Este proceso se compone de las siguientes etapas principales:

1. **Inicio de Sesión o Registro:** A través del sistema de autenticación proporcionado por NextAuth, el usuario puede registrarse o iniciar sesión utilizando un proveedor como Google. Este paso inicial simplifica el acceso a la aplicación y asegura que los datos recopilados estén vinculados a una cuenta única y segura.
2. **Formulario de Perfil del Cultivador:** En esta sección, el usuario completa un formulario en el que se solicitan datos clave como:
   - Años de Experiencia: debe ingresar los años de experiencia que tiene en el cultivo de cannabis.
   - Tipo de Cultivador: debe identificar qué tipo de cultivador es de acuerdo a la producción y finalidad de su cultivo. Las categorías son: Autocultivador "Cultiva para consumo propio o para alguien cercano." (Pequeñas Cantidades); Cultivador Solidario "Cultiva para consumo propio y de otras personas en una sociedad." (Cantidades Medianas); Cultivador Industrial "Cultiva para comercialización o fines industriales." (Grandes Cantidades).
   - Educación al Respecto: debe ingresar su máximo nivel de educación relevante al cultivo de cannabis. Las opciones son las siguientes: Ninguna, recién comienza; Autodidacta, aprendió a través de la experiencia personal e investigación; Cursos, completó clases específicas sobre cultivo de cannabis; Nivel de Grado, tiene educación formal en agricultura o campos relacionados.
   - Número de Plantas por Rotación: debe ingresar el número aproximado de plantas que suele tener en floración a la vez.
   - Detalles del Equipo: debe ingresar los equipos que implementa en sus cultivos.
3. **Revisión y Confirmación del Perfil:** Tras completar el formulario, el usuario accede a una pantalla de revisión, donde puede verificar los datos ingresados y realizar ajustes si es necesario. En este paso, también se

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Ing. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

solicita que elija un nombre de usuario único, lo que personaliza aún más la experiencia y otorga un sentido de anonimato al usuario.

4. **Acceso a Funcionalidades:** Una vez confirmado el perfil, el usuario tiene acceso completo a la aplicación, incluyendo la posibilidad de iniciar el flujo de registro de ciclos de cultivo y explorar herramientas adicionales. Este paso marca el inicio de la interacción activa con Green Star y de su contribución al dataset colectivo. Cuando el usuario inicia el proceso de registrar un ciclo de cultivo, se encontrará con 3 opciones: Historia (ciclos finalizados): este es el proceso habilitado al momento del desarrollo de este proyecto, esta es la funcionalidad clave para la obtención de datos reales de ciclos de cultivo finalizados. Alternativo (ciclos en curso) y Futuro (ciclos planeados): estos procesos son visibles a través de tarjetas, pero no están habilitadas ya que corresponden a funciones futuras relacionadas con modelos predictivos entrenados a partir del dataset obtenido al final de este proyecto.

Este flujo guía al usuario con la creación de su perfil, validando dinámicamente los datos ingresados.

Datos de Cultivo: Registro de Ciclos de Cultivo

Una vez que el cultivador logra completar su perfil podrá agregar simulaciones de ciclos de cultivo terminados. Para estas simulaciones, el cultivador deberá ingresar los siguientes datos del lote de cultivo. Este flujo registra los ciclos de cultivo y constituye la funcionalidad central de Green Star. Está orientado a recopilar datos detallados de los cultivos de los usuarios, abarcando desde la planificación inicial hasta los resultados finales. Este flujo se divide en varias etapas secuenciales:

0. **Límites de la Simulación (Introducción):** Al iniciar este flujo, el usuario visualiza una pantalla introductoria que explica los límites y alcances del registro. Se hace énfasis en la importancia de agrupar plantas con características homogéneas (como genética, entorno y técnicas utilizadas) en un mismo lote para garantizar datos consistentes.

1. **Número de Plantas:** El usuario comienza especificando el número de plantas que componen el lote. Este dato inicial establece la base para el resto del flujo. En casos de lotes pequeños o kits pre-armados de semillas, se proporcionan recomendaciones para agrupar genéticas adecuadamente.

2. **Selección de Genéticas:** En esta etapa, el usuario selecciona las genéticas cultivadas dentro del lote. Para ello, utiliza un buscador con autocompletado que facilita encontrar la genética deseada, este buscador fue desarrollado para simplificar la búsqueda entre miles de registros provenientes del dataset generado en la etapa anterior del informe. El usuario debe introducir el nombre de la genética, el buscador responderá con una lista de genéticas entre las que el usuario puede seleccionar e ingresar la cantidad de plantas en el lote que corresponden a esta. Cada genética seleccionada aparece como una tarjeta que muestra su información básica (nombre, fenotipo, fotoperiodo). El flujo avanza sólo cuando todas las plantas del lote han sido asignadas a una genética.
   - Además, existe la opción de agregar nuevas genéticas no listadas a través de un flujo adicional "Agregar una Nueva Genética", enriqueciendo el dataset de las genéticas.

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

3. **Geolocación:** El usuario ingresa la ubicación geográfica del lote utilizando un buscador de texto con un mapa interactivo debajo. Al seleccionar el nombre de la ubicación del menú desplegable debajo del buscador con autocompletado, se obtienen los valores de ubicación geográfica (latitud y longitud) del lugar seleccionado.
4. **Cronograma de Cultivo:** En esta etapa, el usuario registra las fechas clave del ciclo de cultivo para cada genética. Se presentan tarjetas para cada genética seleccionada, y el usuario debe seleccionar el tipo de inicio del cultivo (germinación o clonación), e ingresar las fecha de inicio, tras lo cual el sistema genera un cronograma sugerido para las etapas posteriores (plantin, vegetación, pre-floración, floración, cosecha). Las fechas autocompletadas dependen principalmente del fotoperiodo de la genética, aunque estas pueden ajustarse manualmente. Esta pantalla también incluye una funcionalidad que permite copiar las fechas entre genéticas para agilizar el proceso.
5. **Configuración del Entorno de Cultivo:** Aquí, el usuario selecciona parámetros clave del entorno de cultivo, como:
   - **Ambiente:** Indoor, outdoor o invernadero.
   - **Medio:** LivingSoil, hidroponía o sustrato convencional.
   - **Métodos aplicados:** Técnicas específicas como Screen of Green o Super Cropping entre otras.

   Estos datos contextualizan las condiciones del cultivo y son esenciales para análisis más detallados.
6. **Registro de Resultados de Cosecha:** Finalmente, el usuario ingresa los resultados obtenidos, especificando la cantidad de gramos producidos por planta para cada genética del lote. Esta información se recopila en tarjetas individuales que resumen los datos de la genética correspondiente. Se incluye una opción para copiar valores entre genéticas, lo que simplifica la tarea en lotes homogéneos.

Los datos recolectados incluyeron características del cultivador (experiencia, tipo de equipo, número de plantas), características de ciclos de cultivo (genéticas, cronogramas, métodos), y finalmente la cantidad de gramos obtenidos por planta como variable objetivo.

Finalmente, una vez ingresados los datos del ciclo de cultivo, el cultivador debe ingresar la cantidad de gramos obtenidos por planta al finalizar la cosecha. Este valor debe ser aproximado ya que la cantidad varía de una planta a la otra y los ciclos de cultivo pueden ser numerosos para ingresar de forma individual por planta. Estos datos se eligieron por su relevancia en la predicción del rendimiento.

El diagrama de la Figura 11 representa las entidades planteadas en los flujos recién explicados y las relaciones que se establecen entre ellas.

Figura 11: Modelo entidad relación de la aplicación Green Star.

Las tablas de cada entidad pueden encontrarse en el siguiente anexo, Anexo 12.

Mecanismos de Validación de Datos

Se implementaron diversas estrategias para garantizar la precisión y completitud de los datos ingresados por los usuarios durante ambos flujos de recolección de datos. En cada pantalla de los flujos de Onboarding y Datos de Cultivo, se diseñaron interfaces específicas para cada campo.

Tyc. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Estas interfaces detallan el tipo de dato requerido, incluyen botones informativos con descripciones adicionales sobre el valor solicitado, y aplican controles de validación al input correspondiente.

Cada campo tiene validaciones automáticas que aseguran que los datos ingresados se encuentren dentro de los parámetros esperados. Por ejemplo, en el caso de los gramos por planta, se verifica que el valor ingresado esté dentro de un rango previamente definido. Asimismo, se implementaron ayudas contextuales como sugerencias y autocompletado en campos específicos, como los nombres de genéticas, para facilitar la experiencia del usuario y reducir errores de entrada.

Adicionalmente, antes de que los datos sean registrados en la base de datos, se realiza una validación adicional desde el endpoint de la API. Esto asegura que los valores ingresados cumplan con los criterios definidos en el modelo de datos. La estructura misma de la aplicación contribuye significativamente a la precisión y organización de los datos. Por ejemplo, el modelo SimXGen actúa como una entidad intermedia entre los modelos Simulación y Genética Seleccionada y posee campos como availablePlants y hasAvailablePlants que ayudan a determinar si el usuario debe asignar más genéticas al lote de cultivo, evitando inconsistencias en los datos.

Las validaciones de cada campo correspondiente pueden encontrarse en el siguiente anexo, Anexo 12.

Promoción de la Aplicación

La promoción incluyó mensajes directos en redes sociales a cultivadores preseleccionados y conversaciones con cultivadores conocidos, describiendo el concepto general del proyecto, explicando el motivo de su participación y destacando los beneficios de contribuir al proyecto. Se ofreció retroalimentación personalizada sobre sus cultivos como incentivo y el acceso a una herramienta para organizar de manera más eficiente sus cultivos una vez finalizado el proyecto.

Algunos usuarios enfrentaron dificultades técnicas o dudas sobre los campos requeridos. Para resolver esto, se implementaron reuniones virtuales breves y soporte técnico a través de diversas redes sociales. También varios formularios fueron simplificados tras recibir retroalimentación inicial, resaltando los inputs que
pasaban por alto o eran difíciles de identificar y agregando ayudas en el interfaz para agilizar el proceso de completado de datos.

Otros usuarios sugirieron la creación de nuevos campos e incluso agregaron opciones a campos existentes. Como por ejemplo, algunos usuarios sugieren la opción de ampliar el contexto de un ciclo de cultivo ya concretado, agregando un campo Notas a la simulación, donde el cultivador puede agregar detalles sobre el contexto del ciclo, justificando el resultado de un ciclo (e.g. exceso de estrés por aumento en la humedad).

Esta y otras sugerencias serán agregadas a la aplicación una vez finalizado el proyecto final.

Segmentación y Normalización de Cronogramas de Cultivo

Durante el registro de ciclos de cultivo, la aplicación utiliza varias tablas de datos almacenadas en formato CSV, entre las cuales destacan: auto_photo.csv, hybrid_photo.csv, photoperiod_photo.csv y vpd.csv (adjunto se encontraran los archivos). Estas tablas tienen roles específicos dentro del sistema:

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

c. Enrique R. Chiesa Torres
Secretario Académico
niversidad Nacional de Villa Mercedes

- **Tablas con sufijo *_photo:** estas tablas permiten determinar los valores asociados al tipo de fotoperiodo de la genética seleccionada, categorizados en tres variables principales: "Photoperiodic", "Auto" y "Hybrid".

Cada una de estas tablas contiene las siguientes columnas principales:

- **range:** El atributo segmenta los datos de acuerdo con los rangos definidos para las distintas etapas del cronograma de cultivo. Durante la recolección de datos, los usuarios especifican las fechas de inicio y finalización de cada etapa del ciclo de cultivo. Sin embargo, debido a que la duración de cada genética varía considerablemente, fue necesario aplicar una metodología de segmentación para garantizar la consistencia y normalización de los datos. Esta segmentación se logró dividiendo cada etapa según su duración relativa dentro del cronograma de cultivo. Las etapas más extensas, como la vegetativa, se subdividieron en un mayor número de segmentos, mientras que las etapas más cortas, como la germinación, se asignaron a un único segmento. En total, cada cronograma se dividió en 15 segmentos, que corresponden a las filas de las tablas CSV relacionadas. La estructura de segmentación es la siguiente:

6,	//	4/5	de	Vegetativo
7,	//	5/5	de	Vegetativo
8,	//	1/2	de	Pre-Flora
9,	//	2/2	de	Pre-Flora
10,	//	1/4	de	Flora
11,	//	2/4	de	Flora
12,	//	3/4	de	Flora
13,	//	4/4	de	Flora
14,	//	1/2	de	Maduración
15,	//	2/2	de	Maduración

- **stage:** Define la etapa del ciclo de cultivo (e.g., germinación, vegetativa, floración), que afecta los valores de las demás columnas.
- **Datos sobre la luz:**
  - **DLI y DLIwCO2:** Indican la ingesta diaria de luz (Daily Light Integral) sin y con la presencia de dióxido de carbono adicional.
  - **PPFD y PPFDwCO2:** Miden la densidad del flujo de fotones fotosintéticamente activos, un parámetro clave para evaluar la eficiencia de la iluminación en las plantas.
  - **Las columnas:** spectrum1, spectrum1Color, spectrum2, spectrum2Color contienen datos acerca de los diferentes rangos de espectros de luz.
  - **Distancia de luz:** Proporcionada en la columna distance, representa la distancia de la luz LED a la copa del cultivo.
- **Datos sobre dióxido de carbono (CO2):**
  - **regCO2:** Indica el nivel óptimo de CO2 para una circulación normal de aire en el entorno de cultivo.
  - **boostCO2:** Indica el nivel óptimo de CO2 con una circulación mayor de aire en el entorno de cultivo, combinado con los valores de DLI y PPFD, puede potenciar la ingesta de luz y mejorar la absorción de las plantas.
  - **regAbsortion y boostAbsortion:** Proporcionan el porcentaje de absorción,' parámetro clave para la circulación de CO2 en ppm y su impacto en las plantas.

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

• **Tabla vpd:** permite calcular los valores asociados al Déficit de Presión de Vapor (VPD) en función de la genética seleccionada y la etapa del ciclo de cultivo. Los índices de esta tabla corresponden a la temperatura y el porcentaje de humedad relativa del entorno de cultivo, mientras que los valores internos representan el VPD en kPa para cada combinación específica de dichos índices. Para garantizar la precisión de los valores de VPD en cada etapa, se aplica un proceso de segmentación del cronograma de cultivo, similar al utilizado en la columna range. En este caso, el cronograma se divide en 7 segmentos principales:

'R1'; // Germinación
'R2'; // Plantín
'R3'; // 1/3 de Vegetativo
'R3'; // 2/3 de Vegetativo
'R4'; // 3/3 de Vegetativo
'R4'; // Pre-flora
'R5'; // 1/3 de Flora
'R5'; // 2/3 de Flora
'R6'; // 3/3 de Flora
'R7'; // Zone de Pérdida

Cada segmento define un rango óptimo de VPD para el cultivo en el momento correspondiente del ciclo. Una vez identificado el segmento actual del cronograma, es posible consultar en la tabla vpd.csv los valores óptimos de VPD y determinar cuál es la combinación ideal de temperatura y humedad relativa para maximizar el rendimiento del cultivo en esa etapa específica.

El análisis detallado de estos datos permitió establecer una metodología de normalización basada en el cronograma de cultivo. Esta normalización, implementada mediante la segmentación de las etapas del ciclo, facilita la estructuración de las muestras recolectadas, las cuales presentan una alta variabilidad debido a la diversidad genética inherente a los cultivos. Al segmentar y categorizar los datos según las etapas del cronograma y los parámetros específicos de cada genética, se garantiza la consistencia en el análisis y se proporciona una base sólida para futuras comparaciones y simulaciones predictivas.

II- Armado del Dataset

Integración de los Datos Recolectados en un Dataset General

Como se mencionó en el segmento anterior los datos ingresados por los usuarios en la aplicación son normalizados automáticamente durante su ingreso. Este proceso incluye la estandarización de unidades, la validación de valores atípicos y el mapeo de las variables con el esquema general del proyecto, asegurando la consistencia y calidad de la información, al igual que la normalización de los cronogramas.

Una vez estructurados y validados, estos datos son integrados en el dataset principal mediante un proceso de exportación desde las tablas de la base de datos hacia un archivo CSV unificado.

Para la creación del dataset general, se seleccionaron campos específicos de las entidades principales de la base de datos que reflejan las características principales de cada ciclo de cultivo. El objetivo es consolidar la información más relevante en un único archivo CSV que pueda ser utilizado para análisis y simulaciones.

Tpc. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Las tablas seleccionadas y los campos incluidos son las siguientes:

Tabla User: Proporciona datos básicos de los usuarios que interactúan con la aplicación, como su identificador único, nombre, nombre de usuario y correo electrónico.

Tabla GrowerProfile: Incluye información sobre la experiencia y las prácticas de cultivo de los usuarios, como su nivel de experiencia, tipo de cultivador, educación relacionada al tema, número de plantas que acostumbra tener en rotación y equipos utilizados.

Tabla Simulacion: Contiene datos relacionados con las simulaciones realizadas por los usuarios, incluyendo su identificador único, el tipo de simulación, número de plantas involucradas, datos de geolocalización, tipo de medio de cultivo, tipo de ambiente y métodos de cultivo, así como los resultados obtenidos, total cosechado para la simulación.

Tabla GeneticaSeleccionada: Representa las genéticas de cannabis seleccionadas en los ciclos de cultivo, incluyendo su identificador único, su nombre, slug, fenotipo, tipo de fotoperiodo y el número de plantas asociadas.

Tabla CronogramaDeCultivo: Contiene los datos relacionados con las etapas del cronograma de cultivo, incluyendo su identificador único, tipo de origen del ciclo (germinación o clonación), fechas de inicio y finalización de las distintas fases y la cantidad cosechada.

Esta selección permite consolidar un archivo unificado que contiene la información necesaria para los análisis de los datos recolectados, al tiempo que facilita la manipulación y visualización de la base de datos.

La aplicación cuenta con un interfaz y funciones de servidor para recorrer las tablas de la base de datos, extrayendo los campos seleccionados y los exportando el csv actual.

A continuación, se detalla el proceso empleado para extraer los datos recolectados en un dataset unificado:

1. **Conexión a la base de datos:** se utiliza Prisma como ORM para interactuar con la base de datos, permitiendo realizar consultas específicas y optimizadas. Esto asegura un acceso eficiente y seguro a las tablas relevantes.
2. **Selección de columnas relevantes:** mediante consultas definidas en Prisma, se extraen únicamente los campos necesarios de cada tabla. Estas consultas son configuradas para incluir relaciones entre tablas, como las genéticas seleccionadas por simulación o los cronogramas de cultivo asociados.
3. **Estructuración y transformación de datos:** los datos extraídos se estructuran y normalizan en un formato unificado utilizando funciones de mapeo y aplanamiento (flatMap). Esto permite consolidar información de múltiples tablas en una sola estructura. Para valores complejos, como listas o ubicaciones geográficas, se emplean transformaciones específicas (e.g., conversión a JSON o concatenación de elementos).
4. **Exportación a formato CSV:** la estructura consolidada se convierte a un archivo CSV utilizando la biblioteca @json2csv/plainjs. Este archivo contiene todas las columnas seleccionadas de manera consistente y legible, facilitando su uso en simulaciones y análisis posteriores. Además, los encabezados del CSV reflejan claramente las relaciones entre los datos, como userId, SimulacionId o cronogramaDeCultivoId.

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

5. **Automatización del flujo:** la funcionalidad está implementada como un API endpoint en la aplicación, permitiendo generar el archivo CSV dinámicamente con los datos más recientes almacenados en la base de datos. Esto asegura que el dataset se mantenga actualizado y disponible para exportación en cualquier momento a través de un botón de descarga.

Proceso de Automatización Continuo

El proyecto enfrenta ciertos desafíos relacionados con la cantidad de datos recopilados. En su estado actual, no se dispone de suficientes instancias para entrenar un modelo de machine learning robusto. Al momento de la redacción de este informe, se han recopilado 63 instancias de datos, cuyos cronogramas de cultivo están completos. Estas variables son fundamentales para el análisis de datos, y su ausencia se debe a que algunos usuarios dejaron sus simulaciones sin completar. Por lo tanto, con solo 63 filas utilizables, no es viable realizar un análisis predictivo riguroso ni obtener resultados concluyentes en esta etapa del proyecto.

No obstante, para abordar esta limitación y avanzar en la consecución de los objetivos planteados, se propone implementar un proceso de automatización continuo para la recolección de datos.

La aplicación Green Star se mantendrá activa y seguirá recopilando datos de nuevos usuarios. Con el propósito de aumentar el volumen de datos registrados, se pretende llevar a cabo una estrategia de difusión activa para promover el uso de la aplicación en comunidades relevantes. Esto incluye la publicación en foros especializados, páginas web dedicadas al cultivo de cannabis medicinal, y redes sociales afines. Adicionalmente, se pueden establecer colaboraciones con asociaciones de cultivadores y foros académicos interesados en la agricultura de precisión y el análisis de datos aplicado al cultivo.

Estas acciones no solo permitirán ampliar la base de datos, sino también diversificar las instancias recopiladas, lo que contribuirá a obtener un dataset más representativo y adecuado para futuras implementaciones del modelo predictivo.

Asimismo, esta estrategia garantiza que la automatización del proceso de recolección de datos se alinee con el objetivo a largo plazo de establecer una base sólida para estudios posteriores en agricultura de precisión aplicada al cultivo de cannabis medicinal.

Pipeline para el Procesamiento de Datos Recopilados

El pipeline propuesto para el procesamiento de los datos recopilados tiene como objetivo asegurar la calidad, consistencia y actualización periódica del conjunto de datos, garantizando su utilidad para futuros entrenamientos de modelos predictivos. A continuación, se describe cada paso del pipeline CI/CD:

1. **Recopilación de datos a través de Green Star:**

a. Los usuarios completan nuevos ciclos de cultivo ingresando los datos directamente en la aplicación Green Star. Cada registro incluye información clave como el cronograma de cultivo, la cantidad cosechada por planta, y las características genéticas de las plantas.

2. **Validación y manejo de campos faltantes:**

a. La aplicación implementa reglas de validación en tiempo real para verificar que todos los campos requeridos estén completos antes de aceptar el registro y asegurar la integridad del mismo.

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Ec. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

b. Sí el registro cuenta con todos los datos críticos, es apto para incluirlo en el dataset general. En caso contrario continúa almacenado en la base de datos hasta que el usuario complete la información necesaria para poder incluirlo al dataset general. Este enfoque garantiza que el dataset general solo contenga instancias completas y listas para análisis predictivo.

3. Almacenamiento y exportación periódica del dataset:

a. Los datos recopilados se almacenan en una base de datos centralizada.

b. La exportación del dataset general se realiza de manera periódica en función de una de las siguientes estrategias:

i. Por tiempo: la exportación es realizada con una frecuencia de 30 días, permitiendo observar tendencias a corto plazo.

ii. Por volumen: Cuando se registran al menos 10 nuevas instancias completas, se genera una versión actualizada del dataset.

c. Cada archivo exportado sigue la nomenclatura green-star_dd_mm_aaaa_hh_mm.csv para facilitar su organización y trazabilidad.

4. Preparación del conjunto de datos para el entrenamiento del modelo:

a. Integración de nuevos datos: Los registros recopilados se integran al dataset existente mediante un proceso automatizado que realiza las siguientes tareas:

i. Unificación de los nuevos registros con el dataset existente: Los datos recientes se agregan al archivo general, respetando el formato y las columnas establecidas previamente.

ii. Eliminación de duplicados: Se verifica que las nuevas instancias no sean duplicados de registros ya existentes en el dataset general.

iii. Actualización del dataset consolidado: Una vez validados y procesados, los datos nuevos se integran de manera definitiva, creando una nueva versión del archivo que estará lista para entrenamientos futuros. Este pipeline garantiza que el conjunto de datos evolucione de manera continua y se vuelva más robusto con el tiempo. Al filtrar registros incompletos, normalizar los datos y realizar exportaciones regulares, se asegura la calidad y consistencia del dataset, sentando las bases para análisis predictivos confiables y replicables. El diagrama de este pipeline puede encontrarse en la Figura 12.

Figura 12: Diagrama de flujo del pipeline del procesamiento de datos recolectados.

III - Desarrollo y Entrenamiento del Modelo

El desarrollo del modelo predictivo para la estimación del rendimiento del cultivo de cannabis medicinal se estructuró en una serie de etapas, incluyendo la exploración de datos, preprocesamiento, técnicas de aumento de datos y el entrenamiento de diferentes algoritmos de clasificación. A continuación, se detallan estos procesos en función de la estructura establecida en el repositorio green-star_data. La dirección de acceso al repositorio con los scripts utilizados durante esta etapa puede encontrarse en el siguiente anexo, Anexo 13.

Estructura del Proyecto

ES COPIA

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

El proyecto green-star_data se organizó en diversas carpetas y scripts, cada uno enfocado en una fase específica del desarrollo del modelo:

data/: Contiene los datos recopilados de la aplicación Green Star, contiene las subcarpetas history/, donde se almacenan los datasets de fechas anteriores, y preprocessed/, donde se almacenan los datasets preprocesados.

scripts/preprocessing/: Incluye los scripts para limpieza, normalización y transformación de los datos crudos obtenidos de la aplicación hasta su normalización para la aplicación de las distintas técnicas de aumento de datos y entrenamiento.

scripts/oversampling/: Implementaciones de distintas técnicas de oversampling como Random Oversampling, SMOTE, ADASYN, Cluster-Based Oversampling y KNN Interpolation para abordar el problema del desbalance de clases y generar más instancias del muestreo previo al entrenamiento del modelo.

scripts/training/: Contiene los scripts de entrenamiento de diferentes modelos de machine learning (Random Forest, SVM y OGBoost).

scripts/testing/: Scripts para la comparación de los modelos de oversampling y para la evaluación del rendimiento de los modelos de entrenamiento con métricas como precisión, recall y F1-score.

outputs/oversampled/: Almacena los resultados obtenidos tras aplicar las técnicas de oversampling.

outputs/trained/: Almacena los resultados obtenidos tras el entrenamiento y validación de los modelos.

Esta estructura modular permite una gestión eficiente de los experimentos y facilita la reproducibilidad de los resultados.

Preprocesamiento y Preparación de los Datos

En esta etapa, se aplicaron diversas técnicas para limpiar, transformar y estructurar la información cruda obtenida de la aplicación de manera óptima. Puede encontrar el script en el siguiente anexo, Anexo 14.

A continuación, se describen los pasos principales realizados en el pipeline de preprocesamiento del dataset:

0. Carga y Limpieza Inicial de Datos

El primer paso consistió en la carga del dataset a partir de un archivo CSV. Posteriormente, se eliminaron columnas irrelevantes o redundantes, tales como identificadores temporales, datos administrativos y variables que no aportan valor predictivo. La eliminación de estas variables se basó en distintos criterios, que se detallan a continuación:

Columnas redundantes o poco informativas:

- **plantasEnRotacion:** Se trata de una clasificación descriptiva del número de plantas en rotación. En su lugar, se conservó plantasEnRotacionNro, que proporciona una métrica más clara y cuantificable.
- **geneticaName:** Contiene los mismos valores que geneticaSlug, pero sin normalización. Se prefirió geneticaSlug por ser más consistente en formato (minúsculas y sin espacios) y más eficiente para indexación y búsqueda.

Identificadores internos de la base de datos:

- **SimulacionId, GeneticaSeleccionadaId y cronogramaDeCultivoId:** Son UUIDs que funcionan como claves primarias en la base de datos, pero no representan información relevante sobre el cultivo en sí. Dado que su

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

función es administrativa y no aporta significado en términos de predicción, fueron descartados.

- **creado y modificado:** Corresponden a marcas de tiempo utilizadas para control de versiones dentro de la base de datos. No reflejan características del cultivo ni influyen en su rendimiento.

Datos poco fiables o con inconsistencias:

- **totalCosechado:** Fue originalmente utilizado durante el desarrollo de la aplicación para recolectar datos, pero contenía errores de medición. Se optó por utilizar cantidadCosechada, que representa de manera más precisa la variable objetivo del modelo.

Columnas con estructura no óptima para el modelo:

- **equipo:** Es un array de strings con los equipos utilizados por el cultivador, recopilado durante el onboarding. Aunque los usuarios pueden agregar nuevos equipos, la mayoría de las entradas contienen los mismos elementos de una lista sugerida, lo que genera una distribución poco informativa y difícil de procesar sin una transformación previa.

Con base en estos criterios, se procedió a la eliminación de las columnas:

1. Procesamiento de Datos del Usuario

Se unificaron los datos de identificación del usuario (userId, userName, username, email) en una única clave compuesta, la cual fue reemplazada por un identificador numérico único. Esto permite anonimizar los datos y reducir la dimensionalidad del dataset. Unificar las columnas identificadoras del usuario y reemplazarlas con un identificador numérico contribuye a la anonimización de los datos y la protección de información sensible, eliminando detalles como nombres de usuario y correos electrónicos que podrían ser utilizados para identificar individuos. Además, esta transformación reduce el tamaño del dataset al consolidar múltiples columnas textuales en un solo valor numérico, optimizando el almacenamiento y facilitando la manipulación de datos. Desde una perspectiva de modelado, los algoritmos de machine learning funcionan de manera más eficiente con datos numéricos, por lo que eliminar estas variables textuales innecesarias mejora el desempeño del modelo al evitar el procesamiento de información redundante o irrelevante. Asimismo, se previenen problemas asociados con la codificación de variables categóricas, ya que mantener estas columnas en formato texto requeriría estrategias como one-hot encoding, lo que incrementa drásticamente la dimensionalidad del dataset sin aportar valor significativo a la predicción del rendimiento del cultivo. Link de acceso al Anexo 15.

2. Codificación del Tipo de Simulación

Se convirtió la variable categórica tipoDeSimulacion en valores numéricos según un mapeo predefinido [Historia → 1, Alterno → 2, Presagio → 3]. Sin embargo en este momento del proyecto esta variable no se incluirá en el entrenamiento de los modelos ya que por el momento todas las muestras son tipoDeSimulacion = 1.

Esta variable proviene de la aplicación de recolección de datos, donde en el futuro los usuarios podrán seleccionar entre tres tipos de simulación de cultivo:

- **Historia (habilitada actualmente):** permite a los cultivadores ingresar datos de ciclos de cultivo ya finalizados, incluyendo la cosecha obtenida.

Téc. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

- **Alter (no habilitada en este proyecto):** los usuarios registran condiciones de un ciclo de cultivo en curso, aún sin cosechar.
- **Presagio (no habilitada en este proyecto):** se ingresarán datos proyectados para un cultivo futuro.

Para este estudio, se optó por restringir la recolección de datos exclusivamente a ciclos finalizados, deshabilitando las opciones Altern y Presagio. Esta decisión se tomó con el objetivo de simplificar la estructura y calidad de los datos recolectados, asegurando que toda la información utilizada en los modelos correspondiera a resultados concretos. Link de acceso al Anexo 16.

3. Cálculo del Puntaje del Cultivador

La métrica cultivador_rating fue diseñada específicamente para este proyecto, basada en la información proporcionada por los usuarios durante el proceso de onboarding en la aplicación. Su propósito es cuantificar la experiencia del cultivador a partir de distintos factores relevantes, asignando un peso específico a cada uno:

- **Años de experiencia (40%).**
- **Cantidad de plantas en rotación por sala en simultáneo (20%).**
- **Tipo de cultivador (20%) – [Autocultivador → 1, Cultivador Solidario → 2, Cultivador Industrial → 3].**
- **Nivel de educación en cultivo (20%) – [Ninguna → 0, Autodidacta → 1, Cursos → 2, Nivel de Grado → 3].**

Cada uno de estos factores fue normalizado en función del valor máximo observado en la muestra y posteriormente ponderado según su peso asignado. La combinación de estos valores genera el cultivador_rating, una métrica compuesta que permite comparar de manera relativa el nivel de experiencia de los diferentes cultivadores. Link de acceso al Anexo 17.

4. Procesamiento de Datos de Geolocalización

Se extrajeron las coordenadas geográficas (latitud y longitud) desde la columna geolocation, almacenada en formato JSON, eliminando la información textual no relevante. Link de acceso al Anexo 18.

5. Cálculo del DLI (Daily Light Integral)

Se estimó el DLI acumulado en cada etapa del ciclo de cultivo utilizando tablas de referencia para diferentes tipos de genética de acuerdo a la columna geneticaPhoto (Photoperiod, Auto, Hybrid). Este cálculo permite evaluar la exposición lumínica total durante el ciclo de crecimiento de la planta. De estos cálculos se obtuvieron nuevas variables numéricas para cada etapa de cultivo y una extra para el total del cronograma acumulando el DLI del ciclo completo. Link de acceso al Anexo 19.

6. Codificación de Variables Categóricas

Las variables categóricas fueron transformadas mediante técnicas de codificación aplicando one-hot encoding a las siguientes columnas haceGerminacion, geneticaPheno, geneticaPhoto obteniendo los dummies para cada caso. Link de acceso al Anexo 20.

7. Transformación de Fechas

Los ciclos de cultivo fueron convertidos de fechas a características numéricas, representando los días de duración para cada etapa, facilitando su uso en modelos de aprendizaje automático. Link de acceso al Anexo 21.

8. Categorización de la Variable Objetivo

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Dado el carácter continuo de la variable objetivo cantidadCosechada, se optó por su discretización en tres categorías (yield_Baja, yield_Media, yield_Alta), definiendo 3 bins de acuerdo a la distribución de las muestras. Este enfoque permitió reformular el problema como una tarea de clasificación, habilitando el uso de técnicas de oversampling para balancear el dataset. Link de acceso al Anexo 22.

9. Eliminación de Registros con Valores Nulos

Aunque en al momento de extracción de los datos de la aplicación se excluyen los datos incompletos, también se eliminaron las filas con valores nulos en la variable objetivo para garantizar la consistencia del dataset.

10. Selección de Variables Finales

Finalmente, se descartaron variables que ya no eran necesarias después de las transformaciones previas. Se definieron los conjuntos de datos de entrada (X) y salida (y), asegurando que la estructura del dataset fuera adecuada para su posterior uso en modelos de Oversampling y Machine Learning.

El resultado de este proceso es un dataset preprocesado legible por los modelos, almacenado en la carpeta de datos preprocesados con un formato estructurado, su tag de creación y listo para ser utilizado en las siguientes fases del análisis predictivo.

Técnicas de Data Augmentation

Debido a que el dataset extraído de la aplicación Green Star es relativamente pequeño, con solo 63 muestras al momento del informe, se hizo necesario aplicar técnicas de sobremuestreo para generar más datos con los cuales entrenar los modelos de aprendizaje automático. El aumento del tamaño del dataset permite mejorar la capacidad de generalización de los modelos y reducir posibles sesgos en la clasificación.

Para abordar esta problemática, se implementaron diversas técnicas de oversampling:

- **Random Oversampling. Link de acceso al Anexo 24.**
- **SMOTE (Synthetic Minority Over-sampling Technique). Link de acceso al Anexo 25.**
- **ADASYN (Adaptive Synthetic Sampling). Link de acceso al Anexo 26.**
- **Cluster-Based Oversampling. Link de acceso al Anexo 27.**
- **KNN Interpolation. Link de acceso al Anexo 28.**

Implementación del Oversampling

El proceso de generación de nuevas muestras fue centralizado en el script oversampling/main.py, el cual se encarga de:

1. **Preprocesar los datos:** sí los datos no están preprocesados, el script carga el dataset original y realiza la limpieza y normalizaciones necesarias implementando el script visto en el segmento anterior.
2. **Técnicas de Oversampling:** aplica cada técnica de oversampling en secuencia y almacena los datasets resultantes en el directorio outputs/oversampled/, dentro de subdirectorios específicos para cada técnica.
3. **Guardar los datasets generados con marcas temporales para asegurar trazabilidad.**

Código principal del script oversampling/main.py. Puede encontrar el script en el siguiente anexo, Anexo 23.

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Evaluación Comparativa de las Técnicas

Para determinar qué técnica de oversampling proporciona mejores resultados, se desarrolló un script de evaluación (testing/comparative_analysis.py), script disponible en el Anexo 29. Este script mide el rendimiento de cada método utilizando:

- Accuracy en el conjunto de test
- F1-score
- Overfitting Ratio (razón entre el accuracy en entrenamiento y en test)

Resultados Obtenidos

Recordando que el mejor valor posible tanto para Accuracy, F1-score y Overfitting Ratio es 1, y que un valor aproximado indica un rendimiento óptimo sin sobreajuste. La evaluación comparativa de las técnicas de oversampling mostró los siguientes resultados:

Método	Accuracy (Test)	F1-score	Overfitting Ratio
KNN	0.8542	0.8638	1.0427
Random	0.7700	0.7500	1.1900
SMOTE	0.7500	0.7407	1.2200
ADASYN	0.7500	0.7407	1.2200
Cluster	0.7430	0.7303	1.2500

Tabla 4: Evaluación comparativa de las técnicas de oversampling.

Estos resultados evidencian que el método de interpolación basado en KNN fue el más efectivo, logrando el mejor equilibrio entre rendimiento y sobreajuste. Mientras que los demás métodos ofrecieron resultados similares, KNN destacó con una mayor precisión y F1-score. Es por esto que el dataset resultante de la interpolación KNN se utilizó para el entrenamiento de los modelos de clasificación.

Entrenamiento del Modelo

El entrenamiento del modelo representa una de las etapas clave del proyecto, ya que define la capacidad predictiva de la solución propuesta. Dado que el objetivo del proyecto es estimar el rendimiento del cultivo de cannabis medicinal en función de
diversas variables recolectadas, se optó por un enfoque basado en clasificación supervisada. Debido a la cantidad limitada de datos recolectados y la necesidad de obtener un modelo confiable, se analizaron tres modelos de clasificación:

Random Forest

Algoritmo basado en múltiples árboles de decisión, donde cada árbol se entrena con un subconjunto aleatorio de los datos, y el resultado final se obtiene a través de un proceso de votación. Se seleccionó debido a su capacidad para manejar datos con ruido, su baja sensibilidad a valores atípicos y su capacidad para capturar relaciones no lineales entre variables. Además, permite evaluar la importancia de cada variable en la predicción, lo que facilita la interpretación de los resultados. Link de acceso al Anexo 31.

Support Vector Machine (SVM)

Basado en la construcción de un hiperplano que maximiza la separación entre clases en un espacio de características, permitiendo una clasificación óptima.

Se escogió debido a su eficacia en problemas de clasificación con datos no lineales y su capacidad para generalizar bien en datasets pequeños

ES COPIA

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

mediante el uso de funciones kernel. Es particularmente útil cuando las clases no son perfectamente separables, ya que permite ajustar un margen tolerante al error mediante el parámetro de regularización. Link de acceso al Anexo 32.

XGBoost

Un algoritmo basado en gradient boosting, que optimiza de manera iterativa un conjunto de árboles de decisión mediante el algoritmo de descenso por gradiente, de ahí su nombre. Su objetivo es corregir los errores cometidos por modelos anteriores, mejorando progresivamente el rendimiento. Se seleccionó debido a su alta eficiencia computacional, su capacidad para manejar relaciones complejas entre las variables y su capacidad de generalización en datos desbalanceados. Link de acceso al Anexo 33.

Proceso de Entrenamiento Implementado

Para garantizar la validez de los resultados y optimizar el rendimiento de los modelos, se centralizaron las distintas técnicas de entrenamiento seleccionadas a través del script training/main.py, el cual ejecuta secuencialmente los distintos scripts para cada técnica. Puede encontrar el script en el Anexo 30.

Cada técnica sigue un proceso similar:

1. **División del Conjunto de Datos:** se realizó una división en 80% de datos para entrenamiento y 20% para prueba, asegurando que la distribución de clases se mantuviera proporcional en ambos conjuntos.
2. **Entrenamiento de los Modelos:** cada modelo fue entrenado con los datos preprocesados y se utilizaron valores estándar de hiperparámetros para realizar una comparación inicial sin sesgos. Los modelos entrenados en se almacenaron en formato pickle (.pkl) en el directorio outputs/trained correspondiente a cada técnica.
3. **Evaluación del Rendimiento:** se utilizaron las métricas de accuracy y F1-score para analizar el rendimiento de cada modelo.

IV - Resultados

Se aplicaron distintos scripts para analizar el comportamiento y el rendimiento de los modelos.

Importancia de Características

Comenzando con el análisis de la importancia de características, este reveló diferencias significativas en la forma en que cada modelo pondera los factores que influyen en la clasificación de los cultivos.

Random Forest

La Figura 6 muestra la importancia de las características para el modelo Random Forest, destacando que las variables más influyentes son total_dias_cultivados y DLITotal, seguidas por los valores de días y DLI por etapa de cultivo, la igual que los valores de ubicación geográfica (latitud y longitud). Esto indica que el modelo basa su predicción en factores directamente relacionados con el tiempo y el entorno del cultivo.

Figura 13: Importancia de características en el modelo Random Forest.

SVM

El modelo SVM no cuenta con una funcionalidad nativa para calcular la importancia de las características, por lo que se utilizó un método alternativo para obtener estos valores. La Figura 7 muestra Que a diferencia de Random Forest, SVM asigna mayor relevancia a los datos del

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

c. Enrique R. Chiesa Torres
Secretario Académico
niversidad Nacional de Villa Mercedes

cultivador, como educacionAlRespecto, experiencia, plantasEnRotacionNro y las características genéticas de la planta (fenotipo). Esto sugiere que el modelo se enfoca en quién cultiva y qué genética se utiliza, en lugar de los factores ambientales o temporales.

Figura 14: Importancia de características en el modelo SVM.

XGBoost

En la Figura 8 se observa que XGBoost también asigna la mayor importancia a total_dias_cultivados, aunque con una diferencia clave respecto a Random Forest: los valores de días por etapa tienen menor relevancia relativa. La variable DLITotal se encuentra entre las más importantes, pero en una proporción significativamente menor. Esto sugiere que XGBoost captura patrones diferentes, priorizando la duración total del cultivo pero con menor énfasis en la variabilidad dentro de cada fase.

Figura 15: Importancia de características en el modelo XGBoost.

Con este primer análisis del comportamiento de los modelos fue posible identificar que Random Forest es el modelo que más se enfoca en la duración, el DLI y el entorno del cultivo, variable que consideramos de mayor importancia desde el principio del proyecto. Por otro lado, SVM prioriza al cultivador y la genética de la planta y aunque XGBoost pondera la duración total del cultivo, lo hace con un menor peso en las etapas intermedias y el DLI.

Análisis de las Matrices de Confusión

A través de las matrices de confusión fue posible analizar los errores cometidos por cada modelo al clasificar las categorías de rendimiento del cultivo.

Random Forest

La Figura 9 muestra que Random Forest clasifica correctamente la mayoría de los casos en cada categoría, con 78 aciertos en Baja, 65 en Media y 72 en Alta. No obstante, se observa una confusión significativa entre Media y Alta, con 13 casos de Media predichos como Alta.

Figura 16: Matriz de confusión para el modelo Random Forest.

SVM

El modelo SVM, representado en la Figura 10, muestra una peor clasificación de la categoría Media, con 25 casos incorrectamente predichos como Alta. Esto afecta su rendimiento general, ya que aunque clasifica bien las categorías Baja y Alta, la categoría Media presenta la mayor cantidad de errores.

Figura 17: Matriz de confusión para el modelo SVM.

XGBoost

La Figura 11 muestra que XGBoost mejora la clasificación en la categoría Media, pero introduce errores en la categoría Alta, con 7 casos incorrectamente clasificados como Baja. Esto sugiere que el modelo encuentra patrones en Media con mayor precisión, pero tiene dificultades en la diferenciación de la categoría Alta.

Figura 18: Matriz de confusión para el modelo XGBoost.

Por un lado Random Forest tiene el mejor equilibrio general, aunque puede confundir algunos casos de Media con Alta. Pero en perspectiva SVM tiene dificultades en la clasificación de Media, afectando su rendimiento general. Finalmente aunque XGBoost mejora en Media, tiene más errores en Alta.

ES COPIA

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Evaluación Comparativa de Modelos

Se calcularon las métricas de desempeño para cada modelo, incluyendo Accuracy, Precision, Recall y F1-Score. Los resultados se presentan en la Figura # y la Tabla 12.

Figura 19: Comparación de desempeño entre modelos.

Modelo	Accuracy	Precisión	Recall	F1-Score
Random Forest	0.896	0.897	0.899	0.895
SVM	0.846	0.856	0.851	0.843
XGBoost	0.867	0.871	0.870	0.866

Tabla 5: Comparación de métricas de desempeño.

Sí bien los resultados son similares, Random Forest obtiene el mejor rendimiento global en todas las métricas, lo que confirma su equilibrio entre precisión y generalización. SVM tiene el peor desempeño, lo cual concuerda con su pobre clasificación de la categoría Media. Y XGBoost se encuentra en un punto intermedio, con buen desempeño en Media pero más errores en Alta.

Limitaciones Actuales

A pesar de los resultados prometedores obtenidos en la fase de entrenamiento, es importante reconocer ciertas limitaciones inherentes al proceso actual, principalmente relacionadas con el tamaño del conjunto de datos y su impacto en la precisión y generalización de los modelos.

Uno de los principales desafíos es el tamaño reducido del conjunto de datos. Con solo 63 instancias disponibles, la capacidad del modelo para capturar patrones representativos y generalizables es limitada. En problemas de machine learning, un número reducido de muestras puede derivar en modelos que se ajustan demasiado a los datos de entrenamiento (overfitting) y no logran un desempeño estable en nuevas observaciones.

Además, este volumen de datos restringido afecta la precisión y confiabilidad de las predicciones. Si bien las métricas obtenidas son alentadoras, es difícil garantizar que el modelo funcione de manera óptima en un entorno de producción o en escenarios con variaciones en las condiciones de cultivo. La aplicabilidad inmediata del sistema queda condicionada hasta que se disponga de un conjunto de datos más amplio y diverso.

V - Conclusiones

Los resultados obtenidos permiten validar el uso de técnicas de machine learning para predecir el rendimiento del cultivo de cannabis medicinal, demostrando que la información recolectada y procesada es adecuada para la tarea de clasificación.

Además, resaltan la importancia de la selección del modelo en función de la estructura de los datos y el nivel de generalización requerido.

El análisis comparativo de los modelos aplicados permitió identificar diferencias clave en su desempeño. Random Forest se destacó como la mejor opción, logrando una clasificación más equilibrada en todas las categorías y obteniendo las mejores métricas de precisión, recall y F1-score. SVM, por otro lado, mostró limitaciones significativas, ya que pondera en exceso las características del cultivador, afectando su capacidad de generalización. XGBoost se presentó como una alternativa viable con buen desempeño en la categoría Media, aunque con más errores en la clasificación de Alta.

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Enrique R. Chiesa Torres
cretario Académico
Universidad Nacional de Villa Mercedes

Sin embargo, los resultados obtenidos tras aplicar técnicas de preprocesamiento, oversampling y entrenamiento han sido mejores de lo esperado, lo que constituye un indicador positivo para el futuro del proyecto. La mejora en las métricas tras la aplicación de técnicas de oversampling sugiere Que una vez que se logre recolectar una mayor cantidad de datos, será posible desarrollar modelos más representativos y robustos.

Dado el tamaño actual del dataset, futuras investigaciones podrían considerar el uso de redes neuronales o la implementación de un Voting Classifier, combinando Random Forest y XGBoost, para mejorar la estabilidad de las predicciones.

Por lo tanto, aunque la cantidad de datos actuales impide afirmar con certeza que los modelos sean completamente generalizables, los hallazgos obtenidos respaldan la viabilidad del enfoque planteado. A medida que se amplíe la base de datos con más ciclos de cultivo y se continúe refinando el proceso de modelado, se podrá mejorar la precisión y fiabilidad de las predicciones, acercando el proyecto a una aplicación práctica en entornos reales de cultivo.

Potencial Futuro del Proyecto

Si bien el desarrollo actual ha sido suficiente para cumplir con los objetivos planteados en esta instancia, es evidente que la recolección de un conjunto de datos más amplio y representativo permitirá mejorar significativamente la precisión y utilidad práctica del modelo. Esto abrirá la puerta a nuevas aplicaciones, tales como:

- **Recomendaciones personalizadas:** el modelo podrá sugerir ajustes específicos en el cultivo para optimizar el rendimiento, en función de las condiciones particulares de cada ciclo.
- **Monitoreo predictivo:** será posible anticipar los rendimientos en distintas etapas del cultivo, basándose en el cronograma y en variables clave del entorno.
- **Integración con IoT:** en el futuro, combinar datos recolectados manualmente con información proveniente de sensores permitirá un análisis más detallado y en tiempo real.

A corto plazo, el proyecto se enfocará en mejorar la usabilidad y el alcance de la aplicación Green Star, con el objetivo de expandir la base de datos mediante la recopilación de ciclos de cultivo de un espectro más amplio de cultivadores. Las tareas inmediatas incluyen la incorporación de ajustes y mejoras basadas en el feedback recibido por los usuarios, seguida del lanzamiento oficial de la aplicación y una campaña promocional en redes sociales para incrementar su adopción.

En una fase posterior, una vez que se disponga de un volumen mayor de datos, el modelo será reentrenado y optimizado para su integración en la aplicación a través de una API. Esta API analizará los cronogramas de cultivo y las características del entorno, proporcionando recomendaciones automatizadas sobre los cronogramas de cultivo para mejorar el rendimiento de los cultivos.

VI - Bibliografía

【1】 Haley Mills (2023, abril, 21). "The Economic Impact of Marijuana Legalization.". Leafy Doc. Disponible en: https://leafydoc.com/the-economic-impact-of-marijuana-legalization.

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

【2】 J. P. Brown, E. D. Cohen, y A. Felix (2023, septiembre, 19; actualizado 2024, junio 7). "Economic Benefits and Social Costs of Legalizing Recreational Marijuana". Federal Reserve Bank of Kansas City, Research Working Paper RWP 23-10.
Disponible en: http://doi.org/10.18651/RWP2023-10.

【3】 Bruce Barcott y Beau Whitney (2022, febrero, 23). "Jobs Report 2022," Technical Report, Leafly 2022. Disponible en: https://www.leafly.com/news/industry/cannabis-jobs-report.

【4】 Dhanasekaran, M M. Nadar, R McDonald, K Deruiter, J Pathak, S Ramesh, S Vijayarani, R Gopal, K Babu Ramapuram, J Dua, K ORCID badge Moore, T Ren, J Dhanasekaran, M (2022, octubre, 13). "A Re-Evaluation of Past to Present-Day Use of the Blissful Neuronal Nutraceutical Cannabis". Science Repository OU, Journal Article, Journal of Food Nutrition and Metabolism. Disponible en: http://hdl.handle.net/10453/162991.

【5】 Russo, E. B. (2007, agosto, 21). "History of Cannabis and Its Preparations in Saga, Science, and Sobriquet." Chemistry & Biodiversity. Disponible en: https://pubmed.ncbi.nlm.nih.gov/17712811/.

【6】 Mechoulam, R., & Gaoni, Y. (1964, abril, 1). "Isolation, Structure, and Partial Synthesis of an Active Constituent of Hashish." Journal of the American Chemical Society. Vol. 86(8). Disponible en: https://pubs.acs.org/doi/10.1021/ja01062a046.

【7】 Howlett, A. C., & Devane, W. A. (1992, octubre, 13). "The cannabinoid receptor: Biochemical, anatomical and pharmacological characterization." Trends in Neurosciences. Vol. 15(10), pp. 428-433. Disponible en: https://pubmed.ncbi.nlm.nih.gov/1700516/.

【8】 Booth, J. K., Bohlmann, J. (2019). "Terpenes in Cannabis sativa – From plant genome to humans." Plant Science, 284, 67-72. Disponible en: https://doi.org/10.1016/j.plantsci.2019.03.022.

【9】 Russo, E. B. (2011). "Taming THC: potential cannabis synergy and phytocannabinoid-terpenoid entourage effects." British Journal of Pharmacology, 163(7), 1344–1364. Disponible en: https://doi.org/10.1111/j.1476-5381.2011.01238.x.

【10】 Chandra, S., Lata, H., ElSohly, M. A. (Eds.). (2017). Cannabis sativa L. - Botany and Biotechnology. Springer International Publishing. Disponible en: https://doi.org/10.1007/978-3-319-54564-6.

【11】 Ángeles López, G. E., Brindis, F., Cristians Niizawa, S., & Ventura Martínez, R. (2014, diciembre). "Cannabis sativa L., una planta singular". Revista Mexicana de Ciencias Farmacéuticas, 45(4), 1-6. Disponible en: http://www.scielo.org.mx/scielo.php?script=sci_arttext&pid=S1870-01952014000400 004.

【12】 David Potter JP (2009, marzo). "The Propagation, Characterization, and Optimization of Cannabis sativa L. as a Phytopharmaceutical." Phytopharmaceutical. Ph.D. dissertation, King's College, London. Disponible en: The Propagation, Characterisation and Optimisation of Cannabis Sativa L. as a Phytopharmaceutical (PDF).

【13】 Dan Jin, Shengxi Jin y Jie Chen (2019, junio, 6). "Cannabis Indoor Growing Conditions, Management Practices, and Post-Harvest Treatment:

ES COPIA

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

A Review" American Journal of Plant Sciences, Vol.10. Disponible en: https://doi.org/10.4236/ajps.2019.106067.

【14】George F. Van Patten, aka Jorge Cervantes (2015, abril, 20). "The Cannabis Encyclopedia, The Definitive Guide to Cultivation & Consumption of Medical Marijuana" Van Patten Publishing, USA. Disponible en: https://library.lol/main/BF77CCC6C13BBA07E9749AF2310B371D.

【15】OSRAM (2019, noviembre). "Photobiology Guide". Fluence. Disponible en: https://fluence-led.com/wp-content/uploads/2018/11/Fluence-Photobiology-Guide-20 19.pdf.

【16】Anna Chlingaryan, Salah Sukkarieh, Brett Whelan (2021, Mayo, 28). "Machine learning approaches for crop yield prediction and nitrogen status estimation in precision agriculture: A review". Computers and Electronics in Agriculture, Volume 151, Pages 61-69, ISSN 0168-1699. Disponible en: https://doi.org/10.1016/j.compag.2018.05.012.

【17】Benos, L., Tagarakis, A. C., Dolias, G., Berruto, R., Kateris, D., & Bochtis, D. (2021). "Machine Learning in Agriculture: A Comprehensive Updated Review".
Sensors 2021(11), 3758. Disponible en: https://doi.org/10.3390/s21113758.

【18】González, F. A., Gómez, J. J., & Amaya, D. F. (2017, diciembre, 30). "Procesamiento de imágenes multiespectrales en cultivos de café y cacao". Revista CINTEX, 22(2), 51–67. Disponible en: https://doi.org/10.33131/24222208.294.

【19】G. Mohyuddin, K. A. Muhammad, A. Haseeb, S. Mahpara, M. Waseem & A. Noman. (2024, enero). "Evaluation of Machine Learning Approaches for Precision Farming in Smart Agriculture System: A Comprehensive Review". IEEE Access. PP. Disponible en: http://dx.doi.org/10.1109/ACCESS.2024.3390581.

【20】M. Abdel-Salam, N. Kumar & S. Mahajan. (2024, Agosto). "A proposed framework for crop yield prediction using hybrid feature selection approach and optimized machine learning". Neural Computing and Applications. Disponible en: http://dx.doi.org/10.1007/s00521-024-10226-x.

【21】IBM. "What Is a Digital Twin?". Disponible en: https://www.ibm.com/topics/what-is-a-digital-twin.

【22】Amazon Web Services (AWS). "What Is a Digital Twin?". Disponible en: https://aws.amazon.com/es/what-is/digital-twin/.

【23】Boston Consulting Group (BCG). "Creating Value with Digital Twins in Oil and Gas." Disponible en:
https://www.bcg.com/publications/2019/creating-value-digital-twins-oil-gas.

VII - Anexos

En esta sección encontrará documentación adicional relevante, como gráficos, tablas o documentos adicionales.

Anexo 1

Script de scrapping iterativo.

Anexo 2

Script de conversión de formato json a csv.

Anexo 3

Tabla 1: Composición original del dataset previo al procesamiento de datos.

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Columna	Tipo de Dato	Valores No Nulos	Valores Nulos
slug	object	8166	0
id	int64	8166	0
averageRating	float64	8166	0
award	object	8166	0
cannabinoids	object	8166	0
category	object	7609	557
celebrationColors	object	3	8163
children	object	8166	0
conditionReview Count	int64	8166	0
conditions	object	8166	0
description	object	6867	1299
descriptionPlain	object	6861	1305
effectReviewCou nt	int64	8166	0
effects	object	8166	0
energizeScore	float64	6238	1928
flavorReviewCou nt	int64	8166	0
flavors	object	8166	0
flowerImagePng	object	8166	0
flowerImageSvg	object	8166	0
growInfo	object	8166	0
highlightedPhoto s	object	8166	0
name	object	8166	0
negativeReviewC ount	int64	8166	0
negatives	object	8166	0
nucleusImagePn g	object	8166	0
nucleusImageSv	object	8166	0g
nugImage	object	8166	0
nugImageAltText	object	77	8089
parents	object	8166	0
phenotype	object	7608	558
photoCount	int64	8166	0
rating	float64	8166	0
reviewCount	in64	8166	0
stockNugImage	object	7847	319
subtitle	object	1748	6418
symbol	object	8164	2
symptomReview Count	int64	8166	0
symptoms	object	8166	0
terps	object	8166	0
topEffect	object	6385	1781
totalFollowers	int64	8166	0
traitsCountTotal	int64	8166	0
traitsSourceCoun tTotal	int64	8166	0

Anexo 4

Script para identificar variabilidad en las columnas 'flowerImagePng', 'flowerImageSvg', 'nucleusImagePng', 'nucleusImageSvg'.

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Anexo 5

Script para identificar duplicados y valores únicos en las columnas 'growInfo', 'parents'.

Anexo 6

Script para categorizar el fenotipo en genéticas con el campo phenotype faltante.

```
# Aplicar la función para completar los valores faltantes de 'phenotype'
df['phenotype'] = df.apply(asignar_hibrido_segun_linaje, axis=1)
# Recurso final: Asignar 'Hybrid' para cualquier valor faltante restante
df['phenotype'] = df['phenotype'].fillna('Hybrid')
# Definir la cepa para probar cepa_a_probar = 'wubba-punch'
# Verificar si la cepa existe en el conjunto de datos info_cepa = df[df['slug']
== cepa_a_probar]
if not info_cepa.empty:
# Extraer detalles relevantes para la cepa categoria =
info_cepa.iloc[0]['category'] sabores = info_cepa.iloc[0]['flavors']
print(f"Probando para la cepa: {cepa_a_probar}") print(f"Categoría:
{categoria}") print(f"Sabores: {sabores}")
# Inspeccionar la moda para el grupo ('categoría' y 'sabores') moda_grupo
= df[(df['category'] == categoria) & (df['flavors']
== sabores)]['phenotype'].mode()
# Imprimir el valor de la moda del grupo
if not moda_grupo.empty:
print(f"Fenotipo más común para el grupo (categoría:
{categoria}, sabores: {sabores}): {moda_grupo[0]}")
else:
print(f"No se encontró una moda para el grupo (categoría:
{categoria}, sabores: {sabores}). Se aplicará un recurso alternativo.")
# Aplicar la lógica de imputación con recurso alternativo a 'Hybrid' si no se
encuentra una moda
df['phenotype'] = df['phenotype'].fillna( df.groupby(['category',
'flavors'])['phenotype'].transform(
```

Anexo 7

Script para completar los datos faltantes en la columna descriptionPlain.

Anexo 8

Script para completar los datos faltantes en la columna terps.

```
from collections import Counter
# Cargar el archivo CSV csv_file = 'strains_data_v3.csv' df =
pd.read_csv(csv_file)
# Convertir '{}' a None para un manejo adecuado
df['terps'] = df['terps'].apply(lambda x: None if x == '{}' else
x)
# Paso 1: Extraer prefijos y sufijos de la columna 'slug'
def obtener_prefijo_sufijo(slug): if isinstance(slug, str):
partes = slug.split('-')
return partes[0], partes[-1]
return None, None
df[['prefijo', 'sufijo']] = df['slug'].apply(lambda x:
pd.Series(obtener_prefijo_sufijo(x)))
```

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

```
# Paso 2: Identificar combinaciones únicas de prefijo-sufijo
df['grupo_prefijo_sufijo'] = df['prefijo'] + '-' + df['sufijo']
# Paso 3: Contar la cantidad de ocurrencias de cada grupo prefijo-sufijo
conteo_prefijo_sufijo = df['grupo_prefijo_sufijo'].value_counts()
print("\nGrupos de prefijo-sufijo más comunes:")
print(conteo_prefijo_sufijo.head(10))
# Paso 4: Calcular la moda de 'terps' para cada grupo modas_grupo = {}
for grupo in df['grupo_prefijo_sufijo'].dropna().unique(): datos_grupo =
df[(df['grupo_prefijo_sufijo'] == grupo) &
df['terps'].notna()]['terps']
if not datos_grupo.empty:
modas_grupo[grupo] = datos_grupo.mode()[0]
print("\nModa de 'terps' por grupo de prefijo-sufijo:") print({k: v for k, v in
list(modas_grupo.items())[:10]}) # Mostrar las primeras 10 modas de grupo
# Paso 5: Rellenar valores faltantes en 'terps' usando la moda del grupo
prefijo-sufijo
def rellenar_terps_desde_grupo(fila):
if pd.isna(fila['terps']) and fila['grupo_prefijo_sufijo'] in
modas_grupo:
return modas_grupo[fila['grupo_prefijo_sufijo']]
return fila['terps']
df['terps'] = df.apply(rellenar_terps_desde_grupo, axis=1)
# Paso 6: Recurso final para rellenar 'terps' faltantes con la moda general
terps_no_vacios = df.dropna(subset=['terps'])['terps'] moda_general =
terps_no_vacios.mode().iloc[0] if not terps_no_vacios.empty else None
df['terps'] = df['terps'].fillna(moda_general)
# Verificar si quedan datos faltantes en 'terps' terps_faltantes_despues =
df['terps'].isna().sum() print(f"\nValores faltantes en 'terps' después de la
curación:
{terps_faltantes_despues}")
# Guardar el DataFrame actualizado en un nuevo archivo CSV
archivo_salida = 'strains_data_v4.csv' df.to_csv(archivo_salida,
index=False)
print(f"\nDatos actualizados guardados en {archivo_salida}")
```

Anexo 9

Script para completar los datos faltantes en la columna growInfo.

```
# Paso 1: Convertir 'growInfo' de cadena de texto a diccionario (si es
necesario)
df['growInfo'] = df['growInfo'].apply(lambda x: ast.literal_eval(x) if
isinstance(x, str) else x)
# Paso 2: Verificar valores faltantes (None) para los pares clave-valor en la
columna 'growInfo'
resumen_valores_faltantes = df['growInfo'].apply(lambda x: {k: v is None for
k, v in x.items()}).apply(pd.Series).sum() print("Resumen de Valores
Faltantes:") print(resumen_valores_faltantes)
# Paso 3: Manejar los valores faltantes rellenando con el valor más
frecuente para cada clave
valores_comunes = {}
# Calcular la moda para cada clave (columna)
for clave in resumen_valores_faltantes.index:
```

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

```
if clave not in ['growNotes', 'growNotesPlain']: # Omitir campos de texto como 'growNotes'
valores_comunes[clave] = df['growInfo'].apply(lambda x: x.get(clave) if x.get(clave) is not None else None).mode().iloc[0]
# Paso 4: Rellenar los valores faltantes basados en los valores más comunes
def rellenar_valores_faltantes(growinfo):
for clave, valor in valores_comunes.items():
if growinfo.get(clave) is None: growinfo[clave] = valor
return growinfo
# Aplicar la función de relleno a la columna 'growInfo' df['growInfo'] = df['growInfo'].apply(rellenar_valores_faltantes)
# Paso 5: Guardar el DataFrame actualizado en un nuevo archivo CSV
archivo_salida = 'strains_data_v5.csv'
df.to_csv(archivo_salida, index=False)
print(f"\nDatos actualizados guardados en {archivo_salida}")
```

Anexo 10

Script para completar deducir la columna fotoperiodo.

Anexo 11

Acceso a la aplicación Green Star de recolección de datos.

https://www.green-star.app/auth.

Anexo 12

Modelo: Usuario

Campo	Descripción	Tipo de Dato	Valores Posibles Relaciones Validación
id	Identificador único del usuario.	Int	Clave primaria. Valor único, autogenerado
username	Nombre de usuario.	String	- Longitud mínima de 3 caracteres y String único.
password	Contraseña cifrada del usuario.	String	- Hash de contraseña, no se almacena en texto plano.
email	Dirección de correo electrónico.	String	- Formato válido de email.
emailVeri fied	Fecha de verificación del correo.	DateTime	
image	URL de la imagen de perfil del usuario.	String	
growerPro fileCompl eted	Indica si el perfil de cultivador está completo.	Boolean	true, false

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

growerPro file
Perfil del cultivador asociado.
GrowerPr ofile
- Relación con GrowerPr ofile.
tokens Tokens asociados al usuario.
Token[]
- Relación con Token.
simulacio nes
Simulaciones realizadas por el usuario.
Simulaci on[]
- Relación con Simulaci on.
Modelo: Token
Campo
Descripción Tipo de Dato Valores Posibles
Relaciones
Validación
id
Identificador único del token.
String
Clave primaria. Valor único, autogenerado
userId Identificador del usuario propietario.
String
- Relación con Usuario. Debe existir en la tabla Usuario.
token Token de autenticación o acceso.
String
type
Tipo de token.
String Ej.:
refresh, access
expiresA t Fecha de expiración del token.
DateTim e
Modelo: GrowerProfile
Campo
Descripción Tipo de Dato Valores Posibles
Relaciones
Validación
id
Identificador único del perfil de cultivador.
String
Clave primaria.
Valor único, autogenerad o.
userId
Identificador del usuario asociado.
String
Relación con
Usuario. Debe existir en la tabla Usuario.
experien cia
Años de experiencia del cultivador.
Decimal

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Mayor o igual a 0.
tipoDeCu ltivador
Tipo de cultivador.
TipoDeCu ltivador
Ej.:
Profesional
, Amateur
- Solo valores definidos: (Autocultiva dor, CultivadorSo lidario, CultivadorIn dustrial)
tipoDeCu ltivador Detalle Detalles adicionales sobre el tipo de cultivador.
String
educacio nAlRespe cto
Nivel de educación relacionado con el cultivo.
Educacio nAlRespe cto
Básico, Intermedio, Avanzado
- Solo valores definidos: (Ninguna, Autodidacta, Cursos, NivelDeGrad o)
educacio nAlRespe ctoDetal le
Detalles adicionales sobre la educación.
String
plantasE nRotacio n
Categoría de plantas en rotación. PlantasE nRotacio n
Ej.: Baja, Media, Alta
- Solo valores definidos: (S, M, L, XL, XXL)
plantasE nRotacio nNro
Número de plantas en rotación.
Int
- Mayor o igual a cero, este input actualiza la categoría de plantasEnRo tacion automáticam ente.
equipo
Equipos utilizados por el cultivador.
String[] Ej.:
Lámparas, Ventiladore s
Array con valores únicos.
Modelo: Simulacion
Campo
Descripción Tipo de Dato Valores Posibles
Relaciones
Validación
id
Identificador único de la simulación.
Int
Clave primaria. Valor único autogenerad o.
usuariol d Identificador del usuario que realizó la simulación.
Int
Relación con
Usuario. Debe existir en la tabla Usuario.
tipoDeSi mulacion
Tipo de simulación realizada.

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

TipoDeSi mulacion
Historia, Alterno, Presagio
- Solo valores definidos: (Historia, Alterno, Presagio)
numeroDe Plantas Número de plantas consideradas en la simulación.
Int
Mayor a cero.
geolocat ion
Ubicación geográfica asociada.
Json
- Latitud y longitud válidas obtenidas desde la API de geolocación.
placeNam e
Nombre del lugar de cultivo.
String
- Opcional, obtenido desde la API de geolocación.
ambiente DeCultiv o
Ambiente de cultivo utilizado.
Ambiente DeCultiv o
Indoor, Outdoor
- Solo valores definidos: (Outdoor, Indoor)
medioDeC ultivo
Medio de cultivo utilizado.
MedioDeC ultivo
LivingSoil, Hidroponia
, Sustrato
- Solo valores definidos: (LivingSoil, Hidroponia, Sustrato)
metodoDe Cultivo
Método de cultivo implementado.
MetodoDe Cultivo
SOG,
ScrOG, etc.
- Solo valores definidos: (SOG,
ScrOG, SuperCroppi ng, GreenHouse s, ToppingAnd Fimming, DWC)
totalCos echado Cantidad total cosechada en gramos.
Int
Mayor o igual a 0.
creado Fecha de creación de la simulación.
DateTime
modifica do Fecha de modificación de la simulación.
DateTime
simXGen Relación con las genéticas utilizadas.
SimXGens []
- Relación con
SimXGen.
Modelo: SimXGen
Campo
Descripción Tipo de Dato Valores Posibles
Relaciones
Validación
id Identificador único de SimXGen.
String

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Clave primaria. Valor único autogenerad o.
simulacio nId
Identificador de la simulación asociada.
String
Relación con Simulacio n. Debe existir en la tabla Simulacion available Plants
Número de plantas disponibles.
Int
Valor numérico dinámico actualizado a través del CRUD de las genéticas asignadas a esta simulación.
hasAvaila blePlants
Indica si hay plantas disponibles.
Boolean
true, false
Actualizado a través del CRUD de las genéticas asignadas a esta simulación.
genéticas Seleccionadas
Genéticas seleccionadas en la simulación.
Genética Seleccionada[]
Relación con Genética Selecciona da.
Modelo: Genética Seleccionada
Campo
Descripción Tipo de Dato Valores Posibles
Relaciones
Validación
id Identificador único de la genética seleccionada.
String
Clave primaria.
Valor único autogenerad o.
simXGenId Identificador del modelo SimXGen asociado.
String
Relación con SimXGen.
Debe existir en la tabla SimXGen.
numeroDeP lantas Número de plantas asignadas a esta genética.
Int
Mayor a 0.
geneticaN ame
Nombre de la genética seleccionada.
String
- No vacío, longitud mínima de 3 caracteres. Autoseleccio nado desde el csv de genéticas.
geneticaS lug
Slug único basado en el nombre de la genética.
String
- No vacío, formato en minúsculas y sin espacios. Autoseleccio nado desde el csv de genéticas.
geneticaP heno
Fenotipo de la genética (e.g., indica, sativa, híbrido).
String
Indica, Sativa, Híbrido

ES COPIA

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

- Solo valores permitidos: (Indica, Sativa, Hibrida).
geneticaP hoto
Tipo de fotoperiodo de la genética.
Genetica Fotoperi odo Photoperi od, Auto, Hybrid
- Solo valores permitidos: (Photoperiod, Auto, Hybrid).
cronogram aDeCultiv o
Cronograma asociado a esta genética.
Cronogra maDeCult ivo
- Relación con Cronogram
aDeCultiv o. Debe existir y estar asociado a la genética seleccionada.
Modelo: CronogramaDeCultivo
Campo
Descripción Tipo de Dato Valores Posibles
Relaciones
Validación
id Identificador único del cronograma.
String
- Clave primaria. Valor único, autogenerado.
genetica Seleccio nadaId
Identificador de la genética seleccionada.
String
- Relación con GeneticaS elecciona da. Debe existir en la tabla
GeneticaSe leccionada.
haceGerm inacion Indica si la genética pasó por una fase de
germinación.
Boolean
Valor booleano obligatorio.
inicioGe rminacio nClonaci on Fecha de inicio de la fase de
germinación/clonac ión.
DateTim e
Formato ISO 8601, fecha válida.
inicioPl antin
Fecha de inicio de la fase de plantín.
DateTim e
- Fecha posterior a inicioGerm
inacionClo nacion.
inicioVe getativo
Fecha de inicio de la fase vegetativa.
DateTim e
posterior a inicioPlan tin.
inicioPr eFloraci on
Fecha de inicio de la fase de prefloración.
DateTim e
Fecha posterior a inicioVege tativo.
inicioFl oracion
Fecha de inicio de la fase de floración.
DateTim e
- Fecha posterior a inicioPreF loracio.

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

cosecha
Fecha de cosecha de la genética.
DateTim e
- Fecha posterior a inicioFlor acion.
cantidad Cosechad a Cantidad cosechada en gramos.
Int
Mayor o igual a 0.
Anexo 13
Acceso al repositorio con los scripts utilizados durante la etapa de Desarrollo y Entrenamiento del Modelo.
https://github.com/micaellatorre/green-star_data.
Anexo 14
Script principal para el pipeline del preprocesamiento del dataset.

```
from scripts.preprocessing.tipo_de_simulacion import
get_tipo_de_simulacion
from scripts.preprocessing.geolocation_processing import
process_geolocation_columns
from scripts.preprocessing.dli_calc import calculate_dli from
scripts.preprocessing.var_coding import encode_categorical_vars
from scripts.preprocessing.categorize_yield import
categorize_yield
from scripts.preprocessing.dates_transform import transform_dates
def preprocess_data(file_path data = pd.read_csv(file_path)
# 0. Eliminar columnas sin valor data.drop(columns=['plantasEnRotacion',
'equipo',
'SimulacionId', 'creado', 'modificado', 'GeneticaSeleccionadaId',
'totalCosechado', 'geneticaName', 'cronogramaDeCultivoId'],
inplace=True)
# 1. Procesar columnas relacionadas con el usuario data =
process_user_columns(data)
# 2. Numerar el tipo de simulación data = get_tipo_de_simulacion(data)
# 3. Calcular el puntaje del cultivador data =
calculate_cultivador_rating(data)
# 4. Procesar columnas geolocation y placeName data =
process_geolocation_columns(data)
# 5. Calcular DLI por etapas data = calculate_dli(data)
# 6. Codificar variables categóricas data = encode_categorical_vars(data)
# 7. Transformar fechas a características numéricas data =
transform_dates(data)
# 8. Categoriazar la variable objetivo
data = categorize_yield(data)
# 9. Eliminar filas con valores nulos en la variable objetivo
data.dropna(subset=["cantidadCosechada"], inplace=True)
# 10. Eliminar la columnas que no se usarán
data.drop(columns=['geneticaSlug', 'ambienteDeCultivo',
'medioDeCultivo',
'metodoDeCultivo', 'tipoDeSimulacion', 'user_id'], inplace=True)
# Eliminar la columna original, ya que ahora usamos one-hot encoding
data.drop(columns=["cantidadCosechada"], inplace=True)
```

ES COPIA

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

```
# Definir características (X) y nueva variable objetivo (y)
X = data.drop(columns=["yield_Baja", "yield_Media", "yield_Alta"])
y = data[["yield_Baja", "yield_Media", "yield_Alta"]]
# Guardar dataset preprocesado
save_path = ".../green-star_data/data/preprocessed/" timestamp =
datetime.now().strftime("%d_%m_%Y_%H_%M") output_file =
os.path.join(save_path,
f"green-star_preprocessed_{timestamp}.csv") os.makedirs(save_path,
exist_ok=True) data.to_csv(output_file, index=False)
print(f"Dataset preprocesado guardado en: {output_file}")
return X, y
if   name        == " main ": file_path =
. (green-star_dd_mm_aaaa_hh_mm.csv)
" /green-star_data/data/history/green-star_24_01_2025_15_15.csv"
X, y = preprocess_data(file_path)
print("Preprocesamiento completado. X shape:", X.shape, "y shape:",
y.shape)
```

Seguido encontrará los scripts para cada función ejecutada en el pipeline (Anexos del 15 al 22).

Anexo 15

Script para procesar las columnas identificadoras del usuario.

Anexo 16

Script para procesar las columnas de tipo de simulación.

Anexo 17

Script para calcular rating del cultivador.

```
 # Mapeo de valores para 'educacionAlRespecto'
educacion_al_respecto_map = {
'Ninguna': 0,
'Autodidacta': 1,
'Cursos': 2,
'NivelDeGrado': 3}
data['educacionAlRespecto'] =
data['educacionAlRespecto'].map(educacion_al_respecto_map)
# Normalizamos las variables de entrada data['experiencia_normalizada']
= data['experiencia'] /
data['experiencia'].max()
data['plantas_normalizadas'] = data['plantasEnRotacionNro'] /
data['plantasEnRotacionNro'].max()
data['tipo_cultivador_normalizado'] = data['tipoDeCultivador']
/ data['tipoDeCultivador'].max()
data['educacion_normalizada'] = data['educacionAlRespecto'] /
data['educacionAlRespecto'].max()
# Asignamos un peso para cada variable (puedes ajustar estos valores)
experiencia_weight = 0.4
plantas_weight = 0.2
tipo_cultivador_weight = 0.2
educacion_weight = 0.2
# Calculamos el puntaje data['cultivador_rating'] = (
experiencia_weight * data['experiencia_normalizada'] + plantas_weight *
data['plantas_normalizadas'] + tipo_cultivador_weight *
```

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

```
data['tipo_cultivador_normalizado'] +
educacion_weight * data['educacion_normalizada'])
# Eliminamos columnas auxiliares utilizadas para el cálculo data.drop(
['experiencia_normalizada', 'plantas_normalizadas',
'tipo_cultivador_normalizado', 'educacion_normalizada'],
axis=1, inplace=True
```

Anexo 18

Script para procesar las columnas de geolocación.

Anexo 19

Script para calcular el dli por etapa.

```
def get_photo_range(date, cultivation_dates): """
Determina el rango de fotoperiodo correspondiente para una fecha y ciclo
de cultivo.
Parameters:
date (datetime): Fecha actual a evaluar. cultivation_dates (list): Lista de
fechas de inicio y
fin de cada etapa del ciclo.
Returns:
str: Rango de fotoperiodo correspondiente (de 1 a 15).
# Calcular duraciones y divisiones de las etapas Vegetativo, Prefloración y
Floración
vegetativo_duration = (cultivation_dates[2]["endDate"] -
cultivation_dates[2]["startDate"]).days
vegetativo_5th = vegetativo_duration / 5 vegetativo_limits = [
cultivation_dates[2]["startDate"] + timedelta(days=i * vegetativo_5th)
for i in range(1, 5)
]preflora_duration = (cultivation_dates[3]["endDate"] -
cultivation_dates[3]["startDate"]).days
preflora_3rd = preflora_duration / 3 preflora_limits = [
cultivation_dates[3]["startDate"] + timedelta(days=i * preflora_3rd)
for i in range(1, 3)
floracion_duration = (cultivation_dates[4]["endDate"] -
cultivation_dates[4]["startDate"]).days
floracion_5th = floracion_duration / 5 floracion_limits = [
cultivation_dates[4]["startDate"] + timedelta(days=i * floracion_5th)
for i in range(1, 5)
# Determinar el rango basado en las fechas
if date < cultivation_dates[1]["startDate"]:
return "1" # Germinación
if date < cultivation_dates[2]["startDate"]:
return "2" # Plantín
for i, limit in enumerate(vegetativo_limits):
if date < limit:
return str(3 + i)
if date < cultivation_dates[2]["endDate"]:
return "7"
for i, limit in enumerate(preflora_limits):
if date < limit:
return str(8 + i)
if date < cultivation_dates[3]["endDate"]:
```

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Ec. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

```
return "10"
for i, limit in enumerate(floracion_limits):
if date < limit:
return str(11 + i)
if date < cultivation_dates[4]["endDate"]:
return "15"
return ""
# Iterar sobre cada fila del DataFrame
for index, row in data.iterrows():
# Obtener la tabla de fotoperiodo correspondiente photoperiod_table =
genetica_map[row["geneticaPhoto"]]
# Preparar las fechas de cultivo cultivation_dates = [
{"startDate": datetime.strptime(row["inicioGerminacionClonacion"], "%Y-
%m-%dT%H:%M:%S.%fZ"),
"endDate": datetime.strptime(row["inicioPlantin"], "%Y-%m-
%dT%H:%M:%S.%fZ")},
{"startDate": datetime.strptime(row["inicioPlantin"], "%Y-%m-
%dT%H:%M:%S.%fZ"),
"endDate": datetime.strptime(row["inicioVegetativo"], "%Y-%m-
%dT%H:%M:%S.%fZ")},
{"startDate": datetime.strptime(row["inicioVegetativo"], "%Y-%m-
%dT%H:%M:%S.%fZ"),
"endDate": datetime.strptime(row["inicioPreFloracion"], "%Y-%m-
%dT%H:%M:%S.%fZ")},
{"startDate": datetime.strptime(row["inicioPreFloracion"], "%Y-%m-
%dT%H:%M:%S.%fZ"),
"endDate": datetime.strptime(row["inicioFloracion"], "%Y-%m-
%dT%H:%M:%S.%fZ")},
{"startDate": datetime.strptime(row["inicioFloracion"], "%Y-%m-
%dT%H:%M:%S.%fZ"),
"endDate": datetime.strptime(row["cosecha"], "%Y-%m-
%dT%H:%M:%S.%fZ")}]
# Inicializar acumuladores de DLI por etapa dli_etapas = {
"DLIGerminacionClonacion": 0,
"DLIPlantin": 0,
"DLIVegetativo": 0,
"DLIPreFloracion": 0,
"DLIFloracion": 0,}
# Calcular DLI acumulado para cada etapa
for etapa, fechas in enumerate(cultivation_dates): dias_etapa =
(fechas["endDate"] -
fechas["startDate"]).days
for dia in range(dias_etapa): fecha_actual = fechas["startDate"] +
timedelta(days=dia)
# Determinar el rango de fotoperiodo range_index =
get_photo_range(fecha_actual,
cultivation_dates)
# Obtener DLI diario de la tabla dli_diario =
photoperiod_table.loc[int(range_index) - 1, "DLI"]
# Asignar al acumulador correspondiente
```

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Anexo 20

Script para procesar las variables categóricas.

Anexo 21

Script para obtener la duración de cada etapa en días transcurridos por etapa.

```
 # Columnas de fechas date_columns = [
"inicioGerminacionClonacion", "inicioPlantin", "inicioVegetativo",
"inicioPreFloracion", "inicioFloracion",
"cosecha"]
# Convertir las columnas de fechas a formato datetime
for col in date_columns:
data[col] = pd.to_datetime(data[col])
# Crear columnas para la duración en días de cada etapa
data["dias_germinacion_clonacion"] = (data["inicioPlantin"] -
data["inicioGerminacionClonacion"]).dt.total_seconds() / 86400
data["dias_plantin"] = (data["inicioVegetativo"] -
data["inicioPlantin"]).dt.total_seconds() / 86400 data["dias_vegetativo"] =
(data["inicioPreFloracion"] -
data["inicioVegetativo"]).dt.total_seconds() / 86400
data["dias_prefloracion"] = (data["inicioFloracion"] -
data["inicioPreFloracion"]).dt.total_seconds() / 86400 data["dias_floracion"]
= (data["cosecha"] -
data["inicioFloracion"]).dt.total_seconds() / 86400
# Calcular el total de días del cultivo data["total_dias_cultivo"] = (
data["dias_germinacion_clonacion"] + data["dias_plantin"] +
data["dias_vegetativo"] + data["dias_prefloracion"] + data["dias_floracion"])
# Eliminar las columnas de fechas originales
data.drop(columns=date_columns, inplace=True)
return data
```

Anexo 22

Script para categorizar la variable objetivo en bins.

Anexo 23

Script principal para aplicar las técnicas de oversampling al dataset preprocesado.

```
# Importar las funciones de cada módulo de oversampling from
scripts.oversampling.random_oversampling import random_oversampling
from scripts.oversampling.smote import smote_oversampling from
scripts.oversampling.adasyn import adasyn_oversampling from
scripts.oversampling.cluster_based import cluster_based_oversampling
from scripts.oversampling.knn_interpolation import
knn_interpolation_oversampling
# Importar el pipeline de preprocesamiento
from scripts.preprocessing.main import preprocess_data
def guardar_resultados(X_resampled, y_resampled, output_dir,
technique_name):"""
Guarda los resultados del oversampling en un archivo CSV.
Parameters:
X_resampled (pd.DataFrame): Conjunto de características
sobremuestreadas.
y_resampled (pd.Series): Variable objetivo sobremuestreada.
```

Téc. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Dr. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

output_dir (str): Ruta del directorio de salida. technique_name (str): Nombre de la técnica de oversampling
utilizada. """
os.makedirs(output_dir, exist_ok=True)
timestamp = datetime.now().strftime("%Y%m%d_%H%M%S") output_path = os.path.join(output_dir,
f"{technique_name}_oversampled_{timestamp}.csv")
Crear DataFrame y guardar
result_df = pd.concat([pd.DataFrame(X_resampled), y_resampled], axis=1)
result_df.to_csv(output_path, index=False) print(f"Resultados guardados con {technique_name} en:
{output_path}")
if __name__ == "__main__":
preprocessed = False
Ruta del dataset original file_path = ".../green-star_data/data/history/green-star_31_01_2025_17_31.csv" # Paso 1: Preprocesar los datos si no se han preprocesado
if not preprocessed:
Preprocesar los datos print("Iniciando preprocesamiento...") X, y = preprocess_data(file_path)
print(f"Preprocesamiento completado. X shape: {X.shape}, y shape: {y.shape}")
else:
Cargar dataset preprocesado data = pd.read_csv(file_path)
X = data.drop(columns=["yield_Baja", "yield_Media", "yield_Alta"])
y = data[["yield_Baja", "yield_Media", "yield_Alta"]]
Semilla para reproducibilidad seed_value = 420
np.random.seed(seed_value)
Definir directorio base de salida
output_base_dir = ".../green-star_data/outputs/oversampled" # Paso 2: Aplicar técnicas de oversampling
1. Random Oversampling print("Ejecutando Random Oversampling...")
X_res_rand, y_res_rand = random_oversampling(X, y, random_state=seed_value)
guardar_resultados(X_res_rand, y_res_rand, os.path.join(output_base_dir, "random"), "random")
2. SMOTE Tradicional print("Ejecutando SMOTE...")
X_res, y_res = smote_oversampling(X, y, random_state=seed_value)
guardar_resultados(X_res, y_res, os.path.join(output_base_dir,
Seguido encontrará los scripts para cada función ejecutada en el pipeline (Anexos del 24 al 28).
Anexo 24
Script para aplicar Random Oversampling a los datos preprocesados.

Anexo 25
Script para aplicar SMOTE a los datos preprocesados.
Anexo 26
Script para aplicar ADASYN a los datos preprocesados.
Anexo 27

ES COPIA
Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes
Universidad Nacional de Villa Mercedes UNViMe Ministerio de Educación
Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes
Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Script para aplicar Cluster-Based Oversampling a los datos preprocesados.

Anexo 28

Script para aplicar Interpolación con KNN a los datos preprocesados.

```
import numpy as np
import pandas as pd
from sklearn.neighbors import NearestNeighbors
def knn_interpolation_oversampling(X: pd.DataFrame, y: pd.DataFrame,
n_neighbors: int = 5):"""
Aplica interpolación con KNN para generar nuevas muestras sintéticas.
Parameters:
X (pd.DataFrame): Conjunto de características.
y (pd.DataFrame): Variable objetivo en formato one-hot. n_neighbors (int):
Número de vecinos a considerar.
Returns:
X_resampled (pd.DataFrame), y_resampled (pd.DataFrame)"""
if X.empty or y.empty:
raise ValueError("X e y no pueden estar vacíos.")
if len(X) != len(y):
raise ValueError("X e y deben tener el mismo número de filas.")
# Convertir a NumPy para eficiencia X_np = X.to_numpy()
y_np = y.to_numpy()
nn = NearestNeighbors(n_neighbors=min(n_neighbors + 1, len(X)))
nn.fit(X_np)
# Generar nuevas muestras interpoladas new_samples = []
new_labels = []
for i in range(len(X_np)):
neighbors = nn.kneighbors([X_np[i]], return_distance=False)[0][1:] #
Omitimos el propio punto
for neighbor in neighbors:
interpolated_sample = (X_np[i] + X_np[neighbor]) / 2
```

Anexo 29

Script comparativo para la evaluación de las técnicas de oversampling aplicadas.

```
print(f"No se encontraron archivos para {method}")
latest_file = max(files, key=os.path.getctime) # Selecciona el más reciente
# Cargar dataset
df = pd.read_csv(latest_file)
# Separar características (X) y variable objetivo (y) en formato one-hot
target_columns = ["yield_Baja", "yield_Media", "yield_Alta"]
X = df.drop(columns=target_columns) y = df[target_columns]
# Dividir en train y test (80-20)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
stratify=y, random_state=42)

# Entrenar modelo multi-clase con OneVsRest model =
OneVsRestClassifier(RandomForestClassifier(n_estimators=100,
random_state=42))
model.fit(X_train, y_train)
```

ES COPIA

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

Ing. Alejandro Pablo Rosa
Director de Escuela de Ingeniería y Ciencias Ambientales
Universidad Nacional de Villa Mercedes

Lic. Enrique R. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

```
# Predicciones en train y test y_train_pred = model.predict(X_train)
y_test_pred = model.predict(X_test)
# Evaluar desempeño
train_acc = accuracy_score(y_train, y_train_pred) test_acc =
accuracy_score(y_test, y_test_pred)
f1 = f1_score(y_test, y_test_pred, average="weighted") overfit_ratio =
train_acc / test_acc # Medida de sobreajuste
# Guardar resultados results.append({
"Método": method,
"Accuracy (Test)": round(test_acc, 4), "F1-score": round(f1, 4),
"Overfitting Ratio": round(overfit_ratio, 4)})
```

Anexo 30

Script principal para aplicar las técnicas de entrenamiento al dataset aumentado con KNN Interpolation.

```
import os
import pandas as pd
from datetime import datetime
import numpy as np
# Import functions from oversampling modules
from scripts.oversampling.random_oversampling import
random_oversampling
from scripts.oversampling.smote import smote_oversampling from
scripts.oversampling.adasyn import adasyn_oversampling from
scripts.oversampling.cluster_based import cluster_based_oversampling
from scripts.oversampling.knn_interpolation import
knn_interpolation_oversampling
# Import preprocess_data function from preprocessing/main.py
from scripts.preprocessing.main import preprocess_data
def guardar_resultados(X_resampled, y_resampled, output_dir,
technique_name):"""
Guarda los resultados del oversampling en un archivo CSV.
Parameters:
X_resampled (pd.DataFrame): Conjunto de características
sobremuestreadas.
y_resampled (pd.Series): Variable objetivo sobremuestreada.
output_dir (str): Ruta del directorio de salida. technique_name (str):
Nombre de la técnica de oversampling
utilizada. """
os.makedirs(output_dir, exist_ok=True)
timestamp = datetime.now().strftime("%Y%m%d_%H%M%S") output_path
= os.path.join(output_dir,
f"{technique_name}_oversampled_{timestamp}.csv")
# Crear DataFrame y guardar
# result_df = pd.concat([pd.DataFrame(X_resampled),
pd.Series(y_resampled, name="target")], axis=1)
result_df = pd.concat([pd.DataFrame(X_resampled), y_resampled],
axis=1)
result_df.to_csv(output_path, index=False) print(f"Resultados guardados
con {technique_name} en:
{output_path}")
```

ES COPIA

Tec. María Ester Bazan
a/c Dirección de Despacho
Universidad Nacional de Villa Mercedes

Universidad Nacional de Villa Mercedes
UNViMe
Ministerio de Educación

```
if __name__ == "__main__": preprocessed = True
# Ruta del dataset preprocesado (Actualizar según corresponda) file_path
=
".../green-star_data/data/preprocessed/green-star_preprocessed_exa
mple.csv"
# Ruta del dataset original # file_path =
".../green-star_data/data/history/green-star_example.csv"
# Paso 1: Preprocesar los datos si no se han preprocesado
if not preprocessed:
# Preprocesar los datos print("Iniciando preprocesamiento...") X, y =
preprocess_data(file_path)
print(f"Preprocesamiento completado. X shape: {X.shape}, y shape:
{y.shape}")
else
# Cargar dataset preprocesado data = pd.read_csv(file_path)
X = data.drop(columns=["yield_Baja", "yield_Media", "yield_Alta"])
y = data[["yield_Baja", "yield_Media", "yield_Alta"]]
# Semilla para reproducibilidad seed_value = 420
np.random.seed(seed_value)
# Definir directorio base de salida output_base_dir =
"update_direct_path/green-star_data/outputs/oversampled" # Paso 2:
Aplicar técnicas de oversampling
# 1. Random Oversampling print("Ejecutando Random Oversampling...")
X_res_rand, y_res_rand = random_oversampling(X, y,
random_state=seed_value)
guardar_resultados(X_res_rand, y_res_rand,
os.path.join(output_base_dir, "random"), "random")
# 2. SMOTE Tradicional print("Ejecutando SMOTE...")
X_res, y_res = smote_oversampling(X, y, random_state=seed_value)
guardar_resultados(X_res, y_res, os.path.join(output_base_dir, "smote"),
"smote")
# 3. ADASYN
print("Ejecutando ADASYN...")
X_res, y_res = adasyn_oversampling(X, y, random_state=seed_value)
guardar_resultados(X_res, y_res, os.path.join(output_base_dir, "adasyn"),
"adasyn")
# 4. Cluster-Based Oversampling print("Ejecutando Cluster-Based
Oversampling...")
X_res, y_res = cluster_based_oversampling(X, y, n_clusters=5,
random_state=seed_value)
```

Seguido encontrará los scripts para cada función ejecutada en el pipeline (Anexos del 31 al 33).

Anexo 31

Script para entrenar el modelo utilizando Random Forest.

Anexo 32

Script para entrenar el modelo utilizando SVM.

Anexo 33

Script para entrenar el modelo utilizando XG Boosting.

RESOLUCIÓN C. ESC. ING. Y CS. AMB. Nº 8/2025

Lic. Enrique F. Chiesa Torres
Secretario Académico
Universidad Nacional de Villa Mercedes

Ing. Alejandro Pablo Rosso
Director de Escuela de Ingeniería
y Ciencias Ambientales
Universidad Nacional de Villa Mercedes